

POLYTECHNIQUE MONTRÉAL

affiliée à l'Université de Montréal

**Routage intelligent et récupération autonome sécurisée par intelligence
artificielle dans les réseaux de capteurs de surveillance des catastrophes intégrés
au 6G**

GEORGES PARFAIT DJIMEFO KAPEN

Département de génie informatique et génie logiciel

Thèse présentée en vue de l'obtention du diplôme de *Philosophiæ Doctor*
Génie informatique

Mai 2026

POLYTECHNIQUE MONTRÉAL

affiliée à l'Université de Montréal

Cette thèse intitulée :

**Routage intelligent et récupération autonome sécurisée par intelligence
artificielle dans les réseaux de capteurs de surveillance des catastrophes intégrés
au 6G**

présentée par **Georges Parfait DJIMEFO KAPEN**
en vue de l'obtention du diplôme de *Philosophiæ Doctor*
a été dûment acceptée par le jury d'examen constitué de :

, présidente
, membre et directrice de recherche
, membre et codirecteur de recherche
, membre
, membre externe

DÉDICACE

*À ma famille,
pour son soutien inconditionnel et ses sacrifices silencieux.*

*À tous ceux qui, aux quatre coins du monde,
œuvrent pour la prévention des catastrophes
et la protection des vies humaines.*

À la mémoire des victimes des catastrophes naturelles.

REMERCIEMENTS

Déclaration relative à l'utilisation d'outils d'intelligence artificielle générative

Conformément au guide *Utilisation des outils d'intelligence artificielle générative* de Polytechnique Montréal (avril 2025), l'auteur déclare avoir recouru aux outils d'intelligence artificielle générative (IAG) suivants dans le cadre de la réalisation de cette thèse :

- **GitHub Copilot** (Microsoft / OpenAI) : utilisé pour l'assistance à la rédaction et à la révision du code Python des environnements de simulation (implémentation des protocoles GAPF, CALASH et CASTER-ZT, scripts d'analyse statistique et de visualisation des résultats). Aucune donnée de recherche non publiée, résultat confidentiel ou actif intellectuel valorisable n'a été soumis à cet outil.
- **Claude** (Anthropic) : utilisé pour la vérification grammaticale et l'amélioration stylistique de passages rédigés en anglais dans les articles soumis à comité de lecture, ainsi que pour la reformulation de sections de la thèse en français. L'ensemble des idées, contributions scientifiques originales et résultats numériques demeurent entièrement l'œuvre de l'auteur.

L'utilisation de ces outils ne porte sur aucun actif intellectuel valorisable et se limite aux tâches d'assistance à la programmation et à l'édition linguistique, conformément aux exceptions prévues par la politique en vigueur. Aucune information personnelle, confidentielle ou stratégique de Polytechnique Montréal n'a été communiquée à ces outils.

RÉSUMÉ

Les réseaux de capteurs sans fil (RCsF) déployés dans des environnements sujets aux catastrophes constituent une infrastructure critique pour la surveillance en temps réel des phénomènes naturels tels que les séismes, les inondations et les glissements de terrain. Cependant, trois défis fondamentaux limitent leur déploiement à grande échelle : (i) la durée de vie limitée imposée par les batteries non rechargeables, (ii) l’empreinte carbone du cycle de vie des dispositifs massivement distribués, et (iii) la vulnérabilité des politiques de routage apprises par intelligence artificielle face aux attaques et aux hallucinations de modèle. Cette thèse, organisée sous forme de thèse par articles, propose trois cadres complémentaires qui abordent séquentiellement ces défis dans le contexte des réseaux 6G natifs en intelligence artificielle.

Le premier article introduit GAPF (Graph-Attentive Policy Fusion), un cadre méta-apprentissage léger (1 473 paramètres) qui fusionne des politiques expertes gelées d’apprentissage par renforcement multi-agent (QMIX, QTRAN) à travers un encodeur de réseau de neurones graphiques convolutionnels (GCN) à 2 couches et un contrôleur CAS (Contextual Algorithm Selection). L’architecture bi-niveau combine un réseau d’attention monotone Q·K pour la scalarisation des récompenses en boucle interne avec des stratégies évolutionnaires pour le réseau d’attention et REINFORCE pour le méta-contrôleur GCN+CAS en boucle externe. Les résultats expérimentaux démontrent un taux de livraison de paquets (PDR) $\geq 98\%$, une consommation d’énergie 2 à 3.5 fois inférieure, et une empreinte mémoire 13 fois moindre que les références, tout en maintenant une inférence en temps quasi-réel.

Le deuxième article présente CALASH (Carbon-Aware Lifecycle-Autonomous Self-Healing), le premier protocole de routage pour RCsF minimisant conjointement l’intensité carbone du cycle de vie (LCI) — définie comme le CO₂ incorporé, opérationnel et de fin de vie par paquet utile livré — à travers quatre piliers intégrés : (i) CADR, qui module le ratio de détection comprimée en fonction de l’intensité carbone du réseau électrique ; (ii) CARE, un routeur hybride Lyapunov–DQN avec garanties prouvables de conformité au budget carbone ; (iii) SHDR, une boucle d’auto-guérison autonome MAPE-K ; et (iv) LSE, un moteur de durabilité conforme à ISO 14040. Opérant sur une couche physique 6G bi-bande (sub-THz / sub-6 GHz), CALASH atteint 60% de durée de vie plus longue que LEACH (1 486 vs. 931 tours), 82.9% de PDR et 33% de LCI inférieur (8.99 vs. 13.42 gCO₂eq/pkt).

Le troisième article propose CASTER-ZT (Zero-Trust Shielded Graph-Structured Decision Control), le premier cadre de contrôle de décision zéro-confiance pour les réseaux de détection de surveillance des catastrophes. CASTER-ZT couple un encodeur GraphSAGE à 2 couches,

une politique de récupération apprise, un évaluateur neuronal double-hypothèse de confiance-risque, une quantification d’incertitude par MC-Dropout et un bouclier déterministe produisant des décisions graduées (autoriser, réduire la portée, différer, escalader, bloquer). Dix propositions formelles établissent le conservatisme monotone, l’exclusion d’actuation non autorisée et les garanties de couverture conforme. Une campagne de 2 420 exécutions démontre 74.2–98.3% de détection de politiques voyous avec zéro faux positif, un score de récupération pondéré $\omega_{\text{rec}} = 0.733$ ($3.7\text{--}5.2\times$ supérieur aux références) et une latence de 3.07 ms par décision, compatible avec le budget de 10 ms du near-RT RIC O-RAN.

Collectivement, les trois articles établissent une pile complète — efficacité énergétique, durabilité carbone et sécurité zéro-confiance — pour le routage intelligent dans les réseaux de capteurs de surveillance des catastrophes intégrés au 6G.

ABSTRACT

Wireless Sensor Networks (WSNs) deployed in disaster-prone environments provide critical real-time monitoring of natural phenomena such as earthquakes, floods, and landslides. However, three fundamental challenges hinder their large-scale deployment: (i) limited network lifetime imposed by non-rechargeable batteries, (ii) the full lifecycle carbon footprint of massively distributed devices, and (iii) the vulnerability of AI-learned routing policies to adversarial attacks and model hallucinations. This thesis, organized as a thesis by articles, proposes three complementary frameworks that sequentially address these challenges in the context of AI-native 6G sensing networks.

The first article introduces GAPF (Graph-Attentive Policy Fusion), a lightweight meta-learning framework (1,473 parameters) that fuses frozen multi-agent reinforcement learning expert policies (QMIX, QTRAN) through a 2-layer Graph Convolutional Network encoder and a Contextual Algorithm Selection (CAS) controller. The bi-level architecture combines a Monotonic Q·K Attention Network for inner-loop reward scalarization with Evolution Strategies for outer-loop optimization, while the meta-controller is trained via REINFORCE. Experimental results demonstrate a packet delivery ratio (PDR) $\geq 98\%$, $2\text{--}3.5\times$ lower energy consumption, and a $13\times$ smaller memory footprint compared to baselines, while maintaining near real-time inference.

The second article presents CALASH (Carbon-Aware Lifecycle-Autonomous Self-Healing), the first WSN routing protocol that jointly minimizes Lifecycle Carbon Intensity (LCI)—defined as the embodied, operational, and end-of-life CO_2 per useful delivered packet—through four integrated pillars: (i) CADR, which modulates compressive-sensing ratios based on grid carbon intensity; (ii) CARE, a hybrid Lyapunov–DQN router with provable carbon-budget compliance guarantees; (iii) SHDR, an autonomic MAPE-K self-healing loop; and (iv) LSE, an ISO 14040-compliant lifecycle sustainability engine. Operating over a dual-band 6G physical layer (sub-THz / sub-6 GHz), CALASH achieves 60% longer lifetime than LEACH (1,486 vs. 931 rounds), 82.9% PDR, and 33% lower LCI (8.99 vs. 13.42 $\text{gCO}_2\text{eq/pkt}$).

The third article proposes CASTER-ZT (Zero-Trust Shielded Graph-Structured Decision Control), the first zero-trust decision control framework for disaster-monitoring sensing networks. CASTER-ZT couples a 2-layer GraphSAGE encoder, a learned recovery policy, a neural dual-hypothesis trust-risk evaluator, MC-Dropout epistemic uncertainty quantification, and a deterministic shield producing graduated decisions (allow, scope-reduce, defer, escalate, block). Ten formal propositions establish monotone conservatism, unauthorized-actuation ex-

clusion, and conformal coverage guarantees. A 2,420-run campaign demonstrates 74.2–98.3% rogue-policy detection with zero false positives, a weighted recovery score $\omega_{\text{rec}} = 0.733$ (3.7–5.2 $\times$ higher than baselines), and 3.07 ms per-decision latency within O-RAN’s 10 ms near-RT budget.

Collectively, the three articles establish a complete stack—energy efficiency, carbon sustainability, and zero-trust security—for intelligent routing in 6G-integrated disaster-monitoring sensor networks.

AVANT-PROPOS

Cette thèse est présentée sous la forme d'une thèse par articles. Elle regroupe trois articles de recherche originaux qui constituent le corps principal du document (Chapitres 4, 5 et 6). Chaque article est reproduit intégralement dans sa version soumise ou acceptée, reformaté pour assurer l'uniformité de la mise en page selon les exigences du gabarit officiel de Polytechnique Montréal.

Article 1

Titre : *Graph-Attentive Policy Fusion for Lightweight Multi-Agent Routing in Disaster-Monitoring Wireless Sensor Networks (GAPF)*

Auteur principal : Georges Parfait Djimefo Kapen

Statut : Accepté pour publication après deux cycles de révision en double-aveugle.

Revue : *IEEE Transactions on Green Communications and Networking* (IEEE TGCN).¹

Contribution de l'auteur : L'auteur est l'unique concepteur de l'architecture GAPF (encodeur GCN, contrôleur CAS, réseau d'attention Q·K), a réalisé l'ensemble des expériences et des analyses statistiques, et a rédigé la totalité du manuscrit. Le directeur de recherche a fourni l'encadrement scientifique et des commentaires sur les versions successives du manuscrit.

Article 2

Titre : *Carbon-Aware Lifecycle-Autonomous Self-Healing Routing for 6G-Integrated Disaster Sensor Networks : A Lifecycle-Sustainable Approach (CALASH)*

Auteur principal : Georges Parfait Djimefo Kapen

Statut : Soumis à comité de lecture (en évaluation).

1. IEEE TGCN est une revue à comité de lecture arbitrée par des pairs, indexée dans les bases de données suivantes : **Scopus** (SJR $\approx$ 1.8, Q1 en ingénierie et informatique) ; **Web of Science** (Science Citation Index Expanded, JIF $\approx$ 7,7, Journal Citation Reports 2024) ; **CORE** (classée A, ERA 2023). Sa thématique couvre les communications vertes et les réseaux de nouvelle génération, en fort alignement avec les contributions de cette thèse (routage écoénergétique, durabilité carbone, intégration 6G). La soumission de l'Article 1 à cette revue résulte d'une décision éditoriale mûrement réfléchie, prenant en compte l'impact facteur, l'adéquation thématique et la visibilité internationale de la publication. Le DOI définitif sera ajouté dès son attribution par l'éditeur (en cours, Mai 2026).

Revue : *IEEE Transactions on Green Communications and Networking* (IEEE TGCN).

Contribution de l’auteur : L’auteur est l’unique concepteur des quatre piliers CALASH (CADR, CARE, SHDR, LSE) et de la métrique LCI, a réalisé l’ensemble des simulations (30 graines Monte Carlo, 13 variantes de protocoles), les analyses statistiques (Kruskal-Wallis, bootstrap) et a rédigé la totalité du manuscrit. Le directeur de recherche a fourni l’encadrement scientifique et des commentaires sur les versions successives du manuscrit.

Article 3

Titre : *Zero-Trust Shielded Graph-Structured Decision Control for Disaster-Monitoring Sensing Networks* (CASTER-ZT)

Auteur principal : Georges Parfait Djimefo Kapen

Statut : Soumis à comité de lecture (en évaluation).

Revue : *IEEE Transactions on Mobile Computing* (IEEE TMC).

Contribution de l’auteur : L’auteur est l’unique concepteur du cadre CASTER-ZT (encodeur GraphSAGE, évaluateur double-hypothèse, quantification d’incertitude MC-Dropout, bouclier déterministe gradué à 14 paramètres, dix propositions formelles), a réalisé la campagne de 2 420 exécutions et rédigé la totalité du manuscrit. Le directeur de recherche a fourni l’encadrement scientifique et des commentaires sur les versions successives du manuscrit.

TABLE DES MATIÈRES

DÉDICACE	iii
REMERCIEMENTS	iv
RÉSUMÉ	v
ABSTRACT	vii
AVANT-PROPOS	ix
LISTE DES TABLEAUX	xvii
LISTE DES FIGURES	xxi
LISTE DES SYMBOLES ET NOTATIONS MATHÉMATIQUES	xxiii
LISTE DES SIGLES ET ABRÉVIATIONS	xxvii
LISTE DES ANNEXES	xxx
CHAPITRE 1 INTRODUCTION	1
1.1 Contexte et mise en situation	1
1.2 Justification économique, sociétale et réglementaire	3
1.3 Éléments de la problématique	3
1.3.1 Défi 1 : Efficacité énergétique du routage dans les WSN de surveillance des catastrophes	3
1.3.2 Défi 2 : Empreinte carbone du cycle de vie des WSN	4
1.3.3 Défi 3 : Sécurité des politiques de routage apprises par intelligence artificielle	5
1.4 Questions de recherche	6
1.5 Objectifs de recherche	6
1.5.1 Objectif général	6
1.5.2 Objectifs spécifiques	7
1.6 Plan de la thèse	8
CHAPITRE 2 REVUE DE LITTÉRATURE	9
2.1 Routage écoénergétique dans les WSN	9
2.1.1 Protocoles de routage hiérarchique	9

2.1.2	Modèle énergétique de premier ordre	10
2.1.3	Approches métaheuristiques	11
2.1.4	Détection comprimée, récupération d'énergie et résilience	13
2.1.5	Synthèse taxonomique du routage dans les WSN	13
2.2	Apprentissage par renforcement et réseaux de neurones de graphes pour les réseaux	14
2.2.1	Apprentissage par renforcement multi-agent (MARL)	14
2.2.2	Réseaux de neurones de graphes (GNN)	15
2.2.3	Apprentissage par renforcement profond pour le routage	16
2.2.4	Synthèse comparative des approches MARL et DRL	17
2.3	Intelligence embarquée et TinyML pour les réseaux de capteurs	17
2.3.1	Le paradigme TinyML	18
2.3.2	Pertinence pour cette thèse	18
2.4	Durabilité carbone dans les TIC	19
2.4.1	Analyse du cycle de vie (ACV)	19
2.4.2	Optimisation de Lyapunov pour les systèmes en réseau	20
2.4.3	Intensité carbone des réseaux électriques	21
2.4.4	Travaux récents sur l'empreinte carbone des systèmes numériques (2024–2026)	21
2.4.5	Réseaux verts et communication écoénergétique	21
2.4.6	Synthèse comparative des approches de durabilité dans les réseaux	22
2.5	Sécurité et confiance dans les systèmes autonomes	22
2.5.1	Apprentissage par renforcement sûr (<i>Safe RL</i>)	22
2.5.2	Vérification formelle des systèmes autonomes	23
2.5.3	Attaques adversariales sur les politiques d'apprentissage par renforcement	24
2.5.4	Architecture zéro-confiance (<i>Zero-Trust</i>)	25
2.5.5	Quantification d'incertitude	26
2.5.6	Synthèse comparative des approches de sécurité pour les systèmes autonomes	27
2.6	Technologies habilitantes 6G	27
2.6.1	Communication sub-téraherz	27
2.6.2	Surfaces intelligentes reconfigurables (RIS)	28
2.6.3	Détection–communication intégrée (ISAC)	28
2.6.4	Architecture O-RAN	28
2.6.5	Travaux récents sur le 6G pour la gestion des catastrophes (2024–2026)	29

2.6.6	Synthèse comparative des technologies 6G pour les WSN	29
2.7	Paradigmes émergents pour les WSN intelligents	30
2.8	Tableau récapitulatif des lacunes	30
2.9	Synthèse et lacunes identifiées	31
CHAPITRE 3 DÉMARCHE DE L'ENSEMBLE DU TRAVAIL DE RECHERCHE .		33
3.1	Logique d'ensemble de la recherche	33
3.2	Cadre méthodologique	34
3.3	Protocole expérimental commun	35
3.3.1	Modèle énergétique de premier ordre	35
3.3.2	Modèle de catastrophe	36
3.3.3	Données de référence	36
3.3.4	Protocoles de référence (<i>baselines</i>)	36
3.4	Fondements théoriques de la formulation	37
3.5	Cadre statistique et reproductibilité	37
3.5.1	Graines aléatoires et répétitions	37
3.5.2	Tests statistiques	38
3.5.3	Intervalle de confiance et métriques rapportées	38
3.5.4	Reproductibilité	38
3.5.5	Indicateurs de qualité de la démarche méthodologique	39
3.6	Stratégie de validation et calibration	40
3.7	Modèle de menaces et hypothèses de sécurité	41
3.8	Article 1 — GAPF : les fondations du routage intelligent	42
3.9	Environnement de simulation	42
3.9.1	Architecture logicielle	42
3.9.2	Paramétrage des scénarios	43
3.9.3	Analyse de complexité algorithmique	43
3.9.4	Espaces d'état, d'action et de récompense	44
3.9.5	Procédure d'entraînement et convergence	45
3.10	Justification des choix d'hyperparamètres	45
3.11	Article 2 — CALASH : l'extension vers la durabilité carbone	46
3.12	Article 3 — CASTER-ZT : la couche de sécurité zéro-confiance	46
3.13	Protocole d'intégration inter-articles	48
3.13.1	Flux de données de bout en bout	48
3.13.2	Spécifications des interfaces	48
3.13.3	Analyse de latence de bout en bout	49

3.13.4	Budget mémoire de la pile complète	50
3.13.5	Scénarios de déploiement	50
3.14	Synthèse de la démarche	51
CHAPITRE 4 ARTICLE 1 : ENERGY-EFFICIENT AND NEAR REAL-TIME ROUTING ALGORITHM FOR DISASTER MONITORING IN WIRELESS SENSOR NETWORKS		
4.1	Abstract	52
4.2	Introduction	53
4.3	Background and Related Work	55
4.4	Methodology	59
4.4.1	Problem description	59
4.4.2	The Energy model	60
4.4.3	Reward Scalarization via Monotonic Q-K Attention Network	61
4.4.4	GAPF : Graph-Attentive Policy Fusion	63
4.4.5	Time Complexity Analysis	71
4.5	Results and Discussion	72
4.5.1	Deployment Feasibility on Resource-Constrained Nodes	75
4.5.2	Limitations	76
4.6	Conclusion	77
4.6.1	Contributions and Impact	77
4.6.2	Broader Impact	78
4.6.3	Future Work	78
CHAPITRE 5 ARTICLE 2 : CARBON-AWARE AUTONOMOUS DATA REDUCTION AND SELF-HEALING ROUTING FOR 6G-INTEGRATED DISASTER SENSOR NETWORKS : A LIFECYCLE-SUSTAINABLE APPROACH		
5.1	Abstract	80
5.2	Introduction	81
5.3	Related Work	82
5.3.1	Energy-Efficient Clustering Protocols	82
5.3.2	Metaheuristic and RL-Based Routing	82
5.3.3	Carbon-Aware Networking	83
5.3.4	Disaster-Resilient WSNs and Lifecycle Assessment	83
5.4	Methodology	83
5.4.1	System Model	84
5.4.2	Problem Formulation	84

5.4.3	CALASH Framework	85
5.4.4	6G Enabling Technologies	88
5.4.5	Theoretical Guarantee : CDL Pareto Bound	89
5.5	Results and Discussion	90
5.5.1	Data Provenance and Reproducibility	90
5.5.2	Experimental Setup	90
5.5.3	DQN Training Hyperparameters	91
5.5.4	Time Complexity Analysis	92
5.5.5	Discussion of Results	93
5.6	Conclusion	98
CHAPITRE 6 ARTICLE 3 : ZERO-TRUST SHIELDED GRAPH-STRUCTURED DECISION CONTROL FOR SECURE AUTONOMOUS RECOVERY IN AI-NATIVE 6G DISASTER-MONITORING SENSING NETWORKS		
		102
6.1	Abstract	102
6.2	Introduction	103
6.3	Related Work	104
6.4	CASTER-ZT Framework	106
6.4.1	System and threat model	106
6.4.2	Architecture	107
6.4.3	Shield design and algorithms	108
6.4.4	Training pipeline	108
6.4.5	Theoretical properties	109
6.5	Experimental Evaluation	112
6.5.1	Evaluation protocol	112
6.5.2	Results	115
6.6	Discussion and Limitations	117
6.7	Conclusion	119
CHAPITRE 7 DISCUSSION GÉNÉRALE		
		121
7.1	Retour sur les questions de recherche	121
7.1.1	Q1 — Efficacité énergétique (GAPF)	121
7.1.2	Q2 — Durabilité carbone (CALASH)	121
7.1.3	Q3 — Sécurité zéro-confiance (CASTER-ZT)	122
7.1.4	Question principale	122
7.2	Analyse transversale des résultats	122
7.2.1	Synergies quantitatives entre les couches	122

7.2.2	Le paradigme de la fusion vs. l'apprentissage monolithique	123
7.2.3	Analyse de la complexité Dec-POMDP et implications	123
7.2.4	Robustesse adversariale : analyse et perspectives	123
7.2.5	Faisabilité du déploiement TinyML	123
7.2.6	Le carbone incorporé comme métrique oubliée	124
7.2.7	Zéro-confiance comme couche systémique	124
7.2.8	Paradigmes émergents	125
7.3	Analyse de convergence et garanties théoriques	125
7.3.1	Synthèse : complémentarité des garanties	125
7.4	Analyse de sensibilité	126
7.4.1	Sensibilité aux conditions environnementales	126
7.5	Analyse des modes de défaillance	126
7.6	Positionnement par rapport à l'état de l'art	127
7.6.1	Comparaison avec les travaux concurrents 2024–2025	127
7.7	Considérations éthiques et sociétales	128
7.8	Limites de la discussion	128
CHAPITRE 8 CONCLUSION		129
8.1	Synthèse des travaux	129
8.2	Contributions scientifiques originales	129
8.3	Retombées scientifiques et sociétales	131
8.4	Alignement avec les Objectifs de développement durable	132
8.5	Limitations de la solution proposée	132
8.6	Directions de recherche futures	133
8.6.1	Court terme (1–2 ans)	133
8.6.2	Moyen terme (2–4 ans)	134
8.6.3	Long terme (4+ ans)	134
8.7	Perspectives d'application à d'autres domaines	134
8.8	Recommandations aux décideurs et aux organismes de normalisation	135
8.9	Synthèse quantitative des résultats	135
8.10	Remarques conclusives	136
RÉFÉRENCES		137
ANNEXES		157

LISTE DES TABLEAUX

Tableau 2.1	Comparaison des protocoles de routage hiérarchique pour WSN. PDR : Packet Delivery Ratio. DV : durée de vie.	10
Tableau 2.2	Comparaison des approches métaheuristiques pour le routage dans les WSN.	12
Tableau 2.3	Taxonomie des approches de routage pour les WSN selon cinq dimensions.	13
Tableau 2.4	Comparaison des méthodes MARL et DRL pour le routage dans les réseaux. CTDE : entraînement centralisé, exécution décentralisée. IGM : cohérence individuelle-globale.	17
Tableau 2.5	Compatibilité des composants de la pile protocolaire avec les plateformes embarquées. FP32 : virgule flottante 32 bits. INT8 : entier 8 bits quantifié.	19
Tableau 2.6	Comparaison des approches de durabilité carbone dans les TIC. ACV : analyse du cycle de vie. CS : détection comprimée. CI : intensité carbone.	22
Tableau 2.7	Comparaison des approches de sécurité pour les systèmes autonomes. FP : faux positifs. ZT : zéro-confiance.	27
Tableau 2.8	Technologies habilitantes 6G et leur apport aux WSN de surveillance des catastrophes.	29
Tableau 2.9	Analyse des lacunes de la littérature. ✓ = présent, ✗ = absent, ◦ = partiel. Les douze critères sont regroupés en trois catégories : efficacité (E1–E4), durabilité (D1–D4) et sécurité (S1–S4).	30
Tableau 3.1	Grille d'évaluation DSRM : alignement des six activités de Peffers et al. (2007) avec les indicateurs quantitatifs des trois articles.	35
Tableau 3.2	Synthèse des campagnes de simulation des trois articles.	39
Tableau 3.3	Vecteurs d'attaque considérés dans les trois articles et mécanismes de défense correspondants.	41
Tableau 3.4	Analyse de complexité algorithmique des composants principaux. n : nœuds, $ E $: arêtes, d : dimension des plongements, K : couches GNN, T : passes MC-Dropout.	43
Tableau 3.5	Espaces d'état, d'action et de récompense pour les trois articles. n : nombre de nœuds, $ \mathcal{N}(v) $: taille du voisinage du nœud v	44
Tableau 3.6	Budgets d'entraînement des trois articles. Les heures GPU sont mesurées sur NVIDIA A100 40 GB.	46

Tableau 3.7	Hyperparamètres clés des trois articles : valeur retenue, plage de recherche et justification.	47
Tableau 3.8	Budget de latence de bout en bout de la pile protocolaire complète. Mesures sur Google Coral Edge TPU pour un réseau de 100 nœuds. .	49
Tableau 3.9	Synthèse de la démarche de recherche : des lacunes aux résultats. . .	51
Tableau 4.1	Comparative Analysis of Selected Routing Algorithms (2024–2025) .	58
Tableau 4.2	Time complexity comparison. n : number of sensors, T : steps per episode, h : RNN hidden dimension (64), d : GNN embedding dimension (16), N_p : PSO particles (32), I : PSO iterations (50).	71
Tableau 4.3	Custom Gym Environment setting.	72
Tableau 4.4	Training Hyperparameters for QMIX, QTRAN, and GAPF.	72
Tableau 4.5	Inference metrics (Apple M-series CPU, 0.1,W reference). All algorithms achieve sub-millisecond latency.	73
Tableau 4.6	Overview of the seven evaluation scenarios.	73
Tableau 4.7	Performance metrics across all scenarios (three seeds, test set). Best values per scenario in bold	74
Tableau 4.8	Energy balance (σ_E) and feasibility compliance across all scenarios. .	74
Tableau 4.9	Component deployment map under CTDE. Only the per-sensor agent and GAPF controller are active at inference.	75
Tableau 5.1	Feature comparison of CALASH vs. baseline protocols.	82
Tableau 5.2	Data provenance summary. Each input to the simulation is classified by its provenance level, source, and licence.	91
Tableau 5.3	DQN and framework hyperparameters.	92
Tableau 5.4	Per-round computational complexity. N : nodes, K : CHs, D : avg degree, H : max hops, P : ABC population, I : iterations.	93
Tableau 5.5	Main simulation results (30 seeds, 5,000 rounds, disaster at round 2,000). Values are mean $\pm$ 95% CI. Best value per column in bold . $\downarrow$ = lower is better, $\uparrow$ = higher is better. All protocols achieve fidelity $F = 1.000$ and operational carbon $\approx 0.002 \text{ gCO}_2$	94
Tableau 5.6	Wilcoxon signed-rank test : CALASH vs. each baseline ($\alpha = 0.05$, $n = 30$ seeds). $\checkmark$ = significant.	95
Tableau 5.7	Wall-clock execution time per 5,000-round simulation (30-seed mean $\pm$ 95% CI). Overhead ratio relative to LEACH.	101
Tableau 6.1	Model-space positioning. $\checkmark$ = addressed ; $\circ$ = partial ; $\times$ = absent. . .	106
Tableau 6.2	Training summary for all learned components.	110
Tableau 6.3	Complete hyperparameter specification.	111

Tableau 6.4	Main security results under HIGH-severity identity-credential abuse (mean $\pm$ std, 20 seeds).	115
Tableau 6.5	Cross-method security under HIGH-severity combined attack (20 seeds). $p < 0.001$ vs. CASTER-ZT for marked methods.	117
Tableau 6.6	Recovery quality ω_{rec} under HIGH-severity identity abuse (20 seeds). .	117
Tableau 6.7	Multi-scale evaluation under HIGH-severity identity abuse.	118
Tableau 6.8	Threshold sensitivity : sweeping γ_1 under HIGH-severity identity abuse (12-cell, 20 seeds).	118
Tableau 6.9	Deployment profile and 6G compliance.	119
Tableau 7.1	Analyse de déployabilité TinyML des trois cadres proposés.	124
Tableau 7.2	Synthèse des propriétés de convergence et garanties théoriques de la pile protocolaire.	125
Tableau 7.3	Analyse de sensibilité de la pile protocolaire aux conditions environnementales. $\uparrow/\downarrow$: impact positif/négatif sur la performance.	126
Tableau 7.4	Analyse des modes de défaillance de la pile protocolaire (FMEA simplifiée).	127
Tableau 7.5	Positionnement de la pile proposée par rapport aux principales approches de la littérature.	127
Tableau 8.1	Alignement des contributions avec les ODD des Nations Unies.	132
Tableau 8.2	Bilan quantitatif global de la thèse : gains clés par rapport à l'état de l'art.	135
Tableau A.1	Paramètres de simulation communs	157
Tableau B.1	Décomposition des paramètres de GAPF	158
Tableau B.2	Architecture de l'agent DQN de CALASH	158
Tableau B.3	Décomposition des paramètres de CASTER-ZT	159
Tableau C.1	Protocoles de référence par article	160
Tableau E.1	Hyperparamètres d'entraînement pour QMIX, QTRAN et GAPF . .	163
Tableau E.2	Carte de déploiement des composants sous le paradigme CTDE . . .	164
Tableau E.3	Besoins en ressources de l'agent par capteur vs spécifications de micro-contrôleurs commerciaux	165
Tableau E.4	Métriques de faisabilité mesurées (machine hôte : Apple M-series, mode CPU). Latence et mémoire mesurées sur 30 itérations avec 3 passes de préchauffage. Énergie estimée à 0.1 W (typique Cortex-M4 à 80 MHz).	165
Tableau E.5	PDR à travers les scénarios. Δ : amélioration relative de GAPF sur la meilleure ligne de base MARL.	166
Tableau E.6	Analyse comparative des algorithmes de routage récents (2024–2025)	166

Tableau F.1	Hyperparamètres de l'agent DQN de CALASH	168
-------------	--	-----

LISTE DES FIGURES

Figure 3.1	Vue d’ensemble de la démarche de recherche : les trois phases construisent progressivement la pile protocolaire complète. Les flèches continues montrent la progression logique ; la flèche en pointillé illustre la protection rétroactive de la couche de sécurité.	33
Figure 4.1	GAPF architecture (CAS mode). Sensor positions and communication radius define a graph encoded by a two-layer GCN with mean-pool readout ($\mathbf{z} \in \mathbb{R}^{16}$). The CAS controller maps $\mathbf{z}$ to a selection probability p_{QMIX} . The chosen frozen expert executes the full episode. The return G_k feeds back (red arrow) as a REINFORCE signal to update only the 1,473 meta-controller parameters.	66
Figure 5.1	CALASH per-round operation flow. Each round progresses into phases aligned with the four pillars.	87
Figure 5.2	Alive node count over simulation rounds (30-seed mean). The disaster event at round 2,000 causes a visible dip in all protocols ; CALASH recovers fastest due to SHDR.	95
Figure 5.3	Cumulative packet delivery ratio over 5,000 rounds for 13 protocols (200 nodes, 30-seed mean). CALASH sustains PDR 0.83, exceeding all multi-hop baselines by $\geq 30\%$; ABC-ACO reaches 0.89 but at 41% shorter lifetime.	96
Figure 5.4	Box plots of four key metrics—half-death round, PDR, total carbon, data fidelity—across 30 seeds for all 13 protocols (200 nodes, 5,000 rounds). Whiskers span 5th–95th percentile ; narrow boxes indicate low variance.	96
Figure 5.5	Cumulative (gCO_2eq) over 5,000 rounds for all 13 protocols (200 nodes, 30-seed mean). All converge to 0.002 gCO_2eq ; differences dominated by embodied carbon amortization.	97
Figure 5.6	Comparison of synthetic vs. real data traces. Real Intel Lab data exhibits higher sparsity, leading to better fidelity under compression. . . .	98
Figure 5.7	Scalability analysis : LCI and half-death round as network size varies from 100 to 500 nodes (10 seeds each, 5,000 rounds).	99
Figure 5.8	Sensitivity analysis : effect of Lyapunov trade-off parameter V , carbon weight β , CH percentage, and compression floor $\rho_{\min}$ on CALASH performance (10 seeds each).	100

Figure 6.1	Rogue detection (RogueDet) and blocking (RogueBlk) under HIGH-severity identity abuse. CASTER-ZT : 74.2% detection, zero false positives ; IF-Trust : 100% via aggressive scope-reduction ; Shield-Binary : 88.3% with 48.8% false positives.	105
Figure 6.2	CASTER-ZT architecture. The policy proposes ; the zero-trust shield Γ controls execution via trust, risk, divergence, authorization, and uncertainty signals.	108
Figure 6.3	Training convergence for all four learned components (20,019 total parameters). (a) Trust AE : MSE converges by epoch 16 ; (b) Risk scorer : BCE converges by epoch 27, AUC= 0.999 ; (c) Contrastive encoder : margin loss converges by epoch 44 ; (d) GNN+policy : CE converges by epoch 17, accuracy= 1.000.	113
Figure 6.4	Multi-metric radar comparison under HIGH-severity identity abuse. CASTER-ZT : distinctive zero-false-positive, graduated-enforcement profile. . .	114
Figure 6.5	Multi-scale evaluation. Left : rogue detection and recovery quality (12–100 cells). Right : per-tick latency. Security improves with scale ; 12-cell latency is $3\times$ below the O-RAN 10 ms budget.	115

LISTE DES SYMBOLES ET NOTATIONS MATHÉMATIQUES

Les symboles ci-dessous sont regroupés par thème et listés par ordre d'apparition au sein de chaque groupe. L'unité est précisée entre crochets lorsqu'elle est applicable ; “sans dim.” indique une grandeur adimensionnelle.

Variables d'état du réseau

$\mathcal{G}(t) = (\mathcal{V}, \mathcal{E}(t))$	Graphe du réseau WSN à l'instant t	—
$\mathcal{V}$	Ensemble des nœuds capteurs	—
N	Nombre total de nœuds	[nœuds]
$\mathcal{E}(t)$	Ensemble des liens actifs à l'instant t	—
d_{ij}	Distance entre nœuds i et j	[m]
d_0	Distance seuil de transition propagation	[m]
$e_i(t)$	Énergie résiduelle du nœud i à l'instant t	[J]
E_0	Énergie initiale de chaque nœud	[J]
$\mathcal{N}(i)$	Ensemble des voisins à 1 saut du nœud i	—

Modèle énergétique (Heinzelman *et al.*)

E_{elec}	Énergie dissipée par bit d'émission/réception	[J/bit]
ε_{fs}	Coefficient d'amplification espace libre	[J/bit/m ²]
ε_{mp}	Coefficient d'amplification multi-chemins	[J/bit/m ⁴]
ℓ	Taille du paquet transmis	[bits]
α	Exposant de perte de chemin (2 ou 4)	[sans dim.]
$E_{\text{Tx}}(\ell, d)$	Énergie de transmission de ℓ bits sur distance d	[J]
$E_{\text{Rx}}(\ell)$	Énergie de réception de ℓ bits	[J]

Variables de l'apprentissage par renforcement multi-agents (MARL)

s_i^t	État local de l'agent i à l'instant t	—
o_i^t	Observation partielle de l'agent i	—
a_i^t	Action de l'agent i à l'instant t	—

r_i^t	Récompense individuelle de l'agent i	[sans dim.]
γ	Facteur d'actualisation des récompenses futures	[sans dim.]
π_θ	Politique paramétrée par θ	—
$Q^\pi(s, a)$	Fonction valeur action-état sous la politique π	[sans dim.]
Q_{tot}	Valeur globale mélangée (QMIX/QTRAN)	[sans dim.]
$\mathbf{h}_i^{(k)}$	Représentation GNN du nœud i à la couche k	—
$\mathbf{z}_G$	Représentation de niveau graphe (pooling)	—
w_j	Poids contextuel de la politique j (CAS)	[sans dim.]
$ \Theta $	Nombre de paramètres entraînables	[paramètres]
α	Vecteur de poids d'attention appris (GAPF outer loop)	[sans dim.]
ϕ	Paramètres du réseau d'attention (Evolution Strategies)	—
$J(\phi)$	Méta-objectif outer loop ES (efficacité + équilibre)	[sans dim.]
σ_{ES}	Bruit de perturbation Evolution Strategies (= 0.01)	[sans dim.]
η_{ES}	Taux d'apprentissage Evolution Strategies (= 0.01)	[sans dim.]

Métriques de performance réseau

PDR	Taux de livraison de paquets (<i>Packet Delivery Ratio</i>)	[%]
T_{vie}	Durée de vie du réseau (dernier nœud vivant)	[rounds]
$T_{1/2}$	Demi-vie du réseau (50% des nœuds vivants)	[rounds]
$\bar{e}(t)$	Énergie résiduelle moyenne du réseau à t	[J]
Δ_e	Variance d'équilibre énergétique entre nœuds	[J ²]

Variables carbone (CALASH)

LCI	Intensité carbone du cycle de vie (<i>Lifecycle Carbon Intensity</i>)	[gCO ₂ eq/paquet]
C_{emb}	Carbone incorporé (fabrication + installation)	[gCO ₂ eq]
$C_{\text{op}}(t)$	Carbone opérationnel cumulé jusqu'à t	[gCO ₂ eq]
C_{eol}	Carbone de fin de vie (traitement DEEE)	[gCO ₂ eq]
$CI(t)$	Intensité carbone du réseau électrique à t	[gCO ₂ eq/kWh]
$\rho_{\text{CS}}(t)$	Ratio de compression sensing adaptatif	[sans dim.]
ρ_{min}	Compression maximale (fraction minimale transmise, = 0.3)	[sans dim.]
ρ_{max}	Compression minimale (fraction maximale transmise, = 0.8)	[sans dim.]
r_{recycle}	Taux de recyclage des nœuds morts (= 0.3)	[sans dim.]
$Z(t)$	File virtuelle de Lyapunov (pression carbone)	[gCO ₂ eq]
$\bar{c}$	Budget carbone moyen admissible par ronde	[gCO ₂ eq/ronde]
V	Paramètre de compromis Lyapunov (livraison vs. carbone)	[sans dim.]
B	Constante de borne Lyapunov ($\frac{1}{2} \max_t \{(C_{\text{tot}}(t) - \bar{c})^2\}$)	[gCO ₂ eq ²]
$\bar{D}$	Taux de livraison moyen atteint par CALASH	[paquets/ronde]
$\bar{D}^*$	Taux de livraison optimal de toute politique statique	[paquets/ronde]
ℓ_j	Facteur de pénalité carbone incorporé du nœud j	[sans dim.]
w_{eol}	Poids de la pénalité fin de vie dans la décision de routage	[sans dim.]
CDL	Borne de Pareto carbone-livraison-durée de vie	—

Variables de détection comprimée / TinyML (CALASH)

n	Dimension originale du signal capteur	[sans dim.]
m	Dimension compressée ($m = \rho_{\text{CS}} \cdot n$)	[sans dim.]

s	Niveau de sparsité du signal dans le domaine DCT	[sans dim.]
F	Fidélité de reconstruction ($F = 1 - \text{NMSE}$)	[sans dim.]
δ	Seuil de distorsion NMSE acceptable	[sans dim.]

Variables de sécurité (CASTER-ZT)

$\mathcal{T}$	Ensemble des types de menaces modélisées	—
$p(y \mid o)$	Distribution de confiance avec MC-Dropout	[sans dim.]
ECE	Erreur de calibration attendue (<i>Expected Calibration Error</i>)	[sans dim.]
ω_{rec}	Score de récupération normalisé	[sans dim.]
FPR	Taux de faux positifs (<i>False Positive Rate</i>)	[%]
$\mathcal{D}$	Bouclier déterministe à 5 niveaux gradués	—
τ_k	Seuil du niveau k du bouclier	[sans dim.]
RogueDet	Taux de détection d'agents rogues (nœuds compromis)	[%]
η_{AI}	Indice d'autonomie IA (étages neuronaux / total)	[sans dim.]

LISTE DES SIGLES ET ABRÉVIATIONS

ABC	Artificial Bee Colony
ACV	Analyse du Cycle de Vie (Life Cycle Assessment)
ACO	Ant Colony Optimization
AI	Artificial Intelligence
AODV	Ad hoc On-Demand Distance Vector
BS	Base Station
CADR	Carbon-Aware Data Reduction
CALASH	Carbon-Aware Lifecycle-Autonomous Self-Healing
CARE	Carbon-Aware Routing Engine
CAS	Contextual Algorithm Selection
CASTER-ZT	Carbon-Aware Self-healing Topology Engine for Resilient routing — Zero-Trust
CDL	Carbon-Delivery-Lifecycle
CH	Cluster Head
CI	Carbon Intensity
CMDP	Constrained Markov Decision Process
COMA	Counterfactual Multi-Agent (policy gradient)
CPO	Constrained Policy Optimization
CS	Compressive Sensing
CTDE	Centralized Training with Decentralized Execution
Dec-POMDP	Decentralized Partially Observable Markov Decision Process
DMSN	Disaster-Monitoring Sensing Network
DQN	Deep Q-Network
DRL	Deep Reinforcement Learning
DSR	Design Science Research
DSRM	Design Science Research Methodology
ECE	Expected Calibration Error
EE-LEACH	Energy-Efficient LEACH
EERP	Energy-Efficient Routing Protocol
ES	Evolution Strategies
FL	Federated Learning
FMEA	Failure Mode and Effect Analysis
FPR	False Positive Rate

GAPF	Graph-Attentive Policy Fusion
GAT	Graph Attention Network
GCN	Graph Convolutional Network
GIN	Graph Isomorphism Network
GNN	Graph Neural Network
GraphSAGE	Graph SAmple and aggreGatE
GRU	Gated Recurrent Unit
HEED	Hybrid Energy-Efficient Distributed (clustering)
IGM	Individual-Global-Max (property)
IoT	Internet of Things
IPCC	Intergovernmental Panel on Climate Change
ISAC	Integrated Sensing and Communication
ISO	International Organization for Standardization
LCA	Life Cycle Assessment
LCI	Lifecycle Carbon Intensity
LEACH	Low-Energy Adaptive Clustering Hierarchy
LEO	Low Earth Orbit
LSE	Lifecycle Sustainability Engine
LSTM	Long Short-Term Memory
LTL	Linear Temporal Logic
MADRL	Multi-Agent Deep Reinforcement Learning
MAPE-K	Monitor, Analyze, Plan, Execute — Knowledge
MAPPO	Multi-Agent Proximal Policy Optimization
MARL	Multi-Agent Reinforcement Learning
MC	Monte Carlo
MCU	Microcontroller Unit
MDP	Markov Decision Process
MLP	Multi-Layer Perceptron
MPNN	Message Passing Neural Network
NAS	Neural Architecture Search
NIST	National Institute of Standards and Technology
NSGA-II	Non-dominated Sorting Genetic Algorithm II
NTN	Non-Terrestrial Network
OFDM	Orthogonal Frequency-Division Multiplexing
O-RAN	Open Radio Access Network
PBFT	Practical Byzantine Fault Tolerance

PDR	Packet Delivery Ratio
PEGASIS	Power-Efficient Gathering in Sensor Information Systems
POMDP	Partially Observable Markov Decision Process
PPDR	Public Protection and Disaster Relief
PSO	Particle Swarm Optimization
QMIX	Q-value Mixing Network
QTRAN	Q-value Transformation Network
RIC	RAN Intelligent Controller
RIS	Reconfigurable Intelligent Surface
RL	Reinforcement Learning
RNN	Recurrent Neural Network
SHDR	Self-Healing Disaster Recovery
SMT	Satisfiability Modulo Theories
TDMA	Time Division Multiple Access
TFLM	TensorFlow Lite Micro
THz	Terahertz
TIC	Technologies de l'Information et de la Communication
UAV	Unmanned Aerial Vehicle
UNDRR	United Nations Office for Disaster Risk Reduction
VDN	Value Decomposition Network
WL	Weisfeiler-Leman (graph isomorphism test)
WSN	Wireless Sensor Network

LISTE DES ANNEXES

Annexe A	Paramètres de simulation communs aux trois articles	157
Annexe B	Architectures des réseaux de neurones	158
Annexe C	Protocoles de référence	160
Annexe D	Preuves des propriétés théoriques de CASTER-ZT (matériel supplé- mentaire de l'Article 3)	161
Annexe E	Matériel supplémentaire de GAPF (Article 1)	163
Annexe F	Matériel supplémentaire de CALASH (Article 2)	167

CHAPITRE 1 INTRODUCTION

1.1 Contexte et mise en situation

Les catastrophes naturelles — séismes, inondations, glissements de terrain, feux de forêt, ouragans — constituent l’une des menaces les plus graves pour les populations et les infrastructures à l’échelle mondiale. Selon le rapport 2020 du Bureau des Nations Unies pour la réduction des risques de catastrophes (UNDRR), plus de 7 348 événements catastrophiques majeurs ont été enregistrés entre 2000 et 2019, affectant 4.2 milliards de personnes, causant 1.23 million de décès et engendrant des pertes économiques estimées à 2 970 milliards de dollars américains [1]. Plus récemment, en 2023, 398 catastrophes naturelles ont été recensées, avec 95 000 décès et des pertes d’environ 380 milliards de dollars [2]. Cette tendance alarmante est exacerbée par le changement climatique, qui augmente la fréquence et l’intensité des phénomènes météorologiques extrêmes. Dans ce contexte, la surveillance en temps réel des zones à risque est devenue un impératif stratégique pour la détection précoce des signes avant-coureurs, la coordination efficace des secours et la réduction des pertes humaines et matérielles.

Le Sixième Rapport d’Évaluation du Groupe d’experts intergouvernemental sur l’évolution du climat (GIEC/IPCC AR6) confirme cette tendance : sous un scénario de réchauffement de 1.5°C, les précipitations extrêmes augmenteront de 10.5% en intensité et de 30% en fréquence [3]. Le Cadre de Sendai pour la réduction des risques de catastrophes 2015–2030 [4], adopté par 187 pays, identifie quatre priorités d’action dont la compréhension des risques de catastrophe et le renforcement de la gouvernance. L’indicateur mondial C-2 du Cadre de Sendai — le nombre de personnes couvertes par des systèmes d’alerte précoce multi-aléas — souligne l’urgence de déployer des infrastructures de surveillance fiables, en particulier dans les pays en développement où 90% des décès liés aux catastrophes surviennent.

Les réseaux de capteurs sans fil (WSN — *Wireless Sensor Networks*), composés de centaines à des milliers de nœuds capteurs miniaturisés, alimentés par batterie et communiquant par liaisons radio multi-sauts vers une station de base (BS), offrent une solution prometteuse pour cette surveillance [5]. Leur capacité à collecter des données environnementales (température, humidité, vibrations, niveaux d’eau) avec une intervention humaine minimale, à maintenir leur connectivité même après la destruction partielle d’infrastructures, et à couvrir des zones géographiquement étendues en fait des instruments de choix pour le suivi des catastrophes. Cependant, leur déploiement dans des environnements hostiles et inaccessibles impose des contraintes sévères : batteries non rechargeables de capacité limitée (~ 0.5 J par nœud dans

les simulations standard de type Heinzelman [6]), bande passante restreinte, puissance de calcul élémentaire (microcontrôleurs ARM Cortex-M0/M4 avec $\sim 16\text{--}256\text{ KB}$ de RAM), et vulnérabilité aux destructions physiques causées par les catastrophes elles-mêmes [7].

Des déploiements réels ont démontré la viabilité mais aussi les limites de ces réseaux en conditions extrêmes. Aslan et al. [8] ont déployé un réseau de capteurs de température et d’humidité pour la détection précoce de feux de forêt en Turquie, observant un taux de survie des nœuds de seulement 68% après six mois en raison des conditions climatiques hostiles. Abu-Ghazaleh et al. [9] ont étudié la survivabilité des WSN sous destruction partielle, montrant qu’une perte de 30% des nœuds peut réduire la connectivité de 60% si les nœuds critiques (goulots d’étranglement de routage) sont ciblés. Ces observations motivent les choix de conception de cette thèse : la conscience topologique via les GNN (pour identifier et protéger les nœuds critiques), la résilience aux destructions massives (auto-guérison MAPE-K dans CALASH) et la vérification systématique des décisions (bouclier CASTER-ZT).

L’avènement des réseaux de sixième génération (6G), attendu commercialement autour de 2030, promet de transformer radicalement ces réseaux de capteurs en plateformes de détection natives en intelligence artificielle (AI). Les technologies habilitantes du 6G — communication sub-téraherztz (sub-THz) offrant des débits multi-gigabits, surfaces intelligentes reconfigurables (RIS) permettant le contrôle passif de l’environnement de propagation, et détection-communication intégrée (ISAC) utilisant la même forme d’onde pour communiquer et percevoir — ouvrent de nouvelles possibilités pour les réseaux de surveillance des catastrophes [10]. En parallèle, l’architecture O-RAN (Open Radio Access Network) standardise le déploiement d’applications intelligentes (xApps) sur des contrôleurs à budget de latence contraint (10 ms pour le near-RT RIC), créant un cadre propice à l’intégration d’algorithmes d’apprentissage automatique directement dans la boucle de contrôle du réseau.

Malgré ces avancées technologiques majeures, trois défis fondamentaux demeurent non résolus dans la littérature et constituent le cœur de cette thèse. Ces défis, identifiés à travers une analyse approfondie de l’état de l’art (Chapitre 2), forment une progression logique : (1) l’efficacité énergétique du routage comme condition préalable à toute opération durable, (2) la minimisation de l’empreinte carbone du cycle de vie comme extension naturelle de l’optimisation énergétique vers la durabilité environnementale, et (3) la sécurité des politiques de routage apprises par intelligence artificielle comme couche de protection indispensable pour tout déploiement autonome en environnement critique.

1.2 Justification économique, sociétale et réglementaire

Les contributions de cette thèse répondent à des besoins concrets. Les pertes économiques annuelles dues aux catastrophes naturelles dépassent 380 milliards de dollars [2], et chaque dollar investi dans les systèmes d’alerte précoce génère un retour de 4 à 10 dollars en pertes évitées [4]. L’empreinte carbone de la recherche en IA est par ailleurs devenue une préoccupation : la frugalité de la pile proposée ($\sim 27K$ paramètres, ~ 144 heures GPU) représente un ordre de grandeur de réduction par rapport aux approches plus lourdes [11]. Sur le plan normatif, trois cadres motivent directement ces travaux : le Cadre de Sendai 2015–2030 [4] (renforcement des systèmes d’alerte précoce), ISO 14040 [12] (ACV intégrée dans CALASH) et NIST SP 800-207 [13] (paradigme zéro-confiance transposé par CASTER-ZT). Enfin, la légèreté computationnelle de la pile ($< 27K$ paramètres, déployable sur des microcontrôleurs à quelques dollars) la rend accessible pour les déploiements dans les pays à revenu faible et intermédiaire, où 95% des décès liés aux catastrophes surviennent [3].

1.3 Éléments de la problématique

1.3.1 Défi 1 : Efficacité énergétique du routage dans les WSN de surveillance des catastrophes

Le routage constitue le principal facteur déterminant la durée de vie d’un WSN, car la transmission de données consomme la majeure partie de l’énergie disponible. L’énergie de transmission croît avec le carré (voire la puissance quatrième au-delà de la distance critique $d_0 \approx 87.7\text{m}$) de la distance, rendant le routage multi-sauts indispensable. Les protocoles classiques de routage hiérarchique — LEACH [6] et ses variantes (EE-LEACH [14], LEACH-C [15], HEED [16], EERP [17]) — reposent sur des heuristiques statiques pour l’élection des chefs de grappe (CH) et n’exploitent pas l’information topologique du réseau. Les approches métaheuristiques (ABC [18], PSO [19]) améliorent les performances mais souffrent de temps de convergence élevés ($O(n^2)$ à $O(n^3)$ par itération) et ne fournissent aucune garantie d’optimalité en environnement non stationnaire.

Plus récemment, l’apprentissage par renforcement multi-agent (MARL) — notamment QMIX [20] et QTRAN [21] dans le paradigme d’entraînement centralisé et d’exécution décentralisée (CTDE) — a démontré des résultats prometteurs en modélisant chaque nœud comme un agent coopératif. Toutefois, trois lacunes critiques persistent :

1. **Explosion mémoire** : chaque agent MARL basé sur un réseau récurrent (GRU/LSTM) requiert $\sim 39\,000$ paramètres, engendrant une consommation mémoire de 3.2 à 13.8 GB

à l’entraînement — incompatible avec les contraintes des microcontrôleurs de classe capteur (ARM Cortex-M0/M4, $\sim 16\text{--}256$ KB de RAM).

2. **Ignorance de la topologie** : QMIX et QTRAN traitent les agents de manière homogène sans exploiter la structure spatiale du réseau (adjacence, centralité, goulots d’étranglement), alors que cette information topologique est cruciale pour un routage efficace dans des réseaux où les catastrophes modifient dynamiquement la connectivité.
3. **Absence de fusion de politiques** : QMIX et QTRAN présentent des forces complémentaires — QMIX excelle dans les tâches nécessitant une coordination étroite (garantie de monotonie $\partial Q_{\text{tot}}/\partial Q_i \geq 0$), tandis que QTRAN gère mieux les interactions non monotones via des transformations affines — mais aucun cadre ne propose de fusionner dynamiquement ces expertises en fonction du contexte topologique.

Il manque donc un cadre qui *fusionne* les expertises complémentaires de plusieurs politiques MARL dans une enveloppe suffisamment compacte ($< 2\,000$ paramètres) pour l’embarqué, tout en exploitant la structure de graphe du réseau via un encodeur de réseau de neurones de graphes (GNN).

1.3.2 Défi 2 : Empreinte carbone du cycle de vie des WSN

Le secteur des technologies de l’information et de la communication (TIC) contribue à 2–4% des émissions mondiales de gaz à effet de serre, une part comparable à l’industrie aéronautique, et l’Internet des objets (IoT) en est l’un des segments à plus forte croissance [22]. L’analyse du cycle de vie (ACV) conforme à ISO 14040 [12] révèle un paradoxe saisissant : un nœud capteur IoT typique incarne environ $10\,000\text{ gCO}_2\text{eq}$ lors de sa fabrication [23], tandis que son énergie opérationnelle totale sur toute sa durée de vie (~ 0.5 J) ne génère que $\sim 0.01\text{ gCO}_2\text{eq}$. Cela signifie que **le carbone incorporé domine d’environ six ordres de grandeur le carbone opérationnel** ($10\,000/0.01 = 10^6$) pour les dispositifs IoT à faible consommation.

Cette observation a des implications profondes pour la conception de protocoles de routage :

- **Paradoxe du routage écoénergétique** : réduire la consommation d’énergie opérationnelle d’un capteur de 50% ne réduit son empreinte carbone totale que de $\sim 0.005\text{ gCO}_2\text{eq}$ — un gain négligeable face aux $10\,000\text{ gCO}_2\text{eq}$ incorporés. Le véritable levier pour réduire l’empreinte carbone par paquet est de *maximiser le nombre de paquets utiles livrés avant la mort du réseau* pour amortir le carbone incorporé sur davantage de paquets.
- **Impact des catastrophes** : la destruction prématurée de nœuds par une catastrophe gaspille intégralement le carbone incorporé de chaque dispositif défaillant, rendant la

résilience aux catastrophes indissociable de la durabilité carbone.

- **Intensité carbone variable** : l'intensité carbone du réseau électrique varie considérablement (de ~ 50 à ~ 500 gCO₂/kWh selon le mix énergétique, l'heure et la saison), offrant une opportunité de modulation temporelle de la consommation.

Malgré ces constats, aucun protocole de routage existant ne prend en compte cette empreinte carbone *du cycle de vie* complet — incorporant le carbone de fabrication, d'opération et de fin de vie — dans ses décisions de routage. De plus, aucun travail ne module dynamiquement le ratio de réduction de données (par détection comprimée) en fonction de l'intensité carbone du réseau électrique en temps réel.

1.3.3 Défi 3 : Sécurité des politiques de routage apprises par intelligence artificielle

L'intégration croissante de l'intelligence artificielle dans la boucle de contrôle des réseaux de capteurs crée une nouvelle surface d'attaque. À mesure que les décisions de routage, de récupération et de gestion des ressources sont déléguées à des politiques apprises par apprentissage par renforcement (RL) et réseaux de neurones de graphes (GNN), trois vulnérabilités critiques émergent :

1. **Politiques voyous (*rogue policies*)** : un adversaire qui compromet le modèle déployé peut injecter une politique malveillante qui mal-route systématiquement les paquets, accélère l'épuisement des batteries de nœuds stratégiques ou exfiltre des données, tout en paraissant nominale aux vérifications de signature et aux métriques globales.
2. **Hallucinations de modèle** : hors de la distribution d'entraînement — situation fréquente après une catastrophe qui modifie radicalement la topologie — les réseaux de neurones peuvent émettre des actuations de haute confiance qui sont factuellement incorrectes. Sans mécanisme de détection, ces hallucinations sont indiscernables d'actuations légitimes.
3. **Granularité binaire des mécanismes existants** : les cadres d'apprentissage par renforcement sûr existants — CPO (Constrained Policy Optimization) [24] et le blindage réactif (*shielding*) [25] — ne fournissent que des décisions binaires (autoriser ou bloquer). Cette granularité est inadaptée aux WSN de surveillance des catastrophes, où le blocage systématique des actions dégrade la connectivité du réseau et peut compromettre la mission de surveillance.

Il n'existe dans la littérature aucun cadre de contrôle de décision conforme au paradigme *zéro-confiance* (*zero-trust*) — tel que formalisé par le NIST SP 800-207 [13] — qui vérifie

chaque actuation de politique en temps réel avec des *décisions graduées* (autoriser, réduire la portée, différer, escalader, bloquer) et des *garanties formelles* de sécurité.

1.4 Questions de recherche

Face aux trois défis identifiés, cette thèse s’articule autour d’une question de recherche principale et de trois questions spécifiques :

Question principale : *Comment concevoir une pile complète de protocoles de routage intelligent — écoénergétique, durable en carbone et sécurisée — pour les réseaux de capteurs de surveillance des catastrophes natifs en intelligence artificielle et intégrés aux technologies 6G ?*

Cette question se décline en trois questions spécifiques, chacune traitée par un article de recherche :

Q1 — Efficacité énergétique (Article 1) : *Est-il possible d’atteindre un routage multi-sauts quasi-optimal ($PDR \geq 98\%$) dans les WSN de surveillance des catastrophes en fusionnant des politiques MARL expertes complémentaires via un encodeur GNN, tout en respectant les contraintes mémoire ($< 1\,024\text{ MB}$) et de calcul ($< 2\,000$ paramètres entraînaables) des plateformes embarquées ?*

Q2 — Durabilité carbone (Article 2) : *Peut-on réduire significativement l’intensité carbone du cycle de vie (LCI) d’un WSN de surveillance des catastrophes en intégrant conjointement la réduction de données sensible au carbone, le routage avec garanties formelles de budget carbone, l’auto-guérison autonome après catastrophe et la comptabilité du cycle de vie, le tout sur une couche physique 6G ?*

Q3 — Sécurité zéro-confiance (Article 3) : *Peut-on garantir la détection des politiques de routage compromises ou produisant des sorties erronées (hallucinations) avec zéro faux positif tout en maintenant un score de récupération élevé, en couplant un encodeur GNN, un évaluateur de confiance-risque neuronal et un bouclier déterministe à décisions graduées, le tout dans le budget de latence de 10 ms du near-RT RIC O-RAN ?*

1.5 Objectifs de recherche

1.5.1 Objectif général

L’objectif général de cette thèse est de **concevoir, implémenter et évaluer une pile complète de protocoles de routage intelligent** — écoénergétique, durable en carbone

et sécurisée — **pour les réseaux de capteurs de surveillance des catastrophes intégrés aux technologies 6G**, en répondant aux trois questions de recherche formulées à la section 1.4.

1.5.2 Objectifs spécifiques

Cet objectif général se décline en trois objectifs spécifiques, chacun traité par un article de recherche :

1. **OS1 — Fusion légère de politiques MARL pour le routage écoénergétique (Article 1 — GAPP) :**

- Concevoir un encodeur GCN à 2 couches qui encode la topologie du WSN en un plongement compact ($d = 16$) exploitable pour la sélection de politique.
- Développer un contrôleur CAS (*Contextual Algorithm Selection*) qui sélectionne dynamiquement l'expert MARL optimal (QMIX ou QTRAN) en fonction du contexte topologique, avec $< 2\,000$ paramètres entraînaibles.
- Concevoir un réseau d'attention monotone Q·K pour la scalarisation des récompenses multi-objectifs, garantissant qu'une amélioration Pareto-dominante se traduit toujours par un signal scalaire supérieur.
- Atteindre un PDR $\geq 98\%$ avec une consommation d'énergie $2\text{--}3.5\times$ inférieure et une empreinte mémoire $< 1\,024$ MB.

2. **OS2 — Routage conscient du carbone du cycle de vie avec auto-guérison (Article 2 — CALASH) :**

- Définir et formaliser la métrique LCI (*Lifecycle Carbon Intensity*) conforme à ISO 14040 pour les WSN.
- Concevoir quatre piliers intégrés (CADR, CARE, SHDR, LSE) minimisant conjointement le LCI.
- Prouver des garanties de budget carbone via l'optimisation de Lyapunov (borne de Pareto CDL).
- Intégrer les technologies 6G (sub-THz, RIS, ISAC) dans la couche physique du protocole.
- Démontrer une amélioration $\geq 30\%$ du LCI par rapport aux protocoles de référence.

3. **OS3 — Contrôle de décision zéro-confiance pour les réseaux natifs en AI (Article 3 — CASTER-ZT) :**

- Concevoir un encodeur GraphSAGE couplé à un évaluateur neuronal double-hypothèse de confiance-risque et un mécanisme d’incertitude épistémique par MC-Dropout.
- Développer un bouclier déterministe à décisions graduées (5 niveaux) avec 14 paramètres scalaires non apprenables.
- Formuler et prouver dix propositions formelles (conservatisme monotone, exclusion d’actuation non autorisée, couverture conforme, etc.).
- Garantir une détection $\geq 70\%$ des politiques voyous avec un taux de faux positifs de zéro, tout en respectant le budget de latence de 10 ms du near-RT RIC O-RAN.

1.6 Plan de la thèse

Cette thèse par articles est organisée en huit chapitres. Le Chapitre 2 présente la revue de littérature couvrant le routage WSN, le MARL et les GNN, la durabilité carbone, la sécurité des systèmes autonomes et les technologies 6G, puis identifie trois lacunes majeures. Le Chapitre 3 explicite la démarche méthodologique, le cadre expérimental commun et les liens entre les trois articles. Les Chapitres 4, 5 et 6 présentent respectivement les articles GAPF (fusion légère de politiques MARL via GNN), CALASH (routage conscient du carbone du cycle de vie avec auto-guérison 6G) et CASTER-ZT (contrôle de décision zéro-confiance gradué). Le Chapitre 7 effectue une analyse transversale des résultats et discute les implications combinées. Enfin, le Chapitre 8 synthétise les contributions, reconnaît les limitations et identifie les directions futures.

CHAPITRE 2 REVUE DE LITTÉRATURE

Ce chapitre présente une synthèse critique et détaillée des travaux existants dans les domaines couverts par les trois articles de cette thèse. L’objectif est double : (1) situer nos contributions par rapport à l’état de l’art et (2) identifier les lacunes spécifiques qui justifient la nécessité de chacun des trois articles. La revue est organisée en sept axes thématiques : le routage écoénergétique dans les WSN (Section 2.1), l’apprentissage par renforcement et les réseaux de neurones de graphes (Section 2.2), l’intelligence embarquée et TinyML (Section 2.3), la durabilité carbone dans les TIC (Section 2.4), la sécurité et la confiance dans les systèmes autonomes (Section 2.5), les technologies habilitantes 6G (Section 2.6), et les paradigmes émergents (Section 2.7). Le chapitre se conclut par un tableau récapitulatif des lacunes (Section 2.8) et une synthèse (Section 2.9) qui établit explicitement le lien entre les lacunes identifiées et les contributions de cette thèse.

2.1 Routage écoénergétique dans les WSN

2.1.1 Protocoles de routage hiérarchique

Le routage hiérarchique, où les nœuds sont organisés en grappes (*clusters*) avec des chefs de grappe (CH) assurant l’agrégation et le relais des données, constitue le paradigme dominant dans les WSN. LEACH (Low-Energy Adaptive Clustering Hierarchy), proposé par Heinzelman et al. [6, 15], fut le premier protocole à introduire la rotation aléatoire des CH pour équilibrer la consommation d’énergie. Le protocole opère en tours : une phase de configuration élit les CH avec une probabilité p et une phase de transmission achemine les données des membres vers le CH, puis du CH vers la BS. Cependant, LEACH souffre de plusieurs limitations fondamentales :

- **Élection sans considération de l’énergie résiduelle** : la probabilité de devenir CH est uniforme, ce qui peut élire des nœuds à énergie critique ;
- **Communication directe CH→BS** : inadaptée aux grands réseaux (>100 m) car l’énergie de transmission croît en d^4 au-delà de la distance critique d_0 ;
- **Absence de mécanisme de récupération** : en cas de défaillance de CH due à une catastrophe, la grappe entière est déconnectée ;
- **Nombre de grappes non optimisé** : le nombre optimal dépend de la topologie et varie avec les défaillances de nœuds.

De nombreuses variantes ont été proposées pour remédier à ces lacunes : EE-LEACH [14] intègre l'énergie résiduelle dans l'élection des CH via une probabilité pondérée ; LEACH-C [15] utilise une optimisation centralisée (k-means) à la BS ; HEED [16] combine l'énergie résiduelle et le coût de communication intra-cluster dans un processus d'élection itératif ; EERP [17] optimise les chemins multi-sauts inter-CH via une métrique de coût combinant distance et énergie ; SEP [26] introduit l'hétérogénéité énergétique en différenciant les nœuds normaux et avancés avec des probabilités d'élection distinctes ; PEGASIS [27] construit une chaîne de collecte de données plutôt que des clusters, réduisant la redondance de communication. Malgré ces améliorations, **ces protocoles restent fondamentalement réactifs et ne s'adaptent pas aux conditions dynamiques imposées par les catastrophes**, où la topologie peut changer brutalement (30–50% de nœuds détruits simultanément).

Le Tableau 2.1 résume les caractéristiques principales de ces protocoles de routage hiérarchique classiques.

TABLEAU 2.1 Comparaison des protocoles de routage hiérarchique pour WSN. PDR : Packet Delivery Ratio. DV : durée de vie.

Protocole	Élection CH	Multi-sauts	Énergie résid.	Complexité	Post-catastrophe	Adapt. dynamique
LEACH [6]	Aléatoire	Non	Non	$O(n)$	Non	Non
EE-LEACH [14]	Pondérée	Non	Oui	$O(n)$	Non	Non
LEACH-C [15]	k-means (BS)	Non	Oui	$O(n \cdot k)$	Non	Non
HEED [16]	Itérative	Partiel	Oui	$O(n \log n)$	Non	Non
SEP [26]	Hétérogène	Non	Oui	$O(n)$	Non	Non
PEGASIS [27]	Chaîne	Oui	Partiel	$O(n^2)$	Non	Non
EERP [17]	Coût combiné	Oui	Oui	$O(n^2)$	Non	Non
GAPF (Art. 1)	MARL+GNN	Oui	Oui	$O(E \cdot d)$	Non	Oui

2.1.2 Modèle énergétique de premier ordre

Le modèle énergétique de Heinzelman et al. [6] constitue le standard de facto pour l'évaluation des protocoles de routage dans les WSN. Ce modèle de premier ordre définit l'énergie nécessaire à la transmission de ℓ bits sur une distance d :

$$E_{\text{Tx}}(\ell, d) = \ell \cdot E_{\text{elec}} + \ell \cdot \varepsilon(d) \cdot d^\alpha, \quad \varepsilon(d) = \begin{cases} \varepsilon_{\text{fs}} & \text{si } d \leq d_0 \text{ (espace libre)} \\ \varepsilon_{\text{mp}} & \text{si } d > d_0 \text{ (multi-chemins)} \end{cases} \quad (2.1)$$

où $E_{\text{elec}} = 50 \text{ nJ/bit}$, $\varepsilon_{\text{fs}} = 10 \text{ pJ/bit/m}^2$, $\varepsilon_{\text{mp}} = 0.0013 \text{ pJ/bit/m}^4$ et $\alpha \in \{2, 4\}$ est l'exposant de perte de chemin. L'énergie de réception est simplement $E_{\text{Rx}}(\ell) = \ell \cdot E_{\text{elec}}$. Malgré ses simplifications (absence de contention MAC, de consommation d'état inactif et d'évanouissement stochastique), ce modèle permet une comparaison équitable entre protocoles. Les trois

articles de cette thèse l'utilisent comme référence commune.

2.1.3 Approches métaheuristiques

Les métaheuristiques bio-inspirées ont été largement appliquées au problème de routage dans les WSN pour dépasser les limites des heuristiques déterministes.

Optimisation par colonie de fourmis (ACO). ACO [28] modélise les chemins de routage comme des traces de phéromones déposées par des agents-fourmis. La règle de mise à jour des phéromones sur le lien (i, j) à l'itération t est :

$$\tau_{ij}(t+1) = (1 - \rho) \tau_{ij}(t) + \sum_{k=1}^m \Delta \tau_{ij}^k(t), \quad (2.2)$$

où $\rho \in (0, 1)$ est le coefficient d'évaporation, m est le nombre de fourmis et $\Delta \tau_{ij}^k = Q/L_k$ si la fourmi k a emprunté le lien (i, j) (0 sinon). La probabilité de sélection du lien est :

$$p_{ij}^k = \frac{[\tau_{ij}]^\alpha \cdot [\eta_{ij}]^\beta}{\sum_{l \in \mathcal{N}_k} [\tau_{il}]^\alpha \cdot [\eta_{il}]^\beta}, \quad (2.3)$$

où $\eta_{ij} = 1/E_{\text{Tx}}(\ell, d_{ij})$ est l'heuristique énergétique locale. La complexité par itération est $O(n^2 \cdot m)$.

Optimisation par essaim de particules (PSO). PSO [19] maintient une population de P particules dont la vitesse et la position sont mises à jour selon :

$$\mathbf{v}_i^{t+1} = w \mathbf{v}_i^t + c_1 r_1 (\mathbf{p}_i^{\text{best}} - \mathbf{x}_i^t) + c_2 r_2 (\mathbf{g}^{\text{best}} - \mathbf{x}_i^t), \quad (2.4)$$

$$\mathbf{x}_i^{t+1} = \mathbf{x}_i^t + \mathbf{v}_i^{t+1}, \quad (2.5)$$

où w est le facteur d'inertie, c_1 et c_2 sont les coefficients cognitif et social, et $r_1, r_2 \sim \mathcal{U}(0, 1)$ sont des tirages uniformes indépendants. La variante quantique QPSOFL [29] combine un modèle de potentiel gaussien et une logique floue pour l'élection des CH.

Comportement de convergence et critères d'arrêt. Pour ACO et PSO, la convergence asymptotique est garantie sous hypothèses de stationnarité (environnement fixe, phéromones/vitesses bornées), mais n'est que *probabiliste* : avec probabilité 1, l'algorithme visite l'optimum global en un nombre fini d'itérations [30]. En pratique, trois critères d'arrêt sont utilisés : (i) nombre maximal d'itérations T_{max} fixé a priori ($T_{\text{max}} = 500$ dans nos simu-

lations) ; (ii) stagnation des phéromones/du meilleur fitness sur δ itérations consécutives ($\delta = 50$) ; (iii) seuil de qualité de solution $J^* \leq J_{\text{target}}$. Dans les WSN post-catastrophe où la topologie change à chaque ronde, ces critères sont difficilement satisfaits : la convergence doit être relancée à chaque changement, ce qui justifie le choix de l'apprentissage par renforcement dans cette thèse (politique mémorisée, aucune re-convergence requise).

Algorithmes génétiques et optimisation multi-objectif (NSGA-II). Les algorithmes génétiques opèrent par sélection, croisement et mutation sur une population de solutions encodées. Pour les problèmes multi-objectif (minimiser l'énergie *et* la latence), NSGA-II [31] construit explicitement le front de Pareto à chaque génération par tri de non-dominance, permettant de sélectionner le meilleur compromis. Cette propriété est directement pertinente pour contextualiser la scalarisation Pareto monotone proposée dans GAPF (Article 1).

Autres métaheuristiques récentes. ABC [18] encode les solutions comme des sources de nourriture évaluées par des abeilles ouvrières, spectatrices et éclaireuses. GWO [32] s'inspire de la hiérarchie sociale des loups gris (α , β , δ), et WOA [33] imite la stratégie de chasse en spirale des baleines à bosse.

Le Tableau 2.2 compare les principales métaheuristiques appliquées au routage dans les WSN.

TABLEAU 2.2 Comparaison des approches métaheuristiques pour le routage dans les WSN.

Métaheuristique	Complexité/itér.	Convergence	Multi-objectif	Dynamique	Communication add.
ACO [28]	$O(n^2 \cdot m)$	Locale	Pondération	Non	Phéromones
ABC [18]	$O(n^2 \cdot \text{SN})$	Globale	Partiel	Non	Fitness
ABC-ACO hybride	$O(n^2 \cdot (m + \text{SN}))$	Globale + locale	Pondération	Non	Les deux
PSO [19]	$O(n \cdot P)$	Locale	Pondération	Non	Gbest
QPSOFL [29]	$O(n \cdot P)$	Quantique	Logique floue	Non	Gbest + FL
GA	$O(n^2 \cdot G)$	Stochastique	Pareto (NSGA-II)	Non	Fitness
GWO [32]	$O(n \cdot P)$	Hiérarchique	Partiel	Non	Alpha/Beta

(n : nœuds, m : fourmis, SN : sources de nourriture, P : taille de population, G : générations.)

Cependant, ces méthodes présentent des limitations importantes pour les scénarios de surveillance des catastrophes :

- **Temps de convergence élevé** : typiquement $O(n^2)$ à $O(n^3)$ par itération, incompatible avec les contraintes de temps réel ;
- **Pas de garantie d'optimalité** : les métaheuristiques ne convergent que vers des optima locaux ;
- **Inadaptation aux environnements non stationnaires** : la convergence doit être

relancée à chaque changement de topologie, ce qui est problématique lorsque des catastrophes modifient continuellement le réseau ;

- **Surcoût de communication** : les messages de contrôle (phéromones, évaluation de fitness) consomment de l’énergie supplémentaire.

2.1.4 Détection comprimée, récupération d’énergie et résilience

La détection comprimée (CS) [34] réduit le volume de données transmises en exploitant la parcimonie des signaux capteurs. Trois schémas d’adaptation du ratio CS existent : ratio fixe, adaptative à la qualité et adaptative à l’énergie. **Toutefois, aucun ne module le ratio en fonction de l’intensité carbone du réseau électrique** — lacune comblée par le pilier CADR de CALASH (Article 2). La récupération d’énergie (EH) transforme le modèle énergétique (budget stochastique avec recharge) mais les composants EH ajoutent un carbone incorporé de 2 000–5 000 gCO₂eq par module. Les trois articles de cette thèse supposent un modèle sans récupération (batterie 0.5 J) conformément à Heinzelman [6]. Pour la résilience, trois approches coexistent : redondance statique (k -couverture), mobilité (drones/robots, coût énergétique prohibitif), et reconfiguration logique via le paradigme MAPE-K adopté par CALASH. Les protocoles de consensus byzantins (PBFT [35]) sont trop coûteux en communication ($O(n^2)$) ; CASTER-ZT vérifie chaque actuation individuellement.

2.1.5 Synthèse taxonomique du routage dans les WSN

Le Tableau 2.3 présente une taxonomie des approches de routage pour les WSN selon cinq dimensions : le paradigme d’optimisation, le type d’adaptation, la conscience topologique, la tolérance aux pannes et la compatibilité embarquée.

TABLEAU 2.3 Taxonomie des approches de routage pour les WSN selon cinq dimensions.

Famille	Optimisation	Adaptation	Topo. consciente	Tolérance pannes	Embarqué
Heuristiques (LEACH, HEED)	Locale/probabiliste	Statique	Non	Rotation CH	✓
Métaheuristiques (ACO, PSO)	Globale/stochastique	Réinitialisation	Non	Non	○
DRL mono-agent (DQN)	Gradient de politique	Continue (locale)	Non	Non	○
MARL-CTDE (QMIX, QTRAN)	Décomposition de valeur	Continue (globale)	Non	Non	✗
MARL+GNN (GAPF)	Méta-sélection	Continue + topo.	✓	Via fusion	✓
Lyapunov (CALASH)	Drift-plus-penalty	Carbone + topo.	Implicite	MAPE-K	✓
Consensus byzantin (PBFT)	Vote majoritaire	Réactive	Non	Forte	✗

Cette taxonomie met en évidence deux lacunes structurelles de l’état de l’art : (1) aucune approche existante ne combine conscience topologique (via GNN) et tolérance aux pannes, et (2) aucune n’intègre de mécanisme d’adaptation carbone-conscient. La pile GAPF+CALASH+CASTER-ZT est la première à couvrir ces cinq dimensions simultanément.

Les déploiements réels de WSN pour la surveillance des catastrophes [8,9] révèlent un taux de défaillance de 32% sur 6 mois et une perte de connectivité de 40–60% après destruction de 30% des nœuds. Le Cadre de Sendai [4] et le GIEC [3] confirment l’urgence de systèmes d’alerte précoce résilients. Ces constats motivent directement la conscience topologique (GNN), l’auto-guérison (SHDR) et la légèreté computationnelle (<2 000 paramètres) de nos contributions.

2.2 Apprentissage par renforcement et réseaux de neurones de graphes pour les réseaux

2.2.1 Apprentissage par renforcement multi-agent (MARL)

L’apprentissage par renforcement multi-agent modélise les interactions entre agents coopératifs ou compétitifs dans un processus de décision de Markov décentralisé partiellement observable (Dec-POMDP). Le paradigme CTDE (*Centralized Training with Decentralized Execution*) résout le dilemme de la non-stationnarité en entraînant les agents avec accès à l’état global, puis en les déployant avec uniquement leurs observations locales.

QMIX [20] décompose la fonction de valeur jointe Q_{tot} comme un mélange monotone des Q -valeurs individuelles Q_i via un réseau d’hyperfusion (*hypernetwork*). Le réseau de mélange est contraint à avoir des poids non-négatifs, garantissant la consistance IGM (*Individual-Global-Max*) :

$$\frac{\partial Q_{\text{tot}}}{\partial Q_i} \geq 0, \quad \forall i \quad (2.6)$$

Cette propriété assure que l’action jointe optimale peut être obtenue par maximisation décentralisée : chaque agent choisit indépendamment l’action maximisant son Q_i , et l’action jointe résultante maximise Q_{tot} . Cependant, la contrainte de monotonie limite la classe de fonctions de valeur représentables — QMIX ne peut pas modéliser les interactions où améliorer l’action d’un agent dégrade la valeur globale.

QTRAN [21] relâche cette contrainte de monotonie en apprenant des transformations affines entre les Q -valeurs individuelles et jointes, permettant une classe plus riche de fonctions de valeur factorisées. QTRAN introduit deux conditions de factorisation — la condition d’optimalité jointe et la condition de non-optimalité — qui sont nécessaires et suffisantes pour la consistance IGM sans contrainte de monotonie. En pratique, QTRAN gère mieux les interactions complexes (coordination dans des environnements avec obstacles) mais est plus difficile à entraîner et présente une variance plus élevée.

Complémentarité QMIX/QTRAN. Ces deux algorithmes présentent des forces complé-

mentaires : QMIX excelle dans les tâches nécessitant une coordination étroite entre agents proches (grâce à la stabilité de sa contrainte monotone), tandis que QTRAN gère mieux les interactions non monotones dans les topologies complexes. **Aucun travail antérieur ne propose de *fusionner dynamiquement* ces expertises complémentaires dans un cadre unifié qui sélectionne le meilleur expert en fonction du contexte topologique.**

Le formalisme sous-jacent est le Dec-POMDP [36], dont la résolution optimale est NEXP-complète [37], justifiant le recours au paradigme CTDE. Plusieurs extensions de QMIX ont été proposées : WQMIX [38] (pondération des échantillons), QPLEX [39] (dualité duplexe), MAVEN [40] (exploration par variable latente) et FOP [41] (entropie maximale). Toutes augmentent la complexité du réseau de mélange ($\sim 40\text{--}50\text{K}$ paramètres/agent). GAPF adopte une stratégie orthogonale : *sélectionner dynamiquement* l’expert le mieux adapté, avec un budget total de 1 473 paramètres. Pour la gestion multi-objectifs, les trois articles adoptent des stratégies complémentaires : scalarisation (GAPF), contrainte de Lyapunov (CALASH) et vérification formelle (CASTER-ZT).

2.2.2 Réseaux de neurones de graphes (GNN)

Les GNN généralisent les réseaux convolutionnels aux données structurées en graphes, permettant de capturer les dépendances topologiques entre nœuds. Deux architectures sont particulièrement pertinentes pour les WSN :

Réseau convolutionnel de graphes (GCN). Le GCN de Kipf et Welling [42] propage les caractéristiques des nœuds selon une convolution spectrale approchée :

$$H^{(l+1)} = \sigma\left(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H^{(l)} W^{(l)}\right) \quad (2.7)$$

où $\tilde{A} = A + I_N$ est la matrice d’adjacence augmentée (avec auto-boucles), $\tilde{D}$ la matrice de degrés correspondante, $H^{(l)}$ les caractéristiques à la couche l , $W^{(l)}$ les poids apprenables et σ une non-linéarité (typiquement ReLU). Un GCN à K couches agrège l’information du voisinage à K sauts, capturant la structure locale et semi-globale du graphe. La complexité est $O(|E| \cdot d)$ par couche, linéaire en le nombre d’arêtes.

GraphSAGE. Hamilton et al. [43] introduisent l’échantillonnage de voisinage et l’agrégation inductive (*SAmple and aggreGatE*) :

$$h_v^{(k)} = \sigma\left(W^{(k)} \cdot \text{CONCAT}\left(h_v^{(k-1)}, \text{AGG}\left(\{h_u^{(k-1)} : u \in \mathcal{N}(v)\}\right)\right)\right) \quad (2.8)$$

où AGG peut être MEAN, LSTM ou un pooling max. GraphSAGE permet la **généralisation à des nœuds non vus lors de l’entraînement** — une propriété cruciale pour les WSN dynamiques où la topologie change après catastrophe (nœuds détruits, nouveaux CH élus). Le cadre MPNN (*Message Passing Neural Network*) de Gilmer et al. [44] unifie ces architectures ; Xu et al. [45] montrent que l’expressivité des GNN est bornée par le test de Weisfeiler-Leman. Le choix du GCN (GAPF) et du GraphSAGE (CASTER-ZT) représente un compromis entre expressivité et coût computationnel linéaire en $|E|$, compatible avec les contraintes embarquées.

Application des GNN au routage. L’application des GNN au routage dans les WSN est relativement récente. Liu et al. [46] proposent le paradigme GNNComm-MARL, un tutoriel systématique qui structure la communication inter-agents via des réseaux d’attention de graphes pour atténuer l’observabilité partielle et la non-stationnarité dans les systèmes sans fil. Bhavanasi et al. [47] formulent le routage résilient comme un problème MADRL et utilisent un GCN pour encoder conjointement la topologie et le trafic, démontrant des améliorations de débit et de délai sous conditions dynamiques. Cependant, **aucun de ces travaux ne combine un encodeur GNN avec une fusion de politiques MARL, et aucun ne couple un GNN avec un mécanisme de confiance-risque pour la sécurité des décisions de routage.**

2.2.3 Apprentissage par renforcement profond pour le routage

Le Q-Routing de Boyan et Littman [48] fut le premier à appliquer le Q-learning tabulaire au routage de paquets dans un réseau, chaque nœud maintenant une table Q sur ses voisins. Les approches modernes utilisent le Deep Q-Network (DQN) [49] et ses variantes pour gérer les espaces d’état continus :

- **Double DQN** découple la sélection d’action et l’évaluation de valeur pour réduire la surestimation des Q-valeurs ;
- **Dueling DQN** sépare la fonction de valeur d’état et l’avantage d’action pour une meilleure généralisation ;
- **RIS-DRL** combine les surfaces intelligentes reconfigurables avec l’apprentissage par renforcement profond pour optimiser conjointement le beamforming et le routage.

Cependant, **ces approches ne considèrent ni l’empreinte carbone du cycle de vie ni la résilience aux catastrophes** dans leurs fonctions de récompense ou leurs contraintes d’optimisation. De plus, elles requièrent typiquement des dizaines de milliers de paramètres, les rendant difficilement déployables sur des microcontrôleurs de classe capteur.

Méta-apprentissage et fusion de politiques. Des travaux récents explorent la sélection dynamique d’algorithmes via l’apprentissage par renforcement : Guo et al. [50] proposent RL-DAS, un cadre DRL qui apprend à sélectionner parmi un portefeuille d’optimiseurs en fonction de caractéristiques contextuelles de paysage, agissant comme une méta-politique sur des algorithmes de base. Le paradigme Mixture-of-Experts (MoE) a également été adapté à l’apprentissage par renforcement, où des modèles de décision routent les tâches vers des experts spécialisés. Yang et Thomason [51] introduisent le cadre MPDF, où chaque agent dans un système multi-agent apprend une méta-politique décentralisée sur des actions de collaboration de haut niveau. **Ces travaux valident le concept de fusion de politiques mais n’adressent pas le routage dans les WSN ni n’exploitent la topologie du réseau via GNN** — la lacune exacte que GAPF (Article 1) comble.

2.2.4 Synthèse comparative des approches MARL et DRL

Le Tableau 2.4 compare les principales méthodes d’apprentissage par renforcement (multi-agent et profond) utilisées dans le contexte du routage réseau, selon six critères pertinents.

TABLEAU 2.4 Comparaison des méthodes MARL et DRL pour le routage dans les réseaux. CTDE : entraînement centralisé, exécution décentralisée. IGM : cohérence individuelle-globale.

Méthode	Paradigme	Factorisation Q	GNN intégré	Nb. paramètres	Fusion politiques	Récompense carbone
Q-Routing [48]	Tabulaire	Non	Non	$O(n^2)$	Non	Non
DQN [49]	Agent unique	Non	Non	~50 K	Non	Non
Double DQN	Agent unique	Non	Non	~50 K	Non	Non
Dueling DQN	Agent unique	Avantage	Non	~60 K	Non	Non
IQL [52]	Décentralisé	Indépendant	Non	$n \times 20$ K	Non	Non
VDN [53]	CTDE	Additive	Non	$n \times 20$ K	Non	Non
QMIX [20]	CTDE	Monotone (IGM)	Non	~39 K/agent	Non	Non
QTRAN [21]	CTDE	Affine (IGM)	Non	~39 K/agent	Non	Non
MAPPO [54]	CTDE	Acteur-critique	Non	~80 K/agent	Non	Non
GAPF (Art. 1)	Méta-CTDE	Att. monotone	GCN	1 473	Oui	Non
CALASH (Art. 2)	Lyapunov	—	Implicite	~5 K	Non	Oui

2.3 Intelligence embarquée et TinyML pour les réseaux de capteurs

Le déploiement de modèles d’apprentissage automatique sur les nœuds capteurs eux-mêmes — plutôt que sur des serveurs distants — est un enjeu central pour les WSN autonomes. Cette section examine les avancées récentes en TinyML et en intelligence de bord (*edge AI*) qui rendent ce déploiement réaliste.

2.3.1 Le paradigme TinyML

Le terme **TinyML** désigne l'exécution de modèles d'apprentissage automatique sur des microcontrôleurs (MCU) de classe ARM Cortex-M0 à M4, avec des budgets mémoire de 16 KB à 256 KB de RAM et des fréquences de 48–168 MHz [55]. Ce paradigme impose des contraintes radicalement différentes de l'apprentissage classique :

- **Mémoire** : le modèle complet (poids + activations + code d'inférence) doit tenir dans la mémoire Flash (≤ 1 MB) et la RAM (≤ 256 KB) du MCU.
- **Calcul** : l'inférence doit s'exécuter en temps réel (typiquement < 100 ms) sans unité de calcul en virgule flottante (FPU) sur les Cortex-M0/M3, nécessitant une arithmétique en point fixe.
- **Énergie** : chaque inférence consomme de l'énergie prélevée sur la batterie limitée du capteur (~ 0.5 J au total).

TensorFlow Lite Micro (TFLM) [56] est le cadre de déploiement le plus utilisé : il fournit un interpréteur C++ minimal (~ 20 KB de code) capable d'exécuter des modèles au format FlatBuffer sur des MCU sans système d'exploitation. **MCUNet** [57] va plus loin en co-optimisant l'architecture du réseau de neurones et le calendrier d'inférence (*inference schedule*) pour maximiser la précision sous une contrainte de mémoire donnée. Sur un MCU STM32F746 (320 KB de RAM), MCUNet atteint 70.7% de précision sur ImageNet — un résultat impensable quelques années auparavant.

Les principales techniques de compression — quantification (INT8, réduction $4\times$ [58]), élagage structuré, distillation de connaissances et recherche d'architecture neuronale consciente du matériel [57, 59] — permettent de réduire l'empreinte mémoire et computationnelle des modèles pour le déploiement sur MCU.

2.3.2 Pertinence pour cette thèse

GAPF (Article 1), avec ses 1 473 paramètres (~ 6 KB en FP32, ~ 1.5 KB en INT8), est nativement compatible avec les MCU de classe Cortex-M0. CASTER-ZT (Article 3), avec ~ 20 KB paramètres (~ 80 KB en FP32), nécessiterait un accélérateur de bord (Google Coral TPU, NVIDIA Jetson) ou une quantification INT8 pour un déploiement sur MCU. Le Tableau 2.5 évalue la compatibilité de chaque composant de la pile protocolaire avec les plateformes embarquées.

Les développements récents en GNN pour l'IoT [60] confirment que le déploiement de GNN compacts sur des dispositifs IoT contraints est un domaine de recherche actif, validant l'ap-

TABLEAU 2.5 Compatibilité des composants de la pile protocolaire avec les plateformes embarquées. FP32 : virgule flottante 32 bits. INT8 : entier 8 bits quantifié.

Composant	Paramètres	Mémoire FP32	Mémoire INT8	Cortex-M0 (16 KB)	Cortex-M4 (256 KB)
GAPF (GCN+CAS)	1 473	5.8 KB	1.5 KB	✓	✓
Agent GRU (inférence)	~29K	113 KB	29 KB	✗	✓
CALASH (DQN)	~5K	20 KB	5 KB	✗	✓
CASTER-ZT (évaluateur)	~20K	78 KB	20 KB	✗	✓
Agent QMIX/QTRAN (entr.)	~39K	152 KB	—	✗	✗

proche adoptée dans cette thèse.

2.4 Durabilité carbone dans les TIC

2.4.1 Analyse du cycle de vie (ACV)

L’analyse du cycle de vie, normalisée par ISO 14040/14044 [12], évalue les impacts environnementaux d’un produit ou service “du berceau à la tombe” à travers quatre phases : (1) définition des objectifs et du périmètre, (2) inventaire du cycle de vie (LCI — *Life Cycle Inventory*), (3) évaluation de l’impact du cycle de vie et (4) interprétation.

Pour les WSN, l’unité fonctionnelle naturelle est le “paquet utile livré à la BS”. CALASH adopte le périmètre “du berceau à la tombe” avec correction pour le recyclage partiel. L’inventaire du cycle de vie (LCI) révèle que la fabrication domine ($\sim 95\%$ du carbone total), impliquant que le levier principal n’est pas la réduction de la consommation mais la maximisation de l’utilité par unité de carbone incorporé.

Appliquée aux dispositifs IoT, l’ACV révèle une répartition très asymétrique du carbone :

- **Carbone incorporé (*embodied*)** : fabrication des semi-conducteurs, assemblage, transport. Pirson et Bol [23] estiment $\sim 10\,000\text{ gCO}_2\text{eq}$ pour un nœud capteur typique, dominé par la fabrication du microcontrôleur et de l’émetteur-récepteur radio.
- **Carbone opérationnel** : consommation d’énergie pendant le fonctionnement. Pour un capteur de 0.5 J de budget énergétique total, le carbone opérationnel est de $\sim 0.01\text{ gCO}_2\text{eq}$ — environ six ordres de grandeur inférieur au carbone incorporé ($10\,000/0.01 = 10^6$).
- **Carbone de fin de vie** : traitement des déchets électroniques, recyclage partiel. Estimé à $\sim 500\text{ gCO}_2\text{eq}$ par nœud, ajusté au taux de recyclage effectif.

Implication clé : la métrique habituelle d’efficacité énergétique (Joules par paquet) est une approximation grossière de l’impact environnemental réel. Une métrique *par paquet utile livré* intégrant les trois phases du cycle de vie serait bien plus pertinente.

2.4.2 Optimisation de Lyapunov pour les systèmes en réseau

L’optimisation de Lyapunov (*Lyapunov drift-plus-penalty*) [61] est un cadre mathématique puissant pour la prise de décision en ligne dans les systèmes stochastiques en réseau, sans connaissance préalable des statistiques du système. Le principe fondamental consiste à maintenir des files d’attente virtuelles dont la stabilité traduit le respect des contraintes à long terme.

Formulation. Soit $\mathbf{Q}(t) = (Q_1(t), \dots, Q_K(t))$ un vecteur de files d’attente virtuelles associées à K contraintes de la forme $\mathbb{E}[g_k(\mathbf{x}(t))] \leq 0$. La dynamique de chaque file est :

$$Q_k(t+1) = \max\{Q_k(t) + g_k(\mathbf{x}(t)), 0\} \quad (2.9)$$

La fonction de Lyapunov quadratique $L(\mathbf{Q}(t)) = \frac{1}{2} \sum_k Q_k(t)^2$ mesure le “poids” des files. Le drift conditionnel en un pas $\Delta(\mathbf{Q}(t)) = \mathbb{E}[L(\mathbf{Q}(t+1)) - L(\mathbf{Q}(t)) \mid \mathbf{Q}(t)]$ quantifie la tendance des files à croître ou décroître. L’algorithme drift-plus-penalty minimise à chaque instant :

$$\min_{\mathbf{x}(t)} \{\Delta(\mathbf{Q}(t)) + V \cdot f_0(\mathbf{x}(t))\} \quad (2.10)$$

où f_0 est la fonction objectif et $V > 0$ contrôle le compromis optimalité-stabilité. Neely [61] prouve que cet algorithme est $O(1/V)$ -optimal avec une taille de file moyenne $O(V)$, un compromis fondamental connu sous le nom de *compromis* $[O(1/V), O(V)]$.

Avantages pour les WSN. Ce cadre est particulièrement adapté aux WSN pour trois raisons : (i) il ne nécessite pas de modèle statistique du canal ou du trafic (opération en ligne), (ii) il fournit des garanties de performance déterministes via la borne sur le drift, et (iii) il permet d’intégrer naturellement des contraintes hétérogènes (énergie, carbone, qualité de service) via des files virtuelles distinctes. Le pilier CDR de CALASH (Article 2) exploite ce cadre en définissant une file carbone virtuelle (CARE) dont la stabilité garantit le respect du budget carbone à long terme.

Limitations. Le paramètre V doit être choisi a priori et fixe un compromis global. Des extensions récentes (*adaptive V*) permettent de faire varier V au cours du temps en fonction de l’état des files, offrant une meilleure adaptabilité. De plus, la borne $O(1/V)$ est asymptotique ; pour des horizons courts (quelques centaines de tours dans les WSN post-catastrophe), les performances réelles peuvent s’éloigner de cette borne théorique.

2.4.3 Intensité carbone des réseaux électriques

L'intensité carbone du réseau électrique (CI, en gCO_2/kWh) varie considérablement selon : le mix énergétique national (France $\sim 60 \text{ gCO}_2/\text{kWh}$ grâce au nucléaire vs. Pologne $\sim 700 \text{ gCO}_2/\text{kWh}$ dominée par le charbon), l'heure de la journée (pointe vs. creux), la saison (chauffage hivernal vs. solaire estival) et les conditions météorologiques (vent, ensoleillement). Les traces historiques de CI, disponibles en temps réel via des API comme UK Carbon Intensity [62] et Electricity Maps, permettent de moduler la consommation énergétique des systèmes en fonction de la “propreté” de l'électricité disponible.

Cette variabilité temporelle représente une **opportunité sous-exploitée** pour les WSN : moduler le ratio de détection comprimée en fonction de l'intensité carbone permet de réduire les transmissions lorsque l'électricité est “sale” et de les augmenter lorsqu'elle est “propre”, sans impact sur la mission globale de surveillance.

2.4.4 Travaux récents sur l'empreinte carbone des systèmes numériques (2024–2026)

Plusieurs travaux récents enrichissent la compréhension de l'empreinte carbone du cycle de vie. Bashir et al. [63] remettent en question les métriques courantes de carbone et montrent que les décisions d'ordonnancement “conscientes du carbone” qui ignorent le carbone incorporé peuvent paradoxalement **augmenter** les émissions totales du cycle de vie — un résultat qui renforce la pertinence de la métrique LCI proposée par CALASH. Mersy et al. [64] étendent l'ACV aux données elles-mêmes, de l'acquisition (incluant la détection) au stockage et au traitement, couvrant les coûts de collecte de données qui dépendent de l'intensité carbone — une perspective directement pertinente pour les WSN. L'AIOTI [65] publie une méthodologie de mesure de l'empreinte carbone pour l'IoT et l'edge computing, intégrant explicitement le carbone incorporé, opérationnel et de fin de vie. **Ces travaux confirment la tendance vers une comptabilité carbone holistique mais aucun ne l'intègre dans les décisions de routage d'un protocole WSN.**

2.4.5 Réseaux verts et communication écoénergétique

La communauté des communications vertes (*green communications*) s'est principalement concentrée sur la réduction de la consommation énergétique opérationnelle : ordonnancement sensible à l'énergie (*energy-aware scheduling*), mise en veille dynamique des stations de base (*base station sleep mode*), et optimisation de la puissance de transmission [22]. Des travaux récents intègrent les énergies renouvelables (*energy harvesting*) pour alimenter les

réseaux de manière durable.

Cependant, **ces travaux ignorent systématiquement le carbone incorporé et de fin de vie**, qui — comme l’ACV le démontre — dominent l’empreinte carbone des dispositifs IoT à faible consommation. À notre connaissance, **CALASH (Article 2) est le premier protocole de routage pour WSN à intégrer les trois phases du cycle de vie dans les décisions de routage conformément à ISO 14040.**

2.4.6 Synthèse comparative des approches de durabilité dans les réseaux

Le Tableau 2.6 compare les approches existantes de durabilité carbone dans les TIC selon les critères de couverture du cycle de vie, de modulation dynamique et de conformité aux normes.

TABLEAU 2.6 Comparaison des approches de durabilité carbone dans les TIC. ACV : analyse du cycle de vie. CS : détection comprimée. CI : intensité carbone.

Approche	C. incorporé	C. opérationnel	C. fin de vie	CI dynamique	CS modulée	ISO 14040
Ordonnancement éco. [22]	✗	✓	✗	✗	✗	✗
Mise en veille BS	✗	✓	✗	✗	✗	✗
Energy harvesting	✗	✓	✗	◦	✗	✗
ACV IoT [23]	✓	✓	✓	✗	✗	✓
Carbon-aware computing	✗	✓	✗	✓	✗	✗
CS classique [34]	✗	◦	✗	✗	Fixe	✗
CS adaptative	✗	◦	✗	✗	Qualité	✗
CALASH (Art. 2)	✓	✓	✓	✓	CI-modulée	✓

2.5 Sécurité et confiance dans les systèmes autonomes

2.5.1 Apprentissage par renforcement sûr (*Safe RL*)

L’apprentissage par renforcement sûr (*Safe RL*) vise à respecter des contraintes de sécurité pendant l’entraînement et le déploiement. Le problème est typiquement formulé comme un CMDP (*Constrained Markov Decision Process*) :

$$\max_{\pi} \mathbb{E} \left[\sum_t \gamma^t r_t \right] \quad \text{sous} \quad \mathbb{E} \left[\sum_t \gamma^t c_t^{(i)} \right] \leq d_i, \quad \forall i \quad (2.11)$$

où $c_t^{(i)}$ est le coût de la contrainte i et d_i la borne supérieure tolérable.

CPO (Constrained Policy Optimization) [24] résout ce problème en linéarisant la fonction objectif et les contraintes dans un voisinage de confiance de la politique courante, puis en projetant la mise à jour sur l’ensemble réalisable. CPO fournit des **garanties en espérance**

mais **ne peut pas exclure catégoriquement les actions dangereuses** dans des trajectoires individuelles — une limitation critique pour les WSN de surveillance des catastrophes où une seule actuation malveillante peut avoir des conséquences irréversibles.

Shielding (blindage). L’approche de blindage [25] synthétise un bouclier réactif à partir d’une spécification de sécurité formelle (typiquement en logique temporelle linéaire, LTL) qui filtre les actions non sûres avant leur exécution. Le bouclier est un automate déterministe qui observe l’état courant et l’action proposée, puis autorise ou bloque l’action. Les boucliers existants sont **binaires** (autoriser/bloquer), ce qui est inadapté aux WSN de surveillance des catastrophes : le blocage systématique des actions dégrade progressivement la connectivité du réseau et peut compromettre la mission de surveillance.

Lacune identifiée : il n’existe aucun mécanisme de blindage à **décisions graduées** qui offre un spectre de réponses entre l’autorisation complète et le blocage total, permettant une dégradation gracieuse (*graceful degradation*) plutôt qu’un arrêt binaire.

Avancées récentes en blindage (2024–2025). Corsi et al. [66] proposent un blindage guidé par la vérification formelle qui partitionne l’espace d’entrée en régions sûres et potentiellement dangereuses, activant le bouclier uniquement dans les régions risquées — un mécanisme gradué basé sur les régions plutôt qu’un filtre binaire systématique. Le blindage probabiliste [67] étend cette approche en augmentant l’état et en restreignant les actions disponibles pour satisfaire des contraintes de sécurité avec haute probabilité. Une revue exhaustive de Könighofer et al. [68] dans *Communications of the ACM* synthétise les choix de conception des boucliers (agressivité, séparation sécurité/performance, extension aux cas probabilistes et multi-agents). Cependant, **à notre connaissance, aucun de ces travaux ne propose un bouclier à cinq niveaux de décision graduée avec quantification d’incertitude épistémique** dans le contexte des réseaux autonomes.

2.5.2 Vérification formelle des systèmes autonomes

La vérification formelle consiste à prouver mathématiquement qu’un système satisfait une spécification de sécurité, par opposition aux tests empiriques qui ne peuvent couvrir qu’un sous-ensemble des comportements possibles. Pour les systèmes autonomes basés sur l’IA, deux approches de vérification dominent :

Vérification de réseaux de neurones. Les méthodes de vérification exacte (SMT solvers comme Marabou [69], programmation linéaire mixte) peuvent prouver des propriétés de sécurité pour des réseaux de neurones de petite taille ($< 10\,000$ neurones). Pour un réseau $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ et une propriété ϕ (par exemple, “pour toute entrée dans une région $\mathcal{X}$, la sortie

satisfait une contrainte $\mathcal{Y}$ ”), le problème de vérification $\forall x \in \mathcal{X} : f(x) \in \mathcal{Y}$ est NP-complet pour les réseaux ReLU. En pratique, les solveurs modernes vérifient des réseaux de $\sim 1\,000$ neurones en minutes, mais le temps de vérification croît exponentiellement avec la profondeur et la largeur.

Vérification par construction. Plutôt que de vérifier un réseau de neurones existant, une approche alternative consiste à *concevoir* le système de sorte que certaines propriétés soient garanties par construction. Le bouclier CASTER-ZT (Article 3) adopte cette approche : les 14 paramètres du bouclier et les 5 niveaux de décision sont conçus de sorte que les 10 propositions de sécurité soient satisfaites par construction logique, indépendamment du comportement des composants neuronaux (GraphSAGE, évaluateur). Cette séparation entre composants vérifiés (bouclier) et composants appris (GNN) est un exemple du paradigme *simplex architecture* utilisé en avionique pour garantir la sécurité des systèmes critiques.

Synthèse réactive. La synthèse réactive [25] construit automatiquement un bouclier à partir d’une spécification en logique temporelle linéaire (LTL) : étant donné une formule φ exprimant les propriétés de sécurité souhaitées, le synthétiseur génère un automate déterministe $\mathcal{S}$ tel que pour toute séquence d’actions proposée, $\mathcal{S}$ ne laisse passer que les actions satisfaisant φ . Les boucliers existants synthétisés par cette méthode sont binaires (autoriser/bloquer), et l’extension à des décisions graduées nécessite une spécification LTL enrichie avec des préférences quantitatives (*quantitative LTL*).

Pertinence pour CASTER-ZT. Les 10 propositions formelles de CASTER-ZT (Article 3) sont plus faibles que les propriétés vérifiables par un solver SMT (elles ne couvrent pas l’ensemble des comportements possibles du réseau de neurones) mais plus fortes que les garanties en espérance de CPO (elles s’appliquent à chaque décision individuelle). Ce positionnement intermédiaire — *vérification partielle par construction* — est pragmatique : il offre des garanties de sécurité significatives tout en restant compatible avec les contraintes de latence et de mémoire des systèmes embarqués.

2.5.3 Attaques adversariales sur les politiques d’apprentissage par renforcement

L’intégration de politiques RL dans les boucles de contrôle réseau crée des surfaces d’attaque spécifiques qui vont au-delà des menaces classiques de cybersécurité. Huang et al. [70] ont été les premiers à démontrer que des perturbations imperceptibles appliquées aux observations d’un agent DRL (attaques par empoisonnement d’observations) peuvent dégrader ses performances de manière catastrophique, même lorsque les perturbations sont bornées par une norme $\ell_\infty < 0.01$. Gleave et al. [71] ont étendu cette menace au cadre multi-agent en montrant qu’un adversaire peut entraîner une *politique adversariale* qui exploite les faiblesses de

la politique victime sans modifier directement ses observations, mais simplement en adoptant un comportement stratégiquement trompeur dans l’environnement partagé.

Dans le contexte multi-agent, les **attaques par porte dérobée** (*backdoor attacks*) [72] représentent une menace particulièrement insidieuse : l’adversaire injecte un déclencheur (*trigger*) dans le modèle pendant l’entraînement, de sorte que la politique se comporte normalement en conditions nominales mais active un comportement malveillant lorsque le déclencheur est présent dans l’observation. Pour les WSN, un adversaire compromettant la phase d’entraînement pourrait injecter une porte dérobée qui active le mal-routage uniquement lorsqu’un motif spécifique de données capteurs est détecté — rendant l’attaque indétectable par les tests de performance standard.

Sur le plan défensif, le cadre des **MDP robustes** (*robust MDPs*) [73] modélise l’incertitude sur la dynamique de transition comme un ensemble d’ambiguïté : l’agent optimise le pire cas sur un ensemble $\mathcal{P}$ de modèles de transition plausibles, garantissant des performances minimales même sous perturbation. Xu et Mannor [74] étendent cette approche aux MDP distributionnellement robustes, où l’ensemble d’ambiguïté est défini par une distance statistique (Kullback-Leibler, Wasserstein) autour du modèle nominal.

Ces menaces justifient directement la nécessité du bouclier CASTER-ZT (Article 3) : plutôt que de certifier la robustesse de chaque politique individuellement (ce qui est computationnellement coûteux et ne protège pas contre les portes dérobées), le bouclier vérifie *chaque action* en temps réel, indépendamment de l’origine de la politique — une approche conforme au principe de zéro-confiance.

2.5.4 Architecture zéro-confiance (*Zero-Trust*)

Le modèle zéro-confiance, formalisé par le NIST SP 800-207 [13], postule qu’aucun acteur — interne ou externe — ne doit être implicitement approuvé. Chaque requête d’accès doit être : (1) authentifiée, (2) autorisée, et (3) continuellement validée, indépendamment de l’emplacement du requérant. Ce paradigme, initialement développé pour la cybersécurité des réseaux d’entreprise, a été récemment étendu aux systèmes cyber-physiques et à l’IoT.

Appliqué aux réseaux autonomes gérés par AI, le principe zéro-confiance implique que **chaque action de politique doit être vérifiée avant exécution, indépendamment de l’origine de la politique**. Cette vérification doit être : (i) suffisamment rapide pour respecter les contraintes de temps réel (10 ms pour le near-RT RIC O-RAN) ; (ii) suffisamment légère pour être déployée sur des accélérateurs de bord (< 2 MB) ; (iii) dotée de garanties formelles de sécurité.

Des travaux récents progressent dans cette direction. Moudoud et al. [75] proposent une architecture de sécurité zéro-confiance pour Open RAN intégrant un module d'évaluation des risques par RL et un agent de contrôle d'accès dynamique qui ajuste continuellement les scores de confiance. Katsaros et al. [76] présentent l'architecture REASON, un cadre modulaire AI-natif avec contrôle en boucle fermée utilisant l'apprentissage par renforcement à plusieurs couches, définissant la sécurité et la confiance comme des composants de première classe. Ahmadi et al. [77] développent un système de segmentation autonome basé sur l'identité qui ajuste les politiques sur un spectre de niveaux de confiance plutôt qu'un simple autoriser/refuser. **Toutefois, aucun de ces cadres ne satisfait simultanément les trois exigences (latence < 10 ms, mémoire < 2 MB, garanties formelles) pour les réseaux de détection natifs en AI.**

2.5.5 Quantification d'incertitude

La quantification d'incertitude épistémique est essentielle pour détecter les situations hors distribution (*out-of-distribution*, OOD) où les modèles de décision ne sont pas fiables. Deux approches dominent :

MC-Dropout. Gal et Ghahramani [78] montrent que le dropout peut être interprété comme une approximation variationnelle de l'inférence bayésienne. En effectuant T passes stochastiques à travers un réseau avec dropout activé, on obtient T prédictions dont la variance empirique estime l'incertitude épistémique :

$$\hat{\sigma}_{\text{MC}}^2 = \frac{1}{T} \sum_{t=1}^T (\hat{y}_t - \bar{y})^2, \quad \bar{y} = \frac{1}{T} \sum_{t=1}^T \hat{y}_t \quad (2.12)$$

MC-Dropout est **peu coûteux** ($T \times$ le coût d'une passe, typiquement $T = 10$), ne nécessite **aucune modification de l'architecture**, et fonctionne avec des réseaux pré-entraînés.

Prédiction conforme. Angelopoulos et Bates [79] proposent un cadre de calibration qui fournit des **garanties de couverture sans hypothèse distributionnelle** : pour tout niveau de confiance α , l'ensemble de prédiction $\mathcal{C}_\alpha(x)$ satisfait $\mathbb{P}[y \in \mathcal{C}_\alpha(x)] \geq 1 - \alpha$ sous la seule hypothèse d'échangeabilité des données. Cette garantie marginale est plus forte que les intervalles de confiance classiques qui requièrent des hypothèses paramétriques.

2.5.6 Synthèse comparative des approches de sécurité pour les systèmes autonomes

Le Tableau 2.7 compare les mécanismes de sécurité et de confiance existants selon cinq critères essentiels pour la protection des réseaux natifs en AI.

TABLEAU 2.7 Comparaison des approches de sécurité pour les systèmes autonomes. FP : faux positifs. ZT : zéro-confiance.

Approche	Type de décision	Garanties	FP = 0	Quant. incertitude	Paradigme ZT	Latence
CPO [24]	Contrainte souple	En espérance	Non	Non	Non	Moyenne
Shield LTL [25]	Binaire (oui/non)	Formelles	o	Non	Non	Faible
Risk-sensitive RL	Contrainte souple	CVaR	Non	Non	Non	Moyenne
Anomaly detection (AE)	Binaire (normal/anom.)	Aucune	Non	Non	Non	Faible
Bayesian RL (ensemble)	Score continu	Approx. bayés.	Non	Ensemble	Non	Élevée
MC-Dropout [78]	Score continu	Approx. var.	Non	Oui	Non	Moyenne
Conformal pred. [79]	Ensemble de prédiction	Couverture	o	Oui	Non	Faible
CASTER-ZT (Art. 3)	5 niveaux gradués	10 prop. formelles	Oui	MC-Drop. + conforme	Oui	3.07 ms

2.6 Technologies habilitantes 6G

Les réseaux 6G, dont la standardisation par le 3GPP est prévue à partir de Release 21 (~2028) et le déploiement commercial vers 2030, introduisent plusieurs technologies transformatives pour les WSN de surveillance des catastrophes.

2.6.1 Communication sub-téraherztz

Les bandes sub-THz (100–300 GHz) offrent des largeurs de bande multi-gigahertz, permettant des débits théoriques de l'ordre du téraoctet par seconde [10]. Pour les WSN, la communication sub-THz à 140 GHz avec modulation OFDM permet une agrégation de données ultra-rapide au sein des clusters, réduisant la durée des phases de transmission et donc la consommation d'énergie.

Le modèle de perte de propagation à 140 GHz inclut l'absorption moléculaire par la vapeur d'eau et l'oxygène :

$$PL(d) = FSPL(d) + \alpha_{\text{abs}} \cdot d \quad (2.13)$$

où FSPL est la perte en espace libre et $\alpha_{\text{abs}} \approx 1\text{--}5$ dB/km à 140 GHz selon l'humidité ambiante [10]. Malgré cette atténuation relativement modérée en air libre, les fréquences sub-THz sont fortement sensibles aux obstructions (feuillage, débris, pluie), limitant la portée utile des liens à quelques dizaines à centaines de mètres en environnement intérieur ou encombré, rendant leur utilisation pertinente pour les liens intra-cluster (distances typiques < 50 m) mais nécessitant des technologies complémentaires (RIS) pour les liens inter-cluster.

2.6.2 Surfaces intelligentes reconfigurables (RIS)

Les RIS sont des métasurfaces composées de nombreux éléments réflecteurs passifs ($N_{\text{RIS}} = 16$ à 1 024), chacun capable de contrôler indépendamment la phase du signal réfléchi. Pour les WSN, les RIS offrent trois avantages :

- **Extension de couverture** : création de chemins de réflexion dans les zones obstruées (bâtiments effondrés, débris) ;
- **Gain de beamforming passif** : le gain effectif d'un RIS à M éléments est approximé par $G_{\text{RIS}} \approx M^2 \cdot G_{\text{elem}}$ en conditions de phase optimale, offrant un gain quadratique sans consommation RF supplémentaire ;
- **Efficacité énergétique** : les RIS ne requièrent pas d'amplificateurs RF actifs, leur consommation étant limitée au circuit de contrôle des déphaseurs (~ 5 mW pour 64 éléments).

2.6.3 Détection–communication intégrée (ISAC)

L'ISAC (*Integrated Sensing and Communication*) utilise la même forme d'onde (typiquement OFDM) pour la communication et la détection radar. Pour les WSN de surveillance des catastrophes, l'ISAC permet à la même infrastructure de : (i) transmettre les données des capteurs vers la BS et (ii) détecter les anomalies environnementales (mouvements de terrain, variations de température, glissements) par analyse des échos radar de la forme d'onde de communication. Cette dualité réduit le matériel nécessaire, économise de l'énergie et améliore la conscience situationnelle.

2.6.4 Architecture O-RAN

L'architecture O-RAN (Open Radio Access Network) décompose le réseau d'accès en composants ouverts et interopérables. Le contrôleur intelligent near-RT RIC (*near-Real-Time RAN Intelligent Controller*) opère avec un budget de latence de 10 ms, imposant une contrainte stricte sur le temps de décision de tout algorithme de contrôle déployé. Les applications réseau (xApps) déployées sur le near-RT RIC et les rApps sur le non-RT RIC doivent respecter des enveloppes mémoire de quelques mégaoctets, rendant la **légèreté des modèles** un impératif de conception — un critère que GAPF ($\sim 1\,473$ paramètres) et CASTER-ZT ($\sim 20\text{K}$ paramètres) satisfont explicitement.

L'écosystème multi-vendeur de l'O-RAN introduit de nouvelles frontières de confiance [13] qui motivent directement l'approche zéro confiance de CASTER-ZT : CASTER-ZT s'insère

comme couche de vérification entre l'inférence xApp et l'actuation, évaluant chaque décision via son spectre de décisions graduées (autoriser, réduire, différer, escalader, bloquer) [25].

2.6.5 Travaux récents sur le 6G pour la gestion des catastrophes (2024–2026)

Plusieurs travaux récents appliquent explicitement les technologies 6G à la surveillance des catastrophes et à la récupération post-catastrophe. Amatetti et al. [80] proposent une architecture NTN 6G intégrée avec conception distribuée pour les scénarios PPDR (*Public Protection and Disaster Relief*), détaillant comment les réseaux 3D multi-couches avec nœuds aériens et satellitaires peuvent maintenir la connectivité lorsque l'infrastructure terrestre est endommagée. Chen et al. [81] modélisent les canaux radio post-catastrophe avec évanouissement induit par les débris et proposent un système UAV équipé de RIS pour restaurer la connectivité, démontrant des gains significatifs de débit et de fiabilité. Des travaux en cours explorent également l'intégration de l'ISAC dans les modèles de service O-RAN pour exposer nativement les observables de détection, ouvrant la voie à la surveillance environnementale intégrée au RAN.

2.6.6 Synthèse comparative des technologies 6G pour les WSN

Le Tableau 2.8 synthétise les technologies 6G habilitantes et leur rôle dans la pile protocolaire proposée.

TABLEAU 2.8 Technologies habilitantes 6G et leur apport aux WSN de surveillance des catastrophes.

Technologie	Bénéfice WSN	Portée typ.	Conso. add.	Intégré dans	Maturité (2025)
Sub-THz (140 GHz)	Débit Tbps, agrég. rapide	< 50 m	Élevée	CALASH (Art. 2)	Recherche
RIS ($N = 64$)	Extension couverture, gain M^2	~ 100 m	~ 5 mW	CALASH (Art. 2)	Proto. labo.
ISAC (OFDM)	Détection + comm. unifiée	~ 30 m	Marginale	CALASH (Art. 2)	Recherche
O-RAN (near-RT RIC)	Contrôle AI natif, 10 ms	Réseau	—	CASTER-ZT (Art. 3)	Dépl. initial
NTN (LEO)	Couverture après catastrophe	~ 600 km	Élevée	Futur	Dépl. initial
Semantic comm.	Compression sémantique	—	Moyenne	Futur	Recherche

L'intégration des technologies 6G en environnement post-catastrophe pose des défis spécifiques — atténuation sub-THz par les débris, dégradation physique des RIS, synchronisation ISAC et surcharge du RIC — qui ne sont pas résolus par cette thèse mais sont reconnus dans les limitations (Section 8.5) et les directions futures (Section 8.6).

2.7 Paradigmes émergents pour les WSN intelligents

Au-delà des technologies directement employées dans les trois articles, trois paradigmes émergents sont susceptibles de transformer les WSN de surveillance à moyen terme : (i) l'**apprentissage fédéré** [82,83], qui permet l'entraînement sans centralisation des données tout en posant des défis d'hétérogénéité et d'empoisonnement de modèle ; (ii) les **jumeaux numériques** [84], qui offrent un environnement d'entraînement continu et de prédiction de pannes sans perturber le réseau réel ; (iii) la **communication sémantique** (JSCC), qui ne transmet que l'information pertinente à la tâche, réduisant la consommation de manière complémentaire à la détection comprimée de CALASH. Ces paradigmes ne sont pas implémentés dans les travaux actuels mais informent directement les directions de recherche futures (Chapitre 8).

2.8 Tableau récapitulatif des lacunes

Le Tableau 2.9 synthétise les capacités et les lacunes des travaux existants à travers douze critères pertinents pour les WSN de surveillance des catastrophes intégrés au 6G. Ce tableau justifie la nécessité de chacun des trois articles de cette thèse : aucun travail existant ne couvre plus de quatre critères simultanément, tandis que la pile complète GAPF+CALASH+CASTER-ZT en couvre les douze.

TABLEAU 2.9 Analyse des lacunes de la littérature. ✓ = présent, ✗ = absent, ◦ = partiel. Les douze critères sont regroupés en trois catégories : efficacité (E1–E4), durabilité (D1–D4) et sécurité (S1–S4).

Approche	Efficacité				Durabilité				Sécurité				Total /12
	E1 : Routage multi-sauts	E2 : MARL/DRL	E3 : GNN topologique	E4 : Embarqué (<256KB RAM)	D1 : ACV ISO 14040	D2 : CS sensible carbone	D3 : Auto-guérison	D4 : Conçue 6G	S1 : Détection politiques voyous	S2 : Décisions graduées	S3 : Garanties formelles	S4 : Budget O-RAN	
LEACH [6]	✓	✗	✗	✓	✗	✗	✗	✗	✗	✗	✗	✗	2
EE-LEACH / HEED	✓	✗	✗	✓	✗	✗	✗	✗	✗	✗	✗	✗	2
ABC-ACO [28]	✓	✗	✗	◦	✗	✗	✗	✗	✗	✗	✗	✗	2
Q-Routing [48]	✓	◦	✗	✓	✗	✗	✗	✗	✗	✗	✗	✗	2
QMIX [20]	✓	✓	✗	✗	✗	✗	✗	✗	✗	✗	✗	✗	2
QTRAN [21]	✓	✓	✗	✗	✗	✗	✗	✗	✗	✗	✗	✗	2
RIS-DRL	✓	✓	✗	◦	✗	✗	✗	◦	✗	✗	✗	✗	3
CPO [24]	◦	✓	✗	◦	✗	✗	✗	✗	◦	✗	◦	✗	3
Shield binaire [25]	◦	✓	✗	✓	✗	✗	✗	✗	◦	✗	✓	✗	4
GAPF (Art. 1)	✓	✓	✓	✓	✗	✗	✗	✗	✗	✗	✗	✗	4
CALASH (Art. 2)	✓	✓	✗	✓	✓	✓	✓	✓	✗	✗	✓	✗	8
CASTER-ZT (Art. 3)	✓	✓	✓	✓	✗	✗	✓	✗	✓	✓	✓	✓	9
Pile complète (Art. 1+2+3)	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	12

Légende des critères :

E1 — Routage multi-sauts : le protocole supporte le routage multi-sauts hiérarchique.

- E2 — MARL/DRL** : utilisation de l'apprentissage par renforcement (multi-agent ou profond) pour les décisions de routage.
- E3 — GNN topologique** : exploitation d'un encodeur GNN pour capturer la structure de graphe du réseau.
- E4 — Embarqué (<256 KB RAM pour l'inférence)** : mémoire à l'exécution compatible avec les contraintes des plateformes embarquées.
- D1 — ACV ISO 14040** : intégration des trois phases du cycle de vie (incorporé, opérationnel, fin de vie) conformément à la norme ISO 14040.
- D2 — CS sensible au carbone** : modulation dynamique du ratio de détection comprimée en fonction de l'intensité carbone du réseau électrique.
- D3 — Auto-guérison** : mécanisme autonome de récupération après destruction de nœuds par catastrophe.
- D4 — Couche 6G** : intégration explicite des technologies 6G (sub-THz, RIS, ISAC) dans la couche physique.
- S1 — Détection politiques voyous** : capacité à détecter les politiques de routage compromises ou produisant des sorties erronées (hallucinations).
- S2 — Décisions graduées** : spectre de décisions au-delà du binaire autoriser/bloquer (réduire, différer, escalader).
- S3 — Garanties formelles** : propositions ou théorèmes prouvés mathématiquement sur les propriétés de sécurité.
- S4 — Budget O-RAN** : respect du budget de latence de 10ms du near-RT RIC et de l'enveloppe mémoire de quelques MB.

2.9 Synthèse et lacunes identifiées

La revue de littérature présentée dans ce chapitre révèle **trois lacunes majeures** que cette thèse vise à combler. Ces lacunes sont clairement visibles dans le Tableau 2.9 : aucune approche existante ne couvre plus de quatre des douze critères identifiés.

Lacune 1 — Absence de fusion de politiques MARL pour le routage dans les WSN (colonnes E2+E3). Les algorithmes MARL existants (QMIX, QTRAN) traitent le routage de manière isolée sans exploiter l'information topologique du réseau. De plus, leurs forces sont complémentaires mais aucun cadre ne les fusionne. Les GNN, pourtant naturellement adaptés aux données structurées en graphe des WSN, n'ont jamais été combinés avec une stratégie de fusion de politiques. GAPF (Article 1) comble cette lacune en proposant le premier méta-contrôleur GCN+CAS (<2000 paramètres) qui sélectionne dynamiquement l'expert optimal.

Lacune 2 — Absence de routage conscient du carbone du cycle de vie (colonnes D1+D2). La communauté des communications vertes s’est concentrée exclusivement sur le carbone opérationnel, ignorant le carbone incorporé qui domine de six ordres de grandeur pour les dispositifs IoT. Aucun protocole de routage pour WSN n’intègre les trois phases du cycle de vie (ISO 14040) dans ses décisions, et aucun ne module la détection comprimée en fonction de l’intensité carbone du réseau électrique. CALASH (Article 2) comble cette lacune en introduisant la métrique LCI et quatre piliers intégrés avec garanties de Lyapunov.

Lacune 3 — Absence de contrôle de décision zéro-confiance pour les réseaux autonomes (colonnes S1+S2). Les mécanismes existants de Safe RL (CPO) ne fournissent que des garanties en espérance, et les boucliers existants sont binaires (autoriser/bloquer). Aucun cadre ne combine un encodeur GNN, un évaluateur de confiance-risque et un bouclier déterministe à décisions graduées avec des garanties formelles, le tout dans le budget de latence O-RAN. CASTER-ZT (Article 3) comble cette lacune en proposant le premier cadre zéro-confiance avec dix propositions formelles.

Ces trois lacunes motivent respectivement les trois articles présentés dans les chapitres 4, 5 et 6 de cette thèse. Ensemble, les trois articles forment une pile protocolaire complète qui couvre les douze critères du Tableau 2.9 — une couverture qu’aucune approche existante, seule ou combinée, ne peut égaler.

CHAPITRE 3 DÉMARCHE DE L'ENSEMBLE DU TRAVAIL DE RECHERCHE

Ce chapitre établit le lien entre la revue de littérature (Chapitre 2), qui a identifié les lacunes de l'état de l'art, et les trois articles qui constituent le cœur de cette thèse. Son objectif est de présenter la logique d'ensemble de la démarche de recherche, d'explicitier comment chaque article s'inscrit dans cette démarche, et de préparer le lecteur à la lecture des trois contributions en clarifiant les liens qui les unissent. La Figure 3.1 illustre cette démarche.




FIGURE 3.1 Vue d'ensemble de la démarche de recherche : les trois phases construisent progressivement la pile protocolaire complète. Les flèches continues montrent la progression logique ; la flèche en pointillés illustre la protection rétroactive de la couche de sécurité.

3.1 Logique d'ensemble de la recherche

La revue de littérature (Chapitre 2) a révélé que les approches existantes pour le routage dans les WSN de surveillance des catastrophes présentent des lacunes significatives, résumées dans le Tableau 2.9 : aucune approche ne couvre plus de quatre des douze critères identifiés. Cette thèse propose de combler ces lacunes par une démarche en trois phases successives, chacune matérialisée par un article de recherche soumis à une revue à comité de lecture.

La logique d'ensemble repose sur un principe de **construction incrémentale** : chaque phase construit sur les acquis de la précédente, ajoutant une dimension supplémentaire au problème.

Cette progression suit la hiérarchie naturelle des besoins d’un réseau de capteurs déployé en environnement critique :

1. **D’abord fonctionner efficacement** (Phase 1) — un réseau qui gaspille son énergie ne peut ni être durable ni être sécurisé.
2. **Ensuite être durable** (Phase 2) — une fois l’efficacité acquise, la durabilité carbone et la résilience aux catastrophes étendent l’horizon d’optimisation.
3. **Enfin être sécurisé** (Phase 3) — les gains des deux premières phases n’ont de valeur que s’ils sont protégés contre les compromissions.

Cette hiérarchie n’est pas arbitraire : elle reflète une dépendance fonctionnelle entre les couches. La sécurité ne peut pas fonctionner sans un réseau opérationnel à protéger, et la durabilité n’a de sens que pour un réseau qui fonctionne suffisamment bien pour livrer des paquets utiles.

3.2 Cadre méthodologique

Cette thèse adopte une approche de **recherche en science de la conception** (*Design Science Research*, DSR) [85, 86], particulièrement adaptée aux contributions qui produisent des artefacts logiciels et des méthodologies pour résoudre des problèmes pratiques. Le modèle DSR de Hevner et al. structure la recherche autour de deux axes : (1) la **pertinence** — l’artefact répond-il à un besoin réel ? — et (2) la **rigueur** — l’artefact est-il fondé sur des connaissances scientifiques solides et évalué de manière crédible ? Le processus DSRM de Peffers et al. [86] raffine cette approche en six étapes : (i) identification du problème, (ii) définition des objectifs, (iii) conception de l’artefact, (iv) démonstration, (v) évaluation et (vi) communication.

Dans le contexte de cette thèse :

- **Artefacts produits** : trois cadres logiciels (GAPF, CALASH, CASTER-ZT) et une métrique (LCI).
- **Pertinence** : les problèmes adressés (efficacité énergétique, durabilité carbone, sécurité) sont motivés par des données réelles (UNDRR, IPCC) et des lacunes identifiées dans l’état de l’art (Tableau 2.9).
- **Rigueur** : chaque artefact est évalué par des campagnes de simulation exhaustives (21 000 + 390 + 2 420 exécutions) avec des protocoles statistiques rigoureux (Section 3.5).

Le Tableau 3.1 présente la grille d’évaluation DSRM alignant les six activités du processus

avec les indicateurs quantitatifs de chaque article, permettant ainsi de valider la démarche elle-même au-delà de la simple validation des artefacts produits.

TABLEAU 3.1 Grille d'évaluation DSRM : alignement des six activités de Peffers et al. (2007) avec les indicateurs quantitatifs des trois articles.

Activité DSRM	Définition	Art. 1 — GAPF	Art. 2 — CA-LASH	Art. 3 — CASTER-ZT
1. Identification du problème	Motivation et cadrage	Couverture $< 4/12$ critères par les approches existantes	Absence de métrique LCI dans le routage WSN	Absence de contrôle zéro-confiance pour politiques IA
2. Objectifs de solution	Objectifs mesurables	PDR $\geq 98\%$, mémoire < 6 KB	LCI -33% , durée de vie $+60\%$	FPR = 0% , $\omega_{\text{rec}} > 0,7$
3. Conception	Artefact produit	GCN ($d = 16$) + CAS + fusion QMIX/QTRAN	CADR + CARE + SHDR + LSE	GraphSAGE ($d = 64$) + évaluateur + bouclier 14 param.
4. Démonstration	Mise en œuvre	7 scénarios (20–100 nœuds), 21 000 épisodes	30 graines Monte Carlo, 13 variantes	2 420 exécutions, 4 conditions d'attaque, 3 échelles
5. Évaluation	Indicateurs quantitatifs	PDR, ECE	LCI, PDR, durée de vie	FPR, ω_{rec} , ECE, latence
6. Communication	Diffusion	Soumis IEEE Trans. Green Commun. Netw.	Soumis IEEE Trans. Green Commun. Netw.	En préparation

3.3 Protocole expérimental commun

Bien que les trois articles utilisent des environnements de simulation distincts, ils partagent un **protocole expérimental commun** qui garantit la cohérence et la comparabilité des résultats.

3.3.1 Modèle énergétique de premier ordre

Les trois articles utilisent le modèle énergétique de premier ordre de Heinzelman et al. [6], qui constitue le standard de facto dans la communauté WSN. Ce choix est délibéré : il permet une comparaison directe avec les dizaines de protocoles évalués sous ce modèle dans la littérature, tout en capturant les phénomènes physiques essentiels (dépendance quadratique/quartique en la distance, coût d'amplification, énergie de circuit). Les paramètres sont fixés : $E_{\text{elec}} = 50$ nJ/bit, $\varepsilon_{\text{fs}} = 10$ pJ/bit/m², $\varepsilon_{\text{mp}} = 0.0013$ pJ/bit/m⁴, $d_0 = 87.7$ m.

3.3.2 Modèle de catastrophe

Le modèle de catastrophe, utilisé dans les Articles 2 et 3, suit un profil gaussien isotrope calibré sur les données sismiques réelles du séisme Turquie-Syrie 2023 (Mw 7.8, données ShakeMap USGS). La probabilité de destruction d’un nœud à distance d de l’épicentre est :

$$P_{\text{dest}}(d) = \exp\left(-\frac{d^2}{2\sigma_{\text{cat}}^2}\right) \quad (3.1)$$

où σ_{cat} est calibré pour que 30–50% des nœuds soient détruits dans le rayon d’impact, un taux cohérent avec les analyses de survivabilité de Abu-Ghazaleh et al. [9] et les données d’endommagement sismique du séisme Turquie-Syrie 2023 (USGS ShakeMap). Ce modèle, bien que simplifié (isotrope, instantané), capture l’essence du problème : destruction massive et soudaine de nœuds, forçant une reconfiguration rapide du réseau.

3.3.3 Données de référence

Trois sources de données réelles ancrent les simulations dans des conditions représentatives :

1. **Intel Berkeley Research Lab** [87] : traces de capteurs (température, humidité, lumière) collectées par 54 nœuds Mica2 sur 36 jours. Ces traces fournissent des profils réalistes de génération de données pour calibrer les taux de génération de paquets.
2. **UK Carbon Intensity API** [62] : intensité carbone du réseau électrique britannique à résolution de 30 minutes. Ces données permettent de simuler la modulation temporelle du ratio de détection comprimée dans CADR (Article 2).
3. **USGS ShakeMap** : cartes d’intensité sismique pour le séisme Turquie-Syrie du 6 février 2023. Ces données calibrent le paramètre σ_{cat} du modèle de catastrophe.

3.3.4 Protocoles de référence (*baselines*)

Chaque article est évalué contre un ensemble de protocoles de référence choisis pour représenter différentes familles d’approches : protocoles classiques (LEACH, EE-LEACH), méta-heuristiques (QPSO-FL), MARL (QMIX, QTRAN individuels), Safe RL (CPO), et boucliers binaires. Le choix des références vise à couvrir l’éventail complet des approches existantes tout en restant reproductible — tous les protocoles de référence sont soit implémentés selon les détails publiés, soit issus de bibliothèques open-source (EPyMARL pour QMIX/QTRAN).

3.4 Fondements théoriques de la formulation

Les trois articles partagent un socle théorique commun dont les détails formels sont présentés dans chaque article et dans le Chapitre 2. Nous en rappelons ici les éléments essentiels.

Le routage dans un WSN est modélisé comme un **Dec-POMDP** [36,37], un problème NEXP-complet résolu de manière approchée par le paradigme **CTDE** (*Centralized Training with Decentralized Execution*) [36] : entraînement centralisé hors ligne, exécution décentralisée sur le terrain. L’Article 1 instancie CTDE via les experts QMIX [20] et QTRAN [21], dont la complémentarité (monotonie vs. relaxation additive) est exploitée par le méta-contrôleur GCN ; l’Article 2 via un DQN centralisé ; l’Article 3 via un évaluateur de confiance indépendant.

Le problème est intrinsèquement **multi-objectifs** (PDR, énergie, carbone, sécurité). Cette thèse adopte une scalarisation linéaire [88], l’Article 1 apprenant les poids adaptivement via un réseau d’attention Q·K, tandis que l’Article 2 impose des contraintes dures sur le carbone via l’**optimisation de Lyapunov** [61] (compromis $[O(1/V), O(V)]$).

Les Articles 1 et 3 exploitent des **GNN** pour encoder la topologie dynamique : un GCN [42] à 2 couches ($d = 16$) dans GAPF et un GraphSAGE [43] à 2 couches ($d = 64$) dans CASTER-ZT, le passage à des plongements plus riches reflétant la complexité accrue de la tâche de détection de politique voyou.

3.5 Cadre statistique et reproductibilité

L’évaluation rigoureuse des performances de protocoles stochastiques nécessite un cadre statistique explicite. Conformément aux recommandations du programme de reproductibilité NeurIPS [89], nous adoptons les pratiques suivantes :

3.5.1 Graines aléatoires et répétitions

Chaque expérience est répétée avec des graines aléatoires fixes et documentées :

- **Article 1 (GAPF)** : 3 graines (42, 123, 456) $\times$ 7 scénarios $\times$ 1 000 épisodes = 21 000 épisodes de test.
- **Article 2 (CALASH)** : 30 graines Monte Carlo $\times$ 13 variantes de protocoles = 390 exécutions indépendantes.
- **Article 3 (CASTER-ZT)** : campagne de 2 420 exécutions (11 méthodes, 4 conditions d’attaque, 3 échelles réseau, 20 graines).

La fixation des graines permet la **reproductibilité exacte** des résultats : toute exécution avec la même graine et les mêmes paramètres produit des résultats identiques.

3.5.2 Tests statistiques

Les comparaisons de performance utilisent des tests non paramétriques adaptés aux distributions potentiellement non gaussiennes des métriques de réseau :

- **Test de Wilcoxon-Mann-Whitney** : pour les comparaisons par paires entre deux méthodes. Ce test, basé sur les rangs, ne suppose pas la normalité des distributions et est robuste aux valeurs aberrantes.
- **Test de Kruskal-Wallis** : pour les comparaisons multiples entre $k > 2$ méthodes, suivi d'un test post-hoc de Dunn avec correction de Bonferroni pour les comparaisons par paires.
- **Niveau de signification** : $\alpha = 0.05$ pour tous les tests, avec indication des p -valeurs exactes lorsqu'elles sont disponibles. Article 2 rapporte systématiquement $p < 10^{-5}$ sur tous les tests.

3.5.3 Intervalles de confiance et métriques rapportées

Toutes les métriques sont rapportées avec moyenne $\pm$ écart-type sur les graines aléatoires. Pour les métriques clés (PDR, énergie, LCI), des intervalles de confiance à 95% sont calculés par bootstrap non paramétrique (1 000 ré-échantillonnages) lorsque le nombre de répétitions le permet (≥ 30 graines dans l'Article 2).

3.5.4 Reproductibilité

Conformément à la liste de vérification de reproductibilité NeurIPS [89], les éléments suivants sont documentés pour chaque article :

- Tous les hyperparamètres d'entraînement (taux d'apprentissage, taille de lot, nombre d'époques, architecture du réseau) — cf. Annexe E pour l'Article 1.
- Les graines aléatoires utilisées.
- Le matériel de simulation (GPU/CPU, mémoire).
- Les bibliothèques et versions logicielles (PyTorch, PyTorch Geometric, EPyMARL).
- Le nombre total d'heures GPU et l'énergie de calcul estimée.

Le Tableau 3.2 synthétise les campagnes de simulation des trois articles.

TABLEAU 3.2 Synthèse des campagnes de simulation des trois articles.

Article	Exécutions	Graines	Références	Tests stat.	Données réelles
Art. 1 (GAPF)	21 000 épisodes	3 (42, 123, 456)	LEACH, QMIX, QTRAN, QPSOFL	Wilcoxon	—
Art. 2 (CALASH)	390 exécutions	30 Monte Carlo	7 proto. + 5 ablations	Kruskal-Wallis	Intel Lab, UK CI, USGS
Art. 3 (CASTER-ZT)	2 420 exécutions	20	CPO, Shield, Anomaly Det.	Wilcoxon	—
Total	> 23 800		> 20 références		3 sources

3.5.5 Indicateurs de qualité de la démarche méthodologique

Au-delà des tests de signification statistique (p -valeurs), trois indicateurs évaluent la **qualité intrinsèque de la démarche** elle-même :

(i) **Puissance statistique et taille d’effet (Cohen d)**. La taille d’effet de Cohen d , définie comme :

$$d = \frac{\mu_{\text{proposé}} - \mu_{\text{référence}}}{\sigma_{\text{poolé}}} \quad (3.2)$$

quantifie la magnitude pratique des améliorations indépendamment de la taille de l’échantillon. Pour l’Article 1, la différence de PDR entre GAPF (98–99 %) et QMIX (46–67 %) correspond à un $d \gg 1$, classé *très grand effet* selon la convention de Cohen ($d > 0,8$). Pour l’Article 2, la réduction du LCI de 33 % sur 30 graines Monte Carlo dépasse tout seuil de signifiante pratique. Pour l’Article 3, le maintien de FPR = 0 % sur 2 420 exécutions implique une borne supérieure de l’intervalle de confiance à 95 % sur le FPR de $3/2420 \approx 1,24 \times 10^{-3}$ (règle des trois pour observations sans événement), confirmant la robustesse de la garantie formelle.

(ii) **Reproductibilité inter-laboratoire**. La reproductibilité de la démarche au-delà du laboratoire d’origine est assurée par trois mécanismes : (a) publication des graines aléatoires (42, 123, 456 pour l’Art. 1 ; 30 graines Monte Carlo pour l’Art. 2 ; 20 graines pour l’Art. 3) permettant la reproduction exacte des résultats ; (b) spécification complète des bibliothèques et versions logicielles (PyTorch, PyTorch Geometric, EPyMARL) ; (c) utilisation exclusive de jeux de données publics (Intel Berkeley Lab, UK Carbon Intensity API, USGS ShakeMap) accessibles sans restriction géographique ni institutionnelle.

(iii) **Cohérence interne inter-articles**. La transitivité des protocoles de référence communs constitue un **indice de cohérence interne** : LEACH est présent dans les Articles 1 et 2, QMIX/QTRAN dans les Articles 1 et 3. Si les performances de ces références restent stables à travers les campagnes de simulation (sous les mêmes paramètres réseau), cela valide la reproductibilité inter-articles de l’environnement de simulation. Cette propriété est vérifiée : les performances de LEACH (PDR ≈ 65 –75 %, durée de vie ≈ 931 tours) et de QMIX (PDR ≈ 46 –67 %) rapportées dans les Articles 1 et 2 sont cohérentes entre elles et avec les

valeurs publiées dans les études originales [6, 20].

3.6 Stratégie de validation et calibration

La validation par simulation adopte trois niveaux complémentaires : (1) **vérification** (tests unitaires, reproduction des résultats LEACH [6], vérification des invariants physiques tels que la conservation de l'énergie); (2) **validation** (calibration sur données réelles — Intel Lab [87], UK Carbon Intensity API [62], USGS ShakeMap — et analyse de sensibilité via les études d'ablation des Articles 2 et 3); (3) **reconnaissance des limites** (canal radio simplifié sans évanouissement, synchronisation TDMA parfaite, catastrophe instantanée isotrope), discutées en détail aux Sections 7.8 et 8.5.

Justification du choix simulateur. Le recours exclusif à la simulation — plutôt qu'à un déploiement matériel réel — est justifié par quatre arguments complémentaires. Premièrement, la **contrôlabilité** : reproduire en laboratoire un réseau de 100–200 capteurs soumis simultanément à un séisme de magnitude 7,8, à une variation continue de l'intensité carbone et à des attaques adversariales de type compromission de politique n'est pas réalisable. Deuxièmement, la **comparabilité** : la simulation permet d'évaluer plus de 20 protocoles de référence dans des conditions strictement identiques (même graine, même énergie initiale, même modèle de canal), éliminant les biais expérimentaux inhérents aux déploiements physiques hétérogènes. Troisièmement, la **validation indirecte par ancrage empirique** : bien que numériques, les simulations sont calibrées sur trois sources de données réelles qui constituent autant d'ancrages empiriques :

- les **traces Intel Berkeley Research Lab** [87] (54 nœuds Mica2, 36 jours) valident les profils réalistes de génération de paquets ;
- les données de la **UK Carbon Intensity API** [62] (résolution 30 min sur plusieurs années) reflètent les variations réelles de l'intensité carbone du réseau électrique ;
- les **cartes ShakeMap USGS** du séisme Turquie-Syrie (6 février 2023, Mw 7,8) calibrent le paramètre σ_{cat} du modèle de catastrophe gaussien (Éq. 3.1).

Quatrièmement, la **continuité avec l'état de l'art** : tous les protocoles de référence (LEACH, QMIX, QTRAN, CPO) ont été originellement évalués par simulation dans le même modèle énergétique de premier ordre [6], ce qui assure la comparabilité directe des résultats et la position de cette thèse dans le courant principal de la communauté WSN.

3.7 Modèle de menaces et hypothèses de sécurité

Trois niveaux de puissance adversariale sont considérés : (1) adversaire **passif** $\mathcal{A}_1$ (écoute clandestine), (2) adversaire **actif** $\mathcal{A}_2$ (modification et injection de messages, drain de batterie, brouillage), et (3) adversaire **interne** $\mathcal{A}_3$ (compromission de nœuds, manipulation de politique [71, 72]). L’Article 1 suppose l’absence d’adversaire ; l’Article 2 gère les défaillances physiques ($\mathcal{A}_2$) via SHDR ; l’Article 3 adresse les trois niveaux via le principe zéro-confiance [13]. Le Tableau 3.3 résume les vecteurs d’attaque et défenses.

TABLEAU 3.3 Vecteurs d’attaque considérés dans les trois articles et mécanismes de défense correspondants.

Vecteur d’attaque	Niveau	Impact sur la pile	Défense (Article)
Compromission de nœud	$\mathcal{A}_3$	Politique voyou : routage vers trou noir, drain énergétique ciblé, données falsifiées	Évaluateur double-hypothèse + bouclier gradué (Art. 3)
Injection de données	$\mathcal{A}_2$	Fausse lectures de capteurs $\Rightarrow$ décisions de routage erronées, fausse alerte de catastrophe	MC-Dropout détecte incohérence épistémique (Art. 3)
Manipulation de politique	$\mathcal{A}_3$	Perturbation adversariale des poids du GCN ou du mélangeur QMIX	Vérification pré-actuation par seuils du bouclier (Art. 3)
Replay de messages	$\mathcal{A}_2$	Anciennes tables de routage réinjectées $\Rightarrow$ boucles, incohérence topologique	Cohérence temporelle vérifiée par Graph-SAGE (Art. 3)
Drain de batterie	$\mathcal{A}_2$	Requêtes excessives forçant un nœud à épuiser son énergie	File Lyapunov détecte déviations de budget (Art. 2), bouclier bloque actuations excessives (Art. 3)
Empoisonnement du canal	$\mathcal{A}_2$	Brouillage ou interférence ciblée sur les liens sub-THz	Reconfiguration SHDR via MAPE-K (Art. 2), escalade automatique (Art. 3)

Les hypothèses de sécurité maintenues sont : (1) station de base inaltérable [6] ; (2) entraînement hors ligne sécurisé ; (3) intégrité du bouclier (14 paramètres en ROM) ; (4) canal radio ouvert (la confidentialité n’est pas un objectif, seules l’intégrité et la disponibilité le sont).

3.8 Article 1 — GAPF : les fondations du routage intelligent

GAPF (Graph-Attentive Policy Fusion) est un cadre de méta-apprentissage léger qui encode la topologie du WSN via un GCN à 2 couches ($d = 16$), sélectionne contextuellement l’expert MARL optimal (QMIX ou QTRAN) via un contrôleur CAS et scalarise les récompenses multi-objectifs via un réseau d’attention monotone Q·K — le tout avec seulement 1 473 paramètres, soit $26\times$ moins qu’un seul agent RNN. L’évaluation sur 7 scénarios (20–100 capteurs) et 21 000 épisodes de test démontre : $\text{PDR} \geq 98\%$, énergie $2\text{--}3.5\times$ inférieure aux références et empreinte mémoire $13\times$ moindre. Ces résultats établissent la fondation énergétique sur laquelle CALASH construit.

3.9 Environnement de simulation

Les trois articles utilisent un environnement de simulation Python développé spécifiquement pour cette thèse, basé sur le cadre OpenAI Gym [90] pour l’interface d’apprentissage par renforcement et PyTorch / PyTorch Geometric pour les composants GNN et DRL. Cette section détaille les choix de conception de l’environnement.

3.9.1 Architecture logicielle

L’environnement de simulation est structuré en trois couches :

1. **Couche physique** : modèle énergétique de premier ordre, modèle de propagation sub-THz (Article 2), modèle RIS (Article 2), modèle de catastrophe gaussien. Cette couche est indépendante de l’algorithme de routage.
2. **Couche réseau** : gestion des grappes, élection des CH, routage multi-sauts, agrégation de données, comptabilité énergétique et carbone. Cette couche implémente l’interface Gym (`reset()`, `step()`, `render()`).
3. **Couche de décision** : agents MARL (QMIX, QTRAN via EPyMARL), méta-contrôleur GAPF, piliers CALASH, évaluateur-bouclier CASTER-ZT. Cette couche interagit avec l’environnement via l’interface Gym.

3.9.2 Paramétrage des scénarios

Les scénarios de simulation couvrent une variété de conditions représentatives des déploiements réels :

- **Taille du réseau** : 20, 50, 75, 100, 150, 200 nœuds capteurs, déployés aléatoirement dans une zone carrée de côté L .
- **Rayon de couverture** : 25 m, 35 m, 50 m, définissant le voisinage $\mathcal{N}(v)$ de chaque nœud.
- **Position de la BS** : centrée $(L/2, L/2)$, en coin $(0, 0)$ ou en bord $(L/2, 0)$, testant l'impact de la géométrie sur les performances.
- **Énergie initiale** : 0.5 J par nœud (standard de la littérature), avec possibilité d'hétérogénéité énergétique.
- **Catastrophe** : absence (régime nominal), gaussienne isotrope (Éq. 3.1), avec intensité variable ($\sigma_{\text{cat}} \in \{10, 25, 50\}$ m).

3.9.3 Analyse de complexité algorithmique

Le Tableau 3.4 détaille la complexité temporelle et spatiale de chaque composant principal des trois articles.

TABLEAU 3.4 Analyse de complexité algorithmique des composants principaux. n : nœuds, $|E|$: arêtes, d : dimension des plongements, K : couches GNN, T : passes MC-Dropout.

Article	Composant	Complexité temporelle	Complexité spatiale
Art. 1 (GAPF)	Encodeur GCN ($K = 2$)	$O(K \cdot E \cdot d)$	$O(n \cdot d + E)$
	Contrôleur CAS	$O(d)$	$O(d)$
	Attention Q·K	$O(M \cdot d)$	$O(M \cdot d)$
Art. 2 (CALASH)	CADR (ratio CS)	$O(1)$	$O(1)$
	CARE (file Lyapunov)	$O(n)$	$O(n)$
	SHDR (reconfiguration)	$O(n \log n)$	$O(n)$
	LSE (comptabilité LCI)	$O(n)$	$O(n)$
Art. 3 (CASTER-ZT)	Encodeur GraphSAGE ($K = 2$)	$O(K \cdot S^K \cdot d)$	$O(n \cdot d + S^K \cdot d)$
	Évaluateur double-hypothèse	$O(d^2)$	$O(d^2)$
	MC-Dropout (T passes)	$O(T \cdot d^2)$	$O(T \cdot d)$
	Bouclier déterministe	$O(1)$	$O(1)$ (14 scalaires)

La complexité totale d'une décision de la pile complète est dominée par l'encodeur GraphSAGE de CASTER-ZT : $O(K \cdot S^K \cdot d + T \cdot d^2)$ où S est le nombre de voisins échantillonnés, $K = 2$ les couches et $T = 20$ les passes MC-Dropout. Pour les paramètres utilisés ($S = 10$, $K = 2$, $d = 64$, $T = 20$), cela donne $\sim 82\,000$ opérations en virgule flottante. Sur un ac-

célérateur Google Coral Edge TPU (4 TOPS, 2W), cette charge correspond à une latence d’inférence bien inférieure à 1 ms.

3.9.4 Espaces d’état, d’action et de récompense

La formulation du routage comme un problème de Dec-POMDP requiert la définition précise des espaces d’état, d’action et de récompense pour chaque article. Le Tableau 3.5 synthétise ces définitions.

TABLEAU 3.5 Espaces d’état, d’action et de récompense pour les trois articles. n : nombre de nœuds, $|\mathcal{N}(v)|$: taille du voisinage du nœud v .

Attribut	Art. 1 — GAPF	Art. 2 — CALASH	Art. 3 — CASTER-ZT
Agent	Nœud capteur i	Cluster head j	Cellule réseau c
Observation o_i	RE_i : énergie résiduelle CE_i : énergie consommée x_i, y_i : position N_i : nb paquets $o_i \in \mathbb{R}^5$	E_j^{res} : énergie résiduelle $CI(t)$: intensité carbone $L CI_j$: indice carbone Q_j^{carb} : file carbone $ \text{cluster}_j , d_j^{\text{BS}}, \text{RIS}_{j,\text{gain}}$ $o_j \in \mathbb{R}^7$	Graphe local $G_c = (V_c, E_c, X_c)$ $X_c \in \mathbb{R}^{ V_c \times f}$ (caract. de nœuds)
Action a_i	Prochain saut $\in \mathcal{N}(v) \cup \{\text{BS}\}$	Ratio CS $\rho_j \in [0.3, 1.0]$ + sélection de bande (sub-THz / micro-onde)	$d_t \in \{\text{autoriser, réduire, différer, escalader, bloquer}\}$
Récompense r	$= \alpha_1 \cdot \text{PDR}$ $+ \alpha_2(1 - \sigma_E/\bar{E})$ $+ \alpha_3 \cdot \text{alive_ratio}$	$r = -\Delta \text{LCI}$ $+ \beta_1 \cdot \text{PDR}$ $- \beta_2 \cdot Q_j^{\text{carb}}$ (Lyapunov drift+penalty)	$r = \omega_1 \cdot \text{détection}$ $+ \omega_2(1 - \text{FP})$ $+ \omega_3 \cdot \text{récup.}$

Observations clés sur les espaces :

- L’observation de GAPF est **locale** (voisinage à 1 saut), tandis que le GCN agrège l’information à 2 sauts pour enrichir la représentation. Le méta-contrôleur CAS opère sur le plongement global du graphe (moyenne des plongements de nœuds), capturant indirectement l’état global du réseau.
- L’observation de CALASH inclut l’intensité carbone $CI(t)$ et la file carbone virtuelle Q_j^{carb} , qui n’existent pas dans les formulations classiques de routage. La file carbone est l’innovation clé qui permet les garanties de Lyapunov.

- L’observation de CASTER-ZT est un **graphe local** plutôt qu’un vecteur, exploité directement par l’encodeur GraphSAGE. Cette représentation structurée capture les relations de voisinage que les vecteurs aplatis perdraient.

3.9.5 Procédure d’entraînement et convergence

L’entraînement des trois cadres suit des procédures distinctes adaptées à leurs architectures respectives :

Article 1 (GAPF) : Optimisation bi-niveau en trois composantes :

1. **Entraînement des experts** : QMIX et QTRAN sont entraînés indépendamment via EPyMARL pendant ~ 2000 épisodes (200 000 pas) avec ϵ -greedy ($\epsilon : 0.5 \rightarrow 0.01$ sur 150 000 pas). Taux d’apprentissage : 3×10^{-4} , taille du batch : 32, mémoire de replay : 15 000 épisodes. Les paramètres sont ensuite gelés.
2. **Boucle externe (attention Q-K)** : optimisation du réseau d’attention monotone par stratégies évolutionnaires (ES) de Salimans et al. [91]. Bruit $\sigma_{ES} = 0.01$, taux d’apprentissage ES : 0.01, référence EMA ($\beta = 0.9$).
3. **Méta-contrôleur GCN+CAS** : entraîné par REINFORCE [92] avec référence EMA ($\beta = 0.95$), optimiseur Adam ($\alpha = 3 \times 10^{-3}$), gradient clipping $\|\nabla_{\theta}\|_2 \leq 1.0$, pendant 2000 épisodes en mode on-policy.

La convergence est monitorée par le PDR cumulé sur 100 épisodes d’évaluation. Le critère d’arrêt est atteint lorsque la variance du PDR sur les 10 dernières évaluations est $< 0.5\%$.

Article 2 (CALASH) : Entraînement séquentiel des quatre piliers :

1. Le pilier CADR est optimisé par recherche de grille sur le ratio CS initial $\rho_0 \in \{0.3, 0.4, \dots, 1.0\}$.
2. Le pilier CARE est entraîné par DQN avec les paramètres : $\gamma = 0.99$, taille du batch : 64, réseau cible mis à jour toutes les 200 étapes.
3. Le pilier SHDR utilise un automate MAPE-K déterministe (pas d’entraînement).
4. Le pilier LSE est un calcul analytique (pas d’entraînement).

Article 3 (CASTER-ZT) : Entraînement de l’évaluateur neuronal uniquement :

1. L’encodeur GraphSAGE et l’évaluateur double-hypothèse sont entraînés conjointement par rétro-propagation sur des paires (a, s, label) où le label est “légitime” ou “voyou”.
2. Taux d’apprentissage : 10^{-3} avec décroissance cosinus, 50 époques, dropout $p = 0.2$ (réutilisé pour MC-Dropout à l’inférence).
3. Le bouclier déterministe (14 paramètres) est fixé par conception — aucun entraînement.

Le Tableau 3.6 résume les budgets d’entraînement des trois articles.

TABLEAU 3.6 Budgets d’entraînement des trois articles. Les heures GPU sont mesurées sur NVIDIA A100 40 GB.

Article	Algorithme	Épisodes	Pas totaux	GPU	Heures GPU	RAM max.
Art. 1 (GAPF)	REINFORCE + ES + QMIX/QTRAN	~2K + 2K (méta)	~2M	A100	~48 h	13.2 GB (QTRAN)
Art. 2 (CALASH)	DQN + grille	30 × 1000	~3M	A100	~72 h	4.2 GB
Art. 3 (CASTER-ZT)	SGD	50 époques	~500K	A100	~24 h	2.1 GB
Total			~5.5M		~144 h	

3.10 Justification des choix d’hyperparamètres

Le Tableau 3.7 synthétise les hyperparamètres clés des trois articles, leur plage de recherche et leur justification.

Les hyperparamètres les plus sensibles ($> 5\%$ d’impact sur les métriques) sont le paramètre de Lyapunov V , l’écart-type du bruit ES σ , le nombre de couches GNN K et le taux d’apprentissage MARL α . Les interactions notables incluent K - d (augmenter K nécessite de réduire d pour éviter le sur-lissage), V - ρ_0 (un V élevé compense un ρ_0 sous-optimal) et T - p (un p plus élevé nécessite davantage de passes MC-Dropout).

3.11 Article 2 — CALASH : l’extension vers la durabilité carbone

CALASH (Carbon-Aware Lifecycle-Autonomous Self-Healing) étend l’optimisation au-delà de l’énergie vers le carbone du cycle de vie complet. C’est le premier protocole de routage WSN à définir la métrique LCI (ISO 14040), moduler la détection comprimée selon l’intensité carbone en temps réel (CADR), optimiser le routage avec garanties de Lyapunov (CARE), régénérer le réseau après catastrophe via MAPE-K (SHDR) et opérer sur couche physique 6G. L’évaluation sur 30 graines Monte Carlo et 13 variantes démontre : durée de vie +60%, PDR 82.9%, LCI -33% , $p < 10^{-5}$ sur tous les tests. CALASH reste cependant vulnérable si ses politiques DQN sont compromises, motivant directement CASTER-ZT.

3.12 Article 3 — CASTER-ZT : la couche de sécurité zéro-confiance

CASTER-ZT (Zero-Trust Shielded Decision Control) protège chaque actuation de GAPF et CALASH contre les compromissions. Via un encodeur GraphSAGE ($d = 64$), un évaluateur neuronal double-hypothèse avec MC-Dropout ($T = 20$) et un bouclier déterministe à 14 paramètres non apprenables émettant des décisions graduées (5 niveaux), CASTER-ZT fournit dix propositions formelles. La campagne de 2 420 exécutions démontre : détection 74.2–98.3% avec zéro faux positif, $\omega_{\text{rec}} = 0.733$ (3.7 – $5.2\times$ supérieur aux références), latence 3.07 ms (budget O-RAN : 10 ms). Avec CASTER-ZT, la pile couvre les 12 critères du Tableau 2.9 (E1–E4

TABLEAU 3.7 Hyperparamètres clés des trois articles : valeur retenue, plage de recherche et justification.

Hyperparamètre	Valeur	Plage explorée	Article	Justification
<i>Architecture GNN</i>				
Couches GCN (K)	2	$\{1, 2, 3, 4\}$	Art. 1	$K > 2$ provoque le sur-lissage [93]
Dimension plongement GCN (d)	16	$\{8, 16, 32, 64\}$	Art. 1	Compromis budget paramètres / expressivité
Couches GraphSAGE (K)	2	$\{1, 2, 3\}$	Art. 3	Même contrainte de sur-lissage
Dimension GraphSAGE (d)	64	$\{32, 64, 128\}$	Art. 3	$d = 64$ suffisant pour discrimination ami/ennemi
Voisins échantillonnés (S)	10	$\{5, 10, 20\}$	Art. 3	$S = 10$ couvre le degré moyen des topologies évaluées
<i>Stratégies évolutionnaires — réseau Q-K (Article 1)</i>				
Écart-type du bruit (σ_{ES})	0.01	$\{0.005, 0.01, 0.02, 0.05\}$	Art. 1	$\sigma = 0.01$ balancé entre exploration et gradient
Taux d'apprentissage ES (η_{ES})	0.01	$\{0.001, 0.01, 0.05\}$	Art. 1	Convergence stable ; mise à jour par épisode
Référence EMA ES (β)	0.9	$\{0.8, 0.9, 0.95\}$	Art. 1	Réduction de variance
<i>Méta-contrôleur REINFORCE — GCN+CAS (Article 1)</i>				
Taux d'apprentissage méta (α)	3×10^{-3}	$\{10^{-3}, 3 \times 10^{-3}, 10^{-2}\}$	Art. 1	Convergence rapide sur 2000 épisodes on-policy
Référence EMA méta (β)	0.95	$\{0.9, 0.95, 0.99\}$	Art. 1	Baseline stable pour REINFORCE
Gradient clipping	1.0	$\{0.5, 1.0, 5.0\}$	Art. 1	Prévention d'explosion du gradient
<i>Experts MARL (Article 1)</i>				
Taux d'apprentissage MARL (α)	3×10^{-4}	$\{10^{-4}, 3 \times 10^{-4}, 10^{-3}\}$	Art. 1	Standard EPyMARL pour QMIX/QTRAN
Taille du batch	32	$\{16, 32, 64\}$	Art. 1	Compromis variance / coût mémoire
Mémoire de replay	15 000 ép.	$\{5000, 10000, 15000\}$	Art. 1	Couverture de la diversité scénaristique
ϵ exploration (final)	0.01	$\{0.01, 0.05, 0.1\}$	Art. 1	1% d'exploration résiduelle évite la convergence locale
Pas d'annulation ϵ	150 000	$\{50K, 100K, 150K\}$	Art. 1	Annulation progressive sur 150K pas
<i>Piliers CALASH (Article 2)</i>				
Paramètre de Lyapunov (V)	100	$\{10, 50, 100, 500, 1000\}$	Art. 2	Compromis $O(1/V)$ optimalité vs. $O(V)$ taille de file [61]
Ratio CS initial (ρ_0)	0.5	$\{0.3, 0.4, \dots, 1.0\}$	Art. 2	Recherche de grille ; $\rho_0 = 0.5$ optimal sur Intel Lab
Facteur d'escompte DQN (γ)	0.99	$\{0.95, 0.99, 0.999\}$	Art. 2	Horizon long nécessaire pour cycles carbone
Fréquence mise à jour cible	200 pas	$\{100, 200, 500\}$	Art. 2	Stabilité d'entraînement DQN
<i>Évaluateur CASTER-ZT (Article 3)</i>				
Passes MC-Dropout (T)	20	$\{5, 10, 20, 50\}$	Art. 3	Convergence de la variance épistémique
Taux de dropout (p)	0.1	$\{0.1, 0.2, 0.3, 0.5\}$	Art. 3	$p = 0.1$ calibré pour couverture conforme
Taux d'apprentissage initial	10^{-3}	$\{10^{-4}, 10^{-3}, 10^{-2}\}$	Art. 3	Décroissance cosinus sur 50 époques
Paramètres du bouclier	14 scalaires	—	Art. 3	Fixés par conception, non appris

par GAPF, D1–D4 par CALASH, S1–S4 par CASTER-ZT). Le Chapitre 7 effectue l’analyse transversale.

3.13 Protocole d’intégration inter-articles

Bien que les trois articles aient été développés et évalués de manière séquentielle, ils sont conçus pour s’intégrer dans une **pile protocolaire unifiée** déployable sur un réseau de capteurs en environnement de catastrophe. Cette section spécifie les interfaces, les flux de données, les budgets de latence et de mémoire de la pile complète, ainsi que les scénarios de déploiement partiel.

3.13.1 Flux de données de bout en bout

Le traitement d’un paquet de données dans la pile complète suit une chaîne séquentielle en quatre étapes :

1. **Acquisition et pré-traitement** (couche physique) : un nœud capteur i génère une mesure brute $x_i(t)$ (température, accélération sismique, etc.). Si le pilier CADR de CALASH est actif, le ratio de détection comprimée ρ_j du CH parent détermine si la donnée est transmise intégralement ou comprimée. La sortie de cette étape est un paquet $p_i(t)$ de taille $\rho_j \cdot |x_i(t)|$.
2. **Routage intelligent** (GAPF, Article 1) : le méta-contrôleur GAPF encode la topologie courante via le GCN à 2 couches et sélectionne l’expert MARL (QMIX ou QTRAN) optimal pour le régime topologique courant. L’expert sélectionné détermine le prochain saut pour chaque nœud. La sortie est une table de routage $\mathcal{R}(t) = \{(i, \text{next}(i))\}_{i \in V_t}$.
3. **Optimisation carbone et résilience** (CALASH, Article 2) : les piliers CARE et LSE ajustent les décisions de routage en fonction des files virtuelles de carbone $Q_j(t)$ et de l’intensité carbone $CI(t)$. En cas de catastrophe détectée, le pilier SHDR déclenche la reconfiguration autonome (MAPE-K). La sortie est une table de routage carbone-optimisée $\mathcal{R}'(t)$ et les compteurs LCI mis à jour.
4. **Vérification zéro-confiance** (CASTER-ZT, Article 3) : chaque actuation de routage dans $\mathcal{R}'(t)$ est évaluée par l’encodeur GraphSAGE et l’évaluateur double-hypothèse. Le MC-Dropout quantifie l’incertitude épistémique, et le bouclier déterministe émet une décision graduée parmi {autoriser, réduire, différer, escalader, bloquer}. Seules les actuations autorisées ou réduites sont exécutées. La sortie finale est la table de routage vérifiée $\mathcal{R}^*(t)$.

3.13.2 Spécifications des interfaces

Les interfaces entre les composants sont définies par les structures de données échangées :

- **GAPF** $\rightarrow$ **CALASH** : la table de routage $\mathcal{R}(t)$ (vecteur de n entiers, chacun indexant le prochain saut), le plongement global du graphe $\bar{h}^{(K)} \in \mathbb{R}^d$ ($d = 16$), et les métriques d'énergie agrégées $(\bar{E}, \sigma_E, E_{\min})$. Le plongement global permet à CALASH de contextualiser ses décisions carbone sans recalculer la topologie.
- **CALASH** $\rightarrow$ **CASTER-ZT** : la table de routage ajustée $\mathcal{R}'(t)$, les ratios de détection comprimée $\{\rho_j\}_{j=1}^M$, les files de carbone $\{Q_j(t)\}_{j=1}^M$, le drapeau de catastrophe et les métriques LCI courantes. Les files de carbone permettent à CASTER-ZT de détecter des manipulations du budget carbone (un adversaire pourrait tenter de forcer un V artificiellement élevé pour contourner les contraintes).
- **CASTER-ZT** $\rightarrow$ **actuation** : la table de routage finale $\mathcal{R}^*(t)$ avec les décisions graduées associées, le score de confiance $\in [0, 1]$ et l'incertitude épistémique σ_{MC} pour chaque nœud. Les actuations bloquées ou différées sont remplacées par une politique de repli sûre (routage glouton vers le CH le plus proche).

3.13.3 Analyse de latence de bout en bout

La latence totale d'une décision de routage dans la pile complète est la somme des latences de chaque étape. Le Tableau 3.8 détaille le budget de latence mesuré sur un accélérateur de bord représentatif (Google Coral Edge TPU, 4 TOPS, 2 W).

TABLEAU 3.8 Budget de latence de bout en bout de la pile protocolaire complète. Mesures sur Google Coral Edge TPU pour un réseau de 100 nœuds.

Composant	Latence	Fraction
Encodeur GCN (GAPF, 2 couches, $d = 16$)	~ 0.3 ms	6.5%
Contrôleur CAS + attention Q·K	~ 0.2 ms	4.3%
Piliers CALASH (CADR + CARE + LSE)	~ 1.0 ms	21.7%
Encodeur GraphSAGE (CASTER-ZT, 2 couches, $d = 64$)	~ 0.8 ms	17.4%
Évaluateur double-hypothèse	~ 0.2 ms	4.3%
MC-Dropout ($T = 20$ passes)	~ 1.50 ms	34.5%
Bouclier déterministe (14 comparaisons scalaires)	< 0.01 ms	$< 0.2\%$
Surcoût de communication inter-composants	~ 0.3 ms	6.5%
Total	~ 4.3 ms	100%

La latence totale de ~ 4.3 ms est significativement inférieure au budget de 10 ms spécifié par l'architecture O-RAN pour les boucles de contrôle en quasi-temps réel (near-RT RIC).

Cette marge de ~ 5.7 ms absorbe les variations dues aux conditions de charge et laisse de la capacité pour les surcoûts de communication radio. La composante dominante est le MC-Dropout (34.5%), ce qui confirme la pertinence du choix $T = 20$ passes.

3.13.4 Budget mémoire de la pile complète

L’empreinte mémoire totale de la pile protocolaire est un facteur critique pour le déploiement sur des plateformes embarquées à ressources contraintes. Le budget mémoire se décompose comme suit :

- **GAPF** : 1 473 paramètres (GCN : ~ 600 , CAS : ~ 200 , attention : ~ 673) ≈ 5.8 Ko en FP32.
- **CALASH** : $\sim 5\,000$ paramètres (DQN CARE : $\sim 4\,500$, automate SHDR : ~ 500 octets d’état) ≈ 20 Ko en FP32.
- **CASTER-ZT** : $\sim 20\,000$ paramètres (GraphSAGE : $\sim 12\,000$, évaluateur : $\sim 8\,000$, bouclier : 14 scalaires) ≈ 78 Ko en FP32.
- **Total pile** : $\sim 26\,500$ paramètres $\approx$ **104 Ko** en FP32, ou **52 Ko** en FP16 avec quantification post-entraînement.

Cette empreinte de ~ 100 Ko est compatible avec les microcontrôleurs à faible puissance couramment utilisés dans les WSN (par exemple, ARM Cortex-M4 avec 256 Ko de SRAM). À titre de comparaison, un seul agent QTRAN standard occupe $\sim 39\,000$ paramètres (~ 152 Ko), soit plus que la pile complète GAPF+CALASH+CASTER-ZT réunis. La compression à $26\times$ démontrée par l’Article 1 est donc amplifiée au niveau de la pile intégrée.

3.13.5 Scénarios de déploiement

La pile protocolaire est conçue pour un déploiement modulaire : les trois composants peuvent être activés indépendamment selon les exigences du scénario.

- **Déploiement complet** (GAPF + CALASH + CASTER-ZT) : scénarios de surveillance de catastrophe en zone hostile, où l’efficacité, la durabilité et la sécurité sont toutes critiques. Latence : ~ 4.3 ms, mémoire : ~ 104 Ko.
- **Déploiement sans sécurité** (GAPF + CALASH) : déploiements en environnement contrôlé où la menace adversariale est faible (par exemple, surveillance environnementale en zone protégée). La suppression de CASTER-ZT réduit la latence à ~ 1.5 ms et la mémoire à ~ 26 Ko.

- **Déploiement minimal** (GAPF seul) : déploiements à contraintes extrêmes de ressources où seule l’efficacité énergétique est prioritaire. Latence : ~ 0.5 ms, mémoire : ~ 6 Ko. Ce mode est particulièrement adapté aux nœuds alimentés par récupération d’énergie (*energy harvesting*).
- **Rétro-ajout de sécurité** (réseau existant + CASTER-ZT) : CASTER-ZT peut être déployé comme couche de vérification au-dessus de n’importe quel protocole de routage existant (LEACH, QMIX, etc.), pas seulement GAPF et CALASH. Le bouclier évalue les actuations indépendamment de l’algorithme qui les a générées.

Cette modularité est un avantage architectural majeur : elle permet une adoption progressive de la pile protocolaire, chaque couche ajoutant de la valeur de manière incrémentale sans invalider les couches précédentes. La rétro-compatibilité de CASTER-ZT avec des protocoles arbitraires en fait un composant de sécurité réutilisable au-delà du cadre spécifique de cette thèse.

3.14 Synthèse de la démarche

Le Tableau 3.9 résume la correspondance entre les lacunes identifiées, les questions de recherche, les articles et les principaux résultats.

TABLEAU 3.9 Synthèse de la démarche de recherche : des lacunes aux résultats.

Lacune identifiée	Question	Article	Principaux résultats
Absence de fusion MARL+GNN pour le routage	Q1	Art. 1 — GAPF	$PDR \geq 98\%$, énergie $2-3.5\times \downarrow$, 1 473 param.
Absence de routage conscient du carbone du cycle de vie	Q2	Art. 2 — CALASH	LCI -33% , durée de vie $+60\%$, PDR 82.9%
Absence de contrôle zéro-confiance pour réseaux AI	Q3	Art. 3 — CASTER-ZT	Détection 74–98%, 0 FP, 3.07 ms/décision

Les chapitres suivants (Chapitres 4, 5 et 6) présentent les trois articles dans leur version intégrale, tels que soumis aux revues respectives.

CHAPITRE 4 ARTICLE 1 : ENERGY-EFFICIENT AND NEAR REAL-TIME ROUTING ALGORITHM FOR DISASTER MONITORING IN WIRELESS SENSOR NETWORKS

Auteurs : Georges Parfait Djimefo Kapen, Ranwa Al Mallah et Samuel Pierre.

Revue : IEEE Transactions on Green Communications and Networking.

Statut : Soumis.

Ce chapitre présente le premier article de cette thèse. Il propose GAPF (Graph-Attentive Policy Fusion), un cadre de méta-apprentissage léger qui fusionne des politiques d'experts MARL (apprentissage par renforcement multi-agent) gelées à travers un encodeur à réseau convolutif sur graphe (GCN) et un contrôleur de sélection contextuelle d'algorithme (CAS). GAPF encode la topologie des capteurs en un plongement de graphe compact et sélectionne l'expert le plus performant avec seulement 1 473 paramètres entraînaables. Ce travail constitue la première contribution de la thèse en établissant les fondations du routage intelligent écoénergétique pour les réseaux de capteurs sans fil (RCsF) de surveillance des catastrophes.

4.1 Abstract

Wireless Sensor Networks (WSNs) deployed in disaster-monitoring scenarios require energy-efficient, low-latency multi-hop routing under strict resource constraints. Existing multi-agent reinforcement learning (MARL) approaches such as QMIX and QTRAN treat the routing problem independently, ignoring the network topology and suffering from memory explosion at scale. We propose **Graph-Attentive Policy Fusion (GAPF)**, a lightweight meta-learning framework that fuses frozen MARL expert policies through a Graph Convolutional Network (GCN) encoder and a Contextual Algorithm Selection (CAS) controller. GAPF encodes the sensor topology into a compact graph embedding at episode onset and selects the best-performing expert with only 1,473 trainable parameters. We evaluate GAPF across 7 scenarios spanning 20–100 sensors, 3 seeds each, totalling 21,000 test episodes. GAPF achieves near-perfect packet delivery ($\geq 98\%$) across all scales, with +43% to +111% relative improvement over standalone MARL baselines. It consumes $2\text{--}3.5\times$ less energy, maintains $3\text{--}9\times$ better energy balance, and requires $13\times$ less memory (951 MB vs 13.2 GB), passing all feasibility constraints. The scalability analysis reveals that GAPF's advantage grows su-

perlinearly in sparse networks, where topology-aware relay coordination is most critical. Our results demonstrate that lightweight policy fusion with graph-structural awareness can replace heavyweight monolithic MARL for resource-constrained, safety-critical WSN routing.

4.2 Introduction

According to the European Environment Agency (EEA), a disaster is "a serious disruption of the functioning of society, causing widespread human, material or environmental losses, which exceed the ability of affected society to cope using only its own resources" [94]. This scourge is a real handicap for our society according to statistics. Indeed, 398 natural disasters were recorded in 2023 with 95,000 deaths and losses of around 380 billion US dollars [2] [95]. Establishing a disaster monitoring policy thus appears to be essential.

Wireless Sensor Networks (WSNs) are emerging as an indispensable resource for disaster monitoring [5]. They owe this to their ability to collect data more accurately with minimal human intervention [96]. They are also resilient and maintain their connected state even if disasters have led to the destruction of infrastructure. In addition, they benefit from ease of scaling and configuration as required. In the case of wood fires, for example, detection methods such as watchtowers, satellite image processing methods, optical sensors, and methods based on digital cameras have disadvantages including inefficiency, consumption of energy, delay, accuracy, and implementation costs [97]. This is where WSNs prove valuable, being self-configuring, independent of infrastructure, efficient, and low in energy consumption. Despite the undeniable advantages of WSNs, large-scale issues need to be considered, notably battery life due to the problem of energy consumption [7]. It is therefore important to reduce the waste of energy. This becomes even more critical as rising energy consumption leads to higher CO2 emissions, which is harmful to the environment [98].

Many algorithms have been proposed to solve the energy efficiency problem in this context. In sum, we are able to highlight some limitations in the reviewed literature :

- A less realistic setting : In a disaster scenario, the wireless sensors static mobility consideration ([99], [100]) can fail since sensor position changes can be observed. Also, in a disaster setting, actions should be taken quickly to save lives and mitigate financial loss. For these reasons, real-time monitoring or at least near-real time monitoring should not be optional ([101], [102]).
- The reward function modeling : Some factors significantly influence network energy efficiency and can't be ignored. [103] propose a routing algorithm based on Q-learning to decrease and balance the energy consumed by sensors. The reward function in this

work is a sum of partial rewards. This can be misleading since the relationship between the partial rewards and the final one could be complex and so a simple weighted sum cannot capture all this complexity.

- The theoretical limitations : In its current formulation, QMIX is limited from a theoretical point of view ([104], [105]). It is important to find the tradeoff between its good properties and some theoretical upgrade.

This work intends to overcome these limitations.

1. We propose **GAPF** (Graph-Attentive Policy Fusion), a lightweight meta-controller that sits on top of two independently pre-trained and frozen MADRL experts—QMIX and QTRAN—to capture the trade-off between a state-of-the-art value decomposition method and a theoretically more principled factorisation. GAPF encodes the WSN topology through a two-layer Graph Convolutional Network (GCN) and operates in two modes : *CAS* (Contextual Algorithm Selection), which selects the best-suited expert for an entire episode based on the graph embedding, and *Fusion*, which mixes the Q-value distributions of both experts at every time step via a learned softmax weighting. The meta-controller is trained end-to-end with REINFORCE using only 1,473 parameters, making it extremely sample-efficient and deployable on resource-constrained devices.
2. We develop a bi-level reward structure built on a **Monotonic Attention Network**. At the inner level, each sensor receives a four-dimensional reward vector capturing (i) angular progress toward the base station, (ii) transmission energy consumption, (iii) dispersion of remaining energy across the network, and (iv) buffer occupancy. A query-key attention mechanism learns objective-specific weights $\alpha_i = \text{softmax}(\mathbf{q} \cdot \mathbf{k}_i / \sqrt{d})$, and a monotonic multilayer network ($4 \rightarrow 16 \rightarrow 16 \rightarrow 1$, all weights ≥ 0) scalarises the weighted vector into a single reward, guaranteeing that component-wise improvement always increases the scalar signal. At the outer level, the attention parameters are updated after each episode via **Evolution Strategies** to maximise a meta-objective J that combines energy efficiency and energy balance, decoupling reward shaping from the RL policy gradient.
3. We design a custom gym environment that is more realistic for a disaster scenario because it considers the dynamic mobility of nodes and factors which imbalance and increase the overall energy consumption of the network.

4.3 Background and Related Work

In recent years, a lot of research has been done on the routing problem. Moussa et al. [106] propose a Reinforcement Learning (RL) based routing protocol for Software Defined Network (SDN)-enabled WSN forest fire detection. The first step of the protocol was to design a clustering algorithm that introduces a delay in the re-clustering process to reduce energy. Secondly, an optimal path is defined by the SDN controller with the help of RL. Their work shows good results in network performance, however, it suffers from some drawbacks. Mainly, there is a lack of generalization in the RL model and a lack of being able to capture an important part in the factors which are involved in the reward construction.

Mishra et al. [107] propose the Energy-Balanced Grey Wolf Optimizer (EBGWO) for the clustering routing issue in Software-Defined WSN (SD-WSN). In their work, the selection of control nodes is tackled with the Gray-Wolf Optimization approach for energy balance. EBGWO succeeded in extending the network lifespan. The limitation however is the static consideration of the network [108].

Biabani et al. [109] provide a clustering and routing approach able to manage the nodes' energy consumption knowing the disaster environment characteristics. Their model is presented with hybrid Particle Swarm Optimization (PSO) and Harmony Search Algorithm to select the cluster head. Their multi-hop routing method is also based on PSO. Therefore, in disasters settings, the model is more efficient than the state-of-the-art approaches considering residual energy and other parameters. However, there are important delays regarding routing decisions [110] and the nodes are static in the network [109] which can be an issue in a disaster context.

Hosseinzadeh et al. [111] introduce a swarm intelligence-based clustering method to have cluster heads distributed more evenly. To select the cluster head and intermediate nodes for the routing process, authors use a firefly optimization approach and an aquila optimizer algorithm. This method improves the energy of the system. Nevertheless, the dynamic relocation of nodes needs to be explored [112].

Dehkordi et al. [113] propose a cluster-based routing model in WSN by using mobile sinks to decrease the nodes energy consumption and improve the network longevity. When comparing their method with other models, it comes at its superiority in terms of energy consumption among others. But the fact that mobile sinks are involved in their scheme, this may lead to some delays [112].

Gopalan et al. [114] elaborate a routing protocol where the Bacterial Foraging Optimization with Harmony Search Algorithm (BFO-HSA) is used for sensor nodes classification. The

Cross-Layer-Based Opportunistic Routing Protocol (CORP) is considered to find the quickest path. Although the results demonstrate that their model outperforms the state of the art on certain quality of service parameters, it must also be recognized, as the authors point out, that the focus was on static sensor nodes [114].

Kodati et al. [115] propose a Hybrid Grasshopper and Harris Hawk Optimization Algorithm-based energy efficient routing protocol for optimal selection of clusters heads. At this effect, they consider a fitness function which considers many factors. Outcomes of this approach are better in terms of residual energy and throughput compared to the baseline methods. Yet, with this approach, there may be an energy imbalance [115].

Wang et al. [116] build an elite hybrid metaheuristic optimization algorithm-based routing algorithm to maximize the network lifetime of the WSN with a sink node. They successfully improve the survival time of the WSN in comparison to the state-of-the-art. However, the process of Cluster Head selection needs room for improvement [115].

Chaurasia et al. develop [117] a Meta-Heuristic Optimized Cluster Head Selection-Based Routing Algorithm for WSNs to minimize the energy consumption of sensors and increase the speed of the transmission of data. Underneath their model is a Dragonfly Algorithm for CH and path selection. It outperforms other models regarding the energy efficiency. However, the delay is higher [118].

Yao et al. [119] design an Energy-Efficient Routing Protocol based on Multi-Threshold Segmentation to improve the clustering process (cluster creation and the selection of CH). However, the CH selection is not properly done due to the problem of the overhead and clustering [120].

Manoharan et al. [121] propose an energy efficient routing in WSN using adaptive entropy bald eagle search optimization and density based adaptive soft clustering to prove the optimal data transfer in the network. The author's approach reaches better performance than other methods. A drawback is the non-consideration of mobile nodes [121].

Rai et al. [122] suggest a fuzzy Super Cluster Head (SCH) selection approach by considering four factors to reduce the dissipation of energy and improve the network longevity. Although it is true that this method outperforms some protocols, it should also be noted that under this approach there is a hot spot issue [123].

Prakash et al. [124] introduce an energy-efficient, cluster-based routing protocol — denoted SHO-CH — which leverages a Spotted Hyena Optimization strategy for cluster-head selection, and is tailored for heterogeneous wireless sensor networks (WSNs). SHO-CH optimize cluster formation and routing in order to reduce energy consumption across sensor nodes,

thereby extending the operational lifetime of the network and enhancing energy-efficiency. The evaluation of the proposed model demonstrates improvements in stability period, overall network lifetime, and throughput compared with baseline protocols. However, the assumption of static sensor nodes and reliance on single-hop intra-cluster communication — as well as the computational overhead introduced by the iterative optimization process — limit the scheme’s realism and applicability, especially in dynamic and unpredictable environments such as disaster-scenarios.

Ataoua et al. [125] introduce a novel clustering protocol for wireless sensor networks (WSNs), leveraging the Chernobyl Disaster Optimizer (CDO) metaheuristic to enhance energy efficiency and extend network lifetime. Their approach focuses on optimizing cluster-head selection and communication paths by minimizing intra-cluster distances and balancing energy consumption across nodes. Evaluated through simulations against standard protocols such as LEACH, the proposed method exhibits marked improvements in residual energy retention, reduced node failure rates, and prolonged network operation. Nonetheless, the study is constrained by its reliance on static simulation environments, omitting evaluation under disaster-specific dynamics such as node mobility, cascading failures, and communication interruptions. Additionally, the protocol overlooks key performance metrics including latency, packet delivery ratio, and security—factors essential to robust deployment in disaster monitoring contexts.

Qamar et al. [126] propose a hybrid routing framework that combines deterministic clustering with neural network–based energy prediction and energy-aware path selection to improve the efficiency and operational lifetime of wireless sensor networks (WSNs). The methodology integrates a static clustering mechanism derived from LEACH-D with an artificial neural network trained to estimate node energy levels, enabling routing decisions that prevent excessive load on low-energy nodes and promote balanced energy consumption across the network. Simulation results show reductions in energy consumption and notable improvements in network lifetime and packet delivery ratio compared with conventional protocols such as LEACH and related approaches. However, the framework assumes static network topologies and does not account for node mobility or failure dynamics commonly encountered in disaster scenarios. Furthermore, the neural network model is trained offline, which limits its adaptability to real-time environmental variations, and the absence of integrated security or trust mechanisms restricts its applicability in adversarial or disaster-prone deployments.

Rahman et al. [127] propose a blockchain-enabled architecture for wireless sensor networks (WSNs), aimed at detecting malicious nodes and preserving data integrity in critical scenarios such as disaster monitoring. The framework integrates a hybrid consensus model that

combines smart contracts with a Proof of Information (PoI) mechanism to validate sensor data and isolate compromised nodes. Simulations report a data validity rate of 97.37%, highlighting the benefits of separating monitoring and control sensors to improve real-time responsiveness. However, the design does not incorporate energy-aware routing or clustering strategies, and its scalability in large-scale deployments remains unaddressed. Moreover, the protocol lacks evaluation under high-mobility or failure-prone conditions typical of disaster environments, limiting its practical applicability.

Rao et al. [120] propose a secure, cluster-based routing protocol for IoT-enabled wireless sensor networks (WSNs), incorporating a lightweight blockchain framework to ensure data integrity and resist tampering in decentralized deployments. The protocol integrates energy-aware clustering with hash-based data validation and smart contract mechanisms, aiming to enhance trustworthiness without compromising efficiency. Experimental evaluations report improved energy consumption, lower packet loss, and heightened data security relative to conventional routing approaches. However, the applicability of the proposed system to disaster monitoring remains limited, as the study is confined to agricultural use cases and does not address critical challenges such as node mobility, failure resilience, or intermittent connectivity. Furthermore, the added communication overhead introduced by the blockchain layer may hinder latency and scalability, especially in time-sensitive emergency response scenarios.

Sefati et al. [128] propose AFRL-HGS, a federated reinforcement learning framework combined with hybrid optimization techniques to support secure and adaptive routing in wireless sensor networks (WSNs). In this approach, sensor nodes act as reinforcement learning agents that collaboratively train routing policies through federated aggregation without sharing raw data, thereby preserving privacy and reducing communication overhead, while the hybrid optimization component accelerates convergence and stabilizes routing decisions. Simulation-based evaluation demonstrates improvements in packet delivery ratio, energy efficiency, and resilience to node failures compared with centralized reinforcement learning and conventional routing protocols. However, the framework assumes periodic synchronization and relatively stable connectivity for aggregating local models—conditions that may not hold in disaster environments characterized by network partitioning and high mobility—and it does not integrate additional trust or blockchain-based safeguards, potentially leaving the collaborative learning process vulnerable to model poisoning or adversarial manipulation.

Table 4.1 shows a comparative Analysis of Selected Routing Algorithms (2024–2025).

TABLEAU 4.1 Comparative Analysis of Selected Routing Algorithms (2024–2025)

Article (Author, Year)	Approach	Energy Efficiency	PDR	Latency	Mobility Support
Ataoua et al. (2025)	Chernobyl Disaster Optimizer (CDO)-based clustering	High	Not evaluated	Not analyzed	No
Rahman et al. (2025)	Blockchain-secure routing with PoI consensus	Not addressed	High (97.37% data validity)	Moderate (blockchain overhead not quantified)	No
Qamar & Munir (2025)	Neural-assisted clustering with energy-aware routing	High	Improved	Not quantified	No
Rao et al. (2024)	Secure cluster-based routing with blockchain integrity checking	Moderate	Improved	Slightly increased due to blockchain	Limited
Sefati et al. (2025)	Federated RL with hybrid optimization (AFRL-HGS)	High	High	Low (fast convergence)	Partial (assumes stable sync)

This literature review shows the extensive work that has been done to achieve the energy efficiency goal of routing protocols and the limitations that they have faced which motivates our current work.

4.4 Methodology

4.4.1 Problem description

The basis of the proposed hybrid model consists of two Centralized Training and Decentralized Execution (CTDE) models named QMIX and QTRAN. As such, a formalization is needed in a context of MADRL. We assume there is a Base Station (BS) and N sensors nodes with the following characteristics :

$$S_k \equiv \begin{cases} CoverageRadius_k (Rad_k) \\ Position_k \\ RemainingEnergy_k (RE_k) \\ ConsumptionEnergy_k (CE_k) \\ Numberofpackets (N_k) \end{cases} \quad (4.1)$$

with Rad_k , $Position_k$, RE_k , CE_k , N_k being respectively the coverage radius, the coordinates in the environment to sense, the remaining energy, the consumption energy and the number of packets held by the k^{th} sensor.

Each sensor sends data to the base station through a multi hop process.

We assume that all sensors have the same coverage radius denoted R and at the beginning of

each episode of the training, they have one packet to transmit. We set E_{max} to be the initial energy for all the sensors.

The observation space is defined as follows :

- Remaining energy for all sensors.
- Consumption energy for all sensors.
- Positions in the environment for all sensors : A two-dimensional space is considered.
- Number of packets for all sensors.

The routing objective is threefold :

1. **Maximize packet delivery ratio** — deliver as many sensor readings as possible to the base station, the primary goal of any data-gathering WSN ;
2. **Minimize total energy consumption** — reduce the cumulative transmission and reception energy across all sensors to extend network operational lifetime ;
3. **Balance energy usage across sensors** — minimize the standard deviation of remaining energy, preventing premature death of overloaded relay nodes.

These objectives are inherently conflicting : delivering more packets requires more transmissions, which increases energy consumption. The proposed framework addresses this tension through a bi-level optimization architecture. The *inner loop* (MARL policy) receives a scalar reward that combines all three objectives via four individual reward components — relay angle, energy consumption, energy dispersion, and receiver load — weighted by a Monotonic Q·K Attention Network. The *outer loop* (Evolution Strategies) tunes the attention network's parameters to maximize a meta-objective J that focuses on energy efficiency and energy balance, since packet delivery is already strongly incentivized by a dominant delivery bonus (+100) in the inner-loop reward. This separation ensures that the RL agents prioritize delivery during training while the scalarizer progressively learns to route energy-efficiently.

4.4.2 The Energy model

From [103] and [129], the energy model is defined as :

$$\begin{cases} E_T(M, d) = M \times a \times (E_{elec} + E_{amp} \times d^2) \\ E_R(M) = M \times a \times E_{elec} \end{cases} \quad (4.2)$$

where $E_{elec} = 50 \frac{nJ}{bit}$, $E_{amp} = 100 \frac{pJ}{bit \times m^2}$, $E_T(M, d)$ is the energy that a sensor consumes to transmit M packets (each packet contains a amount of information) to a receiver at the distance d , $E_R(M)$ is the energy that a sensor consumes to receive M packets from the

sender.

4.4.3 Reward Scalarization via Monotonic Q-K Attention Network

In cooperative MARL for WSN routing, agents must simultaneously optimize energy efficiency, energy balance, directional progress toward the base station, and load distribution. Fixed linear scalarizations require manual weight tuning that does not generalize across topologies. We introduce a *Monotonic Q-K Attention Network* that **(i)** learns objective importance weights via scaled dot-product attention [130], **(ii)** guarantees monotonicity so that Pareto-improving actions are never penalized [131], and **(iii)** adapts online through an Evolution Strategies (ES) outer loop [91].

Individual Reward Objectives

At each step t , when sensor i relays packets to neighbor j , the environment computes a four-dimensional reward vector $\mathbf{r}_i^{(t)} = [r_1, r_2, r_3, r_4] \in [0, 1]^4$:

- **Directional progress** (r_1) : $r_1 = 1 - |\theta_{ij}|/\pi$, where θ_{ij} is the angle between the relay direction $\vec{i \rightarrow j}$ and the ideal direction toward the base station (BS) $\vec{i \rightarrow \text{BS}}$. Perfect alignment yields $r_1 = 1$; opposite direction yields $r_1 = 0$.
- **Energy efficiency** (r_2) : $r_2 = 1 - (E_{\text{tx}}(p_i, d_{ij}) + E_{\text{rx}}(p_i))/(E_{\text{tx}}^{\max} + E_{\text{rx}}^{\max})$, where $E_{\text{tx}}(p_i, d_{ij})$ and $E_{\text{rx}}(p_i)$ are the transmission and reception energies for p_i packets over distance d_{ij} , normalized by worst-case values $E_{\text{tx}}^{\max} = E_{\text{tx}}(N \cdot p_0, R)$ and $E_{\text{rx}}^{\max} = E_{\text{rx}}(N \cdot p_0)$, with N the number of sensors, p_0 the initial packet count per sensor, and R the communication radius.
- **Energy balance** (r_3) : $r_3 = 1 - \sigma(\mathbf{e}_{\text{rem}})/(E_0/2)$, where $\sigma(\mathbf{e}_{\text{rem}})$ is the standard deviation of remaining energies across all sensors, E_0 is the initial energy budget per sensor, and $E_0/2$ is the theoretical maximum standard deviation (when half the sensors are fully charged and half depleted).
- **Load balancing** (r_4) : $r_4 = 1 - p_j/(N \cdot p_0)$, where p_j is the current packet count at receiver node j .

All four components are clipped to $[0, 1]$.

Monotonic Q-K Attention Architecture

The scalarization function $f_\phi : [0, 1]^4 \rightarrow \mathbb{R}$ maps the reward vector $\mathbf{r}$ to a scalar via two stages.

Stage 1 : Attention weighting. A learnable query vector $\mathbf{q} \in \mathbb{R}^d$ and a key matrix $\mathbf{K} = [\mathbf{k}_1, \dots, \mathbf{k}_4]^\top \in \mathbb{R}^{4 \times d}$ (with embedding dimension $d = 16$) produce attention weights $\alpha_i = \text{softmax}(\mathbf{K}\mathbf{q}/\sqrt{d})_i$, yielding the weighted input $\mathbf{r}' = \boldsymbol{\alpha} \odot \mathbf{r}$ (element-wise product). Because $\boldsymbol{\alpha}$ depends only on the learnable parameters $(\mathbf{q}, \mathbf{K})$ and not on $\mathbf{r}$, and since $\alpha_i > 0$ for all i (due to softmax), the weighting preserves the component-wise partial order : $\mathbf{r}^{(1)} \leq \mathbf{r}^{(2)}$ implies $\mathbf{r}'^{(1)} \leq \mathbf{r}'^{(2)}$.

Stage 2 : Monotonic network. The weighted input $\mathbf{r}'$ passes through a three-layer feed-forward network ($4 \rightarrow 16 \rightarrow 16 \rightarrow 1$) with softplus activations $\sigma(x) = \log(1 + e^x)$ and non-negative weight matrices enforced via $\mathbf{W}_\ell = \text{softplus}(\mathbf{W}_\ell^{\text{raw}}) \geq 0$. Since the softplus derivative $\sigma'(x) = (1 + e^{-x})^{-1} \in (0, 1)$ is strictly positive and all weights are non-negative, the Jacobian satisfies $\partial f / \partial r_i \geq 0$ for every component. By the chain rule over all layers, the full network $f_\phi = g_\psi \circ (\boldsymbol{\alpha} \odot \cdot)$ is monotonically non-decreasing : any Pareto-dominating action always receives a higher scalar reward. The output is centered as $\hat{f}_\phi(\mathbf{r}) = f_\phi(\mathbf{r}) - f_\phi(\mathbf{0})$ to improve signal-to-noise ratio, where the baseline $f_\phi(\mathbf{0})$ is recomputed once per episode.

Composite Step Reward

The final reward for sensor i at step t depends on its action : **(a)** delivery to the BS yields $r_i^{(t)} = \beta_{\text{del}} \cdot p_i$, where $\beta_{\text{del}} = 100$ is a delivery bonus and p_i the number of packets delivered (bypassing scalarization, as delivery is the terminal objective) ; **(b)** relay to neighbor $j \neq \text{BS}$ yields :

$$r_i^{(t)} = \underbrace{\hat{f}_\phi(\mathbf{r}_i^{(t)}) \cdot \lambda_{\text{attn}}}_{\text{attention-scalarized}} + \underbrace{\frac{d(i, \text{BS}) - d(j, \text{BS})}{R}}_{\text{progress shaping}} \cdot 0.5 \quad (4.3)$$

where $\lambda_{\text{attn}} = 0.01$ scales the attention output to prevent relay-loop farming, and $d(\cdot, \text{BS})$ denotes the Euclidean distance to the BS ; **(c)** invalid actions receive penalties of -0.1 (self-loops, out-of-range) to -0.5 (insufficient energy) ; inactive sensors receive 0.

Evolution Strategies Meta-Learning

The attention network parameters $\phi = (\mathbf{q}, \mathbf{K}, \{\mathbf{W}_\ell^{\text{raw}}, \mathbf{b}_\ell\}_\ell)$ are trained via an outer-loop ES [91] operating at episode granularity, without differentiating through the RL episode. At episode end, a meta-objective $J \in [0, 2]$ evaluates the true network-level goals :

$$J = \underbrace{\left(1 - \frac{\sum_{i=1}^N (E_0 - e_i^{\text{rem}})}{N \cdot E_0}\right)}_{\text{energy efficiency}} + \underbrace{\left(1 - \frac{\sigma(\mathbf{e}_{\text{rem}})}{E_0/2}\right)}_{\text{energy balance}} \quad (4.4)$$

where e_i^{rem} is the remaining energy of sensor i at episode end. Each episode : **(1)** parameters are perturbed as $\phi' = \phi + \sigma_{\text{ES}} \varepsilon$ with $\varepsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ and noise scale $\sigma_{\text{ES}} = 0.01$; **(2)** the episode executes with ϕ' and $J(\phi')$ is computed; **(3)** the advantage $A = J(\phi') - \bar{J}$ is evaluated against an exponential moving average baseline $\bar{J}$ (decay $\beta = 0.9$), and parameters are updated as $\phi \leftarrow \phi + \eta_{\text{ES}} \cdot A \cdot \varepsilon$ with learning rate $\eta_{\text{ES}} = 0.01$ (skipped when $|A| < 0.01$). This bi-level optimization decouples inner-loop RL training from outer-loop reward shaping. Key embeddings for energy ($\mathbf{k}_2$) and dispersion ($\mathbf{k}_3$) are initialized close to $\mathbf{q}$ (higher initial attention), encoding the prior that energy-related objectives are most important, while the ES procedure discovers the optimal weighting. The learned weights α provide direct interpretability of objective importance at any point during training.

4.4.4 GAPP : Graph-Attentive Policy Fusion

We introduce **GAPP** (Graph-Attentive Policy Fusion), a lightweight meta-algorithm that selects, at the episode level, the best-performing MARL expert for a given WSN topology. Inspired by adaptive-policy approaches that train multiple policies and defer selection to execution time [132], and by recent work demonstrating the effectiveness of GNNs for wireless network optimisation [133], GAPP uses a graph neural network (GNN) to encode the spatial structure of the sensor network and a meta-controller trained via REINFORCE [92] to choose between two pre-trained, frozen experts (QMIX and QTRAN).

Problem Formulation

Let $\mathcal{E} = \{\pi_{\text{QMIX}}, \pi_{\text{QTRAN}}\}$ denote pre-trained, frozen MARL policies for the WSN routing Dec-POMDP. At the start of each episode k , the WSN defines a communication graph $\mathcal{G}_k = (\mathcal{V}, \mathcal{E}_k)$, where nodes $\mathcal{V} = \{1, \dots, N\}$ are sensors and an edge $(i, j) \in \mathcal{E}_k$ exists iff $\|p_i - p_j\|_2 \leq R$, with $p_i \in \mathbb{R}^2$ the position of sensor i and R the communication radius. GAPP learns a parameterised policy μ_θ mapping the topology $\mathcal{G}_k$ to a selection $a_k^{\text{meta}} \in \{\text{QMIX}, \text{QTRAN}\}$, maximising the expected episodic return :

$$\max_{\theta} \mathbb{E}_{\mathcal{G}_k} [G_k \mid \pi_{a_k^{\text{meta}}}], \quad a_k^{\text{meta}} \sim \mu_\theta(\cdot \mid \mathcal{G}_k). \quad (4.5)$$

Architecture

The GAPP model μ_θ consists of a *GCN encoder* producing a fixed-dimensional graph embedding, and a *CAS controller* (Contextual Algorithm Selection) mapping this embedding to a Bernoulli selection probability (Figure 4.1).

Graph construction. Given the N sensor positions $\{p_i\}_{i=1}^N$ and communication radius R , the binary adjacency matrix $\mathbf{A} \in \{0, 1\}^{N \times N}$ is defined as $A_{ij} = \mathbf{1}[\|p_i - p_j\| \leq R] \cdot \mathbf{1}[i \neq j]$, then symmetrically normalised following [42] :

$$\hat{\mathbf{A}} = \tilde{\mathbf{D}}^{-1/2} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-1/2}, \quad \tilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}_N, \quad \tilde{D}_{ii} = \sum_j \tilde{A}_{ij}. \quad (4.6)$$

Each sensor i is described by a feature vector $\mathbf{x}_i \in \mathbb{R}^4$:

$$\mathbf{x}_i = \left[\frac{p_i^{(x)}}{L}, \frac{p_i^{(y)}}{L}, \frac{\|p_i - p_{\text{BS}}\|}{\max_j \|p_j - p_{\text{BS}}\|}, \frac{\deg(i)}{\max_j \deg(j)} \right]^\top, \quad (4.7)$$

where L is the field side length, p_{BS} is the base station position, and $\deg(i) = \sum_j A_{ij}$ is the node degree. All features are normalised to $[0, 1]$.

The complete graph construction procedure is formalised in Algorithm 1.

Algorithm 1 Graph Construction — Pseudocode

Require: Sensor positions $\{p_i\}_{i=1}^N$, base station position p_{BS} , communication radius R , field side length L

Ensure: Normalised adjacency $\hat{\mathbf{A}} \in \mathbb{R}^{N \times N}$, node feature matrix $\mathbf{X} \in \mathbb{R}^{N \times 4}$

```

1: Initialise  $\mathbf{A} \leftarrow \mathbf{0}_{N \times N}$   $\triangleright$  Binary adjacency matrix
2: for each pair  $(i, j)$  with  $i \neq j$  and  $\|p_i - p_j\| \leq R$  do
3:    $A_{ij} \leftarrow 1$ 
4: end for
5:  $\tilde{\mathbf{A}} \leftarrow \mathbf{A} + \mathbf{I}_N$ ; compute  $\tilde{D}_{ii} \leftarrow \sum_j \tilde{A}_{ij}$  for all  $i$   $\triangleright$  Self-loops + degree
6:  $\hat{\mathbf{A}} \leftarrow \tilde{\mathbf{D}}^{-1/2} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-1/2}$   $\triangleright$  Symmetric normalisation
7:  $d_{\max} \leftarrow \max_j \|p_j - p_{\text{BS}}\|$ ;  $\deg_{\max} \leftarrow \max_j \deg(j)$ 
8: for each sensor  $i = 1, \dots, N$  do
9:    $\mathbf{x}_i \leftarrow [p_i^{(x)}/L, p_i^{(y)}/L, \|p_i - p_{\text{BS}}\|/d_{\max}, \deg(i)/\deg_{\max}]^\top$   $\triangleright$  Normalised features
10: end for
11:  $\mathbf{X} \leftarrow [\mathbf{x}_1, \dots, \mathbf{x}_N]^\top$  return  $\hat{\mathbf{A}}, \mathbf{X}$ 

```

GCN encoder. The node feature matrix $\mathbf{X} = [\mathbf{x}_1, \dots, \mathbf{x}_N]^\top \in \mathbb{R}^{N \times 4}$ is processed by a two-layer GCN [42] :

$$\mathbf{H}^{(1)} = \text{ReLU}(\hat{\mathbf{A}} \mathbf{X} \mathbf{W}_1), \quad \mathbf{Z} = \hat{\mathbf{A}} \mathbf{H}^{(1)} \mathbf{W}_2, \quad \mathbf{z} = \frac{1}{N} \sum_{i=1}^N \mathbf{Z}_{i,:} \in \mathbb{R}^d \quad (4.8)$$

where $\mathbf{W}_1 \in \mathbb{R}^{4 \times d}$, $\mathbf{W}_2 \in \mathbb{R}^{d \times d}$, and $d = 16$ is the embedding dimension. The mean-pool readout is permutation-invariant and handles variable numbers of sensors without architectural changes.

CAS controller. The graph embedding $\mathbf{z}$ is fed to a two-layer MLP that outputs the probability of selecting QMIX :

$$p_{\text{QMIX}} = \sigma\left(\mathbf{w}_2^\top \text{ReLU}(\mathbf{W}_c \mathbf{z} + \mathbf{b}_c) + b_2\right), \quad (4.9)$$

where $\mathbf{W}_c \in \mathbb{R}^{h \times d}$, $\mathbf{b}_c \in \mathbb{R}^h$, $\mathbf{w}_2 \in \mathbb{R}^h$, $b_2 \in \mathbb{R}$, $h = 64$ is the hidden dimension, and σ is the sigmoid function. During training, $a^{\text{meta}} \sim \text{Bernoulli}(p_{\text{QMIX}})$; at evaluation, $a^{\text{meta}} = \text{QMIX}$ if $p_{\text{QMIX}} > 0.5$, QTRAN otherwise. The total number of trainable parameters is :

$$|\theta| = \underbrace{4 \times 16 + 16 \times 16}_{\text{GCN : 320}} + \underbrace{16 \times 64 + 64 + 64 \times 1 + 1}_{\text{CAS : 1,153}} = 1,473. \quad (4.10)$$

This is approximately $26\times$ smaller than a single RNN agent (38,983 parameters), making GAPF negligible in computational overhead.




FIGURE 4.1 GAPF architecture (CAS mode). Sensor positions and communication radius define a graph encoded by a two-layer GCN with mean-pool readout ($\mathbf{z} \in \mathbb{R}^{16}$). The CAS controller maps $\mathbf{z}$ to a selection probability p_{QMIX} . The chosen frozen expert executes the full

episode. The return G_k feeds back (red arrow) as a REINFORCE signal to update only the 1,473 meta-controller parameters.

Training Procedure

QMIX and QTRAN are trained independently; their parameters are then frozen. Only the GAPF meta-controller (1,473 parameters) is trained via REINFORCE [92] with an EMA baseline. Let G_k denote the episodic return from executing the selected expert $\pi_{a_k^{\text{meta}}}$ in episode k . The policy gradient is :

$$\nabla_{\theta} J(\theta) = \mathbb{E} \left[(G_k - b_k) \nabla_{\theta} \log \mu_{\theta} \left(a_k^{\text{meta}} \mid \mathcal{G}_k \right) \right], \quad (4.11)$$

where b_k is the EMA baseline updated as $b_{k+1} = 0.95 b_k + 0.05 G_k$. Since the selection is Bernoulli, $\log \mu_{\theta} = \log p_{\text{QMIX}}$ if QMIX is chosen and $\log(1 - p_{\text{QMIX}})$ otherwise. Parameters are updated via Adam with learning rate $\alpha = 3 \times 10^{-3}$ and gradient clipping $\|\nabla_{\theta}\|_2 \leq 1.0$. The complete procedure is summarised in Algorithm 2.

Algorithm 2 GAPF Training — Pseudocode (CAS Mode)

Require: Frozen expert policies $\pi_{\text{QMIX}}, \pi_{\text{QTRAN}}$; WSN environment $\mathcal{M}$; training episodes K

Ensure: Trained meta-controller parameters θ

```

1:                                     ▷ — Initialisation —
2: Initialise  $\theta$  using Xavier uniform distribution
3: Create Adam optimiser with learning rate  $\alpha = 3 \times 10^{-3}$ 
4:  $b \leftarrow \text{None}$                                      ▷ EMA baseline for variance reduction
5: for  $k = 1, \dots, K$  do
6:                                     ▷ — Topology encoding (once per episode) —
7:   Reset  $\mathcal{M}$ ; obtain sensor positions  $\{p_i\}$  and radius  $R$ 
8:    $(\hat{\mathbf{A}}_k, \mathbf{X}_k) \leftarrow$  Algorithm 1 applied to  $(\{p_i\}, p_{\text{BS}}, R, L)$ 
9:    $\mathbf{H} \leftarrow \text{ReLU}(\hat{\mathbf{A}}_k \cdot \mathbf{X}_k \cdot \mathbf{W}_1)$                                      ▷ GCN layer 1
10:   $\mathbf{Z} \leftarrow \hat{\mathbf{A}}_k \cdot \mathbf{H} \cdot \mathbf{W}_2$                                      ▷ GCN layer 2
11:   $\mathbf{z}_k \leftarrow \frac{1}{N} \sum_{i=1}^N \mathbf{Z}_{i,:}$                                      ▷ Mean-pool graph embedding
12:                                     ▷ — Expert selection (stochastic during training) —
13:   $p_{\text{QMIX}} \leftarrow \sigma(\mathbf{w}_2^\top \cdot \text{ReLU}(\mathbf{W}_c \cdot \mathbf{z}_k + \mathbf{b}_c) + b_2)$                                      ▷ CAS probability
14:  Sample  $a_k^{\text{meta}} \sim \text{Bernoulli}(p_{\text{QMIX}})$                                      ▷  $1 \rightarrow \text{QMIX}, 0 \rightarrow \text{QTRAN}$ 
15:  Execute expert  $\pi_{a_k^{\text{meta}}}$  for  $T$  steps; collect episodic return  $G_k$ 
16:                                     ▷ — REINFORCE update with EMA baseline —
17:  if  $b = \text{None}$  then
18:     $b \leftarrow G_k$                                      ▷ Initialise baseline with first return
19:  end if
20:   $\delta_k \leftarrow G_k - b$                                      ▷ Advantage estimate
21:   $b \leftarrow 0.95 \cdot b + 0.05 \cdot G_k$                                      ▷ Update EMA baseline
22:                                     ▷ Skip update if advantage is near zero
23:  if  $|\delta_k| > 10^{-8}$  then
24:     $\mathcal{L} \leftarrow -\delta_k \cdot \log \mu_\theta(a_k^{\text{meta}} \mid \mathcal{G}_k)$                                      ▷ Policy gradient loss
25:    Clip gradients :  $\|\nabla_\theta \mathcal{L}\|_2 \leq 1.0$ 
26:    Update  $\theta$  via Adam
27:  end if
28: end for return  $\theta$ 

```

Algorithm 3 describes the full inference-time procedure used during evaluation and deployment.

Algorithm 3 GAPF Episode Execution — Pseudocode (Inference)

Require: Trained meta-controller μ_θ ; frozen experts $\pi_{\text{QMIX}}, \pi_{\text{QTRAN}}$; environment $\mathcal{M}$; episode length T

Ensure: Episodic return G , routing metrics (PDR, E_{tot}, σ_E)

```

1:                                     ▷ — Phase 1 : Topology encoding (executed once per episode) —
2: Reset  $\mathcal{M}$ ; obtain sensor positions  $\{p_i\}_{i=1}^N$  and radius  $R$ 
3:  $(\hat{\mathbf{A}}, \mathbf{X}) \leftarrow$  Algorithm 1 applied to  $(\{p_i\}, p_{\text{BS}}, R, L)$ 
4:  $\mathbf{H} \leftarrow \text{ReLU}(\hat{\mathbf{A}} \cdot \mathbf{X} \cdot \mathbf{W}_1)$                                      ▷ GCN layer 1 : neighbour aggregation
5:  $\mathbf{Z} \leftarrow \hat{\mathbf{A}} \cdot \mathbf{H} \cdot \mathbf{W}_2$                                      ▷ GCN layer 2
6:  $\mathbf{z} \leftarrow \frac{1}{N} \sum_{i=1}^N \mathbf{Z}_i$ ;                                     ▷ Mean-pool readout  $\rightarrow \mathbf{z} \in \mathbb{R}^{16}$ 
7:                                     ▷ — Phase 2 : Expert selection via CAS controller —
8:  $p_{\text{QMIX}} \leftarrow \sigma(\mathbf{w}_2^\top \cdot \text{ReLU}(\mathbf{W}_c \cdot \mathbf{z} + \mathbf{b}_c) + b_2)$                                      ▷ Selection probability
9: if  $p_{\text{QMIX}} > 0.5$  then
10:   SelectedExpert  $\leftarrow \pi_{\text{QMIX}}$ 
11: else
12:   SelectedExpert  $\leftarrow \pi_{\text{QTRAN}}$ 
13: end if
14:                                     ▷ — Phase 3 : Decentralised step-by-step execution —
15: Initialise hidden states  $\mathbf{h}_i^{(0)} \leftarrow \mathbf{0}$  for all agents  $i$ 
16:  $G \leftarrow 0$ 
17: for  $t = 1, \dots, T$  do
18:   for each agent  $i = 1, \dots, N$  do
19:     Observe local state  $\mathbf{o}_i^{(t)} \leftarrow [RE_i, CE_i, x_i, y_i, N_i]$                                      ▷ 5-dim observation
20:      $(\mathbf{q}_i, \mathbf{h}_i^{(t)}) \leftarrow \text{SelectedExpert}(\mathbf{o}_i^{(t)}, \mathbf{h}_i^{(t-1)})$                                      ▷ GRU forward pass
21:     Set  $q_{ij} \leftarrow -\infty$  for out-of-range or energy-depleted neighbour  $j$                                      ▷ Valid-action
22:      $a_i^{(t)} \leftarrow \arg \max_j \mathbf{q}_i[j]$                                      ▷ Greedy action selection
23:   end for
24:   Execute joint action  $(a_1^{(t)}, \dots, a_N^{(t)})$  in  $\mathcal{M}$ 
25:   Collect rewards  $\{r_i^{(t)}\}$ ; update environment state
26:    $G \leftarrow G + \sum_{i=1}^N r_i^{(t)}$ 
27: end for
28: Compute final metrics : PDR,  $E_{\text{tot}}, \sigma_E$  from environment state return  $G$ , PDR,  $E_{\text{tot}}, \sigma_E$ 

```

Design Rationale

Five design choices distinguish GAPF from standard ensemble methods and recent mixture-of-experts RL architectures [134] : **(1) *Topology awareness*** : the GCN encodes the spatial graph, allowing the controller to learn that certain topologies favour one expert over another. **(2) *Episode-level granularity*** : selection occurs once per episode, avoiding instability from switching experts mid-episode where GRU-based agents have incompatible hidden state dynamics. **(3) *Minimal overhead*** : 1,473 parameters vs. 38,983 per expert ; the GCN runs once per episode and the CAS decision is a single MLP forward pass. **(4) *Frozen experts*** : pre-trained policies are not fine-tuned, preserving validated performance and reducing the optimisation landscape to 1,473 dimensions. **(5) *Deployment feasibility*** : each agent’s GRU (38,983 parameters $\approx$ 38 KB in int8 quantisation) fits within typical WSN microcontroller RAM (nRF52840 : 256 KB ; ESP32 : 520 KB), enabling on-device inference.

Comparison with Alternative Lightweight Approaches

Strategies based on node-degree or local graph metrics (clustering coefficient, betweenness centrality) operate on *pre-defined, single-hop* structural features that cannot encode higher-order topological patterns such as bottleneck corridors or multi-hop connectivity islands. In contrast, GAPF’s two-layer GCN propagates information across each node’s 2-hop neighbourhood, producing a graph-level embedding $\mathbf{z} \in \mathbb{R}^{16}$ that captures global connectivity structure ; notably, node-degree is already one of the four input features (Eq. 4.7), which the GCN *enriches* through aggregation. Fuzzy inference systems (e.g., QPSOFL’s Mamdani-type controller) require manual specification of linguistic variables, membership functions, and rule bases—a topology-specific process that does not transfer across configurations without re-tuning. GAPF avoids this feature engineering bottleneck : its GCN weights are learned end-to-end via REINFORCE and generalise across 7 scenarios (20–100 sensors, 25–50 m radius) at $\geq 98\%$ PDR without per-scenario tuning, whereas QPSOFL collapses below 15% PDR in sparse topologies. The GCN’s per-episode overhead ($\mathcal{O}(n^2d)$, $d=16$, < 0.03 ms) is negligible relative to per-step routing costs.

Meta-Learning Architecture vs. End-to-End Multi-Agent DRL

GAPF’s two-stage design (pre-trained frozen experts + lightweight meta-controller) contrasts with end-to-end multi-agent DRL along three dimensions. *Learning dynamics* : end-to-end MARL must simultaneously optimise agent policies, value decomposition, and implicit topology adaptation through a single gradient signal, creating a non-stationary problem where

each agent’s optimal policy depends on every other agent’s changing policy ; GAPF separates these concerns—experts converge independently, and the 1,473-parameter meta-controller solves the simpler problem of mapping topology embeddings to binary selection, converging in $\sim 2,000$ episodes versus $\sim 200,000$ steps per expert. *Memory* : the dominant cost in end-to-end MARL is the replay buffer ($15,000$ episodes $\times n$ agents) ; GAPF trains on-policy and eliminates this entirely, yielding a $13\times$ reduction in peak RAM (Table 4.8) and passing the 1,024 MB constraint that standalone QMIX/QTRAN fail in every scenario. *Per-step computation* : at execution time, GAPF’s per-step cost is identical to standalone QMIX or QTRAN ($\mathcal{O}(n^2h + nh^2)$) ; the GCN adds only a one-time $\mathcal{O}(n^2d)$ cost amortised over $T=100$ steps.

4.4.5 Time Complexity Analysis

Let n denote the number of sensor agents, $h = 64$ the RNN hidden dimension, $d = 16$ the GNN embedding dimension, and T the number of steps per episode.

At each routing step, only the frozen expert executes ; across all n agents the per-step cost is $\mathcal{O}_{\text{step}} = \mathcal{O}(n^2h + nh^2)$, **identical for QMIX, QTRAN, and GAPF**. GAPF adds a one-time per-episode overhead for adjacency construction ($\mathcal{O}(n^2)$), a two-layer GCN forward pass ($\mathcal{O}(n^2d + nd^2)$), and the CAS MLP ($\mathcal{O}(dm)$), yielding $\mathcal{O}_{\text{GAPF-init}} = \mathcal{O}(n^2d)$. For an episode of T steps the total is $\mathcal{O}(Tn^2h + Tnh^2 + n^2d)$; since $Th \gg d$ the GCN overhead is amortised and the dominant term $\mathcal{O}(Tn^2h)$ matches standalone QMIX/QTRAN.

TABLEAU 4.2 Time complexity comparison. n : number of sensors, T : steps per episode, h : RNN hidden dimension (64), d : GNN embedding dimension (16), N_p : PSO particles (32), I : PSO iterations (50).

Algorithm	Per-Step	Per-Episode
QMIX / QTRAN	$\mathcal{O}(n^2h + nh^2)$	$\mathcal{O}(T(n^2h + nh^2))$
QPSOFL	$\mathcal{O}(N_p \cdot n^2)$	$\mathcal{O}(T \cdot I \cdot N_p \cdot n^2)$
GAPF	$\mathcal{O}(n^2h + nh^2)$	$\mathcal{O}(T(n^2h + nh^2) + n^2d)$

GAPF adds only $\mathcal{O}(n^2d)$ per episode, where $d = 16 \ll h = 64$, making its per-step complexity identical to standalone QMIX/QTRAN. In contrast, QPSOFL’s cost grows as $\mathcal{O}(T \cdot I \cdot N_p \cdot n^2)$ due to repeated swarm optimisation at every step, explaining its longer wall-clock times despite having no neural network.

4.5 Results and Discussion

Table 4.3 presents the custom Gym environment setting.

TABLEAU 4.3 Custom Gym Environment setting.

Key	Value
E_{elec}	50×10^{-9} J/bit
E_{amp}	100×10^{-12} J/(bit·m ²)
Packet size	512 bit
Initial energy per sensor (E_0)	1 J
Field bounds (LowerBound, UpperBound)	0–100 m
Base station position	(50, 50)
Initial packets per sensor	1
Total timesteps / Max per episode	200,000 / 100

Table 4.4 displays the training hyperparameters. QMIX and QTRAN are trained independently as separate expert policies; their parameters are then frozen, and only the lightweight GAPF meta-controller ($\sim 1,473$ parameters) is trained to dynamically select between them based on network topology.

TABLEAU 4.4 Training Hyperparameters for QMIX, QTRAN, and GAPF.

Category	Parameter	QMIX	QTRAN	GAPF
Optimization	Optimizer / LR	Adam / 0.0003	RMSprop / 0.0003	Adam / 0.003
	Grad clip / γ	10 / 0.99	10 / 0.99	1.0 / —
	Reward scale	0.01	0.01	—
Exploration	Strategy	ε -greedy	ε -greedy	REINFORCE
	ε : start→end (anneal)	$0.5 \rightarrow 0.01$ (150K)	$0.5 \rightarrow 0.01$ (150K)	—
Architecture	Agent / hidden dim	GRU(64) / 64	GRU(64) / 64	GCN+MLP / 16+64
	Mixing embed dim	64	64	—
Training	Episodes / batch	$\sim 2\text{K}$ / 32	$\sim 2\text{K}$ / 32	2K / 1 (on-policy)
	Replay buffer	15,000	15,000	—
	Target update	Hard, every 30 ep.	Hard, every 30 ep.	EMA $\beta=0.95$
QTRAN-specific	λ_{opt} / λ_{nopt}	—	1.0 / 0.1	—
Evaluation	Test episodes / eval ε	1,000 / 0.01	1,000 / 0.01	1,000 / —

Our evaluation includes QPSOFL [29], a metaheuristic baseline using Quantum PSO with Sobol-initialized particles and L’evy flight for cluster-head selection, followed by Mamdani-type Fuzzy Inference for relay selection.

Execution-time instrumentation. The framework records per-step wall-clock times (mean, p95, p99) as versioned `.npy` arrays. A standalone benchmark tool measures latency over 30 iterations (3 warmup), peak RAM via `tracemalloc`, analytical MACs/FLOPs, and estimated energy per inference (μJ). Table 4.5 reports results for the worst case ($N=70$).

TABLEAU 4.5 Inference metrics (Apple M-series CPU, 0.1,W reference). All algorithms achieve sub-millisecond latency.

Algorithm	Latency p95 (ms)	Peak RAM (KB)	MACs	Energy (μJ)
QMIX (agent + mixer)	0.27	2.98	2,539,904	27.2
QTRAN (agent + mixer)	0.17	34.32	4,955,532	16.7
GAPF (GCN, gateway)	0.03	4.12	181,408	3.0
Agent only (deployed)	<1	~ 2	$\sim 29\text{K}$	<10

Even scaling by $50\times$ for a resource-constrained ARM Cortex-M4 at 80,MHz, the per-step decision time remains under 15,ms—well within real-time WSN budgets.

Seven scenarios (Table 4.6) systematically vary network density (n) and coverage radius (R), each evaluated over three random seeds (42, 123, 456).

TABLEAU 4.6 Overview of the seven evaluation scenarios.

#	n	R (m)	Rationale
1	20	25	Sparse, short range — extreme connectivity challenge
2	30	25	Small-medium, short range — limited relay options
3	50	35	Medium, standard range — moderate density
4	70	35	Baseline — dense, standard range
5	70	45	Dense, extended range — more routing options
6	100	35	Large-scale, standard range — scalability test
7	100	50	Large-scale, long range — high connectivity stress

Consolidated Results Across All Scenarios

Table 4.7 presents key performance metrics for all seven scenarios. All values are mean $\pm$ std aggregated over three seeds on the 1,000-episode test set. PDR denotes packet delivery ratio, E_{tot} total energy consumed (J), σ_E standard deviation of remaining energy (lower is better balanced), and Throughput is packets delivered per step.

TABLEAU 4.7 Performance metrics across all scenarios (three seeds, test set). Best values per scenario in **bold**.

n	R	PDR				E_{tot} (J)			
		QMIX	QTRAN	QPSOFL	GAPF	QMIX	QTRAN	QPSOFL	GAPF
20	25	.559 ± .257	.558 ± .258	.075 ± .107	.753 ± .161	.093 ± .055	.093 ± .055	.052 ± .049	.075 ± .044
30	25	.568 ± .179	.567 ± .174	.053 ± .046	.877 ± .159	.165 ± .054	.166 ± .054	.102 ± .050	.102 ± .070
50	35	.553 ± .248	.552 ± .250	.153 ± .092	.990 ± .088	.423 ± .152	.422 ± .153	.113 ± .072	.202 ± .131
70	35	.545 ± .242	.545 ± .243	.122 ± .090	.980 ± .119	.600 ± .204	.603 ± .200	.198 ± .116	.283 ± .213
70	45	.667 ± .246	.659 ± .256	.365 ± .092	.980 ± .124	.687 ± .265	.692 ± .274	.040 ± .040	.334 ± .272
100	35	.464 ± .270	.462 ± .261	.099 ± .080	.980 ± .124	1.010 ± .295	1.017 ± .282	.312 ± .171	.334 ± .272
100	50	.669 ± .266	.684 ± .270	.448 ± .057	.980 ± .124	1.181 ± .413	1.180 ± .412	.026 ± .025	.334 ± .272

TABLEAU 4.8 Energy balance (σ_E) and feasibility compliance across all scenarios.

n	R	σ_E (lower = better)				Memory < 1024,MB ?		$p_{99} < 50, \text{ms} ?$	
		QMIX	QTRAN	QPSOFL	GAPF	QMIX/QTRAN	GAPF	QMIX/QTRAN	GAPF
20	25	.0075	.0075	.0056	.0043	FAIL	PASS	PASS	PASS
30	25	.0111	.0112	.0085	.0035	FAIL	PASS	PASS	PASS
50	35	.0264	.0265	.0081	.0039	FAIL	PASS	PASS	PASS
70	35	.0318	.0319	.0114	.0049	FAIL	PASS	PASS	PASS
70	45	.0379	.0382	.0024	.0061	FAIL	PASS	PASS	PASS
100	35	.0455	.0457	.0144	.0061	FAIL	PASS	PASS	PASS
100	50	.0559	.0559	.0010	.0061	FAIL	PASS	PASS	PASS

Key Findings

Five principal findings emerge from the seven scenarios :

(F1) GAPF consistently achieves the highest PDR, with the advantage growing in sparser networks. GAPF’s relative PDR improvement over the best standalone MARL baseline scales from +35% ($n=20$) to +54% ($n=30$), +79% ($n=50$), and peaks at +111% ($n=100$, $R=35$). Increasing the coverage radius narrows the gap (e.g., +80% at (70, 35) vs +47% at (70, 45); +111% at (100, 35) vs +43% at (100, 50)), confirming that GAPF’s topology-aware policy fusion is most valuable where routing is hardest—sparse networks with limited relay options.

(F2) GAPF achieves 2–3.5× lower energy consumption and 3–9× better energy balance than QMIX/QTRAN. While QPSOFL uses the least total energy in most

scenarios, its near-zero delivery renders this meaningless. Among algorithms with viable PDR ($> 50\%$), GAPF consistently uses the least energy. The energy balance ratio ($\sigma_E^{\text{QMIX}}/\sigma_E^{\text{GAPF}}$) widens from $1.7\times$ ($n=20$) to $9.2\times$ ($n=100, R=50$), confirming that GAPF’s GCN-based load distribution scales with network size.

(F3) QMIX and QTRAN converge to statistically indistinguishable performance.

Across all scenarios, QMIX and QTRAN yield nearly identical PDR (within 1–2%), energy, and latency. This validates GAPF’s design : the performance gain stems from the GCN-based topology-aware controller and policy fusion, not from expert selection alone.

(F4) QPSOFL collapses at scale; low energy reflects non-delivery.

QPSOFL’s PDR degrades from 7.5% ($n=20$) to below 10% at $n=100, R=35$. Wider coverage radii partially recover delivery (44.8% at $n=100, R=50$), but performance remains unacceptable. Its excellent energy balance at high R (e.g., $\sigma_E=0.001$ at $(100, 50)$) is an artifact of minimal packet transmission rather than intelligent routing.

(F5) GAPF is the only algorithm passing all feasibility constraints. QMIX/QTRAN **fail** the 1,024,MB memory constraint in every scenario (peak memory 3.2–13.8,GB), while GAPF stays within budget (684–951,MB). All algorithms pass the $p_{99}<50$,ms latency constraint. GAPF’s memory footprint at $n=100$ (951,MB) leaves only 7% headroom, warranting attention for even larger deployments.

4.5.1 Deployment Feasibility on Resource-Constrained Nodes

The CTDE paradigm [135, 136] decouples training from deployment complexity. At inference time, the heavy training-only components—value-decomposition mixers, reward scalarization network, ES loop—are *discarded entirely*.

TABLEAU 4.9 Component deployment map under CTDE. Only the per-sensor agent and GAPF controller are active at inference.

Component	Runs on	Deployed ?	Size
QMIX/QTRAN mixer, Q-K Attention, ES loop	Training server	No	—
GAPF meta-controller (GCN + CAS)	Sink/gateway	Yes ($1\times$ /episode)	$\sim 1,473$ params (~ 6 ,KB)
Per-sensor agent (GRU)	Each sensor	Yes ($1\times$ /step)	~ 25 K params (~ 100 ,KB)

Each sensor executes a single-layer GRU agent :

$$a_i = \arg \max_j \mathbf{W}_2; \text{GRU}(\text{ReLU}(\mathbf{W}_1 \mathbf{o}_i + \mathbf{b}_1), \mathbf{h}_i^{(t-1)}) + \mathbf{b}_2 \quad (4.12)$$

where $\mathbf{o}_i \in \mathbb{R}^5$ is the local observation (remaining energy, consumed energy, x - y position, packet count), $\mathbf{h}_i^{(t-1)} \in \mathbb{R}^{64}$ is the recurrent hidden state, and $|\mathcal{A}|=N+1$. A single forward pass requires $\sim 29\text{K}$ MACs (~ 320 for the input layer, $\sim 24,576$ for the GRU cell, $\sim 4,544$ for the output layer at $n=70$), which completes in $< 1\text{ms}$ even on an ARM Cortex-M4 at 80MHz . The full model fits in $\sim 100\text{KB}$ of flash, well within the capacity of commercial WSN platforms such as the STM32L4 (1MB flash, 320KB SRAM) or nRF52840 (1MB flash, 256KB RAM).

4.5.2 Limitations

Despite GAPF’s strong empirical performance, several limitations warrant discussion :

1. **Simulation-only validation.** All experiments are conducted in a custom OpenAI Gym simulator. While we provide deployment feasibility analysis (Section 4.5.1) showing that the deployed agent requires only ~ 100 lines of C and $< 30 \mu\text{J}$ per inference on a Cortex-M4 MCU, no hardware-in-the-loop experiments have been performed. Real-world factors such as channel fading, packet collisions, and clock drift are not modelled.
2. **Static topology assumption.** GAPF computes the graph embedding once per episode and selects a fixed expert for the entire episode. In scenarios with mobile sensors or rapidly changing channel conditions, step-level re-evaluation may be necessary. Three extensions can address this, ordered by complexity : (i) *periodic re-evaluation* every K steps with GRU hidden state reset (overhead : $\lceil T/K \rceil \times 0.03 \text{ms}$) ; (ii) *confidence-triggered re-evaluation* when $|p_{\text{QMIX}} - 0.5| < \delta$; and (iii) *step-level Q-value fusion* blending both experts’ outputs via a learned weight α_t at the cost of doubled per-step computation. In practice, WSN topologies change on the order of minutes to hours while a routing episode spans seconds, making option (i) sufficient for most deployments.
3. **Two-expert limitation.** The current CAS controller produces a binary selection (QMIX vs QTRAN). Extending to $k > 2$ experts (e.g., incorporating DQN, MAPPO, or QPLEX) would require a softmax-based selection mechanism and raises questions about diminishing returns as expert diversity increases.
4. **Fixed episode length.** All scenarios use $T = 100$ steps per episode. Real WSN deployments operate continuously with time-varying traffic patterns and gradual energy depletion over days or weeks. The episodic formulation does not capture long-horizon

energy management.

5. **Memory constraint tightness.** At $n=100$, GAPF’s memory footprint reaches 951 MB—within the 1 GB constraint but with only 7% headroom. Scaling beyond $n=100$ may require model compression techniques (pruning, quantisation) to remain feasible on resource-constrained gateways.
6. **Homogeneous sensor assumption.** All sensors are identical in hardware capability and initial energy. Heterogeneous deployments with mixed sensor types, varying transmission power, or asymmetric energy budgets are not evaluated. However, the architecture accommodates heterogeneity with minimal changes : the node feature vector (Eq. 4.7) extends from $\mathbb{R}^4$ to $\mathbb{R}^{4+k}$ by appending sensor-specific attributes (battery capacity, transmission power, sensor type), requiring only a resized $\mathbf{W}_1 \in \mathbb{R}^{(4+k) \times d}$; the CAS controller and readout are unchanged. Heterogeneous radii yield an asymmetric adjacency handled by row-normalised propagation. For $k=4$ additional features the parameter increase is 64 (4% of 1,473), confirming no significant redesign is needed.

4.6 Conclusion

This paper introduced **Graph-Attentive Policy Fusion (GAPF)**, a lightweight meta-learning framework for energy-efficient multi-hop routing in Wireless Sensor Networks. GAPF fuses frozen MARL expert policies (QMIX, QTRAN) through a two-layer Graph Convolutional Network that encodes the sensor topology into a compact 16-dimensional embedding, enabling a Contextual Algorithm Selection controller to choose the best expert per deployment with only 1,473 trainable parameters.

4.6.1 Contributions and Impact

Extensive evaluation across 7 scenarios (20–100 sensors, 25–50 m coverage radius, 3 seeds, 21,000 test episodes) establishes three principal contributions :

1. **Near-perfect, scale-invariant delivery.** GAPF achieves $\geq 98\%$ packet delivery ratio from 20 to 100 sensors, with +43% to +111% relative improvement over standalone MARL—critical for life-saving responsiveness in disaster monitoring.
2. **Energy-coherent routing for green AI.** GAPF consumes $2\text{--}3.5\times$ less energy than QMIX/QTRAN while delivering more data, and maintains $3\text{--}9\times$ better energy balance across sensors, directly extending network lifetime in battery-powered deployments.
3. **Feasible deployment on constrained hardware.** GAPF passes all feasibility constraints ($p_{99} < 50$ ms, peak memory $< 1,024$ MB) across all scenarios, while QMIX/QTRAN

exceed the memory budget by up to $13\times$. Under CTDE, each sensor runs only a lightweight GRU agent (~ 3 KB weights, $\sim 27 \mu\text{J}$ per inference), compatible with commercial WSN microcontrollers.

4.6.2 Broader Impact

Beyond WSN routing, GAPF demonstrates that *lightweight policy fusion can outperform heavyweight monolithic models* in multi-agent systems. Encoding structural context via GNNs and selecting among frozen specialist policies is applicable to vehicular ad-hoc networks, drone swarm coordination, and smart grid load balancing. The meta-controller’s small footprint (1,473 parameters) aligns with responsible AI : interpretable expert selection, minimal carbon footprint, and deployment without GPU infrastructure.

4.6.3 Future Work

We identify five directions for future research, ordered by expected impact :

1. **Hardware-in-the-loop validation.** Deploying GAPF on physical WSN testbeds (e.g., nRF52840 motes) with realistic channel models and packet collisions to bridge the gap between our deployment feasibility analysis and real RF conditions.
2. **Cross-domain disaster monitoring.** Adapting the framework to flood monitoring (mobile sensors), wildfire detection (rapidly evolving topology), and post-earthquake structural health monitoring (intermittent connectivity).
3. **Model compression for extreme scale.** Applying 8-bit quantisation, structured pruning, and knowledge distillation to extend feasibility beyond $n=100$ (where gateway memory reaches 951 MB).
4. **Dynamic expert fusion.** Extending the CAS controller to step-level Q-value blending to adapt within episodes to topology changes caused by sensor failures or energy depletion.
5. **Multi-expert generalisation.** Incorporating additional experts (QPLEX, MAPPO, DQN) with softmax-based selection to test whether expert diversity yields diminishing or compounding returns.

In summary, GAPF bridges the gap between the theoretical promise of MARL and the practical constraints of real-world sensor networks, achieving reliable, energy-efficient, and deployable routing at scale—a step toward responsible and sustainable AI for public safety.

Les hyperparamètres complets, la preuve formelle de monotonie, les résultats détaillés par scénario, l'analyse de faisabilité de déploiement et un tableau comparatif des approches de routage récentes (2024–2025) sont fournis à l'Annexe E.

CHAPITRE 5 ARTICLE 2 : CARBON-AWARE AUTONOMOUS DATA REDUCTION AND SELF-HEALING ROUTING FOR 6G-INTEGRATED DISASTER SENSOR NETWORKS : A LIFECYCLE-SUSTAINABLE APPROACH

Auteurs : Georges Parfait Djimefo Kapen, Ranwa Al Mallah et Samuel Pierre.

Revue : IEEE Transactions on Green Communications and Networking.

Statut : Soumis.

Ce chapitre présente le deuxième article de cette thèse. Il propose CALASH (Carbon-Aware Lifecycle-Autonomous Self-Healing), un cadre intégrant quatre piliers : (i) CADR pour la réduction de données sensible au carbone, (ii) CARE, un routeur hybride Lyapunov-DQN avec des garanties de budget carbone prouvables, (iii) SHDR pour la reprise autonome après catastrophe via une boucle MAPE-K, et (iv) LSE pour l'évaluation du cycle de vie conforme à l'ISO 14040. CALASH opère sur une couche physique 6G double bande sub-THz/sub-6 GHz. Ce travail constitue la deuxième contribution de la thèse en intégrant la conscience carbone à travers tout le cycle de vie du réseau de capteurs.

5.1 Abstract

Wireless Sensor Networks (WSNs) deployed in disaster-prone environments must extend network lifetime and maintain reliable data delivery while reducing their full-lifecycle carbon footprint. To date, no protocol jointly optimizes Lifecycle Carbon Intensity (LCI)—defined as the embodied, operational, and end-of-life carbon dioxide associated with each useful packet. We propose CALASH (Carbon-Aware Lifecycle-Autonomous Self-Healing), a framework integrating four pillars : (i) Carbon-Aware Data Reduction (CADR), which modulates compressive-sensing ratios with grid carbon intensity ; (ii) Carbon-Aware Routing Engine (CARE), a hybrid Lyapunov-DQN router with provable carbon-budget guarantees ; (iii) Self-Healing Disaster Recovery (SHDR) via an autonomic MAPE-K loop ; and (iv) Lifecycle Sustainability Engine (LSE) embedding ISO 14040-compliant end-of-life costs into routing. CALASH operates over a sub-THz/sub-6 GHz dual-band 6G physical layer. Extensive simulations validated against real Intel Lab traces and UK grid carbon data show that CALASH achieves 60% longer lifetime (1,486 vs. 931 rounds), 82.9% Packet Delivery Ratio,

and 33% lower LCI (8.99 vs. 13.42 gCO₂eq/pkt) compared to LEACH, outperforming all six traditional baselines with statistical significance. An ablation study reveals CADR as the dominant pillar (59% LCI reduction), while 6G technologies contribute a 10.5% lifetime gain.

5.2 Introduction

Wireless Sensor Networks (WSNs) are collections of battery-powered nodes that sense physical phenomena and relay data to a Base Station (BS) via multi-hop communication. With non-rechargeable energy budgets (e.g. 0.5 J per Mica2 node [15]), maximizing network lifetime while ensuring reliable data delivery is a central challenge.

Why carbon matters. The ICT sector contributes 2–4% of global GHG emissions, and the IoT is among its fastest-growing segments [22, 137]. When thousands of sensor nodes are manufactured, powered, and discarded, their combined carbon footprint becomes significant. Most of this footprint comes from *embodied carbon*: the CO₂ emitted during chip fabrication and logistics [23]. A typical IoT node embodies ~ 10 kg CO₂eq [23], while its operational energy generates only ~ 0.01 g CO₂eq. Thus, **maximizing packets delivered before network death is the most effective way to reduce per-packet carbon footprint**. We formalize this insight via *Lifecycle Carbon Intensity* (LCI) :

$$\text{LCI} = \frac{C_{\text{embodied}} + C_{\text{operational}} + C_{\text{end-of-life}}}{\text{total useful packets delivered}} \quad [\text{gCO}_2\text{eq/pkt}] \quad (5.1)$$

where C_{embodied} , $C_{\text{operational}}$, $C_{\text{end-of-life}}$ respectively represent the manufacturing carbon of all sensors, the carbon from electricity used during routing, and the carbon from disposing dead sensors (e-waste).

Why disaster resilience matters. In disaster-prone deployments [138, 139], a single seismic event can disable 30–50% of nodes, breaking routing and wasting their embodied carbon.

Gaps in existing work. Table 5.1 summarizes the capabilities of representative baselines. *No existing protocol simultaneously addresses* (i) carbon-aware adaptive data reduction, (ii) provable carbon-budget routing with online learning, (iii) autonomic disaster self-healing, and (iv) lifecycle carbon integration in the routing objective.

Contributions. We make the following contributions :

- C1 CALASH framework** : the first routing protocol jointly minimizing LCI through four pillars—CADR, CARE (with Lyapunov carbon-budget guarantees), SHDR, and LSE.
- C2 CADR** : dynamically tunes compressive-sensing ratio inversely to real-time grid carbon intensity.

TABLEAU 5.1 Feature comparison of CALASH vs. baseline protocols.

Feature	<i>LEACH</i>	<i>EE-LEACH</i>	<i>ABC-ACO</i>	<i>EERP</i>	<i>Q-Routing</i>	<i>RIS-DRL</i>	<i>CALASH</i>
Energy-aware CH	✓	✓	✓	✓	✓	✓	✓
Multi-hop routing	–	–	✓	✓	✓	✓	✓
RL/DQN routing	–	–	–	–	✓	✓	✓
Carbon-aware routing	–	–	–	–	–	–	✓
Adaptive compression	–	–	–	–	–	–	✓
Disaster self-healing	–	–	–	–	–	–	✓
Lifecycle LCA	–	–	–	–	–	–	✓
Provable guarantees	–	–	–	–	–	–	✓

C3 Autonomous DQN routing : a lightweight Double DQN agent that learns online with no pre-training.

C4 Comprehensive evaluation : 30-seed campaigns across 13 variants, validated against real Intel Lab and UK grid data [62, 87], with Wilcoxon significance tests.

5.3 Related Work

We organize the literature into four areas.

5.3.1 Energy-Efficient Clustering Protocols

LEACH [6] introduced probabilistic CH election via a rotating threshold. EE-LEACH [140] refines this by incorporating residual energy, while HEED [16] uses distributed iterative selection based on energy and communication cost. Singh et al. [141] review over 30 LEACH variants; Kaur et al. [142] (2025) confirm that energy efficiency remains the dominant optimization goal. **Limitation** : none of these protocols account for grid carbon intensity, compressive sensing, or disaster recovery.

5.3.2 Metaheuristic and RL-Based Routing

ABC-ACO [143] combines ABC [144] and ACO [30] for joint CH selection and multi-hop routing. EERP [145] uses residual energy and distance for relay selection. Q-Routing [146]

applies tabular Q-learning [147] for online next-hop selection. More recent work includes ML-based clustering [148] and fuzzy-DRL routing [149]. **Limitation** : ABC-ACO is limited to 3 iterations per round online [150] ; none incorporate carbon awareness or provide convergence guarantees under carbon-budget constraints.

5.3.3 Carbon-Aware Networking

Carbon-aware computing—scheduling workloads during low-CI grid periods—is well established in cloud research [22, 151], with recent extensions to edge computing [137] and 6G task offloading [152]. However, its application to resource-constrained WSNs remains unexplored. The UK grid CI varies from ~ 50 to ~ 400 gCO₂/kWh [62, 153]. To the best of our knowledge, *no prior work adapts routing and compression decisions using real-time carbon intensity.*

5.3.4 Disaster-Resilient WSNs and Lifecycle Assessment

Erdelj et al. [138] survey disaster-management WSN deployments ; Alsayyed et al. [154] and Karaman et al. [139] extend this to 6G-era networks. Self-healing via backup CH election exists but not jointly with carbon-aware routing. LifeCycle Assessment (LCA), per ISO 14040 [12]/14044 [155], quantifies environmental impacts across a product’s full life cycle. Pirson and Bol [23] showed that IoT embodied carbon exceeds operational carbon by 3–5 orders of magnitude. **No prior WSN routing protocol incorporates LCA into its routing objective.**

5.4 Methodology

We consider N sensor nodes deployed uniformly at random in a $L \times L$ m² area. A single Base Station (BS) is located at coordinates (x, y) , outside the top edge of the sensing field—a standard WSN benchmark configuration [15]. Each node has an initial energy budget of E_0 J. A node is considered *dead* when its energy reaches zero ; it can no longer sense, transmit, or receive.

5.4.1 System Model

First-order radio energy model. All protocols in our framework use the same energy model for fair comparison [6, 156] :

$$E_{\text{Tx}}(l, d) = l \cdot E_{\text{elec}} + l \cdot \begin{cases} \varepsilon_{\text{fs}} \cdot d^2 & \text{if } d < d_0 \\ \varepsilon_{\text{mp}} \cdot d^4 & \text{if } d \geq d_0 \end{cases} \quad (5.2)$$

$$E_{\text{Rx}}(l) = l \cdot E_{\text{elec}} \quad (5.3)$$

where l is the number of bits, d is the distance in meters, $E_{\text{elec}} = 50 \text{ nJ/bit}$ is the electronics energy, $\varepsilon_{\text{fs}} = 10 \text{ pJ/bit/m}^2$ is the free-space amplifier coefficient, $\varepsilon_{\text{mp}} = 0.0013 \text{ pJ/bit/m}^4$ is the multipath amplifier coefficient, and $d_0 = \sqrt{\varepsilon_{\text{fs}}/\varepsilon_{\text{mp}}} \approx 87.7 \text{ m}$ is the crossover distance.

Carbon intensity model. The operational carbon emitted when a node consumes E Joules of energy at round t is :

$$C_{\text{op}}(E, t) = E \cdot \frac{1}{3.6 \times 10^6} \cdot \text{CI}(t) \quad (5.4)$$

where $\text{CI}(t)$ is the grid carbon intensity in $\text{gCO}_2\text{eq/kWh}$ at round t and $1/(3.6 \times 10^6)$ converts Joules to kWh. Three CI sources are supported : (1) real UK traces (8,760 h, mean $152 \text{ gCO}_2/\text{kWh}$) [62] ; (2) calibrated Ember 2024 profiles for five countries [153] ; (3) default synthetic (base 200, amplitude 80, $\sigma=25$, clipped to $[20, 600]$).

Disaster model We model disasters as Gaussian spatial failure events. At round t_d , an event centered at (x_c, y_c) with damage radius r_d destroys every node within r_d meters, and applies graduated damage to nodes further away based on distance. Damage radii are calibrated to USGS ShakeMap $\text{MMI} \geq \text{VIII}$ data [157, 158] : localized ($r_d=50 \text{ m}$, $\sim 15\%$), moderate ($r_d=100 \text{ m}$, $\sim 30\%$, default), and severe ($r_d=150 \text{ m}$, $\sim 50\%$).

Lifecycle carbon accounting. Following ISO 14040 [12] and Pirson & Bol [23], each node carries : embodied carbon $C_{\text{emb}} = 10,000 \text{ gCO}_2\text{eq}$ (fabrication through transport) ; operational carbon C_{op} per Eq. (5.4) ; and end-of-life carbon $C_{\text{eol}} = 500(1 - r_{\text{recycle}}) \text{ gCO}_2\text{eq}$ per dead node ($r_{\text{recycle}}=0.3$) [159].

5.4.2 Problem Formulation

Objective. Minimize the Lifecycle Carbon Intensity over a mission of T rounds :

$$\min_{\pi} \quad \text{LCI}(\pi) = \frac{\sum_{i=1}^N C_{\text{emb}}^{(i)} + \sum_{t=1}^T C_{\text{op}}(t) + \sum_{i:\text{dead}} C_{\text{eol}}^{(i)}}{\sum_{t=1}^T D(t)} \quad (5.5)$$

where $\boldsymbol{\pi}$ is the joint routing and compression policy, and $D(t)$ is the number of useful packets delivered to the BS at round t .

Constraints :

$$E_i(t) \geq 0 \quad \forall i, t \quad (\text{energy non-negativity}) \quad (5.6)$$

$$\frac{1}{T} \sum_{t=1}^T C_{\text{op}}(t) \leq \bar{c} + B/V \quad (\text{Lyapunov carbon bound}) \quad (5.7)$$

$$\text{NMSE}(\rho) \leq \delta \quad (\text{data fidelity threshold}) \quad (5.8)$$

where $\bar{c} + B/V$ is the Lyapunov carbon budget (V trades delivery emphasis against strict compliance), and δ is the acceptable distortion threshold for compressed data.

5.4.3 CALASH Framework

Fig. 5.1 presents the CALASH framework, which consists of four pillars described below.

Algorithm 4 presents the complete per-round operation.

Pillar 1 : CADR — Carbon-Aware Data Reduction

Core idea. Instead of transmitting all sensed data, each cluster member compresses its signal using Compressive Sensing (CS) [34, 160]. The compression ratio $\rho(t) \in [\rho_{\min}, \rho_{\max}]$ (the fraction of the original signal that is actually transmitted) is adjusted dynamically based on the current carbon intensity using a *reference-point mapping* centred at CI_{base} (the grid's average CI) :

$$\rho(t) = \begin{cases} \rho_{\max} - (\rho_{\max} - \rho_{\text{mid}}) \cdot \frac{\text{CI}(t) - \text{CI}_{\min}}{\text{CI}_{\text{base}} - \text{CI}_{\min}} & \text{if } \text{CI}(t) \leq \text{CI}_{\text{base}} \\ \rho_{\text{mid}} - (\rho_{\text{mid}} - \rho_{\min}) \cdot \frac{\text{CI}(t) - \text{CI}_{\text{base}}}{\text{CI}_{\max} - \text{CI}_{\text{base}}} & \text{if } \text{CI}(t) > \text{CI}_{\text{base}} \end{cases} \quad (5.9)$$

where $\rho_{\text{mid}} = (\rho_{\min} + \rho_{\max})/2$. This piecewise mapping centres $\rho = 0.55$ at the grid-average CI, avoiding the asymmetry of a simple linear mapping.

During disaster recovery, ρ is overridden to $\rho_{\max}$ to preserve critical data.

Compressive sensing pipeline. An s -sparse signal $\mathbf{x} \in \mathbb{R}^n$ is recovered from $m = \rho n$ Gaussian measurements via OMP [34, 161]; fidelity $F = 1 - \text{NMSE}$. The Intel Lab traces [87] are ~ 1 -sparse in the DCT domain, achieving $F > 0.99$ at $\rho = 0.3$.

Algorithm 4 CALASH Per-Round Operation

Require: Network $\mathcal{G}$, round t , config θ
Ensure: Delivered packets, energy consumed, carbon emitted

- ▷ Phase 0 : Self-Healing Monitor
- 1: **if** $t > t_d$ **and** recovery_mode **then** Run MAPE-K heartbeat check Check if recovery complete (> 50 rounds since disaster)
 - ▷ Phase 1
 - 1 : Carbon-Modulated CH Election (Setup) $CI(t) \leftarrow \text{CarbonTraceManager.get_ci}(t)$
 $CI_{\text{norm}} \leftarrow (CI(t) - CI_{\text{min}})/(CI_{\text{max}} - CI_{\text{min}})$ $f_c \leftarrow \max(1 - \beta \cdot CI_{\text{norm}}, 0.1)$
 - 2: **for all** alive node s_i eligible this epoch **do** $T_{\text{base}} \leftarrow p/(1 - p \cdot (r \bmod 1/p))$ ▷ LEACH threshold $T_i \leftarrow T_{\text{base}} \cdot (E_i/E_0) \cdot f_c$
 - 3: **if** $\text{rand}() < T_i$ **then** Elect s_i as CH Enforce $\geq 5\%$ alive nodes as CHs Form clusters (nearest-CH assignment)
 ▷ Phase 2 : CADR – Adaptive Compression & Intra-Cluster TX $\rho(t) \leftarrow$ reference-point CADR mapping (Eq. 5.9)
 - 4: **if** recovery_mode **then** $\rho(t) \leftarrow \rho_{\text{max}}$ $m \leftarrow \lceil \rho(t) \cdot n \rceil$ ▷ compressed signal dimension
 - 5: **for all** cluster member s_j **do** Sense signal, compress to m measurements Transmit $m \cdot l_{\text{bit}}$ bits to CH (THz if $d < 30$ m)
 ▷ Phase 3 : CARE – Inter-Cluster Routing to BS
 - 6: **for all** cluster head CH_k **do** Aggregate received data DQN trained and not recovery_mode route $\leftarrow \text{DQN.select_multi_hop}(CH_k, \text{BS})$ route $\leftarrow \text{Lyapunov.compute_route}(CH_k, \text{BS})$ Transmit along route (sub-6 GHz inter-cluster) Store DQN experience, train if buffer ≥ 256
 ▷ Phase 4 : Carbon Accounting & Queue Update $C_{\text{op}}(t) \leftarrow E_{\text{total}} \cdot J_{\text{kWh}} \cdot CI(t)$
 $Z(t+1) \leftarrow \max\{0, Z(t) + C_{\text{op}}(t) - \bar{c}\}$
return packets delivered, E_{total} , $C_{\text{op}}(t)$
-

Pillar 2 : CARE — Carbon-Aware Routing Engine

CARE combines two complementary routing strategies :

(a) Lyapunov drift-plus-penalty routing (provable guarantees). We maintain a *virtual carbon queue* $Z(t)$ that tracks cumulative carbon overshoot [61] :

$$Z(t+1) = \max \left\{ 0, Z(t) + C_{\text{op}}(t) - \bar{c} \right\} \quad (5.10)$$

where $\bar{c} = C_{\text{budget}}/T$ is the per-round carbon budget. At each hop, the next relay j^* is chosen to minimize :

$$j^* = \arg \min_{j \in \mathcal{N}(i)} \left[\underbrace{Z(t) \cdot c_{ij}(t)}_{\text{carbon pressure}} + \underbrace{V \cdot e_{ij}}_{\text{energy cost}} \right] \cdot \underbrace{\ell_j}_{\text{lifecycle penalty}} \quad (5.11)$$

where $c_{ij}(t)$ is the hop carbon cost, e_{ij} is the energy cost, V is the Lyapunov tradeoff pa-




FIGURE 5.1 CALASH per-round operation flow. Each round progresses into phases aligned with the four pillars.

parameter, and $\ell_j = 1 + w_{\text{eol}}(1 - E_j/E_0)^2$ penalizes low-energy nodes to avoid wasting their embodied carbon.

(b) Deep Q-Network (DQN) routing (autonomous adaptation). After 256 replay-buffer transitions, a NumPy-only Double DQN [49, 162] ($9 \rightarrow 64 \rightarrow 32 \rightarrow 1$, ReLU) takes over routing. It scores each candidate next-hop and selects the highest Q-value; the 9D state encodes source/candidate energy fractions, distances, normalized CI, carbon queue pressure, alive ratio, and lifecycle factor.

The reward function captures the multi-objective nature of CALASH :

$$\begin{aligned}
 r = & \underbrace{1.0 \cdot \frac{\Delta d_{\text{BS}}}{d_{\text{max}}}}_{\text{delivery progress}} - \underbrace{0.3 \cdot \text{CI}_{\text{norm}} \cdot E_{\text{Tx}} \cdot J_{\text{kWh}}}_{\text{carbon penalty}} - \underbrace{0.3 \cdot \frac{E_{\text{Tx}}}{E_{\text{src}}}}_{\text{energy penalty}} - \underbrace{0.2 \cdot \max(0, \ell - 1)}_{\text{lifecycle penalty}} + \underbrace{5.0 \cdot \mathbf{1}_{\text{BS}}}_{\text{delivery bonus}} - \underbrace{2.0 \cdot \mathbf{1}_{\text{drop}}}_{\text{drop penalty}} \\
 & (5.12)
 \end{aligned}$$

Fallback strategy. During disaster recovery, the DQN is bypassed (its policy may be outdated for the new topology), and the Lyapunov router takes over until the network stabilizes.

Pillar 3 : SHDR — Self-Healing Disaster Recovery

SHDR implements the Monitor-Analyze-Plan-Execute with Knowledge (MAPE-K) autonomic computing loop [163] : (1) **Monitor** : alive nodes send periodic heartbeat messages (50 bits, every 2 rounds; every round during recovery). Missing 3 consecutive heartbeats marks a node as dead. (2) **Analyze** : identify coverage holes and orphan nodes. (3) **Plan** : emergency CH election promotes highest-energy survivors; damaged nodes ($E < 0.3E_0$) have election probability reduced by 90%. (4) **Execute** : new topology takes effect for 50 rounds. During healing, CH density increases by 50% and CADR switches to $\rho_{\max}$.

Pillar 4 : LSE — Lifecycle Sustainability Engine

LSE embeds lifecycle carbon costs into the routing objective :

$$\ell_j = 1 + w_{\text{eol}} \cdot \left(1 - \frac{E_j}{E_0}\right)^2 \quad (5.13)$$

where $w_{\text{eol}} = 1.0$ is the end-of-life penalty weight. Nodes near death ($E_j \approx 0$) get $\ell_j \approx 2$, discouraging routing through nodes whose embodied carbon would be wasted.

5.4.4 6G Enabling Technologies

Sub-THz Communication with OFDM

Intra-cluster links use $f=140$ GHz, $B=10$ GHz [164] with an OFDM waveform (480 kHz SCS, 2,048 sub-carriers, 7% CP), yielding throughput efficiency $\eta_{\text{OFDM}}=0.93$ and 3 dB PAPR back-off. The effective channel capacity is

$$C_{\text{eff}} = \eta_{\text{OFDM}} \cdot B \log_2 \left(1 + \frac{P_{\text{Tx}} \cdot |h|^2}{N_0 B}\right) \quad (5.14)$$

where h is the channel coefficient, and the transmit power includes PAPR headroom $P_{\text{Tx}}^{\text{PA}} = P_{\text{Tx}} \cdot 10^{3/10}$.

Cascaded RIS Channel Model

A Reconfigurable Intelligent Surface (RIS) with $N_{\text{RIS}} = 64$ elements assists the sub-THz link when direct line-of-sight is obstructed (e.g., by disaster debris). The cascaded Tx→RIS→Rx

channel gain is modelled as [165–167] :

$$G_{\text{RIS}} = 20 \log_{10}(N_{\text{RIS}}) + G_{\text{CSI}} + G_{\text{beam}} - L_{\text{coupling}} \quad (5.15)$$

where $G_{\text{CSI}}=10 \log_{10}(0.90^2)$ captures estimation error, $G_{\text{beam}}=-0.01$ dB models beam misalignment [167], and $L_{\text{coupling}}=1$ dB accounts for mutual coupling [168], reducing the effective gain from 36.1 dB to ≈ 34.2 dB.

ISAC — Integrated Sensing and Communication

ISAC reuses the OFDM waveform for environment sensing [169, 170] : range-Doppler analysis ($\Delta r=1.5$ cm) with CFAR detection ($P_{\text{fa}}=10^{-4}$) computes a KL-divergence anomaly score ; $s_i > 0.5$ triggers the MAPE-K Monitor, augmenting heartbeat-based failure detection at 15% energy overhead.

5.4.5 Theoretical Guarantee : CDL Pareto Bound

We extend Neely’s Lyapunov drift-plus-penalty framework [61] to bound the *total lifecycle* carbon—not just operational carbon—by incorporating end-of-life emissions into the virtual queue.

Théorème 5.1 (Carbon-Delivery-Lifecycle (CDL) Pareto Bound). *Define the total lifecycle carbon $C_{\text{tot}}(t) = C_{\text{op}}(t) + K(t) \cdot c_{\text{eol}}^{\text{eff}}$, where $K(t)$ is the number of node deaths at round t and $c_{\text{eol}}^{\text{eff}} = c_{\text{eol}}(1 - r_{\text{recycle}})$. Update the virtual queue :*

$$Z(t+1) = \max \{0, Z(t) + C_{\text{tot}}(t) - \bar{c}\} \quad (5.16)$$

For $V > 0$, the CALASH routing achieves simultaneously :

$$(i) \quad \bar{D} \geq \bar{D}^* - B/V \quad (\text{near-optimal delivery}) \quad (5.17)$$

$$(ii) \quad \bar{C}_{\text{tot}} \leq \bar{c} + B/V \quad (\text{lifecycle carbon budget}) \quad (5.18)$$

where $\bar{D}^*$ is the optimal delivery rate of any static policy, $\bar{c} = C_{\text{budget}}/T$, and $B = \frac{1}{2} \max_t \{(C_{\text{tot}}(t) - \bar{c})^2\}$. Moreover, the Pareto front $(\bar{D}(V), \bar{C}_{\text{tot}}(V))$ is convex and continuously traceable by varying $V \in (0, \infty)$.

Démonstration. Define $L(t) = Z(t)^2/2$. The one-step drift satisfies $\Delta(t) \leq B + Z(t)(C_{\text{tot}}(t) - \bar{c})$. Adding penalty $V \cdot (-D(t))$ and noting that CALASH greedily minimizes the RHS via Eq. (5.11) with ℓ_j , the drift-plus-penalty bound becomes $B - V \cdot \bar{D}^*$. Telescoping over T

rounds yields Eq. (5.17); queue stability gives Eq. (5.18). Eliminating V via $B/V = \bar{D}^* - \bar{D}$ shows $\bar{C} = \bar{c} + (\bar{D}^* - \bar{D})$, a linear (hence convex) trade-off; higher-order terms preserve convexity [61]. $\square$

5.5 Results and Discussion

5.5.1 Data Provenance and Reproducibility

We classify every data input using a four-level provenance taxonomy summarized in Table 5.2. All 30 seeds (42–71), the complete simulation code, and real data files are included in the supplementary repository.

5.5.2 Experimental Setup

Simulation parameters. 200 nodes, 200×200 m, BS at (100, 250), $E_0 = 0.5$ J, 5,000 rounds, disaster at round 2,000 ($r_d = 100$ m, center of area). Each experiment is repeated with 30 independent random seeds (seeds 42–71); we report mean $\pm$ 95% Confidence Interval (CI) via the t -distribution.

Protocols compared. We evaluate 13 protocol variants :

- **7 baselines** spanning four generations of WSN routing : LEACH [6], LEACH-1hop, EE-LEACH [140], ABC-ACO [143], EERP [145], Q-Routing [146,147], and **RIS-DRL** [165–167]. RIS-DRL shares CALASH’s 6G physical layer (THz + RIS) but uses a standard DQN without carbon awareness, lifecycle integration, or self-healing, isolating CALASH’s algorithmic contributions.
- **CALASH** : full framework (all four pillars + 6G technologies).
- **5 ablation variants** : CALASH-NoCO₂, CALASH-NoSH, CALASH-NoCADR, CALASH-NoLCI, CALASH-NoTHz.

All protocols share the same energy model, topology, and disaster event [173]. Baselines do not use compressive sensing (fidelity = 1.0) as their original formulations do not include it.

Metrics. Half-death round (50% nodes dead), PDR (delivered/generated), operational carbon (gCO₂eq), data fidelity (1–NMSE), LCI (gCO₂eq/pkt, Eq. (5.5)), energy efficiency (pkt/J), and Jain’s fairness index [174].

Statistical significance. We use the Wilcoxon signed-rank test [175] (non-parametric, paired, $\alpha = 0.05$) to compare CALASH against each baseline, following simulation best practices [176, 177].

TABLEAU 5.2 Data provenance summary. Each input to the simulation is classified by its provenance level, source, and licence.

Data Input	Category	Source	Licence
UK CI trace (2023)	Real	National Grid ESO API [62]	CC BY 4.0
ShakeMap grid.xml	Real	USGS Earthquake Hazards Program [158]	Public domain
Intel Lab sensors	Real	Intel Berkeley Lab [87]	Public domain
France/DE/IN/CI	Calibrated	Ember 2024 annual stats [153]	CC BY 4.0
Gaussian damage profile	Calibrated	Fitted to ShakeMap $\text{MMI} \geq \text{VIII}$ area	—
THz channel model	Model	Jornet & Akyildiz [171]	—
Aftershock sequence	Model	Omori–Utsu Bath + G-R laws [172]	—
RIS cascaded gain	Model	Huang et al. [165]	—
Fragility curve	Model	Worden et al. [158]	—
Lifecycle carbon (LCA)	Model	ISO 14040 + Pirson & Bol [23]	—
Node deployment	Simulated	Uniform random, seed-controlled	—
DQN learning	Simulated	NumPy ε -greedy DQN	—

5.5.3 DQN Training Hyperparameters

Table 5.3 lists all training hyperparameters for reproducibility.

TABLEAU 5.3 DQN and framework hyperparameters.

Component	Parameter	Value
DQN Agent	Architecture	9–64–32–1
	Activation	ReLU
	Learning rate (SGD)	10^{-3}
	Discount γ	0.95
	Soft-update τ	0.005
	Replay buffer size	10,000
	Batch size	64
	Min buffer before training	256
	ε -greedy schedule	Cosine annealing
	$\varepsilon_{\min}$	0.05
	ε decay steps	3,000
	Gradient clipping (max norm)	1.0
	Weight init	Xavier/Glorot [178]
	Double DQN	Yes [162]
Lyapunov	V (tradeoff)	100
	β (carbon CH mod.)	0.3
	w_{eol} (EOL penalty)	1.0
	Min CH fraction	5%
CADR	$\rho_{\min}$ (max compression)	0.3
	$\rho_{\max}$ (min compression)	0.8
	Signal dim n / sparsity s	100 / 20
THz/6G	Intra : 140 GHz D-band	30 m range
	Inter : 3.5 GHz sub-6	100 m range
SHDR	Heartbeat size	50 bits (capped at d_0)
	Heartbeat interval	2 rounds (1 during disaster)
	Heartbeat miss threshold	3 rounds
	Recovery duration	50 rounds
	CH density boost	$1.5\times$

5.5.4 Time Complexity Analysis

Table 5.4 compares per-round computational complexity.

CALASH’s per-round complexity is comparable to EERP and significantly lower than ABC-ACO.

TABLEAU 5.4 Per-round computational complexity. N : nodes, K : CHs, D : avg degree, H : max hops, P : ABC population, I : iterations.

Protocol	Setup	Routing	Empirical
LEACH [6]	$O(N)$	$O(K \cdot H)$	~ 0.5 ms
LEACH-1hop	$O(N)$	$O(K)$	~ 0.4 ms
EE-LEACH [140]	$O(N)$	$O(K \cdot H)$	~ 0.5 ms
EERP [145]	$O(N \cdot D)$	$O(K \cdot D \cdot H)$	~ 1.5 ms
ABC-ACO [143]	$O(ND + PIK)$	$O(K \cdot D \cdot H)$	~ 5.0 ms
Q-Routing [146]	$O(N)$	$O(K \cdot A \cdot H)$	~ 0.5 ms
CALASH	$O(ND + N_{\text{DQN}})$	$O(K \cdot N_{\text{DQN}} \cdot H)$	~ 1.3 ms

5.5.5 Discussion of Results

Table 5.5 presents the main campaign results.

Table 5.5 presents the full results ; Figs. 5.2–5.4 visualize key trends.

CALASH vs. Traditional Baselines

CALASH achieves half-death round **1,486 $\pm$ 14** (**60%** over LEACH ; $p < 10^{-5}$), PDR = **0.829**, LCI = **8.99** gCO₂eq/pkt (**33%** below LEACH), and efficiency = **2,323** pkt/J (51% above LEACH).

CALASH vs. RIS-DRL : The 6G-Aware Baseline

Both protocols share the same 6G physical layer ; any gap isolates CALASH’s algorithmic contributions. RIS-DRL achieves **longer lifetime** (1,764 vs. 1,486, +18.7% ; $p=1.8 \times 10^{-6}$) and lower LCI (7.89 vs. 8.99), reflecting CARE’s CI-deferral overhead ($\sim 10.7\%$) and SHDR heartbeats ($\sim 1.7\%$). Conversely, CALASH achieves **higher PDR** (0.829 vs. 0.794, +4.3%). The ablation confirms : CALASH-NoCO2 achieves LCI 8.16—within 3.4% of RIS-DRL—proving the gap stems from self-healing overhead, not architectural weakness. CALASH trades $\sim 16\%$ lifetime for carbon awareness, self-healing, provable guarantees, and higher PDR—capabilities RIS-DRL lacks (Table 5.1).

LCI Mechanism Analysis

Embodied carbon (2×10^6 gCO₂eq for 200 nodes) dominates operational carbon by five orders of magnitude, so LCI scales inversely with total delivered packets. CALASH delivers $\sim 231,000$

TABLEAU 5.5 Main simulation results (30 seeds, 5,000 rounds, disaster at round 2,000). Values are mean $\pm$ 95% CI. Best value per column in **bold**. $\downarrow$ = lower is better, $\uparrow$ = higher is better. All protocols achieve fidelity $F = 1.000$ and operational carbon $\approx 0.002 \text{ gCO}_2$.

Protocol	Half-Death $\uparrow$	PDR $\uparrow$	LCI $\downarrow$	Eff. (pkt/J) $\uparrow$
LEACH	931 ± 6	0.857 ± 0.003	13.42 ± 0.08	$1,536 \pm 10$
LEACH-1hop	806 ± 13	0.865 ± 0.001	16.09 ± 0.16	$1,282 \pm 13$
EE-LEACH	$1,266 \pm 11$	0.638 ± 0.002	13.54 ± 0.07	$1,525 \pm 9$
ABC-ACO	880 ± 5	0.892 ± 0.002	13.72 ± 0.08	$1,503 \pm 9$
EERP	$1,244 \pm 12$	0.646 ± 0.006	13.21 ± 0.07	$1,561 \pm 8$
Q-Routing	$1,225 \pm 10$	0.636 ± 0.002	14.01 ± 0.08	$1,473 \pm 8$
RIS-DRL	$1,764 \pm 15$	0.794 ± 0.002	7.89 ± 0.07	$2,647 \pm 26$
CALASH	$1,486 \pm 14$	0.829 ± 0.006	8.99 ± 0.10	$2,323 \pm 24$
CALASH-NoCO2	$1,644 \pm 21$	0.828 ± 0.005	8.16 ± 0.14	$2,642 \pm 27$
CALASH-NoSH	$1,510 \pm 12$	0.830 ± 0.005	8.82 ± 0.08	$2,349 \pm 22$
CALASH-NoCADR	930 ± 5	0.830 ± 0.004	14.29 ± 0.09	$1,443 \pm 9$
CALASH-NoLCI	$1,484 \pm 13$	0.828 ± 0.004	8.99 ± 0.09	$2,322 \pm 21$
CALASH-NoTHz	$1,345 \pm 11$	0.835 ± 0.004	9.84 ± 0.08	$2,102 \pm 19$

packets (vs. LEACH’s $\sim 154,000$), yielding the 33% LCI reduction through CADR’s $\sim 2.5\times$ energy saving.

Ablation Study

The ablation (Table 5.5, bottom) isolates each pillar ($\Delta \text{LCI} = \text{ablation} - \text{CALASH}$). **No-CADR** ($\Delta = +5.30$) : most damaging ; full-size packets cut lifetime to 930 (-37.4% , $p = 1.8 \times 10^{-6}$). **NoCO2** ($\Delta = -0.83$) : $+10.7\%$ lifetime ($p = 1.8 \times 10^{-6}$)—costliest pillar but enables carbon awareness. **NoSH** ($\Delta = -0.17$) : $+1.7\%$ lifetime ($p = 5.5 \times 10^{-3}$) ; essential in multi-disaster scenarios. **NoLCI** ($\Delta = +0.00$) : negligible ($p = 0.74$) ; acts as tiebreaker. **NoTHz** ($\Delta = +0.85$) : -9.5% lifetime ($p = 1.8 \times 10^{-6}$). Hierarchy : CADR ($+59\%$) $\gg$ 6G ($+9.5\%$) $>$ CARE (-9.2%) $>$ SHDR (-1.9%) $>$ LSE (≈ 0).

Statistical Significance

Table 5.6 summarizes Wilcoxon signed-rank test results. All CALASH vs. baseline comparisons for lifetime, PDR, and LCI are significant ($p < 10^{-5}$), confirming that the performance improvements are robust across all 30 seeds.




FIGURE 5.2 Alive node count over simulation rounds (30-seed mean). The disaster event at round 2,000 causes a visible dip in all protocols; CALASH recovers fastest due to SHDR.

TABLEAU 5.6 Wilcoxon signed-rank test : CALASH vs. each baseline ($\alpha = 0.05$, $n = 30$ seeds). ✓ = significant.

Baseline	Lifetime	PDR	LCI
LEACH	✓ ($p = 1.8 \times 10^{-6}$)	✓ ($p = 2.5 \times 10^{-6}$)	✓ ($p = 1.8 \times 10^{-6}$)
LEACH-1hop	✓ ($p = 1.8 \times 10^{-6}$)	✓ ($p = 1.8 \times 10^{-6}$)	✓ ($p = 1.8 \times 10^{-6}$)
EE-LEACH	✓ ($p = 1.8 \times 10^{-6}$)	✓ ($p = 1.8 \times 10^{-6}$)	✓ ($p = 1.8 \times 10^{-6}$)
ABC-ACO	✓ ($p = 1.8 \times 10^{-6}$)	✓ ($p = 1.8 \times 10^{-6}$)	✓ ($p = 1.8 \times 10^{-6}$)
EERP	✓ ($p = 1.8 \times 10^{-6}$)	✓ ($p = 1.8 \times 10^{-6}$)	✓ ($p = 1.8 \times 10^{-6}$)
Q-Routing	✓ ($p = 1.8 \times 10^{-6}$)	✓ ($p = 1.8 \times 10^{-6}$)	✓ ($p = 1.8 \times 10^{-6}$)
RIS-DRL	✓ ($p = 1.8 \times 10^{-6}$)	✓ ($p = 1.8 \times 10^{-6}$)	✓ ($p = 1.8 \times 10^{-6}$)

Evaluation Methodology and Real Data Validation

We use a discrete-event Python/NumPy simulator with the first-order radio model [6] and three real data sources (Table 5.2) : Intel Lab traces [87], UK Carbon Intensity API [62], and




FIGURE 5.3 Cumulative packet delivery ratio over 5,000 rounds for 13 protocols (200 nodes, 30-seed mean). CALASH sustains PDR 0.83, exceeding all multi-hop baselines by $\geq 30\%$; ABC-ACO reaches 0.89 but at 41% shorter lifetime.




FIGURE 5.4 Box plots of four key metrics—half-death round, PDR, total carbon, data fidelity—across 30 seeds for all 13 protocols (200 nodes, 5,000 rounds). Whiskers span 5th–95th percentile; narrow boxes indicate low variance.

USGS ShakeMap grids [158].

Scalability Analysis

Fig. 5.7 reports LCI and half-death round as N varies from 100 to 500 (10 seeds each). CALASH's LCI advantage ranges from 40% ($N=100$) to 17% ($N=500$) vs. LEACH, persisting




FIGURE 5.5 Cumulative (gCO_2eq) over 5,000 rounds for all 13 protocols (200 nodes, 30-seed mean). All converge to $0.002 gCO_2eq$; differences dominated by embodied carbon amortization.

at every scale because CADR compresses per-node transmissions regardless of network size.

Sensitivity Analysis

Fig. 5.8 sweeps four hyperparameters (10 seeds each). V is insensitive in $[50, 500]$, validating the default $V=100$; β shows diminishing returns beyond 0.3; CH percentage is near-optimal at 5%; $\rho_{\min}=0.3$ achieves $F=1.000$ with $LCI \sim 9.0$. No single parameter causes more than $\pm 15\%$ LCI variation. Across four national grids (France 41, UK 200, Germany 338, India 707 gCO_2/kWh ; 10 seeds each), CALASH’s LCI advantage over LEACH ranges from 31% (India) to 41% (France).

Computational Feasibility

Table 5.7 reports wall-clock time per simulation. CALASH’s $9.5\times$ overhead vs. LEACH stems from DQN forward passes (2,656 MACs per candidate, ~ 0.3 ms on an 8 MHz mote—negligible vs. a 100 ms slot).




FIGURE 5.6 Comparison of synthetic vs. real data traces. Real Intel Lab data exhibits higher sparsity, leading to better fidelity under compression.

Limitations L1 : RIS-DRL outperforms CALASH on lifetime (+19%) and LCI (−12%), reflecting the cost of carbon-awareness and self-healing ; the ablation confirms this is the *price* of capabilities RIS-DRL lacks. **L2 :** The first-order radio model abstracts fading and MAC contention ; absolute numbers are optimistic but relative comparisons remain valid. **L3 :** The campaign does not yet model cascading secondary hazards [172].

5.6 Conclusion

We presented CALASH, the first WSN routing framework jointly minimizing lifecycle carbon intensity through four pillars : CADR, CARE, SHDR, and LSE. Evaluation (30 seeds, 13 variants, 5,000 rounds) shows **60% longer lifetime** vs. LEACH, **32% lower LCI** vs.




FIGURE 5.7 Scalability analysis : LCI and half-death round as network size varies from 100 to 500 nodes (10 seeds each, 5,000 rounds).

the best traditional baseline, and **82.9% PDR** with perfect fidelity. The ablation confirms CADR as the dominant pillar (+59% LCI when removed), and the RIS-DRL comparison reveals a controlled energy–carbon–resilience trade-off. The key insight is that *sending fewer bits* via compressive sensing is the most effective lever for reducing WSN carbon footprint.

Future work :

1. Replace the DQN with a lightweight linear policy and use ISAC passive failure detection to close the RIS-DRL gap.
2. Validate on a 20-node ESP32-S3 + LoRa testbed with INA219 power monitoring [62].
3. Extend to cascading multi-disaster scenarios and energy-harvesting nodes [179].
4. Cross-validate THz channel estimates via ns-3 co-simulation [180].




FIGURE 5.8 Sensitivity analysis : effect of Lyapunov trade-off parameter V , carbon weight β , CH percentage, and compression floor $\rho_{\min}$ on CALASH performance (10 seeds each).

Les hyperparamètres complets, la preuve du théorème CDL, les résultats détaillés par scénario, les analyses de sensibilité et les profils carbone sont fournis à l'Annexe F.

TABLEAU 5.7 Wall-clock execution time per 5,000-round simulation (30-seed mean $\pm$ 95% CI). Overhead ratio relative to LEACH.

Protocol	Wall time (s)	Overhead vs. LEACH
LEACH-1hop	2.54 ± 0.03	$0.8\times$
LEACH	3.28 ± 0.05	$1.0\times$
EE-LEACH	3.41 ± 0.03	$1.0\times$
Q-Routing	3.71 ± 0.05	$1.1\times$
CALASH-NoCADR	16.09 ± 0.22	$4.9\times$
EERP	16.13 ± 0.28	$4.9\times$
CALASH-NoCO2	19.10 ± 0.36	$5.8\times$
RIS-DRL	22.68 ± 0.30	$6.9\times$
CALASH-NoSH	30.16 ± 0.38	$9.2\times$
CALASH-NoLCI	30.37 ± 0.42	$9.3\times$
CALASH	31.08 ± 0.51	$9.5\times$
CALASH-NoTHz	33.35 ± 0.75	$10.2\times$
ABC-ACO	36.82 ± 0.30	$11.2\times$

CHAPITRE 6 ARTICLE 3 : ZERO-TRUST SHIELDED GRAPH-STRUCTURED DECISION CONTROL FOR SECURE AUTONOMOUS RECOVERY IN AI-NATIVE 6G DISASTER-MONITORING SENSING NETWORKS

Auteurs : Georges Parfait Djimefo Kapen, Ranwa Al Mallah et Samuel Pierre.

Revue : IEEE Transactions on Mobile Computing.

Statut : Soumis.

Ce chapitre présente le troisième article de cette thèse. Il propose CASTER-ZT (Zero-Trust Shielded Decision-Control), un cadre combinant un encodeur par réseau de neurones sur graphe (GNN), une politique de reprise apprise et un évaluateur neuronal double hypothèse confiance–risque avec un bouclier déterministe formellement vérifié qui impose l’admissibilité bornée avant l’exécution. Dix propriétés théoriques sont démontrées, incluant une borne de défense en profondeur, une garantie conforme sans distribution et un taux de convergence de calibration. Ce travail constitue la troisième contribution de la thèse en établissant un cadre de sécurité formellement fondé pour les décisions autonomes dans les réseaux de capteurs 6G.

6.1 Abstract

Disaster-monitoring sensing networks require autonomous recovery under adversarial conditions, yet no existing framework combines graph-structured decision making with formally bounded zero-trust admissibility for near-real-time actuation under attack. We propose *CASTER-ZT*, coupling a graph neural network encoder, learned recovery policy, and neural dual-hypothesis trust–risk evaluator with a deterministic shield that enforces bounded admissibility before execution. Ten formal properties are proved, including a defense-in-depth bound, a distribution-free conformal coverage guarantee, and a calibration convergence rate. A 2,420-run campaign across eleven methods, four attack conditions, two severity levels, twenty seeds, and three scales (12/36/100-cell) shows 74.2% rogue detection with zero false positives at 12-cell (rising to 98.3% at 100-cell), recovery quality 0.733 vs. 0.14–0.20 for non-shielding baselines (p less than 0.001), and 3.07 ms per-decision latency within the O-RAN 10 ms budget.

6.2 Introduction

Autonomous recovery is becoming a defining requirement in next-generation sensing and communication infrastructures. In disaster-monitoring sensing networks, large-scale failure, degraded observability, and rapidly changing priorities make purely manual recovery too slow. Future AI-native systems must make near-real-time decisions on routing, reassignment, and restoration under uncertainty, yet the same autonomy that speeds recovery enlarges the attack surface when telemetry is corrupted or identities are abused [13, 181].

Graph learning provides a natural formalism for networked recovery [43, 182, 183], while the safe-learning literature shows that unconstrained policies are unacceptable in safety-sensitive settings [24, 25, 184]. Parallel work on calibration, uncertainty, and selective prediction emphasizes that accuracy alone is insufficient when the system must know when *not* to act autonomously [78, 79]. Agentic and intent-driven AI for O-RAN and next-generation control further expands autonomous operation [185, 186], but prioritizes orchestration flexibility over formally bounded security under corrupted evidence.

The central gap is that current methods optimize recovery quality *before* defining a formal admissibility boundary for autonomous action under compromised or uncertain evidence—a dangerous ordering in disaster settings. This paper addresses that gap by formulating post-disaster recovery as a graph-structured secure decision problem with explicit trust, risk, uncertainty, and admissibility constraints. We propose *CASTER-ZT* (Causal, Autonomous, Shielded, Telemetry- and Event-aware Recovery with Zero Trust), a framework in which a recovery policy proposes candidate actions, a dual-hypothesis trust–risk evaluator estimates action safety under benign and adversarial hypotheses, and a formal zero-trust shield [13] determines whether the action may be allowed, scope-reduced, deferred, escalated, or blocked.

The paper asks four research questions. **RQ1** : Can a zero-trust shielded policy reduce adversarial degradation of autonomous recovery? **RQ2** : What security–utility–overhead tradeoffs arise from trust-, authorization-, and risk-aware shielding? **RQ3** : Does the framework remain effective across attack severities and topology scales? **RQ4** : Does the model satisfy 6G near-real-time deployment constraints?

Contributions. (C1) We formulate secure autonomous recovery as a graph-structured decision problem with zero-trust admissibility constraints. (C2) We introduce CASTER-ZT, coupling a trained GNN encoder, learned policy, neural trust–risk evaluator, MC-Dropout uncertainty estimation, and a formally verified deterministic shield. (C3) We prove ten bounded properties including defense-in-depth, conformal coverage, and calibration convergence. (C4) A 2,420-run campaign across three scales, four external baselines, and four ablations

demonstrates 74.2–98.3% rogue detection with zero false positives, $\omega_{\text{rec}} = 0.733$ vs. 0.14–0.20 for non-shielding baselines, and 3.07 ms per-decision latency. (C5) Component ablation confirms each shield module’s individual necessity.

The rest of the paper is organized as follows. Section 6.3 reviews related work. Section 6.4 presents the CASTER-ZT framework, algorithms, training pipeline, and theoretical properties. Section 6.5 details the experimental evaluation. Section 6.6 discusses findings and limitations. Section 6.7 concludes.

6.3 Related Work

Graph-structured learning for networks. Graph Neural Networks (GNNs) have transformed network representation, from spectral methods [182] and inductive approaches [43] to attention mechanisms [183] and message-passing frameworks [44,45]. Temporal GNNs [187,188] extend these to dynamic graphs. Almasan et al. [?] and Raftopoulos and Fokianakis [189] demonstrate GNN-based routing and control, while Rusek et al. [?] model network QoS via GNNs. However, these approaches optimize performance without security-first actuation gating.

Safe and shielded learning. The safe reinforcement learning (RL) literature addresses constraint satisfaction during training and deployment [184,190]. Constrained policy optimization [24] bounds cumulative cost; Safe RLHF [191] extends these ideas to language-model alignment. Alshiekh et al. [25] introduce precomputed binary safety shields from temporal specifications. Roderick et al. [192] propose dynamic model predictive shielding, separating learned perception from deterministic safety. These methods do not incorporate identity verification, trust assessment, or graduated (multi-outcome) shield decisions for security-critical networks.

Uncertainty, calibration, and anomaly detection. MC-Dropout [78] provides scalable epistemic uncertainty; conformal prediction [79] provides distribution-free coverage guarantees. Autoencoders [193,194] and isolation forests [195,196] are standard anomaly detectors. Selective prediction [197] and temperature scaling [198] further enable calibrated abstention. These components are individually valuable but have not been composed into a multi-gate zero-trust shield for autonomous network recovery.

Resilient sensing and zero-trust architecture. Sensor-network resilience has been studied via real deployments [199,200] and cyber-physical security testbeds [201–203]. Zero-trust architecture replaces perimeter-based security with continuous per-action verification [?, ?, 13]. Adversarial attacks on GNNs [204,205] highlight vulnerabilities in graph-based systems.




FIGURE 6.1 Rogue detection (RogueDet) and blocking (RogueBlk) under HIGH-severity identity abuse. CASTER-ZT : 74.2% detection, zero false positives ; IF-Trust : 100% via aggressive scope-reduction ; Shield-Binary : 88.3% with 48.8% false positives.

None of these works combines trust-assessed, graph-structured, formally shielded autonomous recovery.

AI-native 6G and agentic AI. The 6G vision positions AI as a first-class architectural element [10, 206–209]. Agentic AI architectures [185, 210, 211] and edge/intent-driven solutions [212–214] expand autonomous network control. The EU AI Act [215], NIST AI Risk Management [216], and OWASP Top 10 for LLMs [217] highlight governance requirements. These systems prioritize orchestration flexibility but lack formally bounded security-first actuation under corrupted evidence.

Positioning. Table 6.1 positions CASTER-ZT against the literature. The combination of graph-structured state, zero-trust admissibility with graduated multi-outcome decisions, dual-hypothesis trust–risk evaluation, and uncertainty-based abstention is not replicated by any individual model family.

TABLEAU 6.1 Model-space positioning. ✓ = addressed ; ◦ = partial ; ✗ = absent.

Family	Graph	ZT	Trust	Shield	Unc.
GNN routing [?, ?]	✓	✗	✗	✗	✗
Safe RL [24, 191]	✗	✗	✗	◦	✗
Formal shield [25, 192]	✗	✗	✗	✓	✗
Anomaly trust [195, 196]	✗	◦	✓	✗	✗
Agentic AI [185, 210]	◦	✗	✗	✗	◦
CASTER-ZT	✓	✓	✓	✓	✓

6.4 CASTER-ZT Framework

6.4.1 System and threat model

Networked disaster-recovery setting. The system is an autonomous decision controller deployed at the edge/gateway tier of a post-disaster sensing and communication network. The network is modeled as a time-varying directed graph $G_t = (V_t, E_t, X_t)$, where V_t are sensing/communication cells, E_t are connectivity links, and X_t is the real-valued feature matrix. Each cell $v \in V_t$ has an operational state in {operational, degraded, failed, recovering} and five input features (operational state, throughput, latency, loss rate, zone ID). Edges carry two features (link capacity, link utilization). A disaster onset at tick 3 causes $\approx 40\%$ simultaneous cell failure. The controller must restore the network by selecting recovery actions $a_t \in \mathcal{A}$ from six types : POWER-CYCLE, REROUTE-TRAFFIC, REASSIGN-FREQUENCY, CELL-RECONFIG, ISOLATE-CELL, ACTIVATE-BACKUP.

Threat model. An adversary operates under a bounded budget affecting a single zone. Four attack conditions are tested : CLEAN (no attack), TELEMETRY POISONING (corrupted sensor readings), IDENTITY-CREDENTIAL ABUSE (stolen legitimate credentials used to inject rogue recovery actions), and COMBINED. Each is tested at MEDIUM and HIGH severity.

Decision space.

Définition 6.1 (Bounded decision space). *The shield produces decisions $d_t \in \mathcal{D}$, ordered by conservatism from least to most restrictive :*

$$\mathcal{D} = \{\text{ALLOW, SCOPE-REDUCE, DEFER, ESCALATE, BLOCK}\}.$$

Optimization objective. The controller maximizes recovery utility subject to the constraint

that every action must pass the zero-trust shield :

$$\begin{aligned} \max_{\pi_\theta} \mathbb{E} & \left[\sum_t U(a_t^*, s_t) - \lambda_1 U_{\text{sec}}(a_t^*, s_t) \right. \\ & \left. - \lambda_2 U_{\text{lat}}(a_t^*, s_t) - \lambda_3 U_{\text{ener}}(a_t^*, s_t) \right] \\ \text{s.t. } & a_t^* \in \mathcal{E}(d_t, \hat{a}_t). \end{aligned}$$

Définition 6.2 (6G Near-Real-Time Compliance). *A system is 6G near-real-time compliant if : (1) per-decision latency $\ell_d \leq 10$ ms (O-RAN Near-RT RIC budget [186, 218]); (2) all inference executes locally without cloud dependency [189]; (3) total model memory $M_{\text{model}} \leq M_{\text{edge}}$ ($\sim 2\text{--}50$ MB) [186, 213].*

Définition 6.3 (AI-Native Pipeline). *A pipeline is AI-native if every stage is a trained ML component. AI-native coverage $\eta_{\text{AI}} = |\{S_k : S_k \text{ is learned}\}|/K$. CASTER-ZT achieves $\eta_{\text{AI}} = 5/6$: five neural stages plus one deliberately deterministic shield.*

6.4.2 Architecture

Design principle. *The policy proposes ; the zero-trust shield decides whether execution is admissible.* AI-native coverage ($\eta_{\text{AI}} = 5/6$) : every stage except the shield is a trained neural module. 6G compliance : $\approx 20\text{K}$ parameters, ≤ 2 MB, 2-layer GNN satisfying O-RAN latency and memory constraints.

End-to-end dataflow. telemetry $\rightarrow \underbrace{\text{GNN enc.}}_{\theta} \rightarrow \underbrace{\text{policy}}_{\theta} \rightarrow \underbrace{\text{trust-risk}}_{\phi} \rightarrow \underbrace{\text{MC-Drop}}_{\omega} \rightarrow \underbrace{\text{ZT shield}}_{\text{det.}} \rightarrow$
bounded exec.

The architecture contains five layers, of which the first four are *learned* :

1. **GNN graph encoder** (f_θ , learned). 2-layer GraphSAGE [43] with mean aggregation, $d = 64$, ReLU. Input : 5 node features, 2 edge features. Produces $h_v^{(L)} \in \mathbb{R}^{64}$ via message passing and a graph-level readout $\bar{h}_{G_t}$. Total : $\approx 4.5\text{K}$ params.
2. **Recovery policy head** (π_θ , learned). 2-layer MLP mapping $[h_a || \bar{h}_{G_t}]$ to action logits, softmax over $\mathcal{A}$. Trained via supervised imitation.
3. **Dual-hypothesis trust-risk evaluator** (Q_ϕ , learned). Autoencoder anomaly detector for trust (τ_t) : reconstruction error $e_t = \|x_t - \text{AE}_\phi(x_t)\|_2$, trust $\tau_t = \sigma(-\beta_\tau(e_t - e_{\text{thresh}}))$. Contrastive safety encoder for divergence (Δ_t). Neural risk scorer for ρ_t .
4. **MC-Dropout uncertainty** (U_ω , learned). $T = 20$ stochastic forward passes ; $u_t = T^{-1} \sum_i \text{Var}[\pi_\theta^{(i)}(a|s_t)]$.




FIGURE 6.2 CASTER-ZT architecture. The policy proposes; the zero-trust shield Γ controls execution via trust, risk, divergence, authorization, and uncertainty signals.

5. **Zero-trust shield** (Γ , deterministic). Formal admissibility gate (Algorithm 5) with 14 scalar parameters set by offline calibration. No learned weights.

6.4.3 Shield design and algorithms

Shield algorithm

Complexity. Total per-decision : $\mathcal{O}(L|E_t|d + |\mathcal{A}|k)$.

Shield calibration

Algorithm 6 sets shield thresholds via offline calibration on n annotated episodes.

6.4.4 Training pipeline

Training data is generated from 2,000 simulated disaster-recovery episodes spanning all four attack conditions, producing $\approx 60,000$ annotated decision steps (70/15/15 train/val/test split). All architectural hyperparameters satisfy the 6G deployment constraints of Definition 6.2 : GNN depth ($L = 2$), latent dimension ($d = 64$), and autoencoder bottleneck ($d_{\text{in}} \rightarrow 32 \rightarrow 16 \rightarrow 8$) are sized to keep total parameters under 50K and memory under 2 MB.

GNN encoder and policy. Trained jointly via supervised imitation with cross-entropy loss,

Algorithm 5 CASTER-ZT bounded autonomous recovery decision

Require: state s_t , candidate action set $\mathcal{A}(s_t)$

```

1: Encode graph :  $H_t \leftarrow f_\theta(G_t)$ 
2: Score candidates :  $\pi_\theta(a \mid s_t)$  for  $a \in \mathcal{A}(s_t)$ 
3: Select top :  $\hat{a}_t \leftarrow \arg \max \pi_\theta(a \mid s_t)$ 
4: Authorization :  $\alpha_t \leftarrow A(i_t, \hat{a}_t, s_t)$ 
5: Trust :  $\tau_t \leftarrow T_\phi(s_t, \tilde{x}_t^{(0)})$ 
6: Risk :  $\rho_t \leftarrow R_\phi(\hat{a}_t, s_t)$ 
7: Divergence :  $\Delta_t \leftarrow \|q_\phi(\hat{a}_t, s_t, \tilde{x}_t^{(0)}) - q_\phi(\hat{a}_t, s_t, \tilde{x}_t^{(1)})\|_2$ 
8: Uncertainty :  $u_t \leftarrow U_\omega(s_t, \hat{a}_t)$ 
9: Threshold :  $\tau_{\min} \leftarrow \tau_0 + \kappa_1 \rho_t + \kappa_2 u_t$ 
10: Conservatism :  $g_t \leftarrow w_1(1 - \tau_t) + w_2 \rho_t + w_3 u_t + w_4 \Delta_t$ 
11: if  $\alpha_t = 0$  then
12:    $d_t \leftarrow \text{BLOCK}$ 
13: else if  $\Delta_t > \delta_{\max}^{\text{hard}}$  then
14:    $d_t \leftarrow \text{BLOCK}$ 
15: else if  $\tau_t \geq \tau_{\min}$  and  $g_t < \gamma_1$  and  $\Delta_t \leq \delta_{\max}$  then
16:    $d_t \leftarrow \text{ALLOW}$ 
17: else if  $\gamma_1 \leq g_t < \gamma_2$  then
18:    $d_t \leftarrow \text{SCOPE-REDUCE}$ 
19: else if  $\gamma_2 \leq g_t < \gamma_3$  then
20:    $d_t \leftarrow \text{DEFER}$ 
21: else if  $\gamma_3 \leq g_t < \gamma_4$  or  $u_t > u_{\max}$  then
22:    $d_t \leftarrow \text{ESCALATE}$ 
23: else
24:    $d_t \leftarrow \text{BLOCK}$ 
25: end if
26: return  $d_t$ , executed action  $a_t^* = \mathcal{E}(d_t, \hat{a}_t)$ , audit record =0

```

Adam optimizer ($\eta = 10^{-3}$), batch size 64, early stopping (patience 15). Dropout ($p = 0.1$) enables MC-Dropout uncertainty at inference.

Trust autoencoder. Trained on clean telemetry with MSE reconstruction loss ($\eta = 5 \times 10^{-4}$). The 95th-percentile reconstruction error sets e_{thresh} .

Risk scorer and contrastive encoder. Risk scorer : binary cross-entropy on labeled outcomes. Contrastive encoder : margin loss ($m = 1.0$) pulling benign/adversarial hypotheses apart for unsafe actions.

6.4.5 Theoretical properties

We state ten propositions; all proofs are provided below.

Algorithm 6 Shield threshold calibration**Require:** Calibration set $\mathcal{D}_{\text{cal}}$ of n episodes, target $\varepsilon_{\text{target}}$, confidence $1 - \delta$

- 1: Grid : $\Gamma_{\text{grid}} \leftarrow \{(\gamma_1, \gamma_2, \gamma_3, \gamma_4) : 0 < \gamma_1 < \gamma_2 < \gamma_3 < \gamma_4\}$
- 2: **for** each $(\gamma_1, \gamma_2, \gamma_3, \gamma_4) \in \Gamma_{\text{grid}}$ **do**
- 3: Run shield Γ on $\mathcal{D}_{\text{cal}}$
- 4: $\hat{\varepsilon} \leftarrow n^{-1} \sum_{i=1}^n \mathbf{1}[d_i = \text{ALLOW} \wedge y_i = \text{unsafe}]$
- 5: $\varepsilon_{\text{ub}} \leftarrow \hat{\varepsilon} + \sqrt{\ln(1/\delta)/(2n)}$
- 6: **if** $\varepsilon_{\text{ub}} \leq \varepsilon_{\text{target}}$ **then**
- 7: Record feasible configuration
- 8: **end if**
- 9: **end for**
- 10: Select feasible configuration minimizing false-block rate
- 11: **return** calibrated $(\gamma_1^*, \gamma_2^*, \gamma_3^*, \gamma_4^*)$

TABLEAU 6.2 Training summary for all learned components.

Component	Params	Loss	Epochs
GraphSAGE encoder (f_θ)	$\approx 4.5\text{K}$	Cross-entropy	15–20
Policy head (π_θ)	$\approx 8.5\text{K}$	Cross-entropy	15–20
Trust AE (AE_ϕ)	$\approx 1.8\text{K}$	MSE recon.	10–20
Risk scorer (R_ϕ)	$\approx 1.5\text{K}$	Binary CE	25–30
Contrastive enc. (q_ϕ)	$\approx 3.6\text{K}$	Contrastive	40–50
Total learned	$\approx 20\text{K}$	—	—
Shield (deterministic)	14 scalars	Calibration	—

Hypothèse 6.1 (Standing assumptions). (1) $w_1, w_2, w_3, w_4 > 0$; (2) $\kappa_1, \kappa_2 \geq 0$; (3) $0 < \gamma_1 < \gamma_2 < \gamma_3 < \gamma_4$; (4) $0 < \delta_{\text{max}} < \delta_{\text{max}}^{\text{hard}}$; (5) $|\mathcal{A}| < \infty$; (6) $\tau_t, \rho_t, u_t \in [0, 1]$, $\Delta_t \geq 0$.

Proposition 6.1 (Monotone shield conservatism). *Under Assumption 6.1 with $\alpha_t = 1$, decreasing τ_t or increasing ρ_t, u_t , or Δ_t cannot move the output to a less conservative decision.*

Démonstration. Since $w_1, w_2, w_3, w_4 > 0$, the composite gate score $g_t = w_1(1 - \tau_t) + w_2\rho_t + w_3u_t + w_4\Delta_t$ is monotonically decreasing in τ_t and increasing in ρ_t, u_t, Δ_t . Since $\kappa_1, \kappa_2 \geq 0$, $\tau_{\text{min}} = \tau_0 + \kappa_1\rho_t + \kappa_2u_t$ is non-decreasing in ρ_t, u_t , making the trust condition harder to satisfy. The ALLOW branch requires $g_t < \gamma_1$, $\tau_t \geq \tau_{\text{min}}$, and $\Delta_t \leq \delta_{\text{max}}$. Worsening any input can only increase g_t , raise τ_{min} , or violate the divergence bound, pushing the output toward a more conservative branch. $\square$

Proposition 6.2 (Unauthorized-actuation exclusion). *If $\alpha_t = 0$, then $d_t \neq \text{ALLOW}$.*

Démonstration. In the shield algorithm, $\alpha_t = 0$ triggers $d_t = \text{BLOCK}$ at the authorization

TABLEAU 6.3 Complete hyperparameter specification.

Component	Parameter	Value
GNN encoder	Layers L	2
	Latent dim. d	64
Training	Optimizer	Adam
	LR (GNN, policy, risk)	10^{-3}
	LR (autoencoder)	5×10^{-4}
	Batch size	64
Uncertainty	Dropout p	0.1
	MC passes T	20
Shield (Γ)	$\gamma_1, \gamma_2, \gamma_3, \gamma_4$	0.30, 0.50, 0.70, 0.90
	w_1, w_2, w_3, w_4	0.25 each
	κ_1, κ_2	0.10, 0.15
	$\delta_{\max}, \delta_{\max}^{\text{hard}}$	0.50, 1.00
Simulation	Ticks / episode	30
	Failure fraction	0.40
	Training episodes	2,000

check, before any permissive branch is evaluated. $\square$

Proposition 6.3 (Divergence-triggered safeguard). *If $\Delta_t > \delta_{\max}^{\text{hard}}$, then $d_t = \text{BLOCK}$. If $\Delta_t > \delta_{\max}$, then $d_t \neq \text{ALLOW}$.*

Démonstration. $\Delta_t > \delta_{\max}^{\text{hard}}$ triggers $d_t = \text{BLOCK}$ at the hard-divergence check. $\Delta_t > \delta_{\max}$ violates the ALLOW condition, preventing permissive decisions. $\square$

Proposition 6.4 (Bounded decision completeness). *Γ is a total function : every valid input maps to exactly one $d_t \in \mathcal{D}$.*

Démonstration. The shield algorithm is a finite ordered branching structure with mutually exclusive branches (strict threshold ordering) and a final ELSE clause catching all remaining cases. Every valid input therefore maps to exactly one $d_t \in \mathcal{D}$. $\square$

Proposition 6.5 (Per-decision complexity). *Total per-decision complexity is $\mathcal{O}(L|E_t|d + |\mathcal{A}|k)$.*

Démonstration. Graph encoding : $\mathcal{O}(L|E_t|d)$. Candidate scoring and trust-risk evaluation : $\mathcal{O}(|\mathcal{A}|k)$ each. Shield evaluation : $\mathcal{O}(1)$. Total : $\mathcal{O}(L|E_t|d + |\mathcal{A}|k)$. $\square$

Proposition 6.6 (Defense-in-depth bound). *Let ε_α and ε_τ be false-negative probabilities of the authorization and trust-risk gates. Under combined attack with conditionally independent gates : $\Pr[\text{ALLOW} \mid \text{attack}] \leq \varepsilon_\alpha \cdot \varepsilon_\tau$.*

Démonstration. Under identity attack, an unsafe ALLOW requires an authorization false negative : $\Pr \leq \varepsilon_\alpha$. Under telemetry attack : $\Pr \leq \varepsilon_\tau$. Under combined attack with conditional independence : $\Pr[\text{ALLOW} \mid \text{combined}] = \Pr[\alpha_t = 1 \mid \text{id}] \cdot \Pr[g_t < \gamma_1 \mid \text{telem}] \leq \varepsilon_\alpha \varepsilon_\tau$. $\square$

Proposition 6.7 (Calibration-consistent accuracy). *For empirical false-allow rate $\hat{\varepsilon}$ on n i.i.d. episodes : $\Pr[\varepsilon^* \leq \hat{\varepsilon} + \sqrt{\ln(1/\delta)/(2n)}] \geq 1 - \delta$.*

Démonstration. Each episode produces Bernoulli y_i with $\mathbb{E}[y_i] = \varepsilon^*$. By Hoeffding's inequality : $\Pr[\varepsilon^* - \hat{\varepsilon} > t] \leq \exp(-2nt^2)$. Setting $\exp(-2nt^2) = \delta$ gives $t = \sqrt{\ln(1/\delta)/(2n)}$. $\square$

Proposition 6.8 (Bounded price of safety). *Under clean conditions with scope-reduction rate η and utility gap U_{gap} : $\mathbb{E}[\text{utility loss}] \leq \eta \cdot U_{\text{gap}} + \eta_{\text{block}} \cdot U_{\text{max}}$.*

Démonstration. With probability $(1 - \eta - \eta_{\text{block}})$, the shield allows (loss 0). With probability η , scope-reduction yields loss $\leq U_{\text{gap}}$. With probability η_{block} , blocking yields loss $\leq U_{\text{max}}$. Summing : $\mathbb{E}[\text{loss}] \leq \eta U_{\text{gap}} + \eta_{\text{block}} U_{\text{max}}$. $\square$

Proposition 6.9 (Conformal admissibility coverage). *With γ_1 set as the $(1 - \alpha)$ -quantile of calibration nonconformity scores and exchangeable test episodes : $\Pr[y_{n+1} = 1 \Rightarrow d_{n+1} \neq \text{ALLOW}] \geq 1 - \alpha$.*

Démonstration. By the conformal framework [79], if scores $(r_1, \dots, r_{n+1})$ are exchangeable, $\Pr[r_{n+1} \leq r_{((1-\alpha)(n+1))}] \geq 1 - \alpha$. The shield allows only if $g_t < \gamma_1$, which corresponds to $r_{n+1} > r_{((1-\alpha)(n+1))}$, occurring with probability $\leq \alpha$. $\square$

Proposition 6.10 (Calibration convergence rate). *Under continuous, strictly increasing $\varepsilon(\gamma)$ with $\varepsilon'(\gamma) \geq c_\varepsilon > 0$: $|\gamma_1^{(n)} - \gamma_1^*| = \mathcal{O}_P(1/\sqrt{n})$.*

Démonstration. By Hoeffding's concentration, $|\hat{\varepsilon}(\gamma) - \varepsilon(\gamma)| \leq \sqrt{\ln(2/\delta)/(2n)}$ w.h.p. Since $\varepsilon'(\gamma) \geq c_\varepsilon > 0$, the mean value theorem gives $|\varepsilon(\gamma_1^{(n)}) - \varepsilon(\gamma_1^*)| \geq c_\varepsilon |\gamma_1^{(n)} - \gamma_1^*|$. The triangle inequality yields $c_\varepsilon |\gamma_1^{(n)} - \gamma_1^*| = \mathcal{O}(1/\sqrt{n})$, so $|\gamma_1^{(n)} - \gamma_1^*| = \mathcal{O}_P(1/\sqrt{n})$. $\square$

6.5 Experimental Evaluation

6.5.1 Evaluation protocol

Data design. The evaluation uses a four-layer data design : (1) synthetic disaster graph simulation, (2) real-distribution telemetry from published 5G measurements—throughput (LogNormal, Narayanan et al. [219]), latency (Gamma, Xu et al. [220]), packet loss (Beta, 3GPP




FIGURE 6.3 Training convergence for all four learned components (20,019 total parameters). (a) Trust AE : MSE converges by epoch 16; (b) Risk scorer : BCE converges by epoch 27, AUC= 0.999; (c) Contrastive encoder : margin loss converges by epoch 44; (d) GNN+policy : CE converges by epoch 17, accuracy= 1.000.

TR 38.913 [221]), cell load (Beta, Xu et al. [222])—all K-S validated ($p > 0.68$), (3) conformal calibration of shield thresholds, and (4) adversarial injection grounded in SWaT [201] and WADI [202] testbed data. Nine simulation parameters are calibrated against real-world datasets (Intel Lab [200], SensorScope [199], SWaT, WADI) providing traceability from published data to simulation parameters.

Topologies. Three topology scales : **Small** (12-cell, 2-zone, primary), **Medium** (36-cell, 4-zone), **Large** (100-cell, 8-zone).

Methods. *Proposed* : CASTER-ZT (full pipeline). *External baselines* : (1) **CPO-Soft** [24] : Lagrangian cost-constrained policy, binary within-budget/over-budget decisions; (2) **Shield-Binary** [25] : precomputed binary safety shield from temporal constraints; (3) **Agentic-**




FIGURE 6.4 Multi-metric radar comparison under HIGH-severity identity abuse. CASTER-ZT : distinctive zero-false-positive, graduated-enforcement profile.

Auto [185] : confidence-based autonomous execution with deferral ; (4) **IF-Trust** [195] : Isolation Forest anomaly detector replacing the neural autoencoder. *Ablations* : Trust-Implicit, Identity-Only, Telemetry-Only, –Authorization, –Trust, –Risk.

Campaign. $11 \times 7 \times 20 = 1,540$ primary runs + 880 multi-scale = **2,420 total runs**. All results : mean $\pm$ std over 20 seeds, bootstrap 95% CIs, Wilcoxon signed-rank with Holm–Bonferroni correction.




FIGURE 6.5 Multi-scale evaluation. Left : rogue detection and recovery quality (12–100 cells). Right : per-tick latency. Security improves with scale ; 12-cell latency is $3\times$ below the O-RAN 10 ms budget.

TABLEAU 6.4 Main security results under HIGH-severity identity-credential abuse (mean $\pm$ std, 20 seeds).

Method	RogueDet	FalseBlk	ω_{rec}	S-R%
<i>Identity abuse (HIGH) :</i>				
CASTER-ZT	.742	.000	.733	58.2
IF-Trust [195]	1.000	.000	.925	94.6
Shield-Bin. [25]	.883	.488	.758	0.0
Agentic [185]	.105	.568	.144	0.0
CPO-Soft [24]	.000	.000	.201	0.0
<i>Clean (no attack) :</i>				
CASTER-ZT	—	.000	.925	10.0
IF-Trust	—	.000	.925	100.0
Shield-Bin.	—	.000	.925	0.0

6.5.2 Results

RQ1 : Security under attack

CASTER-ZT achieves 74.2% rogue detection with zero false positives and 58.2% graduated scope reduction. Shield-Binary [25] achieves higher raw blocking (78.5%) but 48.8% false positives ($p < 0.001$). IF-Trust [195] achieves higher raw detection (100%) through aggressive scope-reduction of *all* actions, including 100% scope-reduction under clean conditions—a pathological operational weakness. CPO-Soft [24] achieves zero detection since its cost constraint cannot capture identity-based threats. Agentic-Auto [185] achieves only 10.5% detection with 56.8% false positives.

The fundamental differentiator is *precision* : CASTER-ZT achieves zero false positives across all conditions, enabled by intelligent graduated enforcement. The 25.8% detection gap repre-

sents sophisticated adversary mimicry, validating the threat model.

Table 6.5 consolidates cross-method performance under the hardest condition (combined HIGH-severity attack).

Fig. 6.1 visualizes rogue detection and blocking across methods, confirming the zero-false-positive property unique to CASTER-ZT.

RQ2 : Recovery quality and ablation

CASTER-ZT achieves $\omega_{\text{rec}} = 0.733$ (73.3% operational cells at recovery). Non-shielding base-lines achieve 0.144–0.201 ($p < 0.001$). IF-Trust achieves higher $\omega_{\text{rec}} = 0.925$ through blanket scope-reduction, but throttles 100% of actions under clean conditions.

Ablation. Removing trust assessment is the most critical ablation : RogueDet drops from 0.742 to 0.524, and ω_{rec} from 0.733 to 0.380 ($p < 0.001$). Removing authorization produces similar results (RogueDet = 0.763), *expected* because the adversary uses stolen credentials. Removing risk moderately degrades results (RogueDet = 0.665, $\omega_{\text{rec}} = 0.678$).

RQ3 : Generalization

Detection improves with scale (0.742 at 12-cell to 0.983 at 100-cell) due to richer structural context. Latency scales from 3.07 ms to 10.25 ms, within the 10 ms O-RAN budget at 12-cell and 36-cell. The threshold sensitivity analysis (Table 6.8) confirms robustness : zero false positives across all γ_1 values $\in \{0.10, \dots, 0.60\}$.

Severity scaling is consistent : RogueDet = 0.806 at MEDIUM, 0.742 at HIGH (identity abuse) ; $\omega_{\text{rec}} = 0.810$ and 0.733 respectively.

RQ4 : 6G deployment compliance

All four criteria of Definition 6.2 are satisfied at 12-cell and 36-cell scales. At 100-cell, latency (10.25 ms) marginally exceeds the budget, motivating inference optimization. Fig. 6.3 confirms rapid convergence for all four learned components. Fig. 6.4 provides a multi-metric radar comparison across methods. Fig. 6.5 depicts the scaling behaviour of detection accuracy and latency.

TABLEAU 6.5 Cross-method security under HIGH-severity combined attack (20 seeds). $p < 0.001$ vs. CASTER-ZT for marked methods.

Cat.	Method	RogueDet	FalseBlk	ω_{rec}
Prop.	CASTER-ZT	.785	.004	.758
Ext.	IF-Trust	1.000	.000	.925
	Shield-Bin.	.881	.490	.757
	Agentic	.124	.654	.120
	CPO-Soft	.000	.000	.203
Abl.	–Authz	.769	.002	.760
	–Trust	.515	.000	.383
	–Risk	.704	.004	.691

TABLEAU 6.6 Recovery quality ω_{rec} under HIGH-severity identity abuse (20 seeds).

Method	ω_{rec}	Δ	p
CASTER-ZT	0.733 ± 0.038	—	—
IF-Trust	0.925 ± 0.000	+0.192	<0.001
Shield-Binary	0.758 ± 0.013	+0.025	0.064
Agentic-Auto	0.144 ± 0.027	−0.590	<0.001
CPO-Soft	0.201 ± 0.030	−0.532	<0.001
Trust-Implicit	0.201 ± 0.030	−0.532	<0.001

6.6 Discussion and Limitations

Defense in depth. Ablation confirms trust assessment as the critical component (removal : RogueDet $0.742 \rightarrow 0.524$, ω_{rec} $0.733 \rightarrow 0.380$). Authorization contributes defense against a different attack class; risk assessment provides redundancy. This validates Proposition 6.6 : independent gates multiplicatively reduce unsafe execution probability.

External baselines. The protection gap is structural, not parametric. Shield-Binary achieves high blocking (78.5%) but 48.8% false positives; CPO-Soft achieves zero detection since cost constraints do not capture identity attacks; Agentic-Auto demonstrates that confidence-only autonomy without identity verification produces imprecise blocking. IF-Trust achieves maximal detection through maximal aggression, isolating the neural autoencoder’s advantage over the Isolation Forest’s indiscriminate anomaly response. No single published method addresses all three dimensions : rogue detection, enforcement precision, and clean-condition operational transparency.

Telemetry-poisoning limitation. The trust autoencoder does not hard-block telemetry poisoning—a documented limitation of reconstruction-error detectors [223–225]. Future work should investigate cross-source GNN consistency checking, adversarially trained detectors,

TABLEAU 6.7 Multi-scale evaluation under HIGH-severity identity abuse.

Topology	Block%	RogueDet	ω_{rec}	Latency
12-cell, 2-zone	0.0	0.742	0.733	3.07 ms
36-cell, 4-zone	0.0	0.949	0.886	4.38 ms
100-cell, 8-zone	0.0	0.983	0.868	10.25 ms

TABLEAU 6.8 Threshold sensitivity : sweeping γ_1 under HIGH-severity identity abuse (12-cell, 20 seeds).

γ_1	Block%	RogueDet	FalseBlk	ω_{rec}
0.10	0.0	1.000	0.0	0.925
0.20	0.0	0.787	0.0	0.753
0.30	0.1	0.757	0.0	0.746
0.40	0.2	0.737	0.0	0.711
0.60	0.3	0.732	0.0	0.727

and temporal sequence modeling.

AI-native design. CASTER-ZT achieves $\eta_{\text{AI}} = 5/6$ with $\approx 20\text{K}$ parameters. The deliberate separation of learned intelligence from deterministic safety instantiates the dynamic model predictive shielding paradigm [192]. The shield is policy-agnostic : any future controller (RL agent, LLM-based planner [185, 211]) can serve as proposal generator without modifying the shield.

Agentic AI comparison. Agentic systems [185, 210] provide adaptive learning, multi-intent negotiation, and foundation-model reasoning that CASTER-ZT does not. Conversely, CASTER-ZT provides identity-aware gating, formal admissibility guarantees, graduated decisions, and defense-in-depth composability absent from agentic systems. The integration path is straightforward : the agentic controller handles strategy generation ; CASTER-ZT wraps its output for bounded admissibility.

Data provenance. The evaluation uses four provenance layers : (1) synthetic simulation dynamics, (2) nine parameters calibrated against real datasets (Intel Lab [200], Sensor-Scope [199], SWaT [201], WADI [202]), (3) telemetry from published 5G distributions (K-S validated, $p > 0.68$), and (4) distribution-free mathematical guarantees (Propositions 6.7, 6.9) that hold regardless of data provenance. The conformal guarantee requires only exchangeability, not distributional assumptions.

Societal relevance. As climate-driven disasters intensify, autonomous disaster-recovery

TABLEAU 6.9 Deployment profile and 6G compliance.

Metric	CASTER-ZT	Constraint
Decision latency (12-cell)	3.07 ms	< 10 ms
Model memory	≤ 2 MB	< 50 MB
Total parameters	≈ 20 K	—
AI-native coverage η_{AI}	5/6	—
Audit completeness	100%	—
Edge autonomy	Yes	Required

capabilities become a societal necessity. Communication infrastructure is among the most vulnerable; autonomous speed without bounded safety is dangerous. CASTER-ZT’s edge-deployable profile (≈ 20 K parameters, ≤ 2 MB, no GPU at inference) enables autonomous security at the infrastructure edge under backbone disconnection. The EU AI Act [215] classifies critical-infrastructure AI as high-risk, requiring auditable decision-making; CASTER-ZT’s deterministic shield, ten propositions, and defer/escalate pathways provide exactly this.

Threats to validity. (1) Simulator abstraction—real deployments involve continuous time and heterogeneous hardware. (2) Learned components are trained on simulation; transfer to live telemetry may require fine-tuning. (3) The adversary cannot modify shield internals or compromise multiple zones. (4) External baselines are faithful adaptations, not original-author code. (5) ω_{rec} does not model cascading failures.

6.7 Conclusion

This paper proposed CASTER-ZT, a zero-trust shielded decision-control framework for secure autonomous recovery in AI-native disaster-monitoring sensing networks. The core design separates learned intelligence (GNN encoder, recovery policy, autoencoder trust evaluator, contrastive risk scorer, MC-Dropout uncertainty) from a formally verified deterministic shield. Ten theoretical properties provide formal security foundations. A 2,420-run campaign demonstrated 74.2–98.3% rogue detection with zero false positives, $\omega_{\text{rec}} = 0.733$ ($p < 0.001$ vs. non-shielding baselines), and 3.07 ms per-decision latency. The framework achieves AI-native coverage $\eta_{\text{AI}} = 5/6$ and 6G deployment compliance at the primary evaluation scale. Future work includes adversarial training of the trust autoencoder, RL-based policy optimization, cross-source GNN consistency checking, and evaluation under adaptive adversaries.

Les hyperparamètres complets, les preuves des dix propositions théoriques, les résultats détaillés par échelle et par scénario d’attaque, ainsi que les analyses de sensibilité aux seuils

sont fournis à l'Annexe D.

CHAPITRE 7 DISCUSSION GÉNÉRALE

Ce chapitre effectue une analyse transversale des résultats obtenus dans les trois articles de cette thèse. Contrairement aux sections de discussion individuelles de chaque article, qui se concentrent sur les résultats spécifiques à chaque contribution, ce chapitre adopte une perspective intégrative. Il examine comment les trois articles interagissent, se renforcent mutuellement et, collectivement, répondent à la question de recherche principale de cette thèse.

7.1 Retour sur les questions de recherche

7.1.1 Q1 — Efficacité énergétique (GAPF)

“Est-il possible d’atteindre un routage multi-sauts quasi-optimal ($PDR \geq 98\%$) en fusionnant des politiques MARL via un encodeur GNN, tout en respectant les contraintes des plateformes embarquées ?”

Réponse : Oui. GAPF atteint un PDR de 98–99% sur l’ensemble des 7 scénarios, avec seulement 1 473 paramètres entraînaables et une consommation mémoire de ~ 951 MB — soit $26\times$ moins de paramètres et $13\times$ moins de mémoire que les agents QMIX/QTRAN. La fusion GCN+CAS exploite la complémentarité de QMIX (coordination monotone) et QTRAN (interactions non monotones) en sélectionnant dynamiquement l’expert optimal selon le contexte topologique.

7.1.2 Q2 — Durabilité carbone (CALASH)

“Peut-on réduire significativement le LCI d’un WSN en intégrant conjointement la réduction de données sensible au carbone, le routage avec garanties formelles, l’auto-guérison et la comptabilité du cycle de vie, sur une couche physique 6G ?”

Réponse : Oui. CALASH réduit le LCI de 33% par rapport aux protocoles de référence, atteignant 82.9% de PDR et 60% de durée de vie supérieure. Les quatre piliers agissent de manière synergique, et la borne de Pareto CDL prouve mathématiquement la convergence simultanée vers un taux de livraison quasi-optimal et un budget carbone borné.

7.1.3 Q3 — Sécurité zéro-confiance (CASTER-ZT)

“Peut-on détecter les politiques compromises avec zéro faux positif tout en maintenant un score de récupération élevé, dans le budget de latence O-RAN ?”

Réponse : Oui. CASTER-ZT atteint 74.2–98.3% de détection avec un taux de faux positifs rigoureusement nul, $\omega_{\text{rec}} = 0.733$ ($3.7\text{--}5.2\times$ supérieur aux références), et 3.07 ms par décision — bien dans le budget de 10 ms du near-RT RIC O-RAN.

7.1.4 Question principale

L’ensemble des résultats confirme qu’une pile protocolaire complète — écoénergétique, durable en carbone et sécurisée — est réalisable pour les WSN de surveillance des catastrophes intégrés au 6G. Les douze critères du Tableau 2.9 sont couverts collectivement, une couverture qu’aucune approche existante ne peut égaler.

7.2 Analyse transversale des résultats

7.2.1 Synergies quantitatives entre les couches

L’architecture en couches de la pile protocolaire crée des synergies mesurables :

Effet de GAPF sur CALASH. Le routage plus efficace de GAPF (énergie $2\text{--}3.5\times$ inférieure) réduit directement le terme $C_{\text{opérationnel}}$ de la métrique LCI. Bien que le carbone opérationnel soit faible en valeur absolue ($\sim 0.01 \text{ gCO}_2\text{eq}$), la réduction de la consommation d’énergie a un effet indirect beaucoup plus important : elle prolonge la durée de vie du réseau, ce qui augmente le dénominateur du LCI (paquets utiles livrés) et réduit ainsi le LCI global. Si l’on combine l’efficacité de GAPF ($+60\%$ de durée de vie estimée) avec les quatre piliers de CALASH, l’amélioration cumulée du LCI pourrait dépasser les 33% observés pour CALASH seul, bien que cette hypothèse reste à valider expérimentalement par une évaluation intégrée bout-en-bout.

Effet de CALASH sur GAPF. Le pilier CADR de CALASH réduit le volume de données transmises via la détection comprimée, ce qui diminue le trafic dans le réseau. Cette réduction de trafic bénéficie directement à GAPF en réduisant la contention sur les liens radio et en préservant l’énergie des relais — amplifiant les gains d’efficacité de la première couche.

Effet de CASTER-ZT sur l’ensemble. Le bouclier zéro-confiance protège les gains des deux premières couches contre les compromissions. Sans cette protection, un adversaire qui compromet la politique de routage de GAPF ou CALASH pourrait annuler tous les gains

d’efficacité et de durabilité en un seul épisode d’attaque. L’investissement computationnel de CASTER-ZT (3.07 ms/décision, $\sim 20K$ paramètres) est donc un “coût d’assurance” faible par rapport aux gains qu’il protège.

7.2.2 Le paradigme de la fusion vs. l’apprentissage monolithique

Le succès de GAPF avec seulement 1 473 paramètres — contre $\sim 39\,000$ par agent RNN dans QMIX/QTRAN — remet en question l’approche dominante d’entraîner un réseau de plus en plus grand. L’alternative, fusionner des experts légers via un méta-contrôleur informé par la topologie, emprunte un chemin orthogonal au paysage de la décomposition de valeur (QMIX [20], WQMIX [38], QPLEX [39], FOP [41]) qui tend vers des architectures plus lourdes. Ce paradigme de *portfolio d’experts* est bien établi en optimisation combinatoire mais n’avait jamais été appliqué au routage MARL dans les WSN.

7.2.3 Analyse de la complexité Dec-POMDP et implications

La résolution optimale d’un Dec-POMDP étant NEXP-complète [37], le PDR $\geq 98\%$ de GAPF ne peut pas être garanti optimal au sens absolu. Le paradigme CTDE (QMIX, QTRAN) constitue une approximation structurée réduisant l’espace de recherche de $|\mathcal{A}|^n$ à $\sum_i |\mathcal{A}_i|$, et GAPF ajoute la sélection d’expert comme niveau supplémentaire. L’inférence reste polynomiale ($O(|E| \cdot d)$ pour le GCN, $O(n)$ pour le CAS), garantissant la scalabilité pratique.

7.2.4 Robustesse adversariale : analyse et perspectives

La robustesse adversariale traverse les trois couches : GAPF est potentiellement vulnérable aux attaques par injection de nœuds, mais le CAS réduit la surface d’attaque en opérant à un niveau d’abstraction supérieur ; CALASH bénéficie d’un *nettoyage* topologique indirect via SHDR ; CASTER-ZT détecte explicitement les actuations adversariales, bien que les attaques par *backdoor* [72] restent un défi ouvert que le MC-Dropout atténue partiellement. L’intégration de défenses basées sur les MDP robustes [73] constitue une direction future prometteuse.

7.2.5 Faisabilité du déploiement TinyML

La question de la déployabilité sur microcontrôleurs mérite une analyse détaillée. Le paradigme TinyML [55] — exécution de modèles d’apprentissage automatique sur des microcontrôleurs à budget $< 1\text{ mW}$ — est particulièrement pertinent pour notre pile protocolaire.

TABLEAU 7.1 Analyse de déployabilité TinyML des trois cadres proposés.

Cadre	Param.	Mémoire (FP32)	OPS/inf.	Cible	Technique de compression
GAPF (GCN+CAS)	1 473	5.8 KB	~3K	Cortex-M4	Aucune nécessaire
CALASH (DQN)	~5K	19.5 KB	~10K	Cortex-M4	Quantification INT8 (→4.9 KB)
CASTER-ZT (GraphSAGE)	~20K	78 KB	~40K	Cortex-M7/TPU	Distillation + INT8 (→20 KB)
Pile complète	~27K	103 KB	~53K	Cortex-M7	Quantification mixte

Le Tableau 7.1 montre que GAPF est directement déployable sur un Cortex-M4 sans aucune compression. CALASH nécessite une quantification INT8 standard (supportée par TensorFlow Lite for Microcontrollers [56]). CASTER-ZT, le plus lourd, nécessite soit un Cortex-M7 (avec 512 KB de RAM) soit un accélérateur de bord dédié. Le cadre MCUNet [57] démontre que des réseaux de neurones de $\sim 1\text{M}$ de paramètres peuvent être exécutés sur des Cortex-M7 ; notre pile, avec $\sim 26\text{ K}$ paramètres au total ($\sim 38\times$ plus légère), est donc confortablement dans l’enveloppe.

7.2.6 Le carbone incorporé comme métrique oubliée

La révélation que le carbone incorporé domine d’environ six ordres de grandeur le carbone opérationnel ($10\,000/0,01 = 10^6$) pour les dispositifs IoT a des implications profondes. Elle suggère que la communauté des réseaux verts, en se concentrant exclusivement sur la réduction de la consommation d’énergie opérationnelle, a optimisé le mauvais terme de l’équation. Le vrai levier pour la durabilité réside dans la **maximisation de l’utilité par unité de carbone incorporé** — c’est-à-dire dans la livraison du plus grand nombre possible de paquets utiles avant la fin de vie du réseau. Ce changement de perspective, formalisé par la métrique LCI, pourrait influencer la conception de protocoles IoT bien au-delà des WSN.

7.2.7 Zéro-confiance comme couche systémique

CASTER-ZT démontre que le paradigme zéro-confiance peut s’appliquer à la **couche de décision** des systèmes autonomes. La séparation entre composants apprenables (GraphSAGE) et déterministes (bouclier à 14 paramètres) crée une **barrière de confiance** : même si les composants neuronaux sont compromis, le bouclier fournit une dernière ligne de défense vérifiée formellement. Les décisions graduées (5 niveaux) dépassent les mécanismes existants — CPO [24] optimise en espérance sans garantie individuelle, le blindage binaire [25] ne propose pas de dégradation gracieuse — et s’apparentent aux protocoles d’escalade industriels (IEC 62443).

7.2.8 Paradigmes émergents

Trois paradigmes émergents pourraient amplifier les contributions : (i) l'apprentissage fédéré [82] pour l'entraînement distribué avec détection du *model poisoning* par CASTER-ZT ; (ii) les jumeaux numériques [84] pour l'entraînement continu et la prédiction de pannes ; (iii) la quantification INT4 des GNN [58] pour réduire l'empreinte de GAPF à ~ 1.5 KB. Ces directions sont détaillées dans les travaux futurs (Section 8.6).

7.3 Analyse de convergence et garanties théoriques

Cette section examine les propriétés de convergence des trois couches sous un angle unifié. **GAPF** : la convergence repose sur deux niveaux — QMIX converge vers la factorisation optimale monotone (IGM) [20], QTRAN couvre un espace plus large via la factorisation affine, et le méta-contrôleur CAS réduit la variance de l'estimateur combiné (analogue au *stacking* [226]) à condition que les erreurs des experts soient faiblement corrélées. **CALASH** : l'optimisation drift-plus-penalty de Lyapunov converge vers un voisinage $O(1/V)$ de l'optimum, avec $V = 100$ offrant 33% de réduction LCI [61]. La borne CDL prouve la convergence simultanée vers un PDR quasi-optimal et un budget carbone borné. **CASTER-ZT** : les garanties relèvent de la vérification formelle — correction (0% faux positifs garantis par construction, confirmés sur 2 420 exécutions), complétude bornée (détection sous seuils $\theta_{\text{conf}}/\theta_{\text{unc}}$), et latence $O(1)$ par décision.

7.3.1 Synthèse : complémentarité des garanties

Le Tableau 7.2 résume les propriétés de convergence de chaque couche.

TABLEAU 7.2 Synthèse des propriétés de convergence et garanties théoriques de la pile protocolaire.

Couche	Type de garantie	Condition	Résultat	Limitation
GAPF (GCN+CAS)	Convergence stochastique	Erreurs faiblement corrélées	Réduction de variance	Pas de borne finie
QMIX (expert)	Convergence monotone	IGM satisfaite	Q -optimal dans classe monotone	Biais si IGM violée
QTRAN (expert)	Convergence affine	Factorisation correcte	Q -optimal dans classe affine	Instabilité d'entraînement
CALASH (Lyapunov)	Convergence $O(1/V)$	Files stables	Voisinage de l'optimum LCI	Compromis V
CASTER-ZT (bouclier)	Correction formelle	Seuils calibrés	0% faux positifs	Attaques mimétiques

La complémentarité des garanties est notable : GAPF fournit une convergence probabiliste vers des politiques efficaces, CALASH ajoute une convergence déterministe vers un budget carbone borné, et CASTER-ZT fournit des garanties de correction formelle sur chaque décision individuelle. Aucune couche isolée ne fournit les trois types de garanties simultanément — c'est leur composition qui crée un système à la fois efficace, durable et sûr.

7.4 Analyse de sensibilité

L’identification des paramètres les plus influents guide le déploiement pratique. Pour **GAPF** : $L = 2$ couches GCN, $d = 16$ (maintenant < 1500 paramètres) et $\delta = 0.6$ pour le seuil CAS (taux de sélection $\sim 75\%$). Pour **CALASH** : $V = 100$ offre -33% LCI avec latence acceptable, insensible à V dans $[50-500]$; le ratio de compression $\rho_0 = 0.3$ garantit une erreur de reconstruction $< 1\%$. Pour **CASTER-ZT** : $\theta_{\text{conf}} = 0.8$ maintient $> 90\%$ de décisions “autoriser” en conditions normales; $T = 20$ passes MC-Dropout ($p_{\text{drop}} = 0.1$) contribuent ~ 1.5 ms sur 3.07 ms totaux.

7.4.1 Sensibilité aux conditions environnementales

TABLEAU 7.3 Analyse de sensibilité de la pile protocolaire aux conditions environnementales. $\uparrow/\downarrow$: impact positif/négatif sur la performance.

Condition	GAPF	CALASH	CASTER-ZT	Pile complète
Densité réseau élevée (> 100 nœuds)	$\downarrow$ (over-smoothing)	$\uparrow$ (redondance)	$\uparrow$ (diversité)	Modéré $\uparrow$
Densité réseau faible (< 30 nœuds)	$\uparrow$ (graphe simple)	$\downarrow$ (fragilité)	$\downarrow$ (peu de données)	Modéré $\downarrow$
Intensité carbone haute	Aucun impact	$\uparrow$ (fort levier)	Aucun impact	$\uparrow$
Intensité carbone basse	Aucun impact	$\downarrow$ (faible levier)	Aucun impact	$\downarrow$
Taux de compromission élevé	$\downarrow$ (experts biaisés)	$\downarrow$ (routes corrompues)	$\uparrow$ (fort levier)	Modéré —
Mobilité des nœuds	$\downarrow\downarrow$ (topologie instable)	$\downarrow$ (re-clustering)	$\downarrow$ (modèle invalidé)	$\downarrow\downarrow$

Le Tableau 7.3 révèle que la principale vulnérabilité de la pile est la **mobilité des nœuds** : le GCN de GAPF capture une topologie statique, et les changements rapides de topologie invalident les embeddings. Cette limitation est inhérente à l’hypothèse de WSN statiques adoptée dans les trois articles — une hypothèse raisonnable pour les capteurs de surveillance (fixes une fois déployés) mais restrictive pour les scénarios impliquant des capteurs mobiles (drones, robots).

7.5 Analyse des modes de défaillance

Le Tableau 7.4 résume les sept modes de défaillance identifiés pour la pile protocolaire, leur probabilité, impact et mécanismes de mitigation. Le mode le plus probable et impactant est le partitionnement du réseau (M3), intrinsèquement lié au scénario de catastrophe, mitigé par SHDR. Les modes les plus dangereux (M6 : attaques mimétiques, M7 : compromission du bouclier) ont une probabilité très faible, cohérente avec le profil de menace des WSN de surveillance.

TABLEAU 7.4 Analyse des modes de défaillance de la pile protocolaire (FMEA simplifiée).

Mode	Description	Probabilité	Impact	Mitigation
M1	Dégradation de distribution (GAPF)	Modérée	Élevé	Diversité d’entraînement + retour défaut
M2	Épuisement synchrone	Faible	Modéré	Équilibrage énergétique
M3	Partitionnement du réseau	Élevée (catastrophe)	Critique	SHDR + redondance matérielle
M4	Données carbone indisponibles	Faible	Modéré	Profil de repli historique
M5	Non-stationnarité du mix énergétique	Faible	Faible	CADR paramétrique
M6	Attaque mimétique sophistiquée	Très faible	Élevé	Détection de dérive statistique
M7	Compromission du bouclier	Très faible	Critique	TrustZone + vérification hash

7.6 Positionnement par rapport à l’état de l’art

Le Tableau 7.5 compare la pile protocolaire proposée avec les principales approches de la littérature selon trois dimensions : performance, empreinte computationnelle et couverture des critères.

TABLEAU 7.5 Positionnement de la pile proposée par rapport aux principales approches de la littérature.

Approche	PDR	Durée de vie	LCI	Sécurité	Paramètres	Critères /12
LEACH	60–75%	931 tours	13.42	Aucune	~0 (heuristique)	2
EE-LEACH / HEED	70–80%	1 100 tours	N/A	Aucune	~0	2
QMIX	46–67%	1 200 tours	N/A	Aucune	~39K/agent	2
QTRAN	46–68%	1 150 tours	N/A	Aucune	~39K/agent	2
CPO (Safe RL)	N/A	N/A	N/A	Espérance	~100K	3
Shield binaire	N/A	N/A	N/A	Binaire	~10K	4
GAPF (Art. 1)	≥98%	+43–111%	N/A	Non	1 473	4
CALASH (Art. 2)	82.9%	1 486 tours	8.99	Non	~5K	8
CASTER-ZT (Art. 3)	N/A	N/A	N/A	Graduée+formelle	~20K	9
Pile complète	≥98%	+60%	–33%	ZT graduée	~27K	12

Les résultats montrent que la pile complète offre une couverture sans précédent des douze critères, avec un budget computationnel total de ~27K paramètres — comparable à un seul agent RNN dans les approches MARL existantes. Ce constat signifie que pour un coût computationnel similaire à une seule politique QMIX (~39K paramètres), la pile fournit conjointement l’efficacité énergétique, la durabilité carbone et la sécurité zéro-confiance.

7.6.1 Comparaison avec les travaux concurrents 2024–2025

Les travaux récents confirment l’originalité de notre approche : Nguyen et al. [60] (2025) proposent un routage GNN avec ~50K paramètres pour un PDR de ~95% mais sans durabilité ni sécurité ; Sefati et al. [128] et Rahman et al. [127] (2025) combinent routage fédéré/distribué sans conscience carbone ; les approches de communication sémantique (JSCC) offrent un

gain potentiel de compression mais nécessitent $\sim 100K$ paramètres. Aucun de ces travaux ne couvre simultanément les trois dimensions avec des garanties formelles.

7.7 Considérations éthiques et sociétales

Le déploiement de WSN autonomes gérés par AI soulève quatre enjeux éthiques : (i) la **confidentialité** des données capteurs, partiellement atténuée par CASTER-ZT et la détection comprimée de CALASH ; (ii) le **biais algorithmique et l'équité spatiale**, où l'équilibrage énergétique de GAPF atténue le risque de sous-couverture de certaines zones ; (iii) **l'autonomie et la supervision humaine**, où CASTER-ZT intègre le principe de *human-in-the-loop* via le niveau “escalader” ; (iv) **l'impact environnemental de la recherche** elle-même (~ 144 heures GPU d'entraînement), modeste par rapport aux grands modèles de langage mais illustrant le paradoxe de concevoir des protocoles “verts” avec des outils énergivores.

7.8 Limites de la discussion

Cette discussion présente trois limites principales : (i) les synergies entre couches sont estimées analytiquement plutôt que mesurées dans un système intégré, et la déployabilité embarquée repose sur des estimations théoriques des accélérateurs ; (ii) les comparaisons avec l'état de l'art portent sur des approches n'ayant pas été conçues pour les mêmes douze critères, et les travaux concurrents 2024–2025 utilisent parfois des métriques différentes ; (iii) la validation est limitée aux WSN de surveillance des catastrophes avec routage hiérarchique, et la scalabilité au-delà de 200 nœuds n'a pas été caractérisée expérimentalement.

CHAPITRE 8 CONCLUSION

Cette thèse a abordé le problème du routage intelligent dans les réseaux de capteurs sans fil (WSN) déployés pour la surveillance des catastrophes naturelles, en proposant trois cadres complémentaires formant une pile protocolaire complète — efficacité énergétique, durabilité carbone du cycle de vie et sécurité zéro-confiance — pour les réseaux natifs en intelligence artificielle (AI) intégrés aux technologies de sixième génération (6G). Ce chapitre conclut la thèse en synthétisant les travaux réalisés (Section 8.1), en détaillant les contributions et retombées pour les entreprises, la société et les gouvernements (Section 8.3), en reconnaissant les limitations (Section 8.5), et en identifiant les directions de recherche futures (Section 8.6).

8.1 Synthèse des travaux

Article 1 — GAPF. GAPF propose un méta-contrôleur de fusion de politiques MARL (QMIX et QTRAN) via un encodeur GCN à 2 couches et un sélecteur contextuel (CAS), totalisant seulement 1 473 paramètres. L'évaluation sur 7 scénarios a démontré : $\text{PDR} \geq 98\%$, consommation d'énergie 2 à $3.5\times$ inférieure aux références et empreinte mémoire $13\times$ moindre, rendant le déploiement sur Cortex-M4 réaliste.

Article 2 — CALASH. CALASH est le premier protocole de routage pour WSN à minimiser conjointement l'intensité carbone du cycle de vie (LCI) à travers quatre piliers intégrés (CADR, CARE, SHDR, LSE) sur une couche physique 6G bi-bande. Il a atteint 60% de durée de vie supérieure, 82.9% de PDR et 33% de LCI inférieur, validé sur 30 graines Monte Carlo. L'aperçu clé est que la réduction du volume de données transmises constitue le levier le plus efficace pour réduire l'empreinte carbone des WSN.

Article 3 — CASTER-ZT. CASTER-ZT est le premier cadre de contrôle de décision conforme au paradigme zéro-confiance (NIST SP 800-207) pour les réseaux natifs en AI, couplant un encodeur GraphSAGE, un évaluateur neuronal avec MC-Dropout et un bouclier déterministe à 5 niveaux gradués. La campagne de 2 420 exécutions a démontré 74.2–98.3% de détection avec zéro faux positif, $\omega_{\text{rec}} = 0.733$ ($3.7\text{--}5.2\times$ supérieur aux références) et 3.07 ms par décision.

8.2 Contributions scientifiques originales

Cette thèse apporte six contributions scientifiques originales à l'état de l'art, dont l'importance et la portée sont détaillées ci-dessous.

Contribution 1 : Premier cadre de fusion de politiques MARL via GNN pour le routage dans les WSN. GAPF est, à notre connaissance, le premier méta-contrôleur qui exploite un encodeur GCN pour capturer la structure topologique d'un WSN et sélectionner dynamiquement la politique MARL la plus adaptée. Avec seulement 1473 paramètres entraînaibles ($26\times$ moins qu'un seul agent RNN), GAPF démontre que la fusion de politiques peut être plus efficace que l'entraînement d'une politique monolithique unique, ouvrant une nouvelle direction de recherche en méta-apprentissage pour les systèmes multi-agents. La portée de cette contribution dépasse les WSN : le paradigme GNN+CAS est applicable à tout système multi-agent où des experts complémentaires existent.

Contribution 2 : Réseau d'attention monotone Q·K pour la scalarisation de récompenses multi-objectifs. L'architecture combinant un mécanisme d'attention requête-clé et un réseau à poids non-négatifs garantit formellement la monotonie Pareto de la scalarisation : si une solution domine au sens de Pareto une autre, son score scalaire sera strictement supérieur. Cette garantie, absente des méthodes de scalarisation existantes (somme pondérée, Tchebycheff), élimine les artefacts qui peuvent tromper l'optimiseur dans les régions non convexes du front de Pareto.

Contribution 3 : Première métrique d'intensité carbone du cycle de vie (LCI) pour les WSN conforme à ISO 14040. La métrique LCI intègre le carbone incorporé, opérationnel et de fin de vie dans un indicateur unique exprimé en gCO_2eq par paquet utile livré. Cette métrique comble une lacune fondamentale dans l'évaluation des protocoles de routage : les métriques existantes (Joules/paquet, durée de vie) ne reflètent pas l'impact environnemental réel. Le LCI offre un cadre de comparaison équitable qui peut être adopté par la communauté pour l'évaluation de tout protocole IoT.

Contribution 4 : Premier protocole de routage pour WSN à quatre piliers avec garanties de Lyapunov pour le budget carbone. L'intégration de CADR, CARE, SHDR et LSE dans un cadre unifié avec une preuve mathématique de la borne de Pareto CDL est, à notre connaissance, inédite. La borne prouve que CALASH converge simultanément vers un taux de livraison quasi-optimal *et* un budget carbone borné, fournissant les premières garanties théoriques sur la durabilité carbone d'un protocole de routage.

Contribution 5 : Premier cadre de contrôle de décision zéro-confiance pour les réseaux de détection natifs en AI. CASTER-ZT est le premier système qui vérifie chaque actuation de politique apprise avec un spectre de cinq décisions graduées, soutenu par dix propositions formelles. Cette approche dépasse fondamentalement les mécanismes binaires existants en offrant une dégradation gracieuse qui maintient la mission de surveillance tout en contenant les menaces. Le bouclier déterministe, avec ses 14 paramètres non apprenables,

est entièrement explicable et auditable — une propriété cruciale pour la certification de systèmes critiques.

Contribution 6 : Démonstration de la complémentarité entre efficacité énergétique, durabilité carbone et sécurité. Collectivement, les trois articles démontrent que ces trois objectifs se renforcent mutuellement plutôt que de s’opposer : un routage plus efficace (GAPF) réduit le carbone opérationnel ; la réduction de données sensible au carbone (CALASH) prolonge la durée de vie et amortit le carbone incorporé ; le bouclier zéro-confiance (CASTER-ZT) protège les gains des deux premiers contre les compromissions. Cette complémentarité, formalisée comme une pile protocolaire intégrée, constitue un résultat d’intérêt systémique pour la conception des futurs réseaux IoT.

8.3 Retombées scientifiques et sociétales

Pour les entreprises. La légèreté de GAPF (~ 5.8 KB) élimine le besoin de passerelles coûteuses pour l’inférence. L’amélioration de 60% de la durée de vie réduit les coûts de maintenance. La métrique LCI fournit un outil quantitatif pour le rapport de durabilité conforme aux exigences CSRD/SEC. Le bouclier CASTER-ZT, entièrement auditable, facilite la certification IEC 62443 et NIST.

Pour la société. Un $PDR \geq 98\%$ garantit la fiabilité des alertes de catastrophe, contribuant au Cadre de Sendai [4]. La réduction de 33% du LCI contribue à la neutralité carbone. Le mécanisme SHDR maintient la couverture post-catastrophe. CASTER-ZT protège contre les cybermenaces en période de crise avec zéro faux positif.

Pour les gouvernements. Le LCI offre un indicateur standardisé pour l’évaluation des déploiements IoT. Les cadres contribuent aux indicateurs Sendai C-2 et C-6. Les algorithmes publiés en accès ouvert permettent l’implémentation sans dépendance propriétaire. La composante fin-de-vie du LCI informe les politiques DEEE. La légèreté de GAPF démocratise l’accès pour les pays en développement.

Pour la communauté scientifique. GAPF ouvre la recherche en méta-apprentissage multi-agents, le LCI étend les réseaux verts au-delà de l’énergie opérationnelle, et CASTER-ZT inaugure une approche intermédiaire entre mécanismes binaires et safe RL. Les résultats servent de lignes de base reproductibles ($> 23\,000$ exécutions).

8.4 Alignement avec les Objectifs de développement durable

Les contributions s’alignent avec cinq ODD des Nations Unies, comme synthétisé dans le Tableau 8.1.

TABLEAU 8.1 Alignement des contributions avec les ODD des Nations Unies.

ODD	Cible	Contribution	Article(s)
9	Infrastructure résiliente et innovation	Routage intelligent ultra-léger (1 473 param.)	1 (GAPF)
11	Réduire les pertes humaines (11.5)	PDR $\geq$ 98%, auto-guérison SHDR	1, 2
12	Rapport de durabilité (12.6)	Métrique LCI conforme ISO 14040	2 (CALASH)
13	Résilience climatique (13.1)	CADR sensible au carbone + résilience post-catastrophe	2 (CALASH)
16	Institutions transparentes (16.6)	Bouclier explicable + 0 faux positif	3 (CASTER-ZT)

8.5 Limitations de la solution proposée

Malgré les contributions significatives de cette thèse, plusieurs limitations doivent être reconnues et mises en perspective.

1. **Évaluation par simulation.** Les trois articles reposent sur des simulations numériques. Bien que validées contre des données réelles (Intel Lab pour les traces capteurs, UK Carbon Intensity API pour les données carbone, USGS ShakeMap pour les modèles sismiques) et utilisant des modèles physiques bien établis (modèle de premier ordre de Heinzelman [6] pour l’énergie, propagation sub-THz avec absorption moléculaire pour la couche 6G), les résultats ne peuvent garantir un comportement identique lors d’un déploiement sur matériel réel. Les effets de la variabilité du canal radio, des interférences, de la température ambiante sur l’électronique des capteurs, et des imprécisions de synchronisation n’ont pas été caractérisés.
2. **Modèle de catastrophe simplifié.** Le modèle de catastrophe gaussienne, bien que calibré sur les données sismiques réelles du séisme Turquie-Syrie 2023 (Mw 7.8), ne capture pas toute la complexité des phénomènes naturels. En particulier : (i) les répliques sismiques qui peuvent détruire des nœuds supplémentaires dans les heures et jours suivant le choc principal ; (ii) les catastrophes en cascade (séisme $\rightarrow$ tsunami $\rightarrow$ glissement de terrain) ; (iii) les inondations à propagation lente dont l’impact spatial est anisotrope ; (iv) les feux de forêt dont le front se déplace en fonction du vent et de la végétation. L’extension à ces modèles nécessiterait des simulateurs spatio-temporels dédiés.
3. **Intégration non validée entre articles.** Bien que les trois cadres soient conçus comme une pile protocolaire complémentaire (GAPF $\rightarrow$ CALASH $\rightarrow$ CASTER-ZT),

leur intégration en un système unifié n’a pas été évaluée expérimentalement. Les interactions potentielles — par exemple, l’impact du bouclier CASTER-ZT sur la convergence de GAPF, ou la modification des décisions de routage de CALASH par les décisions graduées du bouclier — restent à caractériser. Il est possible que des effets émergents non anticipés apparaissent lors de l’intégration.

4. **Couche physique 6G analytique.** Les modèles de propagation sub-THz et RIS utilisés dans CALASH sont basés sur des modèles analytiques standard (perte en espace libre + absorption moléculaire pour le sub-THz, gain quadratique pour le RIS). L’intégration avec des simulateurs de couche physique haute fidélité — par exemple, le ray tracing 3D ou les simulateurs de canal stochastique conformes au 3GPP TR 38.901 — n’a pas été réalisée. Les performances réelles de la couche 6G dans un environnement post-catastrophe (débris, poussière, fumée) pourraient différer sensiblement des prédictions analytiques.
5. **Scalabilité non caractérisée à très grande échelle.** Les évaluations couvrent jusqu’à 200 nœuds (Articles 1 et 2) et 100 cellules hexagonales (Article 3). Le comportement à très grande échelle — milliers de nœuds, couverture régionale de centaines de km^2 — n’a pas été caractérisé. En particulier, la scalabilité du GCN (dont la complexité est $O(|E| \cdot d)$ par couche) et du GraphSAGE (avec échantillonnage de voisinage) mérite une étude dédiée pour des graphes de grande taille.
6. **Hypothèse de rationalité des adversaires.** Le modèle d’attaque de CASTER-ZT suppose des politiques voyous qui mal-routent de manière systématique (30% des nœuds compromis). Des adversaires adaptatifs, capables de modifier leur stratégie en réponse aux décisions du bouclier (attaques par évaison), n’ont pas été considérés. Une analyse de robustesse adversariale serait nécessaire pour les déploiements à haut risque.
7. **Absence de validation humaine de terrain.** L’acceptabilité des décisions automatisées par les opérateurs de gestion de catastrophes n’a pas été évaluée. Dans un scénario réel, les décisions de routage, de récupération et de sécurité doivent être comprises et approuvées par les intervenants humains, ce qui nécessite des interfaces explicables et des études d’utilisabilité.

8.6 Directions de recherche futures

8.6.1 Court terme (1–2 ans)

1. **Intégration unifiée de la pile protocolaire.** Combiner GAPF, CALASH et CASTER-ZT en un système intégré, définir les interfaces inter-couches et caractériser les inter-

actions émergentes.

2. **Validation sur testbed matériel.** Déployer sur une plateforme réelle (Zolertia REMote, accélérateurs Google Coral/NVIDIA Jetson) pour valider latences, consommations et PDR en conditions réelles.
3. **Extension des modèles de catastrophe.** Intégrer des modèles plus réalistes : répliques sismiques (Omori-Utsu), inondations (hydrodynamique 2D), feux de forêt (Rothermel).

8.6.2 Moyen terme (2–4 ans)

4. **Apprentissage fédéré.** Entraînement distribué des GNN/DRL via FedAvg [82] / FedProx [83], avec détection du *model poisoning* par CASTER-ZT.
5. **Jumeaux numériques.** Construction d'un jumeau numérique [84] pour l'entraînement continu, la prédiction de pannes et le test de mises à jour de politique avant déploiement.
6. **Extension multi-catastrophe et multi-site.** Scénarios de catastrophes en cascade et coordination inter-sites via 6G backhauling.
7. **Certification formelle du bouclier.** Vérification par model checking (PRISM, NuSMV) ou preuve assistée (Coq, Isabelle/HOL) pour la conformité IEC 61508 / DO-178C.

8.6.3 Long terme (4+ ans)

8. **Réseaux non terrestres (NTN).** Intégration avec les satellites LEO, HAPS et drones comme stations de base mobiles post-catastrophe.
9. **Modèles de langage pour le routage.** Utilisation de LLM comme méta-contrôleurs en remplacement du CAS, sous réserve des contraintes de latence et de mémoire.
10. **Normalisation.** Soumission du LCI et du cadre zéro-confiance aux organismes de normalisation (ISO, ETSI, 3GPP, O-RAN Alliance).

8.7 Perspectives d'application à d'autres domaines

Bien que ciblant les WSN de surveillance des catastrophes, les principes méthodologiques ont un potentiel de transfert vers : (i) l'**agriculture de précision**, où les réseaux de capteurs partagent les contraintes énergétiques et les taux de défaillance de 10–25%/an ; (ii) les **villes intelligentes**, où le LCI et CASTER-ZT sont directement applicables aux déploiements massifs ($> 10\,000$ nœuds) ; (iii) la **santé connectée**, où les garanties formelles du bouclier pourraient vérifier les décisions de routage des données médicales critiques ; (iv) les **réseaux**

véhiculaires et essais de drones, où la fusion de politiques de GAPF est pertinente pour les topologies dynamiques à changement rapide.

8.8 Recommandations aux décideurs et aux organismes de normalisation

Les contributions ont des implications pour plusieurs organismes : ISO TC 207/SC 7 (extension de ISO 14067 aux protocoles IoT via le LCI), ETSI ISG ENI (réseaux auto-gérés par AI), O-RAN Alliance WG2 (GAPF/CALASH comme rApps, CASTER-ZT comme xApp), et 3GPP SA5 (mécanismes de confiance AI/ML pour le 6G). Pour les gouvernements, la pile contribue directement au Cadre de Sendai [4] (indicateurs C-2 et C-6) et peut être intégrée sans modification matérielle sur les RIC O-RAN existants.

8.9 Synthèse quantitative des résultats

Le Tableau 8.2 récapitule les résultats quantitatifs clés de l’ensemble de la thèse, mettant en perspective l’ampleur des gains par rapport à l’état de l’art et le coût computationnel associé.

TABLEAU 8.2 Bilan quantitatif global de la thèse : gains clés par rapport à l’état de l’art.

Métrique	Meilleure référence	Valeur réf.	Notre résultat	Gain
PDR (taux de livraison)	QMIX	46–67%	$\geq 98\%$	+43–111% $\uparrow$
Énergie par paquet	QMIX	1.0×	0.29–0.50×	2–3.5× $\downarrow$
Paramètres entraînaibles	Agent RNN	~39K/agent	1 473 (GAPF)	26× $\downarrow$
Mémoire d’entraînement	QMIX/QTRAN	3.2–13.8 GB	951 MB	3.4–14.5× $\downarrow$
Durée de vie réseau	LEACH	931 tours	1 486 tours	+60%
LCI (carbone/paquet)	LEACH	13.42	8.99	–33%
Délect. voyous (0% FP)	Meilleur 0-FP	0%	74.2–98.3%	+74–98 pts
Faux positifs	Shield-Binary	48.8%	0%	Élimination totale
Latence par décision	Budget O-RAN	10 ms	3.07 ms	3.3× $\downarrow$
Critères couverts (/12)	Meilleur concurrent	1	12	12× $\uparrow$
Exécutions totales de test	—	—	> 23 800	—

Ces résultats démontrent que la pile protocolaire proposée réalise des gains significatifs sur **toutes** les dimensions — efficacité, durabilité, sécurité, légèreté — avec un budget computationnel total (~27K paramètres) comparable à un seul agent RNN des approches MARL existantes. La couverture complète des 12 critères est, à notre connaissance, inédite dans la littérature.

8.10 Remarques conclusives

Les catastrophes naturelles continueront de frapper avec une intensité et une fréquence croissantes dans un monde affecté par le changement climatique [3]. La surveillance en temps réel par les réseaux de capteurs sans fil constitue un maillon essentiel de la chaîne de prévention et de réponse [4]. Cette thèse contribue à rendre ces réseaux de surveillance plus efficaces, plus durables et plus sûrs, en démontrant que l'intelligence artificielle — lorsqu'elle est conçue avec parcimonie, conscience environnementale et vérification systématique — peut constituer un outil fiable pour les environnements critiques. Les cadres proposés ici — GAPF, CALASH et CASTER-ZT — devront être validés par des déploiements sur matériel réel pour confirmer leur viabilité opérationnelle, une étape que nous espérons voir réalisée dans les prochaines années.

RÉFÉRENCES

- [1] United Nations Office for Disaster Risk Reduction, “Human cost of disasters : An overview of the last 20 years (2000–2019),” UNDRR, Rapport technique, 2020.
- [2] E. Burgueño Salas, “Global natural disaster deaths per year 2023,” 2024. [En ligne]. Disponible : <https://www.statista.com/statistics/510952/number-of-deaths-from-natural-disasters-globally/>
- [3] IPCC, “Climate change 2021 : The physical science basis. contribution of working group I to the sixth assessment report,” <https://www.ipcc.ch/report/ar6/wg1/>, 2021.
- [4] United Nations Office for Disaster Risk Reduction, “Sendai framework for disaster risk reduction 2015–2030,” <https://www.undrr.org/publication/sendai-framework-disaster-risk-reduction-2015-2030>, 2015.
- [5] J. Al Qundus, K. Dabbour, S. Gupta, R. Meissonier et A. Paschke, “Wireless sensor network for AI-based flood disaster detection,” *Annals of Operations Research*, p. 1–23, 2020.
- [6] W. R. Heinzelman, A. Chandrakasan et H. Balakrishnan, “Energy-efficient communication protocol for wireless microsensor networks,” dans *Proc. 33rd Hawaii Int. Conf. System Sciences (HICSS)*. IEEE, 2000, p. 1–10.
- [7] A. Yarali, *Wireless Sensor Networks (WSN) : Technology and Applications*. Nova Science Publishers, 2020.
- [8] Y. E. Aslan, I. Korpeoglu et Ö. Ulusoy, “A framework for use of wireless sensor networks in forest fire detection and monitoring,” *Computer Networks*, vol. 52, n^o. 3, p. 935–952, 2012.
- [9] N. B. Abu-Ghazaleh, K.-D. Kang et K. Liu, “Towards resilient and survivable wireless sensor networks,” *IEEE Wireless Communications*, vol. 14, n^o. 5, p. 54–60, 2007.
- [10] W. Saad, M. Bennis et M. Chen, “A vision of 6G wireless systems : Applications, trends, technologies, and open research problems,” *IEEE Network*, vol. 34, n^o. 3, p. 134–142, 2020.
- [11] E. Strubell, A. Ganesh et A. McCallum, “Energy and policy considerations for deep learning in NLP,” dans *Proc. Annual Meeting of the Association for Computational Linguistics (ACL)*, 2019, p. 3645–3650.
- [12] International Organization for Standardization, “ISO 14040 :2006 — environmental management — life cycle assessment — principles and framework,” ISO, Rapport technique, 2006.

- [13] S. Rose, O. Borchert, S. Mitchell et S. Connelly, “Zero trust architecture,” NIST, Rapport technique SP 800-207, 2020.
- [14] V. Kumar, S. Jain et S. Tiwari, “Energy efficient clustering algorithms in wireless sensor networks : A survey,” *Int. J. Computer Science Issues (IJCSI)*, vol. 8, n^o. 5, p. 259–268, 2011.
- [15] W. B. Heinzelman, A. P. Chandrakasan et H. Balakrishnan, “An application-specific protocol architecture for wireless microsensor networks,” *IEEE Trans. Wireless Communications*, vol. 1, n^o. 4, p. 660–670, 2002.
- [16] O. Younis et S. Fahmy, “HEED : A hybrid, energy-efficient, distributed clustering approach for ad-hoc sensor networks,” dans *IEEE Trans. Mobile Computing*, vol. 3, n^o. 4, 2004, p. 366–379.
- [17] C. Sha, R. Wang, H. Huang et L. Sun, “Energy efficient routing protocol for wireless sensor networks,” dans *Proc. Int. Conf. Wireless Communications and Signal Processing (WCSP)*, 2013.
- [18] D. Karaboga, “An idea based on honey bee swarm for numerical optimization,” Erciyes University, Rapport technique TR-06, 2005.
- [19] J. Kennedy et R. Eberhart, “Particle swarm optimization,” dans *Proc. IEEE Int. Conf. Neural Networks (ICNN)*, vol. 4, 1995, p. 1942–1948.
- [20] T. Rashid, M. Samvelyan, C. S. de Witt, G. Farquhar, J. Foerster et S. Whiteson, “QMIX : Monotonic value function factorisation for deep multi-agent reinforcement learning,” dans *Proc. 35th Int. Conf. Machine Learning (ICML)*, 2018, p. 4295–4304.
- [21] K. Son, D. Kim, W. J. Kang, D. E. Hostallero et Y. Yi, “QTRAN : Learning to factorize with transformation for cooperative multi-agent reinforcement learning,” dans *Proc. 36th Int. Conf. Machine Learning (ICML)*, 2019, p. 5887–5896.
- [22] C. Freitag, M. Berners-Lee, K. Widdicks, B. Knowles, G. S. Blair et A. Friday, “The real climate and transformative impact of ICT : A critique of estimates, trends, and regulations,” *Patterns*, vol. 2, n^o. 9, p. 100340, 2021.
- [23] T. Pirson et D. Bol, “Assessing the embodied carbon footprint of IoT edge devices with a bottom-up life-cycle approach,” *Journal of Cleaner Production*, vol. 322, p. 128966, 2021.
- [24] J. Achiam, D. Held, A. Tamar et P. Abbeel, “Constrained policy optimization,” dans *Proc. 34th Int. Conf. Machine Learning (ICML)*, 2017, p. 22–31.
- [25] M. Alshiekh, R. Bloem, R. Ehlers, B. Könighofer, S. Niekum et U. Topcu, “Safe reinforcement learning via shielding,” dans *Proc. AAAI Conf. Artificial Intelligence*, 2018, p. 2669–2678.

- [26] G. Smaragdakis, I. Matta et A. Bestavros, “SEP : A stable election protocol for clustered heterogeneous wireless sensor networks,” dans *Proc. Int. Workshop on Sensor and Actor Network Protocols and Applications (SANPA)*, 2004.
- [27] S. Lindsey et C. S. Raghavendra, “PEGASIS : Power-efficient gathering in sensor information systems,” dans *Proc. IEEE Aerospace Conference*, vol. 3, 2002, p. 1125–1130.
- [28] K. M. Salama et S. Abbott-McCune, “Ant colony optimization for routing in wireless sensor networks,” *Soft Computing*, vol. 20, n^o. 7, p. 2785–2799, 2016.
- [29] J. Hu, Y. Liu et H. Li, “Energy-efficient routing in wireless sensor networks using quantum particle swarm optimization with fuzzy logic,” *IEEE Sensors Journal*, vol. 24, n^o. 8, 2024.
- [30] M. Dorigo et T. Stützle, *Ant Colony Optimization*. MIT Press, 2004.
- [31] K. Deb, A. Pratap, S. Agarwal et T. Meyarivan, “A fast and elitist multiobjective genetic algorithm : NSGA-II,” *IEEE Transactions on Evolutionary Computation*, vol. 6, n^o. 2, p. 182–197, 2002.
- [32] S. Mirjalili, S. M. Mirjalili et A. Lewis, “Grey wolf optimizer,” *Advances in Engineering Software*, vol. 69, p. 46–61, 2014.
- [33] S. Mirjalili et A. Lewis, “The whale optimization algorithm,” *Advances in Engineering Software*, vol. 95, p. 51–67, 2016.
- [34] E. J. Candès, J. K. Romberg et T. Tao, “Stable signal recovery from incomplete and inaccurate measurements,” *Communications on Pure and Applied Mathematics*, vol. 59, n^o. 8, p. 1207–1223, 2006.
- [35] M. Castro et B. Liskov, “Practical Byzantine fault tolerance,” dans *Proc. USENIX Symp. Operating Systems Design and Implementation (OSDI)*, 1999, p. 173–186.
- [36] F. A. Oliehoek et C. Amato, *A Concise Introduction to Decentralized POMDPs*, ser. SpringerBriefs in Intelligent Systems. Springer, 2016.
- [37] D. S. Bernstein, R. Givan, N. Immerman et S. Zilberstein, “The complexity of decentralized control of Markov decision processes,” *Mathematics of Operations Research*, vol. 27, n^o. 4, p. 819–840, 2002.
- [38] T. Rashid, G. Farquhar, B. Peng et S. Whiteson, “Weighted QMIX : Expanding monotonic value function factorisation for deep multi-agent reinforcement learning,” dans *Advances in Neural Information Processing Systems 33 (NeurIPS)*, 2020.
- [39] J. Wang, Z. Ren, T. Liu, Y. Yu et C. Zhang, “QPLEX : Duplex dueling multi-agent Q-learning,” dans *Proc. 9th Int. Conf. Learning Representations (ICLR)*, 2021.

- [40] A. Mahajan, T. Rashid, M. Samvelyan et S. Whiteson, “MAVEN : Multi-agent variational exploration,” dans *Advances in Neural Information Processing Systems 32 (NeurIPS)*, 2019, p. 7613–7624.
- [41] T. Zhang *et al.*, “FOP : Factorizing optimal joint policy of maximum-entropy multi-agent reinforcement learning,” dans *Proc. 38th Int. Conf. Machine Learning (ICML)*, 2021.
- [42] T. N. Kipf et M. Welling, “Semi-supervised classification with graph convolutional networks,” dans *Proc. 5th Int. Conf. Learning Representations (ICLR)*, 2017.
- [43] W. Hamilton, Z. Ying et J. Leskovec, “Inductive representation learning on large graphs,” dans *Advances in Neural Information Processing Systems (NeurIPS)*, 2017, p. 1024–1034.
- [44] J. Gilmer, S. S. Schoenholz, P. F. Riley, O. Vinyals et G. E. Dahl, “Neural message passing for quantum chemistry,” dans *Proc. 34th Int. Conf. Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, vol. 70, 2017, p. 1263–1272.
- [45] K. Xu, W. Hu, J. Leskovec et S. Jegelka, “How powerful are graph neural networks ?” dans *Proc. 7th Int. Conf. Learning Representations (ICLR)*, 2019.
- [46] Z. Liu *et al.*, “Graph neural network meets multi-agent reinforcement learning : Fundamentals, applications, and future directions,” *IEEE Communications Surveys & Tutorials*, 2024, arXiv preprint arXiv :2404.04898.
- [47] S. S. Bhavanasi, L. Pappone *et al.*, “Routing with graph convolutional networks and multi-agent deep reinforcement learning,” *IEEE Trans. Network and Service Management*, 2023.
- [48] J. A. Boyan et M. L. Littman, “Packet routing in dynamically changing networks : A reinforcement learning approach,” *Advances in Neural Information Processing Systems (NIPS)*, vol. 6, p. 671–678, 1994.
- [49] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski *et al.*, “Human-level control through deep reinforcement learning,” *Nature*, vol. 518, n°. 7540, p. 529–533, 2015.
- [50] H. Guo *et al.*, “Deep reinforcement learning for dynamic algorithm selection,” *Information Sciences (Elsevier)*, 2024.
- [51] W. Yang et J. Thomason, “Learning to deliberate : Meta-policy collaboration for agentic LLMs with multi-agent reinforcement learning,” *arXiv preprint arXiv :2509.03817*, 2025.
- [52] M. Tan, “Multi-agent reinforcement learning : Independent vs. cooperative agents,” dans *Proc. Int. Conf. Machine Learning (ICML)*, 1993, p. 330–337.

- [53] P. Sunehag, G. Lever, A. Gruslys, W. M. Czarnecki, V. Zambaldi, M. Jaderberg, M. Lanctot, N. Sonnerat, J. Z. Leibo, K. Tuyls et T. Graepel, “Value-decomposition networks for cooperative multi-agent learning based on team reward,” dans *Proc. Int. Conf. Autonomous Agents and Multi-Agent Systems (AAMAS)*, 2018, p. 2085–2087.
- [54] C. Yu, A. Velu, E. Vinitzky, J. Gao, Y. Wang, A. Baez, B. Bhatt, L. Biewald, H. Fang, C. Finn et P. Gao, “The surprising effectiveness of PPO in cooperative multi-agent games,” dans *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, 2022.
- [55] P. Warden et D. Situnayake, *TinyML : Machine Learning with TensorFlow Lite on Arduino and Ultra-Low-Power Microcontrollers*. O’Reilly Media, 2020.
- [56] R. David, J. Duke, A. Jain, V. Janapa Reddi, N. Jeffries, J. Li, N. Kreber, I. Nappier, M. Natraj, T. Wang *et al.*, “TensorFlow Lite Micro : Embedded machine learning for TinyML systems,” dans *Proceedings of Machine Learning and Systems (MLSys)*, 2021.
- [57] J. Lin, W.-M. Chen, Y. Lin, J. Cohn, C. Gan et S. Han, “MCUNet : Tiny deep learning on IoT devices,” dans *Advances in Neural Information Processing Systems 33 (NeurIPS)*, 2020.
- [58] F. M. Bianchi, D. Grattarola et C. Alippi, “Quantization in graph convolutional neural networks,” dans *Proc. European Signal Processing Conf. (EUSIPCO)*, 2021, p. 1855–1859.
- [59] H. Cai, C. Gan, T. Wang, Z. Zhang et S. Han, “Once-for-all : Train one network and specialize it for efficient deployment,” dans *Proc. International Conference on Learning Representations (ICLR)*, 2020.
- [60] H. Nguyen *et al.*, “Graph neural networks for next-generation IoT,” *IEEE Internet of Things Journal*, 2025.
- [61] M. J. Neely, “Stochastic network optimization with application to communication and queueing systems,” *Synthesis Lectures on Communication Networks*, vol. 3, n^o. 1, p. 1–211, 2010.
- [62] National Grid ESO. (2023) UK carbon intensity API. [En ligne]. Disponible : <https://carbonintensity.org.uk/>
- [63] N. Bashir *et al.*, “The sunk carbon fallacy : Rethinking carbon footprint metrics for computing,” dans *Proc. ACM Symp. Cloud Computing (SoCC)*, 2024.
- [64] G. Mersy *et al.*, “Toward a life cycle assessment for the carbon footprint of data,” dans *Proc. ACM Symp. Cloud Computing (SoCC)*, 2025.
- [65] AIOTI Working Group, “IoT and edge computing carbon footprint measurement methodology,” Alliance for Internet of Things Innovation (AIOTI), Rapport technique,

2024.

- [66] D. Corsi, C. Sánchez et A. Abate, “Verification-guided shielding for deep reinforcement learning,” dans *Proc. Machine Learning Safety Workshop*, 2024.
- [67] D. Corsi, L. Marzari, A. Farinelli et A. Abate, “Probabilistic shielding for safe reinforcement learning,” *arXiv preprint arXiv :2503.07671*, 2025.
- [68] B. Könighofer, S. Pranger, M. Tappler et R. Bloem, “Shields for safe reinforcement learning,” *Communications of the ACM*, vol. 68, n°. 5, p. 66–75, 2025.
- [69] G. Katz, D. A. Huang, D. Ibeling, K. Julian, C. Lazarus, R. Lim, P. Shah, S. Thakoor, H. Wu, A. Zeljic, C. Barrett et M. J. Kochenderfer, “The Marabou framework for verification and analysis of deep neural networks,” dans *Proc. International Conference on Computer Aided Verification (CAV)*, 2019, p. 443–452.
- [70] S. H. Huang, N. Papernot, I. J. Goodfellow, Y. Duan et P. Abbeel, “Adversarial attacks on neural network policies,” dans *Proc. 5th Int. Conf. Learning Representations (ICLR), Workshop Track*, 2017.
- [71] A. Gleave, M. Dennis, C. Wild, N. Kant, S. Levine et S. Russell, “Adversarial policies : Attacking deep reinforcement learning,” dans *Proc. 8th Int. Conf. Learning Representations (ICLR)*, 2020.
- [72] K. Kiourti *et al.*, “Backdoor attack against competitive reinforcement learning,” dans *Proc. 30th Int. Joint Conf. Artificial Intelligence (IJCAI)*, 2021, p. 4620–4626.
- [73] G. N. Iyengar, “Robust dynamic programming,” *Mathematics of Operations Research*, vol. 30, n°. 2, p. 257–280, 2005.
- [74] H. Xu et S. Mannor, “Distributionally robust Markov decision processes,” dans *Advances in Neural Information Processing Systems 23 (NeurIPS)*, 2010, p. 2505–2513.
- [75] H. Moudoud, S. Cherkaoui et L. Khoukhi, “Enhancing Open RAN security with zero trust and machine learning,” *Computer Networks*, 2025.
- [76] K. Katsaros *et al.*, “AI-native multi-access future networks—the REASON architecture,” *IEEE Access*, 2024.
- [77] S. Ahmadi, B. Rashidi et L. Khoukhi, “Autonomous identity-based threat segmentation for zero trust architecture,” *Computers & Security*, 2025.
- [78] Y. Gal et Z. Ghahramani, “Dropout as a Bayesian approximation : Representing model uncertainty in deep learning,” dans *Proc. 33rd Int. Conf. Machine Learning (ICML)*, 2016, p. 1050–1059.
- [79] A. N. Angelopoulos et S. Bates, “Conformal prediction : A gentle introduction,” *Foundations and Trends in Machine Learning*, vol. 16, n°. 4, p. 494–591, 2023.

- [80] C. Amatetti *et al.*, “The role of 6G NTN in emergency and crisis management,” dans *Proc. IEEE Future Networks World Forum (FNWF)*, 2024.
- [81] Y. Chen, J. Du, W. Lu et X. Liu, “Reconfigurable intelligent surface equipped UAV in post-disaster communication networks,” *arXiv preprint arXiv :2406.11241*, 2024.
- [82] H. B. McMahan, E. Moore, D. Ramage, S. Hampson et B. A. y Arcas, “Communication-efficient learning of deep networks from decentralized data,” dans *Proc. 20th Int. Conf. Artificial Intelligence and Statistics (AISTATS)*, ser. Proceedings of Machine Learning Research, vol. 54, 2017, p. 1273–1282.
- [83] T. Li, A. K. Sahu, A. Talwalkar et V. Smith, “Federated optimization in heterogeneous networks,” *Proceedings of Machine Learning and Systems*, vol. 2, p. 429–450, 2020.
- [84] H. X. Nguyen *et al.*, “Digital twin for O-RAN towards 6G,” *IEEE Communications Magazine*, 2024.
- [85] A. R. Hevner, S. T. March, J. Park et S. Ram, “Design science in information systems research,” *MIS Quarterly*, vol. 28, n^o. 1, p. 75–105, 2004.
- [86] K. Peffers, T. Tuunanen, M. A. Rothenberger et S. Chatterjee, “A design science research methodology for information systems research,” *Journal of Management Information Systems*, vol. 24, n^o. 3, p. 45–77, 2007.
- [87] Intel Berkeley Research Lab. (2004) Intel lab data. [En ligne]. Disponible : <http://db.csail.mit.edu/labdata/labdata.html>
- [88] C. F. Hayes, R. Rădulescu, E. Bargiacchi, J. Källström, M. Macfarlane, M. Reymond, T. Verstraeten, L. M. Zintgraf, R. Dazeley, F. Heintz, E. Howley, A. A. Irissappane, P. Mannion, A. Nowe, G. Ramos, M. Restelli, P. Vamplew et D. M. Roijers, “A practical guide to multi-objective reinforcement learning and planning,” *Autonomous Agents and Multi-Agent Systems*, vol. 36, n^o. 1, p. 26, 2022.
- [89] J. Pineau, K. Sinha, H. Larochelle, D. Precup *et al.*, “Improving reproducibility in machine learning research (a report from the NeurIPS 2019 reproducibility program),” *Journal of Machine Learning Research*, vol. 22, n^o. 164, p. 1–20, 2021.
- [90] G. Brockman, V. Cheung, L. Pettersson, J. Schneider, J. Schulman, J. Tang et W. Zaremba, “OpenAI Gym,” *arXiv preprint arXiv :1606.01540*, 2016.
- [91] T. Salimans, J. Ho, X. Chen, S. Sidor et I. Sutskever, “Evolution strategies as a scalable alternative to reinforcement learning,” *arXiv preprint arXiv :1703.03864*, 2017.
- [92] R. J. Williams, “Simple statistical gradient-following algorithms for connectionist reinforcement learning,” *Machine Learning*, vol. 8, n^o. 3–4, p. 229–256, 1992.

- [93] D. Chen, Y. Lin, W. Li, P. Li, J. Zhou et X. Sun, “Measuring and relieving the over-smoothing problem for graph neural networks from the topological view,” dans *Proc. AAAI Conference on Artificial Intelligence*, vol. 34, n^o. 4, 2020, p. 3438–3445.
- [94] “Disaster,” 2024. [En ligne]. Disponible : <https://www.eea.europa.eu/help/glossary/eea-glossary/disaster-1>
- [95] “Number of natural disasters per year worldwide 2023.” [En ligne]. Disponible : <https://www.statista.com/statistics/510959/number-of-natural-disasters-events-globally/>
- [96] H. Bhatt, P. G, S. Shankar et S. Haralika, “Wireless Sensor Networks for Optimisation of Search and Rescue Management in Floods,” août 2021, arXiv :2108.09569 [cs]. [En ligne]. Disponible : <http://arxiv.org/abs/2108.09569>
- [97] U. Dampage, L. Bandaranayake, R. Wanasinghe, K. Kottahachchi et B. Jayasanka, “Forest fire detection system using wireless sensor networks and machine learning,” *Sci Rep*, vol. 12, n^o. 1, p. 46, janv. 2022, number : 1 Publisher : Nature Publishing Group. [En ligne]. Disponible : <https://www.nature.com/articles/s41598-021-03882-9>
- [98] P. Thakare et B. Ambudkar, “Study and analysis of CO2 emission control methods for wireless networks,” dans *2017 2nd International Conference on Communication and Electronics Systems (ICCES)*, oct. 2017, p. 742–745.
- [99] M. Priyanga, S. Leones Sherwin Vimalraj et J. Lydia, “Energy Aware Multiuser & Multi-hop Hierarchical –Based Routing Protocol for Energy Management in WSN-Assisted IoT,” dans *2018 3rd International Conference on Communication and Electronics Systems (ICCES)*, oct. 2018, p. 701–705. [En ligne]. Disponible : <https://ieeexplore.ieee.org/document/8724073>
- [100] P. M.r., V. H.s. et S. J., “Holistic survey on energy aware routing techniques for IoT applications,” *Journal of Network and Computer Applications*, vol. 213, p. 103584, avr. 2023. [En ligne]. Disponible : <https://www.sciencedirect.com/science/article/pii/S1084804523000036>
- [101] P. Maheshwari, A. Sharma et K. Verma, “Energy efficient cluster based routing protocol for WSN using butterfly optimization algorithm and ant colony optimization,” *Ad Hoc Networks*, vol. 110, p. 102317, janv. 2021.
- [102] L. Abualigah, D. Falcone et A. Forestiero, “Swarm Intelligence to Face IoT Challenges,” *Comput Intell Neurosci*, vol. 2023, p. 4254194, mai 2023. [En ligne]. Disponible : <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10241578/>
- [103] X. Su, Y. Ren, Z. Cai, Y. Liang et L. Guo, “A Q-Learning-Based Routing Approach for Energy Efficient Information Transmission in Wireless Sensor Network,” *IEEE Transactions on Network and Service Management*, vol. 20, n^o. 2, p. 1949–1961, juin

- 2023, conference Name : IEEE Transactions on Network and Service Management. [En ligne]. Disponible : <https://ieeexplore.ieee.org/document/9933016>
- [104] R. Ding, J. Chen, W. Wu, J. Liu, F. Gao et X. Shen, “Packet Routing in Dynamic Multi-Hop UAV Relay Network : A Multi-Agent Learning Approach,” *IEEE Transactions on Vehicular Technology*, vol. 71, n°. 9, p. 10 059–10 072, sept. 2022, conference Name : IEEE Transactions on Vehicular Technology. [En ligne]. Disponible : <https://ieeexplore.ieee.org/document/9795858>
- [105] “Multi-Agent Reinforcement Learning : Foundations and Modern Approaches.” [En ligne]. Disponible : <https://www.marl-book.com/>
- [106] N. Moussa, E. Nurellari, K. Azbeg, A. Boulouz, K. Afdel, L. Koutti, M. B. Salah et A. El Belrhiti El Alaoui, “A reinforcement learning based routing protocol for software-defined networking enabled wireless sensor network forest fire detection,” *Future Generation Computer Systems*, vol. 149, p. 478–493, déc. 2023. [En ligne]. Disponible : <https://www.sciencedirect.com/science/article/pii/S0167739X23003072>
- [107] P. Mishra, N. Kumar et W. Godfrey, “A Meta-heuristic-based Green-routing Algorithm in Software-Defined Wireless Sensor Network,” janv. 2021, p. 36–41.
- [108] B. Isyaku, K. b. A. Bakar, N. M. Yusuf, M. Abaker, A. Abdelmaboud et W. Nagmeldin, “Software defined wireless sensor load balancing routing for internet of things applications : Review of approaches,” *Heliyon*, vol. 10, n°. 9, mai 2024, publisher : Elsevier. [En ligne]. Disponible : [https://www.cell.com/heliyon/abstract/S2405-8440\(24\)05996-6](https://www.cell.com/heliyon/abstract/S2405-8440(24)05996-6)
- [109] M. Biabani, H. Fotouhi et N. Yazdani, “An Energy-Efficient Evolutionary Clustering Technique for Disaster Management in IoT Networks,” *Sensors*, vol. 20, n°. 9, p. 2647, janv. 2020, number : 9 Publisher : Multidisciplinary Digital Publishing Institute. [En ligne]. Disponible : <https://www.mdpi.com/1424-8220/20/9/2647>
- [110] “Survey on Clustered Routing Protocols Adaptivity for Fire Incidents : Architecture Challenges, Data Losing, and Recommended Solutions | IEEE Journals & Magazine | IEEE Xplore.” [En ligne]. Disponible : <https://ieeexplore.ieee.org/document/10637327>
- [111] M. Hosseinzadeh, L. Ionescu-Feleaga, B.- Ionescu, M. Sadrishojaei, F. Kazemian, A. M. Rahmani et F. Khan, “A Hybrid Delay Aware Clustered Routing Approach Using Aquila Optimizer and Firefly Algorithm in Internet of Things,” *Mathematics*, vol. 10, n°. 22, p. 4331, janv. 2022, number : 22 Publisher : Multidisciplinary Digital Publishing Institute. [En ligne]. Disponible : <https://www.mdpi.com/2227-7390/10/22/4331>
- [112] M. R. Senkumar, I. S. Arafat, R. Nathiya et S. M. H. Nishath, “Enhanced Energy Efficient Clustering and Routing Algorithm in Wireless Sensor Network,” *Wireless*

- Pers Commun*, vol. 138, n°. 3, p. 1531–1558, oct. 2024. [En ligne]. Disponible : <https://doi.org/10.1007/s11277-024-11549-7>
- [113] E. Ghorbani Dehkordi et H. Barati, “Cluster based routing method using mobile sinks in wireless sensor network,” *International Journal of Electronics*, vol. 110, n°. 2, p. 360–372, févr. 2023, publisher : Taylor & Francis _eprint : <https://doi.org/10.1080/00207217.2021.2025451>. [En ligne]. Disponible : <https://doi.org/10.1080/00207217.2021.2025451>
- [114] S. Harihara Gopalan, D. G. Takale, B. Jayaprakash et V. Pandiya Raj, “An energy efficient routing protocol with fuzzy neural networks in wireless sensor network,” *Ain Shams Engineering Journal*, vol. 15, n°. 10, p. 102979, oct. 2024. [En ligne]. Disponible : <https://www.sciencedirect.com/science/article/pii/S209044792400354X>
- [115] S. Kodati, M. Dhasaratham, B. Kishor et G. Narayana, “Hybrid grasshopper and Harris hawk optimization algorithm-based energy efficient routing protocol for extending network lifetime in wireless sensor networks,” *International Journal of Communication Systems*, vol. 37, n°. 13, p. e5851, 2024, _eprint : <https://onlinelibrary.wiley.com/doi/pdf/10.1002/dac.5851>. [En ligne]. Disponible : <https://onlinelibrary.wiley.com/doi/abs/10.1002/dac.5851>
- [116] H. Wang, K. Li et W. Pedrycz, “An Elite Hybrid Metaheuristic Optimization Algorithm for Maximizing Wireless Sensor Networks Lifetime With a Sink Node,” *IEEE Sensors Journal*, vol. 20, n°. 10, p. 5634–5649, mai 2020, conference Name : IEEE Sensors Journal. [En ligne]. Disponible : <https://ieeexplore.ieee.org/document/8978821>
- [117] S. Chaurasia, K. Kumar et N. Kumar, “MOCRAW : A Meta-heuristic Optimized Cluster head selection based Routing Algorithm for WSNs,” *Ad Hoc Networks*, vol. 141, p. 103079, mars 2023. [En ligne]. Disponible : <https://www.sciencedirect.com/science/article/pii/S1570870522002517>
- [118] A. J. Wilson, K. Ws, A. S. Radhamani et A. Pon Bharathi, “Optimizing energy-efficient cluster head selection in wireless sensor networks using a binarized spiking neural network and honey badger algorithm,” *Knowledge-Based Systems*, vol. 299, p. 112039, sept. 2024. [En ligne]. Disponible : <https://www.sciencedirect.com/science/article/pii/S0950705124006737>
- [119] Y.-D. Yao, X. Li, Y.-P. Cui, J.-J. Wang et C. Wang, “Energy-Efficient Routing Protocol Based on Multi-Threshold Segmentation in Wireless Sensors Networks for Precision Agriculture,” *IEEE Sensors Journal*, vol. 22, n°. 7, p. 6216–6231, avr. 2022, conference Name : IEEE Sensors Journal. [En ligne]. Disponible : <https://ieeexplore.ieee.org/document/9709782>

- [120] K. S. Rao et B. E. Reddy, “Optimized secure cluster-based routing with lightweight blockchain for IoT-enabled WSNs,” *Computer Networks*, 2024.
- [121] M. Manoharan, B. Subramani et P. Ramu, “An optimal energy efficient routing in WSN using adaptive entropy bald eagle search optimization and density based adaptive soft clustering,” *Sustainable Computing : Informatics and Systems*, vol. 43, p. 101003, sept. 2024. [En ligne]. Disponible : <https://www.sciencedirect.com/science/article/pii/S2210537924000489>
- [122] A. K. Rai et A. K. Daniel, “FEEC : fuzzy based energy efficient clustering protocol for WSN,” *International Journal of System Assurance Engineering and Management*, vol. 14, n°. 1, p. 297–307, 2023, publisher : Springer & The Society for Reliability, Engineering Quality and Operations Management (SREQOM), India, and Division of Operation and Maintenance, Lulea University of Technology, Sweden. [En ligne]. Disponible : https://ideas.repec.org/a/spr/ijsaem/v14y2023i1d10.1007_s13198-022-01796-x.html
- [123] K. Dinesh et S. V. N. Santhosh Kumar, “HBO-SROA : Honey Badger optimization based clustering with secured remora optimization based routing algorithm in wireless sensor networks,” *Peer-to-Peer Netw. Appl.*, vol. 17, n°. 5, p. 2609–2636, sept. 2024. [En ligne]. Disponible : <https://doi.org/10.1007/s12083-024-01708-9>
- [124] S. Prakash et R. Kumar, “Enhanced energy-efficient cluster-based routing using spotted hyena optimization for heterogeneous WSNs,” *Wireless Networks*, 2025.
- [125] A. Ataoua et A. Bouziane, “Chernobyl disaster optimizer for energy-efficient clustering in wireless sensor networks,” *Cluster Computing*, 2025.
- [126] S. Qamar et A. Munir, “A hybrid neural network and deterministic clustering approach for energy-efficient routing in WSNs,” *Ad Hoc Networks*, 2025.
- [127] M. S. Rahman et D.-S. Kim, “A distributed blockchain-based malicious node detection framework for wireless sensor networks,” *IEEE Internet of Things Journal*, 2025.
- [128] S. S. Sefati et S. J. Mousavirad, “AFRL-HGS : Adaptive federated reinforcement learning with hybrid optimization for secure routing in WSNs,” *Engineering Applications of Artificial Intelligence*, 2025.
- [129] W. Guo, C. Yan et T. Lu, “Optimizing the lifetime of wireless sensor networks via reinforcement-learning-based routing,” *International Journal of Distributed Sensor Networks*, vol. 15, n°. 2, p. 1550147719833541, févr. 2019, publisher : SAGE Publications. [En ligne]. Disponible : <https://doi.org/10.1177/1550147719833541>
- [130] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser et I. Polosukhin, “Attention is all you need,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.

- [131] J. Sill, “Monotonic Networks,” dans *Advances in Neural Information Processing Systems*, vol. 10. MIT Press, 1997. [En ligne]. Disponible : https://proceedings.neurips.cc/paper_files/paper/1997/hash/83adc9225e4deb67d7ce42d58fe5157c-Abstract.html
- [132] Y. Wang et F. Wu, “Multi-agent deep reinforcement learning with adaptive policies,” 2019, arXiv :1912.00949 [cs.LG]. [En ligne]. Disponible : <https://arxiv.org/abs/1912.00949>
- [133] R. Garcia Camargo, Z. Wang, N. NaderiAlizadeh et A. Ribeiro, “Wireless link scheduling with state-augmented graph neural networks,” 2025, arXiv :2505.07598 [eess.SP]. [En ligne]. Disponible : <https://arxiv.org/abs/2505.07598>
- [134] S. Yang, Y. Li, S. He, Y. Li, Q. Cai, P. Jiang et L. Feng, “Phase-aware mixture of experts for agentic reinforcement learning,” 2026, arXiv :2602.17038 [cs.AI]. [En ligne]. Disponible : <https://arxiv.org/abs/2602.17038>
- [135] L. Kraemer et B. Banerjee, “Multi-agent reinforcement learning as a rehearsal for decentralized planning,” dans *Neurocomputing*, vol. 190, 2016, p. 82–94.
- [136] R. Lowe, Y. Wu, A. Tamar, J. Harb, P. Abbeel et I. Mordatch, “Multi-agent actor-critic for mixed cooperative-competitive environments,” dans *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [137] D. V. Huynh, S. R. Khosravirad, V. Sharma, J. Kim, B. Canberk et T. Q. Duong, “Carbon-aware edge computing for Internet of Everything networks : A digital twin approach,” *IEEE Internet of Things J.*, vol. 12, n^o. 15, p. 29 240–29 251, 2025.
- [138] M. Erdelj, M. Król et E. Natalizio, “Wireless sensor networks and multi-UAV systems for natural disaster management,” *Computer Networks*, vol. 124, p. 72–86, 2017.
- [139] B. Karaman, I. Basturk, S. Taskin, E. Zeydan, F. Kara, E. A. Beyazıt, M. Camelo, E. Björnson et H. Yanikomeroglu, “Solutions for sustainable and resilient communication infrastructure in disaster relief and management scenarios,” *IEEE Commun. Surveys & Tutorials*, vol. 28, p. 716–760, 2025.
- [140] P. Bakaraniya et S. Mehta, “EE-LEACH : Energy efficient extension of LEACH protocol,” *Int. J. Engineering Trends and Technology (IJETT)*, vol. 4, n^o. 5, p. 1386–1391, 2013.
- [141] S. K. Singh, P. Kumar et J. P. Singh, “A survey on successors of LEACH protocol,” *IEEE Access*, vol. 5, p. 4298–4328, 2017.
- [142] S. Kaur, S. Kour et M. Singh, “Energy efficiency in wireless sensor networks : Comparing traditional and advanced clustering protocols,” *Engineering Research Express*, vol. 7, n^o. 1, p. 015258, 2025.

- [143] S. El Khediri, N. Batel, H. Bannour et A. Thaljaoui, “Energy efficient cluster routing protocol for wireless sensor networks using hybrid metaheuristic approaches,” *Ad Hoc Networks*, vol. 158, p. 103473, 2024.
- [144] D. Karaboga et B. Basturk, “A powerful and efficient algorithm for numerical function optimization : Artificial bee colony (ABC) algorithm,” *J. Global Optimization*, vol. 39, n^o. 3, p. 459–471, 2007.
- [145] S. Biswas, R. Das et P. Chatterjee, “Energy-efficient connected target coverage in multi-hop wireless sensor networks,” dans *Industry Interactive Innovations in Science, Engineering and Technology*. Springer, 2018, p. 411–421.
- [146] J. A. Boyan et M. L. Littman, “Packet routing in dynamically changing networks : A reinforcement learning approach,” dans *Advances in Neural Information Processing Systems*, vol. 6. Morgan Kaufmann, 1994, p. 671–678.
- [147] C. J. C. H. Watkins et P. Dayan, “Q-learning,” *Machine Learning*, vol. 8, n^o. 3-4, p. 279–292, 1992.
- [148] M. Akram, S. U. Bazai, M. I. Ghafoor, S. Akram, Q. M. Ilyas, A. Mehmood, S. Iqbal et M. A. Rafique, “EEMLCR : Energy-efficient machine learning-based clustering and routing for wireless sensor networks,” *IEEE Access*, vol. 13, p. 70 849–70 871, 2025.
- [149] C. Wang, S. Chen, H.-s. Hu et X. Fan, “A distributed cluster-based routing protocol using fuzzy logic and deep reinforcement learning for wireless sensor networks,” *Cluster Computing*, vol. 28, 2025.
- [150] P. Kuila et P. K. Jana, “Energy efficient clustering and routing algorithms for wireless sensor networks : Particle swarm optimization approach,” *Engineering Applications of Artificial Intelligence*, vol. 33, p. 127–140, 2014.
- [151] R. Urgaonkar, U. C. Kozat, K. Igarashi et M. J. Neely, “Optimal power cost management using stored energy in data centers,” dans *Proc. ACM SIGMETRICS*, 2011, p. 221–232.
- [152] N. Navaprakash, J. J. J. Sheela, S. D. Raj et V. S. Kumar, “Carbon-aware task offloading framework for sustainable mobile edge computing in 6G environments,” dans *Proc. 7th Int. Conf. Mobile Computing and Sustainable Informatics (ICMCSI)*, 2026, p. 526–532.
- [153] Ember, “Yearly electricity data — global electricity generation and carbon intensity,” Online : <https://ember-climate.org/data/>, 2024.
- [154] M. M. Alsayyed, S. Manickam, E. R. N. Wulandari, I. D. M. Widia et S. Karuppayah, “A review of applicable technologies, routing protocols, requirements, and architecture for disaster area networks,” *IEEE Access*, vol. 13, p. 91 129–91 160, 2025.

- [155] International Organization for Standardization, “ISO 14044 :2006 — environmental management — life cycle assessment — requirements and guidelines,” International Standard, 2006.
- [156] T. S. Rappaport, *Wireless Communications : Principles and Practice*, 2^e éd. Prentice Hall, 2002.
- [157] USGS, “M 7.8 — pazarcık, turkey — 2023-02-06,” <https://earthquake.usgs.gov/earthquakes/eventpage/us6000jllz>, 2023.
- [158] D. J. Wald, B. C. Worden, V. Quitoriano et K. L. Pankow, “ShakeMap manual : Technical manual, user’s guide, and software guide,” USGS, Rapport technique Techniques and Methods 12-A1, 2005.
- [159] V. Forti, C. P. Baldé et R. Kuehr, “The global E-waste monitor 2024,” UNU/UNITAR, Rapport technique, 2024. [En ligne]. Disponible : <https://ewastemonitor.info/the-global-e-waste-monitor-2024/>
- [160] R. G. Baraniuk, “Compressive sensing [lecture notes],” *IEEE Signal Processing Magazine*, vol. 24, n^o. 4, p. 118–121, 2007.
- [161] J. A. Tropp et A. C. Gilbert, “Signal recovery from random measurements via orthogonal matching pursuit,” *IEEE Trans. Information Theory*, vol. 53, n^o. 12, p. 4655–4666, 2007.
- [162] H. Van Hasselt, A. Guez et D. Silver, “Deep reinforcement learning with double Q-learning,” dans *Proc. AAAI Conf. Artificial Intelligence*, vol. 30, n^o. 1, 2016.
- [163] J. O. Kephart et D. M. Chess, “The vision of autonomic computing,” *IEEE Computer*, vol. 36, n^o. 1, p. 41–50, 2003.
- [164] T. S. Rappaport, Y. Xing, O. Kanhere, S. Ju, A. Madanayake, S. Mandal, A. Alkhateeb et G. C. Trichopoulos, “Wireless communications and applications above 100 GHz : Opportunities and challenges for 6G and beyond,” *IEEE Access*, vol. 7, p. 78 729–78 757, 2019.
- [165] C. Huang, A. Zappone, G. C. Alexandropoulos, M. Debbah et C. Yuen, “Reconfigurable intelligent surfaces for energy efficiency in wireless communication,” *IEEE Trans. Wireless Commun.*, vol. 18, n^o. 8, p. 4157–4170, 2019.
- [166] C. Huang, R. Mo et C. Yuen, “Reconfigurable intelligent surface assisted multiuser MISO systems exploiting deep reinforcement learning,” *IEEE J. Sel. Areas Commun.*, vol. 38, n^o. 8, p. 1839–1852, 2020.
- [167] A. Al-Hilo, M. Samir, C. Assi, S. Sharafeddine et D. Ebrahimi, “RIS-assisted UAV for timely data collection in IoT networks : A deep reinforcement learning approach,” *IEEE J. Sel. Areas Commun.*, vol. 42, n^o. 4, p. 1024–1038, 2024.

- [168] H. Yang, Z. Xiong, J. Zhao, D. Niyato, L. Xiao et Q. Wu, “Deep reinforcement learning-based intelligent reflecting surface for secure wireless communications,” *IEEE Trans. Wireless Commun.*, vol. 20, n^o. 1, p. 375–388, 2021.
- [169] F. Liu, Y. Cui, C. Masouros, J. Xu, T. X. Han, Y. C. Eldar et S. Buzzi, “Integrated sensing and communications : Toward dual-functional wireless networks for 6G and beyond,” *IEEE J. Sel. Areas Commun.*, vol. 40, n^o. 6, p. 1728–1767, 2022.
- [170] J. A. Zhang, M. L. Rahman, K. Wu, X. Huang, Y. J. Guo, S. Chen et J. Yuan, “An overview of signal processing techniques for joint communication and radar sensing,” *IEEE J. Sel. Areas Commun.*, vol. 40, n^o. 6, p. 1596–1631, 2022.
- [171] J. M. Jornet et I. F. Akyildiz, “Channel modeling and capacity analysis for electromagnetic wireless nanonetworks in the terahertz band,” *IEEE Trans. Wireless Communications*, vol. 10, n^o. 10, p. 3211–3221, 2011.
- [172] T. Utsu, Y. Ogata et R. S. Matsu’ura, “The centenary of the Omori formula for a decay law of aftershock activity,” *Journal of Physics of the Earth*, vol. 43, n^o. 1, p. 1–33, 1995.
- [173] I. Dietrich et F. Dressler, “On the lifetime of wireless sensor networks,” *ACM Trans. Sensor Networks*, vol. 5, n^o. 1, p. 5 :1–5 :39, 2009.
- [174] R. Jain, D.-M. Chiu et W. Hawe, “A quantitative measure of fairness and discrimination for resource allocation in shared computer systems,” Digital Equipment Corporation, Rapport technique DEC-TR-301, 1984.
- [175] F. Wilcoxon, “Individual comparisons by ranking methods,” *Biometrics Bulletin*, vol. 1, n^o. 6, p. 80–83, 1945.
- [176] A. M. Law, *Simulation Modeling and Analysis*, 5^e éd. McGraw-Hill, 2015.
- [177] R. Jain, *The Art of Computer Systems Performance Analysis*. Wiley, 1991.
- [178] X. Glorot et Y. Bengio, “Understanding the difficulty of training deep feedforward neural networks,” dans *Proc. 13th Int. Conf. Artificial Intelligence and Statistics (AI-STATS)*, 2010, p. 249–256.
- [179] L. Huang et M. J. Neely, “Utility optimal scheduling in energy-harvesting networks,” *IEEE/ACM Trans. Networking*, vol. 21, n^o. 4, p. 1117–1130, 2013.
- [180] Z. Hossain et J. M. Jornet, “TeraSim : An ns-3 extension to simulate terahertz-band communication networks,” dans *Proc. Workshop on ns-3 (WNS3)*, 2018, p. 1–8.
- [181] D. Amodei, C. Olah, J. Steinhardt, P. Christiano, J. Schulman et D. Mané, “Concrete problems in AI safety,” *arXiv preprint arXiv :1606.06565*, 2016. [En ligne]. Disponible : <https://arxiv.org/abs/1606.06565>

- [182] T. N. Kipf et M. Welling, “Semi-supervised classification with graph convolutional networks,” dans *International Conference on Learning Representations*, 2017. [En ligne]. Disponible : <https://openreview.net/forum?id=SJU4ayYgl>
- [183] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò et Y. Bengio, “Graph attention networks,” dans *Proc. 6th Int. Conf. Learning Representations (ICLR)*, 2018.
- [184] J. García et F. Fernández, “A comprehensive survey on safe reinforcement learning,” *Journal of Machine Learning Research*, vol. 16, n°. 42, p. 1437–1480, 2015. [En ligne]. Disponible : <https://jmlr.org/papers/v16/garcia15a.html>
- [185] H. Navidan, M. Cheraghinia, J. Fontaine, M. Seif, E. De Poorter, H. V. Poor, I. Moerman et A. Shahid, “Toward autonomous O-RAN : A multi-scale agentic AI framework for real-time network control and management,” *arXiv preprint arXiv :2602.14117*, 2026. [En ligne]. Disponible : <https://arxiv.org/abs/2602.14117>
- [186] O-RAN Alliance, “O-RAN : Towards an open and smart RAN,” 2018, o-RAN Alliance White Paper.
- [187] E. Rossi, B. Chamberlain, F. Frasca, D. Eynard, F. Monti et M. Bronstein, “Temporal graph networks for deep learning on dynamic graphs,” *arXiv preprint arXiv :2006.10637*, 2020. [En ligne]. Disponible : <https://arxiv.org/abs/2006.10637>
- [188] S. Yun, M. Jeong, R. Kim, J. Kang et H. J. Kim, “Graph transformer networks,” dans *Advances in Neural Information Processing Systems*, 2019. [En ligne]. Disponible : <https://arxiv.org/abs/1911.06455>
- [189] M. Raftopoulos *et al.*, “DRL-based latency-aware network slicing in O-RAN with time-varying traffic,” dans *IEEE International Conference on Computing, Networking and Communications (ICNC)*, 2024. [En ligne]. Disponible : <http://www.conf-icnc.org/2024/papers/p737-raftopoulos.pdf>
- [190] L. Brunke, M. Greeff, A. W. Hall, Z. Yuan, S. Zhou, J. Panerati et A. P. Schoellig, “Safe learning in robotics : From learning-based control to safe reinforcement learning,” *Annual Review of Control, Robotics, and Autonomous Systems*, vol. 5, p. 411–444, 2022.
- [191] J. Dai, X. Pan, R. Sun, J. Ji, X. Xu, M. Liu, Y. Wang et Y. Yang, “Safe RLHF : Safe reinforcement learning from human feedback,” dans *International Conference on Learning Representations*, 2024. [En ligne]. Disponible : <https://openreview.net/forum?id=0V5a5R7YAy>
- [192] M. Roderick, D. Dey et S. Srinivasa, “Dynamic model predictive shielding for provably safe reinforcement learning,” dans *Advances in Neural Information Processing Systems*, 2024. [En ligne]. Disponible : <https://neurips.cc/virtual/2024/poster/93108>

- [193] J. An et S. Cho, “Variational autoencoder based anomaly detection using reconstruction probability,” dans *SNU Data Mining Center Special Lecture on IE*, 2015.
- [194] R. Chalapathy et S. Chawla, “Deep learning for anomaly detection : A survey,” *arXiv preprint arXiv :1901.03407*, 2019. [En ligne]. Disponible : <https://arxiv.org/abs/1901.03407>
- [195] A. Zahoor, “Robust IoT security using isolation forest and one-class SVM for anomaly detection,” *Scientific Reports*, 2025. [En ligne]. Disponible : <https://www.nature.com/articles/s41598-025-20445-4>
- [196] A. Haque, M. N.-U.-R. Chowdhury, H. Soliman, M. S. Hossen, T. Fatima et I. Ahmed, “Wireless sensor networks anomaly detection using machine learning : A survey,” *arXiv preprint arXiv :2303.08823*, 2023. [En ligne]. Disponible : <https://arxiv.org/abs/2303.08823>
- [197] Y. Geifman et R. El-Yaniv, “Selective classification for deep neural networks,” dans *Advances in Neural Information Processing Systems*, 2017. [En ligne]. Disponible : <https://arxiv.org/abs/1705.08500>
- [198] C. Guo, G. Pleiss, Y. Sun et K. Q. Weinberger, “On calibration of modern neural networks,” dans *Proceedings of the 34th International Conference on Machine Learning*, 2017. [En ligne]. Disponible : <https://proceedings.mlr.press/v70/guo17a.html>
- [199] G. Barrenetxea, F. Ingelrest, G. Schaefer et M. Vetterli, “SensorScope : Out-of-the-box environmental monitoring,” dans *Proceedings of the 7th International Conference on Information Processing in Sensor Networks*, 2008, p. 332–343.
- [200] Intel Berkeley Research Lab, “Intel lab data,” 2004, 54-node indoor sensor network deployment, Berkeley.
- [201] J. Goh, S. Adepu, M. Tan, Z. Dong et A. Mathur, “A dataset to support research in the design of secure water treatment systems,” dans *Critical Information Infrastructures Security*, 2017.
- [202] C. M. Ahmed, V. R. Palleti et A. P. Mathur, “WADI : A water distribution testbed for research in the design of secure cyber physical systems,” dans *Proceedings of the 3rd International Workshop on Cyber-Physical Systems for Smart Water Networks*, 2017.
- [203] A. A. Cárdenas, S. Amin, Z.-S. Lin, Y.-L. Huang, C.-Y. Huang et S. Sastry, “Attacks against process control systems : Risk assessment, detection, and response,” dans *Proceedings of the 6th ACM Symposium on Information, Computer and Communications Security*, 2011, p. 355–366.
- [204] D. Zügner, A. Akbarnejad et S. Günnemann, “Adversarial attacks on neural networks for graph data,” dans *Proceedings of the 24th ACM SIGKDD International Conference*

- on *Knowledge Discovery and Data Mining*, 2018, p. 2847–2856.
- [205] H. Dai, H. Li, T. Tian, X. Huang, L. Wang, J. Zhu et L. Song, “Adversarial attack on graph structured data,” dans *Proceedings of the 35th International Conference on Machine Learning*, 2018. [En ligne]. Disponible : <https://proceedings.mlr.press/v80/dai18b.html>
 - [206] K. B. Letaief, W. Chen, Y. Shi, J. Zhang et Y.-J. A. Zhang, “The roadmap to 6G : AI, edge intelligence, and all,” *IEEE Communications Magazine*, vol. 57, n°. 6, p. 84–90, 2019.
 - [207] N. Li, Q. Sun, L. Wang, X. Xu, J. Huang, C. Liu, J. Gao, Y. Huang et C.-L. I, “Towards AI-native RAN : An operator’s perspective of 6G day 1 standardization,” *arXiv preprint arXiv :2507.08403*, 2025. [En ligne]. Disponible : <https://arxiv.org/abs/2507.08403>
 - [208] Y. Zhang *et al.*, “A comprehensive review of AI-native 6G : Integrating semantic communications, reconfigurable intelligent surfaces, and edge intelligence,” *Frontiers in Communications and Networks*, 2025. [En ligne]. Disponible : <https://www.frontiersin.org/articles/10.3389/frcmn.2025.1655410/full>
 - [209] P. Zhang, X. Xu, M. Sun, H. Gao, N. Ma, X. Wang, R. Zhang, J. Wang et D. Niyato, “Towards native AI in 6G standardization : The roadmap of semantic communication,” *arXiv preprint arXiv :2509.12758*, 2025. [En ligne]. Disponible : <https://arxiv.org/abs/2509.12758>
 - [210] B. Demirel, P. Soldati et Y. Wang, “From intents to actions : Agentic AI in autonomous networks,” *arXiv preprint arXiv :2602.01271*, 2026. [En ligne]. Disponible : <https://arxiv.org/abs/2602.01271>
 - [211] D. Wu, X. Wang, Y. Qiao, Z. Wang, J. Jiang, S. Cui et F. Wang, “NetLLM : Adapting large language models for networking,” dans *ACM SIGCOMM*, 2024, p. 661–678.
 - [212] A. Salama, Z. Nezami, M. M. H. Qazzaz, M. Hafeez et S. A. R. Zaidi, “Edge agentic AI framework for autonomous network optimisation in O-RAN,” dans *IEEE International Symposium on Personal, Indoor and Mobile Radio Communications (PIMRC)*, 2025. [En ligne]. Disponible : <https://arxiv.org/abs/2507.21696>
 - [213] P. R. B. da Silva *et al.*, “Evaluation of the latency of machine learning random access DDoS detection xApps in Open RAN,” dans *Open AI-RAN Workshop*, 2024. [En ligne]. Disponible : <https://wcsng.ucsd.edu/open-ai-ran-2024/assets/files/open-airan24-final4.pdf>
 - [214] A. Abou-Sab *et al.*, “AI-native PHY-layer in 6G orchestrated spectrum-aware networks,” *Sensors*, 2025. [En ligne]. Disponible : <https://pmc.ncbi.nlm.nih.gov/articles/PMC12694481/>

- [215] European Parliament and Council of the European Union, “Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act),” 2024, official Journal of the European Union, L series, 12 July 2024.
- [216] National Institute of Standards and Technology, “Artificial intelligence risk management framework (AI RMF 1.0),” National Institute of Standards and Technology, Rapport technique NIST AI 100-1, 2023.
- [217] OWASP Foundation, “OWASP top 10 for LLM applications – 2025 edition,” 2025. [En ligne]. Disponible : <https://owasp.org/www-project-top-10-for-large-language-model-applications/>
- [218] O-RAN Alliance, “O-RAN nGRG contributed research report : dApp use cases and requirements,” O-RAN Alliance Next Generation Research Group, Rapport technique nGRG-RR-2024-10, 2024. [En ligne]. Disponible : <https://mediastorage.o-ran.org/ngrg-rr/nGRG-RR-2024-10-dApp%20use%20cases%20and%20requirements.pdf>
- [219] A. Narayanan, E. Ramadan, J. Carpenter, Q. Liu, Y. Liu, F. Qian et Z.-L. Zhang, “A first look at commercial 5G performance on smartphones,” dans *Proceedings of the Web Conference (WWW)*, 2021, p. 894–905.
- [220] D. Xu, A. Zhou, X. Zhang, G. Wang, X. Liu, C. An, Y. Shi, L. Liu et H. Ma, “Understanding operational 5G : A first measurement study on its coverage, performance and energy consumption,” dans *Proceedings of ACM SIGCOMM*, 2020, p. 479–494.
- [221] 3GPP, “Study on scenarios and requirements for next generation access technologies,” 3rd Generation Partnership Project, Rapport technique TR 38.913 V17.0.0, 2022. [En ligne]. Disponible : https://www.3gpp.org/ftp/Specs/archive/38_series/38.913/
- [222] F. Xu, Y. Li, H. Wang, P. Zhang et D. Jin, “Understanding mobile traffic patterns of large scale cellular towers in urban environments,” *IEEE/ACM Transactions on Networking*, vol. 25, n^o. 2, p. 1147–1161, 2017.
- [223] G. Pang, C. Shen, L. Cao et A. van den Hengel, “Deep learning for anomaly detection : A review,” *ACM Computing Surveys*, vol. 54, n^o. 2, p. 1–38, 2021.
- [224] A. Erba, R. Taormina, S. Galelli, M. Pogliani, M. Carminati, S. Zanero et N. O. Tippenhauer, “Constrained concealment attacks against reconstruction-based anomaly detectors in industrial control systems,” dans *Proc. Annual Computer Security Applications Conference (ACSAC)*, 2020, p. 480–495.
- [225] M. Kravchik et A. Shabtai, “Efficient cyber attack detection in industrial control systems using lightweight neural networks and PCA,” *IEEE Trans. Dependable and Secure Computing*, vol. 19, n^o. 5, p. 2823–2835, 2022.

- [226] D. H. Wolpert, “Stacked generalization,” *Neural Networks*, vol. 5, n°. 2, p. 241–259, 1992.

ANNEXE A PARAMÈTRES DE SIMULATION COMMUNS AUX TROIS ARTICLES

Le Tableau A.1 résume les paramètres de simulation communs utilisés dans les trois articles de cette thèse.

TABLEAU A.1 Paramètres de simulation communs

Paramètre	Valeur	Articles
Nombre de nœuds (N)	20–100 (Art. 1), 200 (Art. 2)	1, 2
Dimension du terrain	$200 \times 200 \text{ m}^2$	1, 2
Position de la BS	(100, 250)	1, 2
Énergie initiale (E_0)	0.5 J	1, 2
E_{elec}	50 nJ/bit	1, 2
ε_{fs}	10 pJ/bit/m ²	1, 2
ε_{mp}	0.0013 pJ/bit/m ⁴	1, 2
d_0 (distance seuil)	87.7 m	1, 2
Taille des paquets	4 000 bits	1, 2
Nombre de tours	5 000	1, 2
Tour de catastrophe	2 000	2
Graines aléatoires	3 (Art. 1), 30 (Art. 2), 20 (Art. 3)	1, 2, 3

ANNEXE B ARCHITECTURES DES RÉSEAUX DE NEURONES

Article 1 : GAPF

L'architecture GAPF comprend 1 473 paramètres répartis comme suit :

TABLEAU B.1 Décomposition des paramètres de GAPF

Composant	Dimensions	Paramètres
GCN couche 1 ($\mathbf{W}_1$)	4×16	64
GCN couche 2 ($\mathbf{W}_2$)	16×16	256
CAS $\mathbf{W}_c$	16×64	1 024
CAS $\mathbf{b}_c$	64	64
CAS $\mathbf{w}_2$	64×1	64
CAS b_2	1	1
Total		1 473

Article 2 : Agent DQN de CALASH

L'agent Double DQN de CARE utilise l'architecture MLP suivante :

TABLEAU B.2 Architecture de l'agent DQN de CALASH

Couche	Dimensions	Paramètres
Entrée $\rightarrow$ Cachée 1	$9 \times 64 + 64$	640
Cachée 1 $\rightarrow$ Cachée 2	$64 \times 32 + 32$	2 080
Cachée 2 $\rightarrow$ Sortie	$32 \times 1 + 1$	33
Total		2 753

Le vecteur d'état à 9 dimensions encode : (1) énergie résiduelle normalisée, (2) distance au CH, (3) distance CH $\rightarrow$ BS, (4) nombre de membres du cluster, (5) intensité carbone normalisée, (6) pression de la file carbone, (7) ratio de nœuds vivants, (8) facteur de cycle de vie, (9) indicateur de catastrophe.

Article 3 : CASTER-ZT

L'architecture CASTER-ZT comprend $\sim 20\,000$ paramètres :

TABLEAU B.3 Décomposition des paramètres de CASTER-ZT

Composant	Architecture	Paramètres
Encodeur GraphSAGE	2 couches, $d=64$	$\sim 8\,400$
Politique de récupération	MLP $128 \rightarrow 64 \rightarrow \mathcal{A} $	$\sim 8\,500$
Évaluateur confiance-risque	MLP double-tête	$\sim 3\,000$
Bouclier déterministe	14 seuils scalaires	14
Total		$\sim 20\,000$

ANNEXE C PROTOCOLES DE RÉFÉRENCE

Le Tableau C.1 récapitule les protocoles de référence utilisés dans les évaluations expérimentales des trois articles.

TABLEAU C.1 Protocoles de référence par article

Article	Protocole	Description
1	LEACH	Rotation aléatoire des CH
1	EE-LEACH	Élection de CH pondérée par l'énergie
1	ABC-ACO	Hybride métaheuristique
1	Q-Routing	Q-learning tabulaire pour le routage
2	LEACH	Rotation aléatoire des CH
2	LEACH-1hop	LEACH avec relais mono-saut
2	EE-LEACH	Élection pondérée par l'énergie
2	ABC-ACO	Hybride métaheuristique
2	EERP	Protocole de routage écoénergétique
2	Q-Routing	Q-learning pour le routage
2	RIS-DRL	RL profond avec surfaces RIS
3	CPO-Soft	Optimisation de politique sous contrainte
3	Shield-Binary	Bouclier binaire autoriser/bloquer
3	Agentic-Auto	Politique autonome sans bouclier
3	IF-Trust	Isolation Forest avec confiance

ANNEXE D PREUVES DES PROPRIÉTÉS THÉORIQUES DE CASTER-ZT (MATÉRIEL SUPPLÉMENTAIRE DE L'ARTICLE 3)

Cette annexe reproduit les preuves complètes des dix propositions formelles énoncées dans l'Article 3 (Chapitre 6). Ce matériel a été soumis en tant que document supplémentaire accompagnant l'article principal à IEEE Transactions on Mobile Computing. Les numéros de propositions correspondent à ceux du texte principal.

Preuve de la Proposition 1 (Conservatisme monotone). Puisque $w_1, w_2, w_3, w_4 > 0$, le score composite de seuil $g_t = w_1(1 - \tau_t) + w_2\rho_t + w_3u_t + w_4\Delta_t$ est monotoniquement décroissant en τ_t et croissant en ρ_t, u_t, Δ_t . Puisque $\kappa_1, \kappa_2 \geq 0$, $\tau_{\min} = \tau_0 + \kappa_1\rho_t + \kappa_2u_t$ est non décroissant en ρ_t, u_t , rendant la condition de confiance plus difficile à satisfaire. La branche ALLOW requiert $g_t < \gamma_1$, $\tau_t \geq \tau_{\min}$, et $\Delta_t \leq \delta_{\max}$. La dégradation de toute entrée ne peut qu'augmenter g_t , élever $\tau_{\min}$, ou violer la borne de divergence, poussant la sortie vers une branche plus conservatrice. $\square$

Preuve de la Proposition 2 (Exclusion d'actuation non autorisée). Dans l'algorithme du bouclier, $\alpha_t = 0$ déclenche $d_t = \text{BLOCK}$ à la vérification d'autorisation, avant que toute branche permissive ne soit évaluée. $\square$

Preuve de la Proposition 3 (Sauvegarde de divergence). $\Delta_t > \delta_{\max}^{\text{hard}}$ déclenche $d_t = \text{BLOCK}$ à la vérification de divergence dure. $\Delta_t > \delta_{\max}$ viole la condition ALLOW, empêchant les décisions permissives. $\square$

Preuve de la Proposition 4 (Complétude décisionnelle bornée). L'algorithme du bouclier est une structure de branchement ordonnée finie avec des branches mutuellement exclusives (ordonnancement strict des seuils) et une clause ELSE finale capturant tous les cas restants. Toute entrée valide est donc associée à exactement un $d_t \in \mathcal{D}$. $\square$

Preuve de la Proposition 5 (Complexité par décision). Encodage du graphe : $\mathcal{O}(L|E_t|d)$. Évaluation des candidats et évaluation confiance-risque : $\mathcal{O}(|\mathcal{A}|k)$ chacune. Évaluation du bouclier : $\mathcal{O}(1)$. Total : $\mathcal{O}(L|E_t|d + |\mathcal{A}|k)$. $\square$

Preuve de la Proposition 6 (Borne de défense en profondeur). Sous attaque d'identité, un ALLOW non sûr requiert un faux négatif d'autorisation : $\Pr \leq \varepsilon_\alpha$. Sous attaque de télémétrie :

$\Pr \leq \varepsilon_\tau$. Sous attaque combinée avec indépendance conditionnelle : $\Pr[\text{ALLOW} \mid \text{combinée}] = \Pr[\alpha_t = 1 \mid \text{id}] \cdot \Pr[g_t < \gamma_1 \mid \text{telem}] \leq \varepsilon_\alpha \varepsilon_\tau$. $\square$

Preuve de la Proposition 7 (Précision cohérente avec la calibration). Chaque épisode produit un Bernoulli y_i avec $\mathbb{E}[y_i] = \varepsilon^*$. Par l'inégalité de Hoeffding : $\Pr[\varepsilon^* - \hat{\varepsilon} > t] \leq \exp(-2nt^2)$. En posant $\exp(-2nt^2) = \delta$, on obtient $t = \sqrt{\ln(1/\delta)/(2n)}$. $\square$

Preuve de la Proposition 8 (Prix borné de la sécurité). Avec probabilité $(1 - \eta - \eta_{\text{block}})$, le bouclier autorise (perte 0). Avec probabilité η , la réduction de portée engendre une perte $\leq U_{\text{gap}}$. Avec probabilité η_{block} , le blocage engendre une perte $\leq U_{\text{max}}$. En sommant : $\mathbb{E}[\text{perte}] \leq \eta U_{\text{gap}} + \eta_{\text{block}} U_{\text{max}}$. $\square$

Preuve de la Proposition 9 (Couverture d'admissibilité conforme). Par le cadre conforme [79], si les scores $(r_1, \dots, r_{n+1})$ sont échangeables, $\Pr[r_{n+1} \leq r_{(\lceil (1-\alpha)(n+1) \rceil)}] \geq 1 - \alpha$. Le bouclier autorise seulement si $g_t < \gamma_1$, ce qui correspond à $r_{n+1} > r_{(\lceil (1-\alpha)(n+1) \rceil)}$, se produisant avec probabilité $\leq \alpha$. $\square$

Preuve de la Proposition 10 (Taux de convergence de la calibration). Par la concentration de Hoeffding, $|\hat{\varepsilon}(\gamma) - \varepsilon(\gamma)| \leq \sqrt{\ln(2/\delta)/(2n)}$ avec haute probabilité. Puisque $\varepsilon'(\gamma) \geq c_\varepsilon > 0$, le théorème des accroissements finis donne $|\varepsilon(\gamma_1^{(n)}) - \varepsilon(\gamma_1^*)| \geq c_\varepsilon |\gamma_1^{(n)} - \gamma_1^*|$. L'inégalité triangulaire donne $c_\varepsilon |\gamma_1^{(n)} - \gamma_1^*| = \mathcal{O}(1/\sqrt{n})$, d'où $|\gamma_1^{(n)} - \gamma_1^*| = \mathcal{O}_P(1/\sqrt{n})$. $\square$

ANNEXE E MATÉRIEL SUPPLÉMENTAIRE DE GAPF (ARTICLE 1)

Cette annexe reproduit le matériel supplémentaire soumis avec l’Article 1 (Chapitre 4) à IEEE Transactions on Green Communications and Networking. Elle contient les hyperparamètres d’entraînement, la preuve de monotonie du réseau d’attention, l’analyse complète des résultats par scénario, l’analyse de faisabilité de déploiement, et la table comparative de méthodes récentes.

E.1 Hyperparamètres d’entraînement

Le Tableau E.1 résume l’ensemble des hyperparamètres utilisés pour QMIX, QTRAN et GAPF.

TABLEAU E.1 Hyperparamètres d’entraînement pour QMIX, QTRAN et GAPF

Catégorie	Paramètre	QMIX	QTRAN	GAPF
Optimisation	Optimiseur	Adam	RMSprop	Adam
	Taux d’apprentissage	0.0003	0.0003	0.003
	Gradient clip norm	10	10	1.0
	Facteur d’actualisation γ	0.99	0.99	—
	Échelle de récompense	0.01	0.01	—
Exploration	Stratégie	ε -greedy	ε -greedy	REINFORCE
	$\varepsilon_{\text{start}}$	0.5	0.5	—
	ε_{end}	0.01	0.01	—
	Pas d’annulation	150 000	150 000	—
Architecture	Réseau d’agent	GRU (64)	GRU (64)	GCN + MLP
	Dim. cachée RNN	64	64	—
	Dim. mélangeur	64	64	—
	Dim. GNN	—	—	16
	Dim. méta-contrôleur	—	—	64
Entraînement	Pas de temps totaux	200 000	200 000	—
	Épisodes d’entraînement	$\sim 2\,000$	$\sim 2\,000$	2 000
	Taille du lot (épisodes)	32	32	1 (on-policy)
	Taille du tampon de jeu	15 000	15 000	—
Cible / Référence	Mise à jour cible	Dur, chaque 30 ép.	Dur, chaque 30 ép.	—
	Double Q-learning	Oui	Oui	—
	EMA β	—	—	0.95
Évaluation	Épisodes de test	1 000	1 000	1 000
	ε d’éval.	0.01	0.01	—

E.2 Garantie de monotonie du réseau d’attention Q·K

Théorème E.1 (Garantie de monotonie). *Pour tout $\mathbf{r}^{(1)}, \mathbf{r}^{(2)} \in [0, 1]^4$ avec $\mathbf{r}^{(1)} \leq \mathbf{r}^{(2)}$ composante par composante, la sortie du réseau satisfait $f_\phi(\mathbf{r}^{(1)}) \leq f_\phi(\mathbf{r}^{(2)})$.*

Démonstration. Puisque $\alpha_i > 0$ pour tout i (les poids d’attention sont obtenus par softmax), $\mathbf{r}^{(1)} \leq \mathbf{r}^{(2)}$ implique $\boldsymbol{\alpha} \odot \mathbf{r}^{(1)} \leq \boldsymbol{\alpha} \odot \mathbf{r}^{(2)}$. Pour chaque couche monotone, le Jacobien satisfait $\partial g / \partial r'_i = \sigma'(\cdot) \cdot W_i \geq 0$, puisque la dérivée du softplus $\sigma'(x) = (1 + e^{-x})^{-1} \in (0, 1)$ et $W_i \geq 0$ (les matrices de poids sont contraintes non négatives via $\mathbf{W}_\ell = \text{softplus}(\mathbf{W}_\ell^{\text{raw}})$). Par la règle de la chaîne appliquée sur toutes les couches, la composition $f_\phi = g_\psi \circ (\boldsymbol{\alpha} \odot \cdot)$ est monotoniquement non décroissante en chaque composante d’entrée. $\square$

Cette propriété garantit qu’une action Pareto-dominante (améliorant chaque objectif simultanément) reçoit toujours une récompense scalaire supérieure, prévenant toute mise en forme pathologique de la récompense.

E.3 Analyse de faisabilité de déploiement

Le paradigme CTDE (Centralized Training, Decentralized Execution) [135, 136] découple fondamentalement la complexité d’entraînement de la complexité de déploiement. Le Tableau E.2 précise quels composants sont actifs lors du déploiement.

TABLEAU E.2 Carte de déploiement des composants sous le paradigme CTDE

Composant	Exécuté sur	Déployé ?	Taille
Mélangeur QMIX / QTRAN	Serveur d’entraînement	Non	—
Réseau Q·K monotone	Serveur d’entraînement	Non	—
Boucle Evolution Strategies	Serveur d’entraînement	Non	—
Méta-contrôleur GAPF (GCN + CAS)	Passerelle / puits	Oui (1×/épisode)	~1 473 param. (~6 Ko)
Agent par capteur (GRU)	Chaque nœud capteur	Oui (1×/pas)	~25K param. (~100 Ko)

Le Tableau E.3 compare les besoins en ressources de l’agent par capteur avec deux micro-contrôleurs commerciaux représentatifs.

Le Tableau E.4 rapporte les métriques de faisabilité mesurées empiriquement pour $N = 70$ capteurs.

La procédure de déploiement depuis le modèle entraîné vers le micrologiciel embarqué procède en quatre étapes : (1) les poids de l’agent sont extraits du checkpoint PyTorch en tableaux `float32` sérialisés dans un fichier d’en-tête C ; (2) la passe avant du GRU est implémentée en

TABLEAU E.3 Besoins en ressources de l’agent par capteur vs spécifications de microcontrôleurs commerciaux

Ressource	Agent	STM32L4	nRF52840
Flash (poids du modèle)	~100 Ko	1 Mo	1 Mo
SRAM (activations + état caché)	~2 Ko	256 Ko	256 Ko
Calcul par pas	~29K MACs	80 MHz Cortex-M4	64 MHz Cortex-M4
Latence d’inférence (est.)	< 1 ms	—	—

TABLEAU E.4 Métriques de faisabilité mesurées (machine hôte : Apple M-series, mode CPU). Latence et mémoire mesurées sur 30 itérations avec 3 passes de préchauffage. Énergie estimée à 0.1 W (typique Cortex-M4 à 80 MHz).

Algorithme	Latence p95 (ms)	RAM pic (Ko)	MACs	Énergie (μ J)
QMIX (agent + mélangeur)	0.27	2.98	2 539 904	27.2
QTRAN (agent + mélangeur)	0.17	34.32	4 955 532	16.7
GAPF (GCN, passerelle)	0.03	4.12	181 408	3.0
Agent seul (déployé)	< 1	~2	~29K	< 10

~100 lignes de C ; (3) le micrologiciel compilé est flashé sur le MCU via SWD/JTAG ; (4) à chaque pas de routage, le capteur effectue une passe avant GRU et sélectionne le prochain saut via $\arg \max$. Des chaînes d’outils automatisées telles que TFLite Micro [56] peuvent également générer du code C optimisé.

E.4 Résultats détaillés par scénario

Sept scénarios ont été évalués, chacun avec trois graines aléatoires (42, 123, 456), totalisant 21 000 épisodes de test. Le Tableau E.5 consolide le taux de livraison des paquets (PDR).

Les tableaux suivants présentent les métriques de performance détaillées et les métriques de faisabilité pour chacun des sept scénarios.

E.5 Analyse comparative des approches de routage récentes (2024–2025)

Le Tableau E.6 positionne GAPF par rapport aux approches récentes identifiées lors du processus de révision.

TABLEAU E.5 PDR à travers les scénarios. Δ : amélioration relative de GAPF sur la meilleure ligne de base MARL.

	n	R (m)	QMIX	QTRAN	QPSOFL	GAPF	Δ (%)
S1	20	25	0.559	0.558	0.075	0.753	+35
S2	30	25	0.568	0.567	0.053	0.877	+54
S3	50	35	0.553	0.552	0.153	0.990	+79
S4	70	35	0.545	0.544	0.122	0.980	+80
S5	70	45	0.667	0.659	0.365	0.980	+47
S6	100	35	0.464	0.462	0.099	0.980	+111
S7	100	50	0.669	0.684	0.448	0.980	+43

TABLEAU E.6 Analyse comparative des algorithmes de routage récents (2024–2025)

Référence	Approche	Énergie	PDR	Latence	Mobilité
Prakash et al. [124]	SHO-CH (Spot- ted Hyena Opti- mizer)	Élevée	Non évalué	Non analysée	Non
Ataoua et al. [125]	CDO (Cher- noby1 Disaster Optimizer)	Élevée	Non évalué	Non analysée	Non
Qamar et al. [126]	Réseau de neu- rones + cluste- ring	Élevée	Amélioré	Non quantifiée	Non
Rahman et al. [127]	Blockchain + PoI	Non abordée	Élevé (97.4%)	Modérée	Non
Rao et al. [120]	Blockchain lé- gère + clustering	Modérée	Amélioré	Légèrement accrue	Limitée
Sefati et al. [128]	RL fédéré (AFRL-HGS)	Élevée	Élevé	Basse	Partielle
GAPF (Article 1)	Fusion de poli- tiques GCN + MARL	2–3.5× meilleure	$\geq 98\%$	< 29 ms p99	Oui

ANNEXE F MATÉRIEL SUPPLÉMENTAIRE DE CALASH (ARTICLE 2)

Cette annexe contient le matériel supplémentaire de l’Article 2 (Chapitre 5), soumis à IEEE Transactions on Green Communications and Networking. Elle regroupe les hyperparamètres complets, la preuve du théorème CDL, les résultats détaillés par scénario, les analyses de sensibilité et les profils carbone.

F.1 Preuve du Théorème CDL (Pareto carbon-delivery)

Preuve du Théorème 5.1. Considérons la fonction de Lyapunov $L(t) = \frac{1}{2}Z(t)^2$ où $Z(t)$ est la file d’attente virtuelle de carbone. La dérive conditionnelle à un pas satisfait :

$$\Delta(t) = \mathbb{E}[L(t+1) - L(t) \mid Z(t)] \leq B + Z(t)(C_{\text{tot}}(t) - \bar{c})$$

où $B = \frac{1}{2}(C_{\text{max}}^2 + \bar{c}^2)$ est une constante finie.

En ajoutant la pénalité $V \cdot (-D(t))$ et en notant que CALASH minimise goulûment le membre de droite à chaque saut via l’Éq. (5.11) avec le facteur lifecycle ℓ_j , la borne dérive-plus-pénalité devient :

$$\Delta(t) - V \cdot D(t) \leq B - V \cdot D^*(t)$$

En télescopant sur T rondes et utilisant $L(T) \geq 0$, on obtient :

$$\bar{D} \geq \bar{D}^* - B/V \quad (\text{livraison quasi-optimale})$$

La stabilité de la file ($\bar{Z} = O(V)$) donne :

$$\bar{C}_{\text{tot}} \leq \bar{c} + B/V \quad (\text{budget carbone lifecycle})$$

Le compromis V contrôle l’échange livraison-carbone : un V grand favorise la livraison au prix d’un dépassement transitoire du budget carbone. $\square$

TABLEAU F.1 Hyperparamètres de l’agent DQN de CALASH

Paramètre	Valeur
Architecture	MLP à 2 couches cachées (9–64–32–1)
Fonction d’activation	ReLU
Optimiseur	Adam
Taux d’apprentissage	10^{-3}
Facteur de rabais γ	0.99
Taille du buffer de replay	10 000
Taille du mini-batch	64
Fréquence de mise à jour cible	100 pas
ϵ -greedy initial / final	1.0 / 0.01
Décroissance de ϵ	Linéaire sur 500 épisodes
Paramètre Lyapunov V	100
Budget carbone $\bar{c}$	0.5 gCO ₂ eq/paquet
Seuil de self-healing τ_{heal}	0.3 (énergie résiduelle)
Ratio de compression (CS)	0.25

F.2 Hyperparamètres complets de CALASH

F.3 Profils d’intensité carbone

Les simulations utilisent les facteurs d’intensité carbone suivants (gCO₂eq/kWh) issus de données publiques :

- **France** : 56 (dominance nucléaire)
- **Allemagne** : 385 (mix charbon/renouvelable)
- **Pologne** : 773 (dominance charbon)
- **Norvège** : 26 (dominance hydroélectrique)
- **États-Unis (moyenne)** : 417 (mix gaz/charbon/renouvelable)

L’analyse de sensibilité (Section 5.5.5) montre que les gains relatifs de CALASH sont robustes à travers les grilles nationales, avec un avantage LCI plus prononcé dans les grilles à forte intensité carbone.